

Diseño de Representaciones Temporales Modulares Basado en Datos

Harvey Demian Bastidas Caicedo

Aspirante a doctorado en inteligencia artificial

Contexto Personal

- 48 años
- Soltero
- Interés por la programación y la IA (**algo-trading championship**/2007)
- Viví en Cali 20 años, Bogotá 4 años, por estudios, trabajo
- Desde hace 5 años vivo en Túquerres, Nariño
- El negocio de producción de leche = situación económica **estable**
- **Tiempo disponible** para el desarrollo open-source y/o para estudiar
- Dispongo de los recursos y la motivación para el Doctorado en IA

Formación

2011

Ingeniero electrónico

Universidad de San
Buenaventura Cali

Materias/temas:

Teoría de la Información,
Comunicaciones.

Tesis:

Control de tráfico y calidad de
servicio en una NPU. Director: Óscar
Casas García.

2018

Magíster en Ingeniería

Pontificia Universidad
Javeriana, Cali

Materias/temas:

Teoría de Juegos, Reconocimiento de
Patrones, Calidad de Software

Tesis:

Optimización evolutiva (NEAT)
descentralizada, con blockchain .
Directora: María Constanza Pabón.

2025

Magíster en Ciencia de Datos

Pontificia Universidad
Javeriana, Cali

Materias/temas:

Gobernanza de datos, OLAP,
Descomp.de Series de Tiempo

Tesis:

Comparación en pronóstico, de
modelos de deep learning. Directora:
María Constanza Pabón.

Experiencia Profesional

2005

Aironet S.A.

- Servidores linux
- Red de un proveedor de internet.
- Contról de tráfico y QoS

Implementación de **NEAT/C++** para **algo-trading**

Bash scripts, PHP, PGSQL, C++

2011

Cervecería del Valle

- Prácticante → contratista.
- Sensores, SCADA y redes.
- Sistema de Mantenimiento Basado en Condición.
- Automatizacion de backups.

Implementación de NEAT con candidatos en CUDA.

*Bat Scripts, PHP, Javascript, MySQL, C++ CUDA, **GitHub***

2018

Freelance Dev

- Aplicaciones Web/MySQL
- Mapas, Map Server, ArcGIS (OSSO)

Open source:

- Gym environment for FX
- NEAT trading agent
- **Decentralized** NEAT y DEAP

*PHP, Javascript, **Python**, Node.js, REST API, JSON, Sqlite*

2021

Open Source Dev

- Data Governance (data-gov)
- Optimización P2P (**doin**)
- RL (gym-fx+agent-multi)
- Timeseries Forecasting
- Autoencoder(feature-ext)
- Datos Sintéticos (varios)
- **Algo-trading** (varios)

*Keras/PyTorch, Modular Components, Analytics DB, **OLAP**, TDD, CRISP-DM*

Motivación: Una ventaja pequeña puede importar mucho




Figura 1. Sharpe ratio de simulaciones de trading en datos de test, tesis de M.DS [1, fig. 43]. Usa estrategia heurística de trading basada en predicciones de corto y largo plazo [2]




Figura 2. Barrido de ruido gaussiano sobre un oráculo direccional: resultados y datos históricos de heuristic-strategy [2].

Motivación: El extractor de características con Conv1D produjo el mejor resultado.

El foco: Pronóstico y RL

Entradas heterogéneas

Precios y tasas

Indicadores: RSI, MACD...

Fundam.: S&P 500, VIX

Estacionales: HoD, DoW, MoY

Feature-Engineering

Calendario económico

Datos disponibles en Yahoo

Finance y proveedores pagos
como FX-MacroData

Dos tareas principales

Supervisado: objetivos por horizonte (naive)

RL: política y valor sobre el estado disponible
(SAC, DQN)

Dos tareas de apoyo

Autosupervisado: aprende representaciones(f-extr.)

No-Supervisado: Regímenes de mercado

Opcional: Causal Inference para usar el calendario

Entradas con diferentes comportamientos, que pueden contener distintos niveles de ruido.

Pregunta de Investigación

¿En que condiciones caracterizar las entradas para agruparlas por similitudes en métricas y adaptar el preprocesamiento y extracción de características por grupo, mejora el pronóstico o la política aprendida respecto a un control?




Figura 3. Representación temporal modular para procesamiento diferenciado basado en datos

¿Qué medimos para caracterizar una entrada?

Estacionariedad y deriva

ADF / KPSS; media y varianza por bloques.

Nivel, diferencias o retornos candidatos.

Memoria y frecuencia

ACF / PACF; periodos y entropía espectral.

Hilbert por banda: fase y periodo local.

Relaciones entre entradas

Correlación retardada y coherencia.

Agrupación y alineación temporal.

Estacionalidad

Fuerza estacional STL; periodo y estabilidad.

Ciclos repetidos, distintos de estacionariedad.

Variabilidad y colas

MAD; cuantiles; ACF de |retornos|.

Escalado robusto y pérdidas candidatas.

Disponibilidad y calidad

Latencia, faltantes y revisiones.

Máscaras e información admisible al decidir.

Perfil calculado solo en datos de entrenamiento, validación se usa durante optimización y test reservado.

Fuentes: perfil y estacionalidad [3]; ADF/KPSS [4]; Hilbert, correlación y coherencia [5].

Cómo se forman los grupos y se elige la configuración

1 · Perfilar

Estadísticas de cada serie en entrenamiento.

2 · Agrupar

Similitud + estabilidad.
Número de grupos candidato.

3 · Buscar

Transformación + ventana
+ extractor por grupo.

4 · Evaluar

Validación temporal interna;
prueba exterior intacta.

**Controles: sin grupos · grupos aleatorios · tratamiento común.
Misma información, población y presupuesto de búsqueda declarado.**

Antecedentes: perfiles estadísticos [6] y combinación de pronósticos basada en características [7].

DOIN puede ejecutar la búsqueda; la contribución es el criterio de representación.

Modelos Candidatos

Conv1D / TCN

Motivos locales
y multiescala.

Variar kernel, capas
y dilatación.
Medir campo receptivo.

LSTM / GRU

Dependencias
secuenciales
y estado temporal.

Variar contexto, capas
y profundidad.

Atención/Transformer

Relaciones distantes
y entre variables.

Variar tokens, dimensión
y número de cabezales.

Se selecciona por comparación de resultados experimentales

Fuentes: redes convolucionales y recurrentes [8]; atención multi-cabezal [9].

Tres hipótesis que pondremos a prueba

H1

Mejora global del pronóstico

Caracterizar, agrupar y adaptar las ramas reduce el error global frente al mejor control elegido en desarrollo.

Contraste: método completo vs. control, en familias de datos reservadas.

H2

Agrupar ayuda más ante mayor heterogeneidad

La ventaja de los grupos por perfil aumenta al crecer las diferencias temporales entre las variables.

Contraste: perfiles vs. grupos aleatorios; variar heterogeneidad, no ruido ni tamaño.

H3

Conservar secuencias ayuda ante relaciones retardadas

Fusionar antes de colapsar dimensión temporal mejora el pronóstico, especialmente cuando una entrada anticipa cambios en otra.

Contraste: secuencias vs. resumen; comparar con y sin relaciones retardadas.

Antecedentes del perfilado y la selección por características: [6], [7].

Tres formas de entrenar el mismo extractor

Autoencoder: aprende a reconstruir entradas usando solo entrenamiento.
Reutilizamos el codificador como detector; el decodificador se retira [10].

Modalidad	Pesos iniciales del detector	En la tarea final
R0 · Desde cero	Aleatorios	Se actualizan
R1 · Congelado	Codificador preentrenado	Se congelan
R2 · Ajustable	El mismo codificador de R1	Se actualizan

R1 y R2 parten de los mismos pesos preentrenados por semilla.
En los tres casos se entrenan la fusión, el núcleo y el cabezal.

Se compara utilidad en la tarea final y coste total, no solo reconstrucción.

Qué vamos a probar y en qué datos

Probar cada componente, después el sistema completo.

Datos de electricidad, clima y tráfico de la literatura [11], [12], además de datos financieros.

1 Señales controladas

Crear series con ciclos, ruido y retardos.
Comparar cómo agruparlas y fusionarlas.

2 Comparar alternativas

Comparar modelos y transformaciones,
con y sin extractores preentrenados.

3 Probar en otros datos

Evaluar la solución elegida sin reajustarla
en datos no usados para elegirla.

4 Evaluar en trading

Predecir precios y aprender decisiones.
Simular costes y actualización semanal.

Dos preguntas distintas: ¿mejora la predicción? ¿mejora también el resultado del trading?

Cómo sabremos si nuestra propuesta mejora

Reproducir un modelo publicado y compararlo con nuestra propuesta.

LOS MISMOS DATOS

Mismas variables y fechas para entrenar y evaluar.

LA MISMA PREDICCIÓN

Mismo valor a predecir, horizonte e información disponible.

EL MISMO ERROR

Misma fórmula y normalización que el estudio de referencia.

Predicción [11], [12]

Comparar MAE y MSE con el modelo publicado y con la predicción de referencia: que el valor actual no cambia.

Elegir la configuración sin consultar los datos de prueba final [13]. Repetir entrenamientos. Si cambia la tarea del artículo, ejecutar también su modelo en nuestra tarea.

Trading y aprendizaje por refuerzo

Comparar beneficio neto, Sharpe y caída máxima. Usar las mismas fechas, costes y reglas de ejecución.

Resultado Esperado: Decisiones de Diseño

Un procedimiento verificable para decidir qué transformar, cómo agrupar y qué representación temporal diferenciada es recomendada.

Método	Evidencia	Transferencia
Perfiles medibles.	Dominios y horizontes.	Pronóstico y políticas RL.
Configuraciones candidatas.	Controles.	Componentes abiertos.
Selección temporal sin fuga.	Precisión y coste total.	Resultados reproducibles.

Extensión posterior: contrastar el **preentrenamiento** del núcleo temporal, una vez evaluados el extractor y la fusión, en un bloque separado.

Referencias (1/2)

- [1] H. Bastidas, A. Caicedo y C. Sarmiento, "Predicción de la tasa de cambio EUR/USD: comparación de modelos de deep learning con diversos tipos y cantidades de datos de entrenamiento", proyecto aplicado de Maestría en Ciencia de Datos, Pontificia Universidad Javeriana, Cali, Colombia, jun. 2025, fig. 43.
[En línea]. Disponible: https://github.com/harveybc/predictor/blob/80a1513a/docs/tesis_maestria_ds/tesis_maestria_ciencia_datos_2025.docx
- [2] H. Bastidas, "heuristic-strategy: fuentes del barrido de ruido de la presentación y resultados posteriores", código y datos, GitHub, rev. f2d3922, sep. 2026. Consultado: 27-sep-2026.
[En línea]. Disponible: https://github.com/harveybc/heuristic-strategy/tree/f2d3922/docs/presentation_noise_20260927
- [3] R. J. Hyndman y G. Athanasopoulos, Forecasting: Principles and Practice, 3.^a ed. Melbourne, Australia: OTexts, 2021, caps. 4 y 9. Consultado: 27-sep-2026.
[En línea]. Disponible: <https://otexts.com/fpp3/>
- [4] Desarrolladores de statsmodels, "Stationarity and detrending (ADF/KPSS)", documentación de statsmodels. Consultado: 27-sep-2026.
[En línea]. Disponible: https://www.statsmodels.org/stable/examples/notebooks/generated/stationarity_detrending_adf_kpss.html
- [5] Comunidad SciPy, "Signal processing (scipy.signal)", documentación de SciPy: hilbert, correlate y coherence. Consultado: 27-sep-2026.
[En línea]. Disponible: <https://docs.scipy.org/doc/scipy/reference/signal.html>
- [6] C. H. Lubba, S. S. Sethi, P. Knaute, S. R. Schultz, B. D. Fulcher y N. S. Jones, "catch22: CAnonical Time-series CHaracteristics", Data Min. Knowl. Discov., vol. 33, pp. 1821–1852, 2019.
doi: [10.1007/s10618-019-00647-x](https://doi.org/10.1007/s10618-019-00647-x)
- [7] P. Montero-Manso, G. Athanasopoulos, R. J. Hyndman y T. S. Talagala, "FFORMA: Feature-based forecast model averaging", Int. J. Forecast., vol. 36, n.º 1, pp. 86–92, 2020.
doi: [10.1016/j.ijforecast.2019.02.011](https://doi.org/10.1016/j.ijforecast.2019.02.011)

Referencias (2/2)

- [8]** S. Bai, J. Z. Kolter y V. Koltun, "An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling", arXiv:1803.01271, 2018.
[doi: 10.48550/arXiv.1803.01271](https://doi.org/10.48550/arXiv.1803.01271)
- [9]** A. Vaswani et al., "Attention Is All You Need", en Advances in Neural Information Processing Systems, vol. 30, pp. 5998–6008, 2017.
[\[En línea\]. Disponible: https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need](https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need)
- [10]** Z. Li, Z. Rao, L. Pan, P. Wang y Z. Xu, "Ti-MAE: Self-Supervised Masked Time Series Autoencoders", arXiv:2301.08871, 2023.
[doi: 10.48550/arXiv.2301.08871](https://doi.org/10.48550/arXiv.2301.08871)
- [11]** Y. Nie, N. H. Nguyen, P. Sinthong y J. Kalagnanam, "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers", en Proc. ICLR, 2023.
[Prepublicación: doi: 10.48550/arXiv.2211.14730](https://doi.org/10.48550/arXiv.2211.14730)
- [12]** Y. Liu et al., "iTransformer: Inverted Transformers Are Effective for Time Series Forecasting", en Proc. ICLR, 2024.
[Prepublicación: doi: 10.48550/arXiv.2310.06625](https://doi.org/10.48550/arXiv.2310.06625)
- [13]** G. C. Cawley y N. L. C. Talbot, "On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation", J. Mach. Learn. Res., vol. 11, pp. 2079–2107, 2010.
[\[En línea\]. Disponible: https://jmlr.org/papers/v11/cawley10a.html](https://jmlr.org/papers/v11/cawley10a.html)