
Metaoptimización confiable de modelos de inteligencia artificial a partir de experiencias heterogéneas

Propuesta doctoral preliminar

Harvey Demian Bastidas Caicedo · Doctorado en Inteligencia Artificial · Universidad de La Sabana

Resumen

Optimizar un modelo de inteligencia artificial suele exigir muchas pruebas costosas. Sin embargo, cada entrenamiento anterior deja información sobre qué configuraciones funcionaron, cuáles fallaron y cuánto costó evaluarlas. Esta investigación propone aprender de ese historial para recomendar mejores puntos de partida en tareas nuevas. El problema es que las experiencias disponibles pueden venir de modelos, datos, presupuestos y algoritmos de búsqueda distintos; también pueden estar incompletas, sesgadas o contener errores.

La contribución central será un metaoptimizador que represente cada tarea, lea trazas verificables de optimizaciones previas, estime la utilidad y la incertidumbre de una configuración candidata y decida entre transferir conocimiento o abstenerse. La teoría de la información se usará para distinguir capacidad representacional, información adquirida e información útil para decidir la siguiente evaluación. DOIN aportará un entorno distribuido y trazable para poner a prueba el método, pero el resultado científico no dependerá de una blockchain ni del éxito de un dominio particular.

1. Planteamiento del problema y objetivos

1.1 Problema

La optimización de hiperparámetros y arquitecturas sigue consumiendo tiempo, energía y capacidad de cómputo. Empezar cada tarea desde cero desperdicia conocimiento acumulado; reutilizarlo sin cuidado puede ser peor, porque una configuración exitosa en otra tarea puede inducir transferencia negativa. El reto no es solo predecir buenos parámetros: es reconocer cuándo dos experiencias son comparables, cuánto puede confiarse en ellas y cuándo conviene volver a un optimizador sin transferencia.

Pregunta de investigación. ¿Puede un metaoptimizador que combine trazas verificadas, descriptores informacionales de la tarea y una regla explícita de abstención reducir el costo de optimizar modelos de inteligencia artificial en tareas nuevas, sin empeorar el resultado final cuando cambian los datos, la arquitectura o la calidad de las trazas?

1.2 Objetivo general

Diseñar y evaluar un método de metaoptimización capaz de transferir conocimiento entre tareas heterogéneas de inteligencia artificial y de abstenerse cuando esa transferencia no sea confiable.

1.3 Objetivos específicos

1. Construir una representación de tareas y trazas que separe capacidad del modelo, información aprendida, información útil para la tarea, costo de evaluación y procedencia de cada resultado.
2. Desarrollar un metaoptimizador probabilístico que proponga configuraciones, estime su incertidumbre y active una salida segura sin transferencia cuando la evidencia no sea suficiente.
3. Comparar el método con optimización aleatoria, optimización bayesiana sin transferencia y métodos recientes de transferencia, usando tareas no vistas y escenarios de cambio, censura y corrupción de trazas.

1.4 Alcance

La tesis estudiará optimización de caja negra: una configuración entra a un flujo de aprendizaje y devuelve una medida de desempeño y su costo. No intentará crear un optimizador universal para cualquier problema. El alcance principal será la configuración de modelos supervisados. La confirmación aplicada se hará con series de tiempo y, si el presupuesto lo permite, con adaptación eficiente de modelos de lenguaje compactos. La negociación algorítmica seguirá siendo un caso de estrés, no una condición para que la tesis sea válida.

2. Marco teórico y estado del arte

2.1 Capacidad de una neurona y de una familia de modelos

MacKay estudia una neurona binaria de umbral con K entradas y pesos, sin sesgo. El receptor no puede leer los pesos ni probar entradas arbitrarias: solo observa las salidas sobre los mismos N puntos usados para entrenar. Para puntos en posición general, el número de etiquetados binarios que la neurona puede realizar es [1], [2]:

$$T(N,K) = 2 \sum_{k=0}^{K-1} C(N-1,k)$$

Al comparar $T(N,K)$ con los 2^N etiquetados posibles aparece, para K grande, una transición cerca de $N = 2K$. De ahí surge el resultado de aproximadamente dos bits funcionales por peso: casi todas las etiquetas aleatorias pueden memorizarse antes de ese punto y casi ninguna después. Es una medida de memoria funcional para un clasificador lineal bajo supuestos concretos; no dice que cualquier neurona, red profunda o peso físico almacene siempre dos bits.

La topología cambia la familia de funciones disponibles. Profundidad, recurrencia, atención y pesos compartidos pueden aumentar, restringir o reutilizar capacidad. Por eso esta tesis no multiplica conexiones por dos para estimar la inteligencia de una red. Primero reproducirá el caso conocido de MacKay y Cover; después medirá, en modelos pequeños y controlados, cómo cambian la memorización, la robustez y la generalización al variar la topología y la precisión.

Distinción central. Capacidad es lo que una familia de modelos podría representar; información adquirida es lo que un entrenamiento concreto incorpora; información útil es la parte que ayuda en datos no vistos. Una red grande puede memorizar mucho ruido y aun así aprender poco de valor.

2.2 Información aprendida y decisión de optimización

La complejidad de Kolmogorov ofrece una idea atractiva: describir un objeto por el programa más corto que lo produce. Sin embargo, no puede calcularse exactamente [3]. En los experimentos se usarán aproximaciones reproducibles: análisis de información y generalización, compresión del modelo, sensibilidad a cuantización y cotas PAC-Bayes basadas en compresión [4], [5]. Estas medidas no se presentarán como una cantidad exacta de inteligencia, sino como descriptores cuya utilidad deberá demostrarse por ablación.

Para decidir qué configuración evaluar, la información tiene otro papel. Entropy Search propone elegir la evaluación que más reduzca la incertidumbre sobre la ubicación del óptimo [7]. Esta tesis seguirá esa idea, pero dividirá la ganancia esperada por el costo de la evaluación y descontará la confianza cuando la tarea fuente sea distinta o su procedencia sea débil. El teorema de Shannon sobre canales no se aplicará directamente a un conjunto de datos: usarlo exige definir señal, ruido, ancho de banda y canal. En series de tiempo esos elementos se estimarán y se reportará la sensibilidad a su definición.

2.3 Metaaprendizaje y metaoptimización

Aprender el propio algoritmo de optimización no es nuevo. Los optimizadores aprendidos muestran que una red puede explotar regularidades de familias de problemas [6]. OptFormer aprende de grandes historiales de búsqueda [8]; HyperBO preentrena procesos gaussianos con tareas relacionadas [9]; y PFNs4BO realiza inferencia en contexto para optimización bayesiana [10]. HPO-B ofrece millones de evaluaciones y particiones por tarea para comparar transferencia de manera reproducible [11].

Los trabajos recientes ya tratan espacios de parámetros heterogéneos [12] y secuencias de tareas que cambian con el tiempo [13]. Por tanto, la novedad no puede ser simplemente entrenar una red con pares de parámetros y métricas. La pregunta abierta de esta propuesta es más estrecha: aprender de historiales generados por políticas distintas, con presupuestos desiguales, ejecuciones detenidas y calidad variable, sin convertir esa transferencia en una nueva fuente de error.

2.4 Brecha que abordará la tesis

Una traza histórica no es una muestra neutral. Contiene solo las configuraciones que otro optimizador decidió probar; los fallos pueden desaparecer; la parada temprana censura resultados; y dos procesos de entrenamiento pueden usar nombres iguales con significados distintos. El método propuesto tratará la política de origen, el presupuesto, la censura y la procedencia como datos del aprendizaje, no como metadatos decorativos. Su salida incluirá la opción de no transferir. Esta precaución también es coherente con el principio de que ningún optimizador domina en todas las clases de problemas [14].

3. Metodología

3.1 Unidad de información

Cada tarea τ reunirá un conjunto de datos, un modelo, un espacio de configuración, una métrica, un presupuesto y una versión ejecutable del proceso de entrenamiento. Cada evaluación registrará la configuración probada, los pasos consumidos, el resultado, el costo, el estado terminal o censurado y la procedencia. Las particiones de entrenamiento, calibración y prueba se harán por tareas completas; ninguna evaluación de una tarea de prueba podrá aparecer en el entrenamiento del metaoptimizador.

Grupo	Información observada	Función en el método
Tarea	Tamaño, tipos de variables, ruido estimado, balance, estructura temporal y modelo	Estimar semejanza y cambio de distribución
Traza	Parámetros, presupuesto, métricas, curva parcial, fallos y censura	Aprender la respuesta y proponer candidatos
Procedencia	Proceso ejecutado, versión, política de búsqueda y verificaciones disponibles	Reducir o rechazar evidencia incompatible
Información	Capacidad funcional, compresibilidad y reducción esperada de incertidumbre	Priorizar evaluaciones informativas por costo

3.2 Metaoptimizador propuesto

El modelo tendrá tres piezas. Un codificador de tarea resumirá datos, arquitectura y descriptores informacionales. Un codificador de trazas leerá conjuntos de evaluaciones con máscaras explícitas para parámetros ausentes y un canal ordenado cuando el tiempo importe. Una cabeza probabilística estimará la distribución del desempeño y el costo de cada candidato. La regla de selección elegirá la evaluación con mejor ganancia esperada de información por unidad de costo.

La capacidad funcional se medirá como la mayor cantidad de etiquetas aleatorias que una arquitectura puede memorizar bajo un protocolo fijo. La compresibilidad será el menor número de bits que conserva el desempeño dentro de una tolerancia predeclarada. Ambas son aproximaciones experimentales, no medidas universales, y solo permanecerán en el método si mejoran la predicción sobre tareas no vistas.

Una compuerta de transferencia comparará la tarea nueva con la experiencia disponible y calibrará la incertidumbre sobre tareas reservadas. Si la cobertura o la semejanza no alcanzan el nivel fijado antes de la prueba, el sistema se abstendrá y entregará el control a un optimizador bayesiano sin transferencia. Esta salida no se contará como fracaso: es parte del método y busca evitar que una recomendación segura en apariencia sea peor que empezar de cero.

3.3 Resultado teórico

Se buscará un límite matemático para el arrepentimiento de la política selectiva, entendido como la pérdida acumulada frente a la mejor decisión disponible. Este resultado dependerá de supuestos declarados sobre calibración, semejanza entre tareas y proporción de trazas defectuosas. Si esos supuestos no permiten una garantía útil, se caracterizará una región de imposibilidad: condiciones bajo las cuales ninguna regla basada solo en las trazas observadas puede distinguir una transferencia provechosa de una perjudicial. El resultado teórico y el algoritmo experimental se evaluarán por separado.

3.4 Datos y experimentos

La primera etapa usará HPO-B como conjunto público de referencia, para evitar que el método sea evaluado solo con datos propios. La segunda incorporará trazas verificadas de DOIN y de los procesos existentes de predicción, aprendizaje por refuerzo y dominios alternativos [15], [16]. La confirmación final incluirá dos familias manejables: modelos de series de tiempo y adaptación eficiente de modelos de lenguaje compactos. No se entrenarán modelos fundacionales desde cero.

Se compararán búsqueda aleatoria, optimización bayesiana sin transferencia, inicio con las mejores configuraciones previas y métodos de transferencia compatibles, entre ellos HyperBO, PFNs4BO y una representación inspirada en OptFormer. El presupuesto, las tareas y los puntos iniciales serán compartidos. Los escenarios adversos eliminarán resultados malos, censurarán curvas, duplicarán evaluaciones, alterarán una fracción de métricas y cambiarán gradualmente la distribución de tareas.

3.5 Hipótesis

1. **H1 • Eficiencia.** En tareas nuevas relacionadas, el metaoptimizador reducirá el área bajo la curva de arrepentimiento y el costo necesario para alcanzar un desempeño objetivo frente al mejor método de referencia sin transferencia.
2. **H2 • Seguridad.** Bajo cambio de distribución o trazas defectuosas, la compuerta de abstención mantendrá el resultado final dentro del margen de no inferioridad respecto al método de referencia sin transferencia y reducirá la frecuencia de transferencia negativa.
3. **H3 • Información.** Los descriptores de capacidad, compresibilidad y ganancia informativa mejorarán la calibración y la selección de tareas fuente frente al mismo modelo que use solo metadatos convencionales.

3.6 Evaluación y falsación

La unidad primaria será la tarea no vista, no cada ejecución individual. Se usarán al menos treinta tareas por familia y cinco corridas de optimización por tarea. Las medidas principales serán el arrepentimiento simple normalizado —la diferencia entre el mejor resultado disponible y el mejor encontrado—, el costo hasta el objetivo, el error de calibración, la cobertura de intervalos, la frecuencia de abstención y la transferencia negativa. Un piloto separado fijará el margen práctico de H2 y el tamaño final de muestra; luego quedarán congelados. Los intervalos se estimarán sobre tareas y la multiplicidad de las tres hipótesis se controlará con el método de Holm.

La tesis aceptará un resultado negativo. H1 fallará si la transferencia no mejora costo o arrepentimiento; H2 fallará si abstenerse no protege frente al cambio; H3 fallará si las medidas informacionales no aportan fuera de muestra. En ese caso, el resultado seguirá siendo útil al delimitar cuándo las trazas históricas no justifican un metaoptimizador.

4. Contribuciones esperadas

1. Una formulación clara de la metaoptimización con trazas heterogéneas, censuradas y de procedencia desigual.
2. Un metaoptimizador probabilístico con transferencia selectiva, incertidumbre calibrada y abstención explícita.
3. Evidencia sobre la utilidad real de descriptores informacionales de capacidad y compresibilidad para transferir optimización.
4. Un conjunto reproducible de referencia que combine datos públicos y trazas distribuidas verificadas, junto con resultados positivos o negativos publicables.

5. Plan de trabajo, viabilidad y ética

5.1 Plan de tres años

Periodo	Trabajo y producto verificable
Año 1	Revisión sistemática; definiciones de capacidad, información y procedencia; reproducción de MacKay; preparación de HPO-B; piloto y prerregistro. Producto: artículo de marco y conjunto de referencia.
Año 2	Diseño del metaoptimizador, incertidumbre, abstención y escenarios de corrupción; evaluación por tareas reservadas. Producto: artículo metodológico y código reproducible.
Año 3	Confirmación en series de tiempo y modelos de lenguaje compactos; integración experimental con DOIN; análisis final y tesis. Producto: artículo aplicado y artefacto abierto.

5.2 Viabilidad y plan de recorte

HPO-B permite realizar gran parte del estudio sin repetir millones de entrenamientos. Los experimentos reales se limitarán por presupuesto de cómputo y usarán modelos pequeños o adaptación eficiente. La experiencia del candidato en optimización evolutiva distribuida, series de tiempo y construcción de sistemas de aprendizaje reduce el riesgo técnico inicial; además, ya existen procesos de entrenamiento, registros de optimización y una red experimental derivados de la tesis de maestría [15], [16]. Si DOIN se retrasa, las trazas se consumirán desde un almacén firmado sin cambiar la pregunta científica. Si una de las dos familias aplicadas excede los recursos, HPO-B y una familia confirmatoria bastarán para evaluar las tres hipótesis.

5.3 Ética y reproducibilidad

No se requieren participantes humanos ni datos personales en la fase principal. Para modelos de lenguaje se usarán conjuntos de datos con licencia clara, se filtrará contenido sensible y se documentarán proveedor, versión y costo. Se publicarán semillas, particiones por tarea, presupuestos, fallos y consumo de cómputo. Las trazas privadas solo se usarán después de sanitización y control de procedencia. Ningún experimento ejecutará operaciones financieras reales.

5.4 Pertinencia para el Doctorado en Inteligencia Artificial

La pregunta central es cómo un sistema aprende a mejorar otro proceso de aprendizaje y cómo reconoce los límites de lo aprendido. Esto se ubica en aprendizaje automático avanzado, metaaprendizaje, optimización, incertidumbre y series de tiempo, áreas expresamente relacionadas con el programa [17]. La infraestructura distribuida sirve para obtener evidencia difícil; no reemplaza la contribución en inteligencia artificial.

Criterio de confirmación. Un piloto separado fijará los umbrales, presupuestos, decisiones de arquitectura y tamaño final de muestra. Esas decisiones quedarán congeladas antes de evaluar las hipótesis.

Referencias

- [1] D. J. C. MacKay, *Information Theory, Inference, and Learning Algorithms*. Cambridge, U.K.: Cambridge University Press, 2003, cap. 40, pp. 483–490. [En línea]. Disponible: inference.org.uk/itprnn/book.pdf.
- [2] T. M. Cover, “Geometrical and Statistical Properties of Systems of Linear Inequalities with Applications in Pattern Recognition,” *IEEE Transactions on Electronic Computers*, vol. EC-14, no. 3, pp. 326–334, 1965, doi: 10.1109/PGEC.1965.264137.
- [3] M. Li and P. Vitanyi, *An Introduction to Kolmogorov Complexity and Its Applications*, 4th ed. Cham, Switzerland: Springer, 2019.
- [4] A. Xu and M. Raginsky, “Information-Theoretic Analysis of Generalization Capability of Learning Algorithms,” in *Advances in Neural Information Processing Systems 30*, 2017.
- [5] S. Lotfi, M. Finzi, S. Kapoor, A. Potapczynski, M. Goldblum and A. G. Wilson, “PAC-Bayes Compression Bounds So Tight That They Can Explain Generalization,” in *Advances in Neural Information Processing Systems 35*, 2022.
- [6] M. Andrychowicz et al., “Learning to Learn by Gradient Descent by Gradient Descent,” in *Advances in Neural Information Processing Systems 29*, 2016.
- [7] P. Hennig and C. J. Schuler, “Entropy Search for Information-Efficient Global Optimization,” *Journal of Machine Learning Research*, vol. 13, pp. 1809–1837, 2012.
- [8] Y. Chen et al., “Towards Learning Universal Hyperparameter Optimizers with Transformers,” in *Advances in Neural Information Processing Systems 35*, 2022.
- [9] Z. Wang et al., “Pre-trained Gaussian Processes for Bayesian Optimization,” *Journal of Machine Learning Research*, vol. 25, no. 212, pp. 1–83, 2024.
- [10] S. Müller, M. Feurer, N. Hollmann and F. Hutter, “PFNs4BO: In-Context Learning for Bayesian Optimization,” in *Proc. 40th International Conference on Machine Learning*, PMLR 202, pp. 25444–25470, 2023.
- [11] S. Pineda Arango, H. S. Jomaa, M. Wistuba and J. Grabocka, “HPO-B: A Large-Scale Reproducible Benchmark for Black-Box HPO Based on OpenML,” in *NeurIPS Datasets and Benchmarks*, 2021.
- [12] Z. Fan, X. Han and Z. Wang, “Transfer Learning for Bayesian Optimization on Heterogeneous Search Spaces,” *Transactions on Machine Learning Research*, 2024.
- [13] S. P. Hellan, H. Shen, F.-X. Aubet, D. Salinas and A. Klein, “Obeying the Order: Introducing Ordered Transfer Hyperparameter Optimization,” in *Proc. Fourth International Conference on Automated Machine Learning*, PMLR 293, pp. 14/1–29, 2025.
- [14] D. H. Wolpert and W. G. Macready, “No Free Lunch Theorems for Optimization,” *IEEE Transactions on Evolutionary Computation*, vol. 1, no. 1, pp. 67–82, 1997.
- [15] H. D. Bastidas Caicedo, *Computación Evolutiva Descentralizada de Modelo Híbrido usando Blockchain y Prueba de Trabajo de Optimización*, tesis de Maestría, Pontificia Universidad Javeriana, 2018.
- [16] H. D. Bastidas Caicedo, “DOIN Core: Proof-of-Optimization Consensus,” repositorio de software, 2026. [En línea]. Disponible: github.com/harveybc/doin-core.
- [17] Universidad de La Sabana, “Doctorado en Inteligencia Artificial,” 2026. [En línea]. Disponible: unisabana.edu.co/programas/posgrados/doctorado-en-inteligencia-artificial.