

Diseño de representaciones temporales modulares basado en datos

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje de representaciones · series temporales · arquitectura modular · pronóstico multivariado · aprendizaje por refuerzo · generalización

Resumen

La *representación temporal* es la parte de una arquitectura para pronóstico o aprendizaje por refuerzo que transforma la información de una serie temporal multivariada de entrada en conocimiento usable por las capas de salida. Las series temporales multivariadas pueden reunir variables cuyos ritmos de cambio, periodicidades y relaciones son distintos. Algunos modelos de pronóstico y aprendizaje por refuerzo (RL) procesan todas las variables con la misma ventana y el mismo extractor de características, otros incorporan varias escalas temporales mediante una representación elegida de antemano o una búsqueda de configuraciones que puede ser costosa. Esta propuesta estudiará si las propiedades temporales de los datos de entrenamiento permiten orientar las decisiones de diseño de la representación temporal tanto para pronóstico como para RL.

Se diseñará la *representación temporal modular* mostrada en la Figura 1, formada por:

- *ramas 1..B* que procesan grupos de variables usando extractores de características especializados
- *módulo de fusión de características* que alinea y concatena las secuencias
- *núcleo temporal* que combina la información y reduce dimensionalidad conservando el eje temporal
- *cabezales de salida* que se adaptan a la tarea: pronóstico para estimar valores o aprendizaje por refuerzo para seleccionar acciones y, según el algoritmo, estimar funciones de valor.




Figura 1. Representación temporal modular. Las ramas 1..B procesan grupos de variables, el módulo de fusión de características alinea y concatena sus secuencias, y el núcleo temporal combina la información para los cabezales de salida.

El procedimiento analizará los datos de entrenamiento para proponer grupos de variables, contextos temporales y modelos adecuados para cada rama. Las alternativas se seleccionarán mediante validación de la tarea, considerando sus requisitos y los recursos disponibles.

Cada extractor tendrá un detector de patrones separado y componentes configurables de integración temporal y adaptación, que podrán combinarse u omitirse cuando no sean necesarios. El detector podrá entrenarse desde cero o importar pesos preentrenados, mantenerlos fijos o ajustarlos con el modelo completo.

Se evaluarán tareas de pronóstico y RL con series multivariadas y protocolos disponibles en la literatura. Se comparará la propuesta con referencias sencillas, modelos publicados y variantes sin el diseño modular, controlando entradas, entrenamiento y recursos.

La representación se integrará en plataformas existentes de pronóstico y RL. Sus configuraciones y métricas se registrarán en un cubo OLAP existente que permitirá organizar y facilitar el análisis y visualización de los resultados. Se espera obtener un método reproducible y determinar si el uso de la representación modular basada en datos mejora el desempeño, lo mantiene en un nivel equivalente o lo empeora. La evidencia insuficiente se declarará inconclusa.

1. Definición del problema y justificación

El aprendizaje de representaciones transforma las observaciones en características que facilitan una tarea, como pronosticar valores o seleccionar acciones [1, 2]. En series temporales, diseñar esa transformación exige decidir cuánto pasado proporcionar, cómo agrupar las variables, qué resolución temporal conservar y en qué etapa combinar la información.

Una representación uniforme puede resultar insuficiente cuando las variables cambian a ritmos distintos. Explorar muchas combinaciones de ventanas y arquitecturas permite adaptarlas, pero consume recursos y aumenta el riesgo de escoger una configuración demasiado ajustada a los datos de validación [3]. La pregunta es si un análisis previo de las propiedades temporales permite orientar la selección y configuración de los modelos y mejorar su desempeño en el conjunto de prueba reservado.

El proyecto parte de sistemas de pronóstico y RL para trading en los que se han probado extractores modulares y codificadores preentrenados. La necesidad práctica es orientar la selección y combinación de estos componentes mediante un análisis de los datos, y comprobar tanto su utilidad financiera como su desempeño frente a métodos publicados.

Pregunta de investigación. ¿En qué condiciones agrupar variables según sus propiedades temporales y adaptar el procesamiento de cada rama a las características específicas de estos datos, mejora el desempeño de un modelo de pronóstico o RL en datos reservados, frente a un modelo que no utilice este procesamiento independiente por rama, con datos, entrenamiento y recursos comparables?

La pregunta se responderá con evaluaciones separadas de pronóstico y RL, ya que una mejora predictiva no implica por sí sola mejores decisiones de trading.

2. Objetivos

2.1. Objetivo general

Desarrollar y evaluar un procedimiento basado en las propiedades temporales de los datos para agrupar variables, seleccionar y configurar los modelos de cada rama y aprender una representación temporal modular, comprobando su desempeño en pronóstico y aprendizaje por refuerzo frente a líneas base y modelos sin ese procesamiento diferenciado, con información, entrenamiento y recursos comparables.

2.2. Objetivos específicos

1. Definir los componentes y las interfaces de la representación modular, y estimar propiedades temporales que orienten la agrupación de variables y el contexto de cada rama.

2. Construir un procedimiento reproducible para agrupar variables, seleccionar los modelos adecuados para cada rama y configurar su contexto temporal, integración y adaptación, con entrenamiento desde cero o con detectores preentrenados fijos o ajustables.
3. Comparar el procedimiento con modelos de la literatura y variantes controladas de su arquitectura en tareas públicas reservadas, midiendo error, costo, estabilidad y condiciones de fallo.
4. Integrar la representación en las plataformas existentes de pronóstico y RL, registrar las configuraciones y métricas en la infraestructura analítica y evaluar la aplicación financiera frente a una estrategia trivial, la representación actual y una variante sin el procesamiento modular propuesto.

3. Marco teórico y antecedentes

3.1. Representación temporal y componentes del modelo

Una *ventana de entrada* es el segmento histórico que se entrega al modelo. Se representará por $X_{1:L} \in \mathbb{R}^{L \times p}$, donde L es el número de instantes y p el de variables. El *campo receptivo de una activación* es la parte de esa entrada que puede influir en una salida concreta de una capa. Por ejemplo, una ventana puede contener 144 observaciones mientras una activación de la primera capa utiliza solo tres. Las capas posteriores pueden ampliar ese alcance. Cuando se hable del campo receptivo de una rama, se hará referencia al de sus activaciones de salida, medido respecto de la entrada original.

El bloque de representación realiza una transformación aprendida $Z = f_{\theta}(X)$, donde θ contiene los pesos ajustados durante el entrenamiento y Z es la secuencia de características que utilizarán las capas siguientes. En la arquitectura modular, las variables se distribuyen en B grupos, $G_1, \dots, G_B$. Cada rama contiene un detector de patrones D_j como módulo separado, un componente de integración temporal I_j y una adaptación de salida A_j :

$$Z_j = A_j(I_j(D_j(X_{:,G_j}))) \in \mathbb{R}^{L_j \times c_j}. \quad (1)$$

Aquí $X_{:,G_j}$ contiene las variables del grupo j , L_j es la longitud de la secuencia producida y c_j el número de características por instante, también llamadas *canales*. El detector D_j tendrá una interfaz independiente para entrenarse, guardar sus pesos y reutilizarse. I_j y A_j serán configurables y podrán implementarse separados o en un componente conjunto; si alguna función no requiere una transformación, se representará mediante la identidad. La ecuación describe esa composición funcional y no exige que integración y adaptación sean siempre redes independientes.

Antes de combinar las ramas, el módulo de fusión de características establecerá qué instantes corresponden entre sus salidas y concatenará las características. Si una rama reduce su resolución temporal, L_j podrá ser distinto de L y será necesario especificar esa correspondencia. El núcleo temporal procesará la secuencia conjunta; el cabezal de pronóstico producirá $\hat{Y}_{L+1:L+H}$, las predicciones de los siguientes H pasos. En aprendizaje por refuerzo, las salidas se adaptarán al algoritmo de selección de acciones o estimación de valor. Cada aplicación utilizará un modelo entrenado para su objetivo.

3.2. Propiedades temporales para orientar el diseño

Una *escala temporal* describe la duración de un patrón o una dependencia: por ejemplo, el período de una oscilación o cuánto tarda en disminuir la semejanza entre una señal y sus valores pasados. El *perfil temporal* reunirá medidas de esas propiedades para cada variable. Se calculará exclusivamente con sus datos de entrenamiento e incluirá decaimiento de autocorrelación, distribución de energía entre frecuencias, periodicidades dominantes y estabilidad de las estimaciones entre segmentos de la serie.

Los perfiles se expresarán en unidades comparables entre tareas. Su cálculo y normalización se especifican en la sección 4.3.

Los perfiles individuales pueden orientar la agrupación, pero su semejanza no demuestra causalidad ni dependencias entre variables con retraso. Estas se examinarán por separado. Tampoco se supondrá que una periodicidad determina el campo receptivo óptimo: la utilidad de esa relación se evaluará con señales sintéticas y datos públicos.

3.3. Modelos de referencia

DLinear mostró que un modelo lineal sencillo puede superar arquitecturas más complejas en varios conjuntos de pronóstico [4]. PatchTST divide la historia en segmentos o *parches* y procesa las variables de manera independiente [5]. iTransformer representa cada variable como una unidad de entrada del mecanismo de atención para aprender relaciones entre ellas [6]. Estos trabajos justifican comparar el método tanto con referencias sencillas como con modelos que procesan las variables por separado o conjuntamente.

Varios métodos incorporan múltiples escalas. TimesNet organiza variaciones periódicas en representaciones bidimensionales [7]; MTST utiliza ramas con distintas resoluciones de parche [8]; Pathformer aprende rutas entre escalas [9]; y TimeMixer combina componentes en resoluciones finas y gruesas [10]. MSGNet aprende relaciones entre variables que dependen de la escala [11]. CCM aprende grupos de variables mediante asignaciones y prototipos regularizados por similitud [12]; DUET combina agrupación temporal con pertenencias graduadas de las variables a grupos [13]. Leddam y CATS estudian otras formas de representar dependencias entre series [14, 15]. Por tanto, la presencia de ramas, agrupaciones o múltiples escalas ya tiene antecedentes directos.

También existen representaciones aprendidas que aprovechan propiedades de las señales. CoST separa tendencia y estacionalidad mediante aprendizaje contrastivo [16], mientras BTSF combina información temporal y espectral [17]. En audio, SincNet y LEAF incorporan operaciones de procesamiento de señales cuyos parámetros se aprenden con la tarea [18, 19]. Sin embargo, EfficientLEAF encontró que sus extractores aprendibles no superaban consistentemente un banco de filtros fijo en las tareas evaluadas [20]. Estos antecedentes motivan el diseño basado en propiedades de señales y, a la vez, la necesidad de comprobar su utilidad frente a alternativas sencillas.

3.4. Diferencia que estudiará la propuesta

FFORMA utiliza características de una serie para ponderar modelos completos de pronóstico [21]. EMTSF busca mediante evolución combinaciones de módulos espaciales y temporales [22]. REP-Net divide el procesamiento en representación, extracción y proyección y evalúa configuraciones de esas etapas [23]. DUET es un comparador especialmente cercano porque aborda tanto diferencias temporales como relaciones entre variables.

La contribución propuesta es comprobar si las propiedades temporales orientan conjuntamente la agrupación de variables, el contexto y la selección de modelos por rama. Se evaluará el procedimiento en *familias de datos* reservadas: conjuntos relacionados por su fuente y dominio, cuyas variantes no se contarán como evidencia independiente.

La revisión inicial no identificó un método que combine esa regla previa de diseño con una evaluación entre familias reservadas y controles de capacidad, entrenamiento y costo. Esta diferencia deberá verificarse mediante la revisión sistemática del primer semestre. Si se encuentra un método equivalente, se incorporará como referencia y se delimitará la contribución antes de realizar la evaluación final.

El preentrenamiento por capas y la reconstrucción de valores ocultos tienen antecedentes en autoencoders [24, 25]. El sistema existente permite exportar codificadores y decodificadores y configurar el reajuste de extractores [26, 27]; el entrenamiento conjunto se verificará en la implementación.

4. Metodología

CRISP-DM organizará el trabajo en seis etapas [28], desde la comprensión de los datos y la tarea hasta la evaluación e integración de los modelos. La Tabla 1 especifica las acciones y entregas de cada etapa.

Tabla 1. Aplicación de CRISP-DM al proyecto.

Etapas	Qué se hará	Entrega verificable
Comprensión del problema	Definir las tareas de pronóstico y RL, las restricciones del sistema y las mejoras que justificarían el diseño modular.	Especificación de entradas, salidas y criterios de comparación.
Comprensión de los datos	Inventariar fuentes y resultados publicados; examinar calidad, escalas temporales y disponibilidad de cada variable.	Inventario de datos y diagnóstico temporal.
Preparación de los datos	Construir particiones temporales, ajustar transformaciones con entrenamiento y preparar las entradas de las ramas.	Datos y transformaciones reproducibles, sin información futura.
Modelado	Proponer grupos, seleccionar modelos por rama, configurar su contexto y entrenar el sistema completo.	Procedimiento de diseño, modelos y configuraciones.
Evaluación	Comparar diseños, probar las hipótesis y medir desempeño, incertidumbre y costo.	Resultados frente a controles y límites de interpretación.
Despliegue e integración	Conectar los módulos con las plataformas, registrar experimentos y definir seguimiento y reentrenamiento.	Componentes reutilizables y evaluación financiera histórica.

Estas etapas podrán repetirse durante el desarrollo. Antes de abrir los resultados reservados para evaluación quedarán fijados los datos, las alternativas de diseño, los presupuestos y las reglas de comparación. En una tarea nueva se podrán elegir y entrenar modelos con sus segmentos de entrenamiento y validación, aplicando ese procedimiento ya definido.

4.1. Comprensión del problema: definir qué debe resolver la representación

Se especificarán los requisitos de cada aplicación. Para pronóstico se definirán las variables objetivo, los pasos futuros que deben predecirse y la frecuencia de actualización. Para RL se establecerán las observaciones, acciones, recompensa y condiciones de ejecución del agente. En ambos casos se identificarán las interfaces con los extractores, el módulo de fusión, el núcleo temporal y los cabezales, junto con los límites de memoria y tiempo.

El resultado será una especificación que permita comparar representaciones dentro del mismo problema. Una estrategia trivial de trading o un pronóstico ingenuo aportarán referencias básicas de utilidad; los modelos sin procesamiento diferenciado por ramas permitirán comprobar si la mejora procede del diseño modular. Los márgenes de mejora relevante se justificarán durante el piloto y quedarán registrados antes de la evaluación final.

4.2. Comprensión de los datos: conocer las señales y elegir comparaciones reproducibles

Se partirá del inventario de datos existente para la aplicación financiera y de conjuntos públicos para contrastar resultados con la literatura. Se examinarán, entre otros, los bancos TFB, Monash y GIFT-Eval, que reúnen tareas de distintos dominios [29, 30, 31]. Cada conjunto candidato deberá tener frecuencia y licencia documentadas, historia suficiente y variables distintas observadas conjuntamente que permitan comparar agrupaciones. Los datos univariados podrán verificar una implementación, pero no demostrar el beneficio de agrupar variables.

Para cada fuente se documentarán archivos y versiones, fechas, frecuencia de muestreo, variables, valores ausentes y momento de disponibilidad de las observaciones. El diagnóstico del segmento de entrenamiento examinará ritmos de cambio, periodicidades, autocorrelación y estabilidad entre períodos. Así se distinguirán propiedades persistentes de estimaciones que cambian demasiado para justificar una rama especializada. El inventario también identificará datos ya utilizados por el proyecto o por modelos preentrenados.

La selección de conjuntos partirá de experimentos publicados con tareas, métricas y protocolos recuperables. Se reproducirá al menos un modelo de referencia; la tolerancia se fijará antes de obtener el resultado propio según la precisión numérica y la variación entre ejecuciones. Se conservarán las fechas, particiones, objetivos y métricas del estudio original cuando se afirme una reproducción directa. Si es necesario adaptar el protocolo, todos los métodos recibirán el mismo tratamiento y la comparación se identificará como adaptada.

En finanzas se verificarán además instrumentos, precios y momento de ejecución, comisiones, deslizamiento y restricciones. TradeMaster y FinRL-Meta serán puntos de partida para buscar experimentos compatibles [32, 33]. Si no puede recuperarse una comparación externa, se mantendrá la evaluación con los controles propios y se declarará

esa limitación. La normalización y cualquier posible acceso a información futura se revisarán antes de aceptar un protocolo.

4.3. Preparación de los datos: construir entradas comparables

Cada tarea tendrá segmentos cronológicos de entrenamiento, validación y prueba. El entrenamiento ajustará transformaciones y pesos; la validación seleccionará configuraciones y puntos de parada; la prueba medirá el desempeño del modelo seleccionado. La normalización, la imputación y las descomposiciones que se utilicen se ajustarán solo con entrenamiento. Las ventanas incluirán únicamente información disponible en el instante de pronóstico o decisión, considerando posibles retrasos de publicación.

Para cada variable i se calculará el perfil temporal d_i definido en el marco teórico. Los retardos se expresarán en unidades comparables y las frecuencias respecto de la frecuencia de Nyquist, la mitad de la frecuencia de muestreo. Se utilizará un escalado robusto común, ajustado durante el desarrollo y conservado en las tareas reservadas; se evitará normalizar cada tarea de manera que desaparezcan sus diferencias. El perfil escalado se denotará por $\tilde{d}_i$, y su heterogeneidad se resumirá mediante

$$q(X) = \text{mediana}_{i < k} \|\tilde{d}_i - \tilde{d}_k\|_2. \quad (2)$$

Este valor mide cuánto difieren los perfiles entre sí; no representa causalidad ni dificultad de pronóstico. Las dependencias entre variables con retraso se analizarán mediante un diagnóstico separado, también calculado con entrenamiento.

Se prepararán entradas que conserven las marcas de tiempo y permitan alinear las salidas de las ramas. Las adaptaciones de formato requeridas por un modelo se documentarán sin añadir información a la disponible para sus comparadores.

4.4. Modelado: diseñar las ramas y aprender sus representaciones

El diseño se realizará en dos pasos: el análisis de entrenamiento propondrá configuraciones pertinentes y la validación de la tarea decidirá entre ellas. Se seguirá esta secuencia:

1. **Proponer grupos de variables.** Se utilizará agrupamiento jerárquico de perfiles como punto de partida y se comprobará su estabilidad entre segmentos. Una variable con perfil inestable se asignará a una rama común, dejando constancia de que los datos no justificaron una especialización.
2. **Proponer contexto y modelos.** Para cada grupo se estudiarán alternativas convolucionales, recurrentes, de atención o híbridas compatibles con sus escalas, cantidad de datos y recursos. Se fijarán un catálogo finito y rangos de configuración; las ramas podrán utilizar modelos diferentes.
3. **Ensamblar y entrenar.** Se conectarán detectores, integración, adaptación, fusión, núcleo y cabezales. Se comprobarán dimensiones, correspondencia temporal y actualización de parámetros antes de las ejecuciones completas.
4. **Seleccionar con validación.** Se comparará el desempeño del sistema completo, no solo el error de reconstrucción de un extractor. La búsqueda de hiperparámetros y estructura se reservará para las alternativas que el análisis previo no permita resolver. Se definirán criterios de parada temprana tanto para el entrenamiento como para la búsqueda, utilizando validación.

La parte del procedimiento que propone agrupación G , contextos R y modelos admisibles $\mathcal{M}$ se representará como

$$(G, R, \mathcal{M}) = A_\eta(\tilde{d}_1, \dots, \tilde{d}_p). \quad (3)$$

Los parámetros η describirán sus criterios de diseño. Durante el desarrollo se fijarán esos criterios, el máximo de ramas y el presupuesto de búsqueda. En las tareas reservadas cambiarán los perfiles y los modelos resultantes, pero no el procedimiento utilizado para elegirlos.

Configurar el procesamiento temporal. En convoluciones se ajustarán profundidad, filtros y dilatación para controlar el alcance temporal [34]; en recurrencia, la historia accesible y el tratamiento de estados; y en atención, la longitud de secuencia y las restricciones de acceso. El detector permanecerá como módulo separado. El integrador añadirá contexto cuando sea necesario y la adaptación ajustará dimensiones, desplazamientos y correspondencia

temporal. Ampliar el contexto no exige aumentar la longitud de la secuencia de salida. Integración y adaptación podrán configurarse juntas o separadas, o actuar como identidad.

La Figura 2 muestra el ensamblaje. Cada componente podrá contener varias capas, con tipos, tamaños y repeticiones configurables. Tras la fusión, el núcleo procesará la secuencia conjunta; el cabezal de pronóstico utilizará su último estado para predecir los pasos futuros. En algoritmos de actor y crítico, como el actor-crítico suave (SAC), se decidirá si los modelos de política y valor comparten representación [35].




Figura 2. Arquitectura conceptual. Las líneas discontinuas muestran propuestas de diseño a partir de los datos de entrenamiento; la validación selecciona los modelos. Las continuas muestran el flujo de datos. Cada rama contiene un detector D_j separado e integración I_j y adaptación A_j configurables. Alineación y fusión reúnen el módulo de fusión de características y el núcleo temporal de la Figura 1.

Elegir cómo se inicializa y entrena el detector. Se compararán las tres modalidades de la Tabla 2. Los códigos R0, R1 y R2 identifican únicamente estas modalidades de entrenamiento.

Tabla 2. Modalidades de entrenamiento del detector de patrones.

Código	Modalidad	Qué se entrena
R0	Desde cero	El detector empieza con pesos aleatorios y se ajusta junto con el resto del modelo.
R1	Preentrenado y congelado	Se importan pesos preentrenados y se mantienen fijos; se entrena el resto del modelo.
R2	Preentrenado y ajustable	Se importan los mismos pesos iniciales de la modalidad congelada y se siguen ajustando con el modelo completo.

Para preentrenar el detector se utilizará un autoencoder: su codificador aprenderá a representar la entrada y un decodificador auxiliar intentará reconstruirla, completa o con valores ocultos mediante una máscara definida previamente. Después se incorporará el codificador como detector; el decodificador se conservará por separado. El entrenamiento desde cero no requerirá esta etapa. La reconstrucción ordinaria no se interpretará por sí sola como eliminación de ruido.

Se comprobará que el detector congelado conserve sus pesos y que el ajustable los modifique a partir del objetivo final [36]. Se guardarán por separado los pesos preentrenados y los modificados durante el ajuste. Para la comparación principal en pronóstico se elegirá una modalidad durante el desarrollo y se aplicará por igual al método y sus controles.

El sistema de optimización registrará configuraciones, pesos iniciales y métricas de los candidatos, incluidos los descartados. Ese historial podrá servir para una futura metaoptimización; en esta propuesta su función será permitir el

análisis y la reproducción de las decisiones de diseño. La Figura 3 resume cómo se separará la elección del modelo de su prueba final.




Figura 3. Separación entre desarrollo y evaluación. Durante el desarrollo se fija el procedimiento; cada tarea estima perfiles y entrena candidatos con entrenamiento, selecciona con validación y evalúa el modelo resultante en prueba reservada.

4.5. Evaluación: comprobar el aporte del diseño y sus límites

La evaluación responderá tres preguntas concretas: si el diseño mejora el pronóstico, si agrupar por escalas aporta una ventaja y si conservar las secuencias ayuda a utilizar relaciones entre variables con retraso. La Tabla 3 presenta las hipótesis correspondientes. Sus códigos identifican afirmaciones que se contrastarán; la selección de modelos seguirá el procedimiento de la etapa anterior.

Tabla 3. Hipótesis de investigación y comparación que las pone a prueba.

Código	Qué se espera comprobar	Comparación
H1	El diseño basado en datos mejora el pronóstico global sin perjuicio relevante en ninguna familia evaluada.	Método propuesto frente al control principal elegido durante el desarrollo.
H2	La ventaja de agrupar mediante perfiles aumenta cuando las escalas temporales son más distintas.	Agrupación informada frente a asignación permutada, variando la heterogeneidad de señales sintéticas.
H3	Con relaciones temporales entre variables, conservar las secuencias hasta fusionarlas mejora el pronóstico.	Fusión de secuencias frente a resumen temprano, con y sin relaciones entre variables con retraso.

La evaluación financiera en RL comprobará además la utilidad de la representación dentro del agente. Tendrá métricas y criterios propios; sus resultados no se mezclarán con el error de pronóstico.

4.5.1 Organizar los experimentos y reservar datos para la prueba

Los experimentos se organizarán en cuatro bloques, descritos en la Tabla 4. Estos bloques no sustituyen las etapas de CRISP-DM: indican qué datos se utilizarán para desarrollar el método y cuáles para comprobarlo.

Tabla 4. Bloques experimentales, datos y finalidad.

Código	Bloque	Datos y uso
E0	Pruebas sintéticas	Señales de estructura conocida, con grupos separados para desarrollar diagnósticos y contrastar H2 y H3.
E1	Desarrollo del método	Familias públicas para elegir criterios de diseño, alternativas, controles, entrenamiento y presupuestos, y comprobar la precisión estadística.
E2	Evaluación pública reservada	Otras familias públicas para contrastar H1 con el procedimiento fijado. Cada tarea conserva su entrenamiento, validación y prueba.
E3	Aplicación financiera	Datos históricos para comparar la representación dentro del agente de RL. Es una entrega obligatoria y su análisis es independiente de H1–H3.

El desarrollo precederá a las pruebas reservadas. Antes de ajustar el método se fijarán las ecuaciones, rangos y semillas de la reserva sintética; sus resultados permanecerán cerrados hasta terminar el desarrollo. Antes de la

evaluación pública se fijarán familias, horizontes y divisiones temporales. Las variantes de una misma fuente se mantendrán juntas: separar sus ventanas no creará familias independientes. El piloto determinará cuántas familias y repeticiones pueden sostener una comparación precisa dentro del presupuesto.

Las señales sintéticas combinarán procesos autorregresivos, periodicidades, tendencias y eventos localizados. Para probar la agrupación se variarán las escalas manteniendo constantes cantidad de datos y ruido. Para probar la fusión se construirán pares con y sin dependencias entre variables, preservando en distribución sus propiedades individuales. Se comprobará esa preservación con repeticiones; permutar el orden temporal se reservará para sensibilidad porque altera también cada serie. Se incluirán cambios temporales y casos donde fallen los supuestos del diagnóstico. El ruido añadido será conocido, sin extender esa suposición a los residuos de datos reales.

4.5.2 Comparar con referencias y aislar el efecto de las decisiones

Se utilizarán tres grupos de comparación:

- **Referencias de desempeño:** pronóstico ingenuo y estacional ingenuo, un modelo estadístico multivariado pertinente y DLinear; PatchTST, iTransformer y DUET, junto con un método multiescala elegido entre MTST, Pathformer y TimeMixer antes de examinar los resultados de desarrollo. DUET será obligatorio por su proximidad a la propuesta.
- **Controles del diseño:** un modelo sin procesamiento diferenciado por ramas y uno modular organizado sin utilizar los perfiles. Se elegirá como control principal el que obtenga menor error agregado en los datos de desarrollo, con el mismo criterio que se aplicará después.
- **Ablaciones:** variantes que cambian una decisión concreta, como permutar la asignación de variables, usar un contexto común o resumir las ramas antes de fusionarlas. Permitirán distinguir el efecto de agrupación, selección de modelos y conservación temporal.

Método y controles compartirán información, preprocesamiento común, semillas, criterios de entrenamiento, límites de búsqueda y catálogos comparables. Cuando sea viable, se igualarán parámetros dentro de una tolerancia fijada en el piloto; se informarán también error, tiempo y memoria. El control permutado conservará número y tamaño de ramas, modelos, contextos, interfaces y presupuesto. Se fijarán previamente sus permutaciones y desempates, evitando una permutación conjunta de datos, objetivos y módulos que solo cambie sus nombres. MSGNet o CCM podrá añadirse si su interfaz y costo permiten una comparación útil.

4.5.3 Medir el desempeño y decidir si la diferencia es relevante

La unidad de evaluación será una tarea de pronóstico: conjunto de datos, variables objetivo y horizonte. Se repetirá desde distintos puntos de inicio, llamados *orígenes de evaluación*, y con distintas *semillas aleatorias* del entrenamiento. Estas repeticiones se agregarán dentro de la tarea y no se contarán como tareas independientes.

La medida principal será el error absoluto medio escalado, MASE [37]. Divide el error del modelo por el de repetir un valor de un período anterior, calculado con entrenamiento. Para la variable k , el origen o , las n_o observaciones disponibles, el período estacional m_k y los H pasos futuros, se calcularán

$$a_{k,o} = \frac{1}{n_o - m_k} \sum_{u=m_k+1}^{n_o} |y_{k,u} - y_{k,u-m_k}|, \quad \text{MASE}_{k,o} = \frac{H^{-1} \sum_{h=1}^H |y_{k,n_o+h} - \hat{y}_{k,n_o+h}|}{a_{k,o}}. \quad (4)$$

Todos los métodos compartirán el denominador $a_{k,o}$. El período procederá de metadatos o de una regla fijada durante el desarrollo. Si un denominador requerido es cero, la tarea se informará aparte y no se utilizará para contrastar la hipótesis principal. Para comparar con publicaciones se añadirán sus métricas y formas exactas de agregación, incluidas MAE y MSE cuando correspondan.

Se promediará MASE con igual peso entre variables objetivo, pasos del horizonte, orígenes y semillas. La diferencia entre método y control para la tarea t será

$$\Delta_t = \text{MASE}_{t,\text{método}} - \text{MASE}_{t,\text{control}}. \quad (5)$$

Una diferencia negativa favorece a la propuesta. El efecto global Δ dará igual peso a tareas dentro de cada conjunto, conjuntos dentro de cada familia y familias, para que una fuente abundante no domine el resultado.

Antes de la evaluación reservada se fijará un margen $\varepsilon > 0$, que representa la diferencia mínima de MASE considerada relevante. Con un intervalo de incertidumbre $[L, U]$, la interpretación será:

- **Mejora relevante:** $U < -\varepsilon$.
- **Equivalencia práctica:** $[L, U] \subseteq [-\varepsilon, \varepsilon]$.
- **Perjuicio relevante:** $L > \varepsilon$.
- **Resultado inconcluso:** el intervalo no permite decidir entre las anteriores.

La ausencia de una mejora demostrada no se interpretará como equivalencia. Se publicarán también resultados por horizonte, variación entre semillas y eventos definidos previamente.

4.5.4 Contrastar las hipótesis y cuantificar la incertidumbre

Mejora del pronóstico global (H1). Se comparará el método con el control principal elegido durante el desarrollo. La hipótesis requerirá mejora global relevante, con límite superior de Δ menor que $-\varepsilon$, y ausencia de perjuicio mayor que ese margen en cada familia, con límite superior por familia menor o igual que ε . Una familia sin precisión suficiente impedirá afirmar ese resultado conjunto.

Utilidad de agrupar por escalas (H2). El experimento sintético variará un nivel conocido de heterogeneidad h , conservando tamaño de muestra, número de variables y distribución del ruido. Se calculará

$$e(h) = \text{MASE}(\text{perfiles}, h) - \text{MASE}(\text{permutación}, h).$$

La hipótesis se considerará respaldada si el límite superior del intervalo de la pendiente β de $e(h)$ respecto de h es menor que cero. Esto indicará que la ventaja relativa aumenta con la heterogeneidad; no demostrará que el método sea superior en todos sus niveles. La relación con $q(X)$ en datos públicos será un análisis complementario.

Utilidad de conservar las secuencias (H3). Las dos variantes recibirán las mismas activaciones de un extractor entrenado y mantenido fijo durante el contraste. Solo se ajustarán sus módulos de combinación y cabezales. Se compararán la fusión de secuencias y el resumen temprano en presencia de dependencias entre variables con retraso ($r = 1$) y en un control que conserva el comportamiento individual, pero elimina esa dependencia ($r = 0$):

$$d_r = \text{MASE}(\text{fusión temporal}, r) - \text{MASE}(\text{resumen temprano}, r), \quad \gamma = d_1 - d_0.$$

La hipótesis requerirá un límite superior de d_1 menor que $-\varepsilon$ y de γ menor que cero. Se medirá la memoria adicional para conservar secuencias. En datos públicos se hará un contraste complementario cuando el diagnóstico de entrenamiento identifique relaciones predictivas con retraso.

Control de la incertidumbre. Con F familias reservadas se evaluarán $K = F + 4$ efectos: uno global y F por familia para H1, la pendiente de H2 y dos contrastes para H3. Se fijará $\alpha = 0.05$ y se utilizarán intervalos bilaterales de cobertura nominal $1 - \alpha/K$, con ajuste de Bonferroni para el conjunto de comparaciones. El margen de MASE no se aplicará a la pendiente ni sustituirá el criterio de interacción de la fusión.

Los intervalos se estimarán mediante *bootstrap jerárquico*: remuestreo con reemplazo que conserva las comparaciones sobre los mismos datos. Para el efecto global se remuestrearán familias, conjuntos y tareas; para un efecto por familia, se fijará esa familia y se remuestrearán sus conjuntos y tareas. Se preservará la dependencia entre objetivos y horizontes de una fuente. En señales sintéticas se remuestrearán configuraciones del generador y repeticiones, manteniendo juntas las variantes comparadas. Si se remuestrean errores temporales se utilizarán bloques contiguos.

El piloto comprobará mediante simulación la precisión y cobertura de los intervalos y su sensibilidad a la longitud de bloque. Si el soporte no permite sostenerlas, el resultado afectado será inconcluso. La sensibilidad al retirar conjuntos se informará sin redefinir contrastes ni ampliar la prueba después de ver los resultados.

Evaluación temporal y reentrenamiento. Se avanzará por sucesivos orígenes siguiendo una política fijada previamente [38], con horizontes de prueba no solapados cuando los datos lo permitan. Antes de cada origen se estimarán perfiles y pesos con la información entonces disponible. Una observación ya evaluada podrá incorporarse al entrenamiento cuando forme parte del historial, con la misma política para todos los métodos. Los resultados de prueba no cambiarán reglas de diseño, rangos de búsqueda ni criterios de parada [3]. Un protocolo periódico diferente del publicado se declarará como adaptación.

4.5.5 Medir el costo completo de obtener el resultado

Se contabilizarán diagnóstico, preentrenamiento, selección, ajuste y evaluación, incluidos candidatos descartados, paradas tempranas e intentos fallidos. El costo energético se medirá en vatios-hora con un instrumento validado durante el desarrollo. Para tareas t , métodos m , semillas s y orígenes o , se registrará

$$C_{\text{total}} = \sum_{t,o} C_{\text{perfil},t,o} + \sum_{t,m,s,o} (C_{\text{pre}} + C_{\text{ajuste}} + C_{\text{eval}})_{t,m,s,o}. \quad (6)$$

El preentrenamiento incluirá el decodificador. Al reutilizar pesos se distinguirán costo inicial, costo adicional y acumulado, declarando cómo se reparte el trabajo compartido. Se separará el costo de desarrollar el procedimiento del de aplicarlo a una tarea nueva.

Se informarán además tiempo transcurrido, horas de CPU y GPU, memoria máxima, operaciones estimadas, hardware y concurrencia. Las duraciones de trabajos paralelos no se sumarán como tiempo transcurrido. Esta contabilidad permitirá comprobar si la mejora requiere una búsqueda o una capacidad mayores que las de los controles.

4.6. Despliegue e integración: utilizar los módulos en las plataformas existentes

Se entregarán extractores con interfaces documentadas para cargar datos, importar y exportar pesos y conectar sus salidas con la fusión, el núcleo y los cabezales. Se verificará el flujo de gradientes y la actualización de los componentes configurados como entrenables. La plataforma de pronóstico utilizará estos módulos en sus experimentos; la de RL permitirá comprobarlos en una tarea financiera histórica, sin reconstruir la infraestructura de optimización.

Durante el desarrollo se elegirán una tarea financiera y un algoritmo compatibles con la plataforma. El agente se evaluará con la representación propuesta, la actual y una variante sin procesamiento independiente por ramas; las dos últimas podrán coincidir. Se mantendrán constantes observaciones, recompensa, acciones, entorno, calendario y presupuesto. Se documentará cómo entran la posición y el estado de cuenta. Una estrategia trivial ofrecerá la referencia básica de trading.

Antes de la prueba financiera se fijarán métrica principal, margen de relevancia y métricas complementarias, con ejecución, costos y contabilidad comunes. Las diferencias e intervalos considerarán semillas y períodos compartidos. La comparación entre representaciones medirá su aporte dentro del agente; superar la estrategia trivial solo demostrará utilidad frente a esa referencia. Se distinguirán mejora, equivalencia, perjuicio e incertidumbre, con un análisis separado del de pronóstico y de su ajuste de multiplicidad.

DOIN proporcionará la optimización y el registro de los experimentos. El cubo OLAP existente organizará configuraciones, particiones, semillas, métricas y costos para su análisis y visualización. Se documentarán versiones, seguimiento del desempeño y reglas de reentrenamiento. Las actualizaciones posteriores conservarán su trazabilidad y no sustituirán retrospectivamente los resultados de la evaluación doctoral.

5. Viabilidad, recursos y riesgos

El proyecto dispone de cuatro GPU de distintas capacidades, CPU y plataformas de datos y entrenamiento. El piloto medirá tiempos y memoria, contemplando disponibilidad parcial de las GPU y reservando recursos para RL. Los diagnósticos y generadores que no requieran redes se ejecutarán en CPU.

Si el presupuesto es insuficiente, se retirarán alternativas redundantes y comparadores opcionales, conservando los controles principales. La aplicación financiera podrá acotarse a una tarea y un agente, con su estrategia trivial y control sin procesamiento diferenciado por ramas. El inventario y el piloto cerrarán datos, arquitecturas y presupuestos antes de consultar la prueba.

Los riesgos científicos son que los perfiles no orienten una mejora, que esta se limite a ciertos dominios o que los datos no permitan estimarla con precisión. Se informarán resultados desfavorables e inconclusos. Los datos se utilizarán conforme a sus licencias y la evaluación financiera será histórica. Se documentará cualquier solapamiento del preentrenamiento o desarrollo con las fuentes reservadas.

6. Cronograma

La Tabla 5 distribuye las actividades y entregas en seis semestres.

Tabla 5. Actividades y entregas por semestre.

Sem.	Trabajo principal	Entrega
1	Revisar antecedentes, definir tareas e interfaces, inventariar datos y realizar el piloto de recursos y precisión.	Diseño inicial registrado e inventario de datos y comparaciones.
2	Implementar perfiles, componentes y selección de modelos; construir señales sintéticas y verificar gradientes.	Software reproducible y reserva sintética definida (E0).
3	Desarrollar y comparar criterios de diseño, modalidades de entrenamiento y controles; cerrar los protocolos finales.	Método y presupuestos fijados al terminar el desarrollo (E1); manuscrito metodológico.
4	Evaluar pronóstico en familias reservadas y contrastar agrupación y fusión en señales sintéticas.	Resultados de la evaluación pública (E2) y de las tres hipótesis; manuscrito principal.
5	Integrar y evaluar los módulos en RL, con controles propios y comparación publicada cuando sea recuperable.	Evaluación financiera histórica (E3) y componentes reutilizables.
6	Integrar resultados, realizar la réplica independiente, escribir la tesis y preparar la defensa.	Tesis, modelos, configuraciones y documentación.

7. Resultados y contribuciones esperadas

1. Un procedimiento reproducible para diseñar representaciones temporales modulares a partir del análisis de datos, con criterios explícitos de agrupación, contexto y selección de modelos.
2. Evidencia que distinga el aporte del diseño del efecto de la arquitectura elegida, el preentrenamiento y los recursos empleados, incluyendo sus fallos y límites de generalización.
3. Componentes integrados en pronóstico y RL, evaluados con protocolos comparables y acompañados de configuraciones, pesos y registros experimentales analizables en el cubo OLAP.

Referencias

- [1] Y. Bengio, A. Courville y P. Vincent, «Representation Learning: A Review and New Perspectives», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, n.º 8, pp. 1798–1828, 2013. DOI: 10.1109/TPAMI.2013.50.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. <https://www.deeplearningbook.org/>.
- [3] G. C. Cawley y N. L. C. Talbot, «On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation», *Journal of Machine Learning Research*, vol. 11, n.º 70, pp. 2079–2107, 2010. <https://jmlr.org/papers/v11/cawley10a.html>.
- [4] A. Zeng et al., «Are Transformers Effective for Time Series Forecasting?», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 9, pp. 11121–11128, 2023. DOI: 10.1609/aaai.v37i9.26317.

- [5] Y. Nie et al., «A Time Series is Worth 64 Words: Long-term Forecasting with Transformers», *International Conference on Learning Representations*, 2023. <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=JePfAI8fah>.
- [7] H. Wu et al., «TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis», *International Conference on Learning Representations*, 2023. https://openreview.net/forum?id=ju_Uqw384Oq.
- [8] Y. Zhang et al., «Multi-resolution Time-Series Transformer for Long-term Forecasting», *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, vol. 238, pp. 4222–4230, 2024. <https://proceedings.mlr.press/v238/zhang24l.html>.
- [9] P. Chen et al., «Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=IJkOCMP2aW>.
- [10] S. Wang et al., «TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=7oLshfEIC2>.
- [11] W. Cai et al., «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, n.º 10, pp. 11141–11149, 2024. DOI: 10.1609/aaai.v38i10.28991.
- [12] J. Chen et al., «From Similarity to Superiority: Channel Clustering for Time Series Forecasting», *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-4152.
- [13] X. Qiu et al., «DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting», *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 1185–1196, 2025. DOI: 10.1145/3690624.3709325.
- [14] G. Yu et al., «Revitalizing Multivariate Time Series Forecasting: Learnable Decomposition with Inter-Series Dependencies and Intra-Series Variations Modeling», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 57818–57841, 2024. <https://proceedings.mlr.press/v235/yu24s.html>.
- [15] J. Lu et al., «CATS: Enhancing Multivariate Time Series Forecasting by Constructing Auxiliary Time Series as Exogenous Variables», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 32990–33006, 2024. <https://proceedings.mlr.press/v235/lu24d.html>.
- [16] G. Woo et al., «CoST: Contrastive Learning of Disentangled Seasonal-Trend Representations for Time Series Forecasting», *International Conference on Learning Representations*, 2022. <https://openreview.net/forum?id=PilZY3omXV2>.
- [17] L. Yang y S. Hong, «Unsupervised Time-Series Representation Learning with Iterative Bilinear Temporal-Spectral Fusion», *Proceedings of the 39th International Conference on Machine Learning*, vol. 162, pp. 25038–25054, 2022. <https://proceedings.mlr.press/v162/yang22e.html>.
- [18] M. Ravanelli y Y. Bengio, «Speaker Recognition from Raw Waveform with SincNet», *arXiv preprint arXiv:1808.00158*, 2018. DOI: 10.48550/arXiv.1808.00158.
- [19] N. Zeghidour et al., «LEAF: A Learnable Frontend for Audio Classification», *International Conference on Learning Representations*, 2021. <https://openreview.net/forum?id=jM76BCb6F9m>.
- [20] J. Schlüter y G. Gutenbrunner, «EfficientLEAF: A Faster Learnable Audio Frontend of Questionable Use», *arXiv preprint arXiv:2207.05508*, 2022. DOI: 10.48550/arXiv.2207.05508.
- [21] P. Montero-Manso et al., «FFORMA: Feature-based Forecast Model Averaging», *International Journal of Forecasting*, vol. 36, n.º 1, pp. 86–92, 2020. DOI: 10.1016/j.ijforecast.2019.02.011.
- [22] Z. Liang y Y. Sun, «Evolutionary Neural Architecture Search for Multivariate Time Series Forecasting», *Proceedings of the 15th Asian Conference on Machine Learning*, vol. 222, pp. 771–786, 2024. <https://proceedings.mlr.press/v222/liang24a.html>.
- [23] R. Leppich et al., «Decomposing the Time Series Forecasting Pipeline: A Modular Approach for Time Series Representation, Information Extraction, and Projection», *arXiv preprint arXiv:2507.05891*, 2025. DOI: 10.48550/arXiv.2507.05891.

- [24] Y. Bengio et al., «Greedy Layer-Wise Training of Deep Networks», *Advances in Neural Information Processing Systems*, vol. 19, 2007. https://proceedings.neurips.cc/paper_files/paper/2006/file/5da713a690c067105aeb2fae32403405-Paper.pdf.
- [25] Z. Li et al., «Ti-MAE: Self-Supervised Masked Time Series Autoencoders», *arXiv preprint arXiv:2301.08871*, 2023. DOI: 10.48550/arXiv.2301.08871.
- [26] H. Bastidas, «Gestor de autoencoder en `feature-extractor`», 2026. Inspección estática; commit `df86252`; consultado el 7 de septiembre de 2026. https://github.com/harveybc/feature-extractor/blob/df86252a174a1f5b9f77f4cb1bcb78fcdf e429e8/app/autoencoder_manager.py.
- [27] H. Bastidas, «Configuración de carga de extractor y `train_fe`», 2026. Configuración del repositorio, commit `20ec571`; consultada el 7 de septiembre de 2026. https://github.com/harveybc/predictor/blob/20ec57145b4ed3eb647eabe2b7591f35a3dbbf47/examples/config/phase_3_1/phase_3_1_cnn_25200_1h_config.json.
- [28] IBM, *IBM SPSS Modeler CRISP-DM Guide*, versión 19. Documentación de la metodología y de la selección de técnicas de modelado. https://www.ibm.com/docs/en/SS3RA7_19.0.0/pdf/ModelerCRISPDM.pdf.
- [29] X. Qiu et al., «TFB: Towards Comprehensive and Fair Benchmarking of Time Series Forecasting Methods», *Proceedings of the VLDB Endowment*, vol. 17, n.º 9, pp. 2363–2377, 2024. DOI: 10.14778/3665844.3665863.
- [30] R. Godahewa et al., «Monash Time Series Forecasting Archive», *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2021. <https://openreview.net/forum?id=I0117rc0jcb>.
- [31] T. Aksu et al., «GIFT-Eval: A Benchmark for General Time Series Forecasting Model Evaluation», *arXiv preprint arXiv:2410.10393*, 2024. DOI: 10.48550/arXiv.2410.10393.
- [32] S. Sun et al., «TradeMaster: A Holistic Quantitative Trading Platform Empowered by Reinforcement Learning», *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/file/b8f6f7f2ba4137124ac976286eacb611-Paper-Datasets_and_Benchmarks.pdf.
- [33] X.-Y. Liu et al., «FinRL-Meta: Market Environments and Benchmarks for Data-Driven Financial Reinforcement Learning», *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*, 2022. https://papers.neurips.cc/paper_files/paper/2022/file/0bf54b80686d2c4dc0808c2e98d430f7-Paper-Datasets_and_Benchmarks.pdf.
- [34] S. Bai, J. Z. Kolter y V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling», *arXiv preprint arXiv:1803.01271*, 2018. DOI: 10.48550/arXiv.1803.01271.
- [35] A. Raffin et al., «Stable-Baselines3: Reliable Reinforcement Learning Implementations», *Journal of Machine Learning Research*, vol. 22, n.º 268, pp. 1–8, 2021. <http://jmlr.org/papers/v22/20-1364.html>.
- [36] Keras Team, «Transfer learning & fine-tuning», 2023. Documentación oficial; consultada el 7 de septiembre de 2026. https://keras.io/guides/transfer_learning/.
- [37] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy», *International Journal of Forecasting*, vol. 22, n.º 4, pp. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.
- [38] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.a ed.. OTexts, 2021. Sección 5.10: evaluación con origen rodante. <https://otexts.com/fpp3/tscv.html>.