

Diseño de representaciones temporales modulares basado en datos

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje de representaciones · series temporales · arquitectura modular · pronóstico multivariado · aprendizaje por refuerzo · generalización

Resumen

La *representación temporal* es la parte de una arquitectura para pronóstico o aprendizaje por refuerzo que transforma la información de una serie temporal multivariada de entrada en conocimiento usable por las capas de salida. Las series temporales multivariadas pueden reunir variables cuyos ritmos de cambio, periodicidades y relaciones son distintos. Algunos modelos de pronóstico y aprendizaje por refuerzo (RL) procesan todas las variables con la misma ventana y el mismo extractor de características, otros incorporan varias escalas temporales mediante una representación elegida de antemano o una búsqueda de configuraciones que puede ser costosa. Esta propuesta estudiará si las propiedades temporales de los datos de entrenamiento permiten orientar las decisiones de diseño de la representación temporal tanto para pronóstico como para RL.




Figura 1: Representación temporal modular. Las ramas procesan grupos de variables; el consolidador alinea y concatena sus secuencias, y el núcleo temporal combina la información antes de los cabezales de salida. La reducción de características conserva el eje temporal. B indica el número total de ramas. Fuente: elaboración propia.

Se diseñará una *representación temporal modular* formada por:

- *ramas* que procesan grupos de variables usando extractores de características especializados;
- un *consolidador* que alinea y concatena las secuencias;
- un *núcleo temporal* que combina la información y reduce dimensionalidad conservando el eje temporal;
- *cabezales de salida* que se adaptan a la tarea: pronóstico para estimar valores o aprendizaje por refuerzo para seleccionar acciones y, según el algoritmo, estimar funciones de valor.

La Figura 1 presenta estos componentes básicos.

El procedimiento analizará las propiedades temporales de los datos de entrenamiento para proponer grupos de variables, determinar cuánto contexto temporal procesará cada rama y seleccionar los modelos que compondrán sus extractores. La selección considerará las características de los datos, los requisitos de la tarea, el desempeño en validación y los recursos disponibles. Las distintas ramas podrán utilizar modelos diferentes.

Cada extractor contará con un detector de patrones como módulo separado y con componentes configurables de integración temporal y adaptación de salida. Estos dos últimos podrán implementarse por separado o conjuntamente; cuando alguna función no sea necesaria, podrá dejar la señal sin cambios. El detector podrá entrenarse desde cero o preentrenarse externamente, importar o exportar sus pesos y mantenerse fijo o continuar ajustándose con el modelo completo. Se comparará el comportamiento de estas configuraciones. La Figura 2 muestra la estructura de los extractores.

El estudio combinará tareas de pronóstico y aprendizaje por refuerzo con series temporales multivariadas seleccionadas de la literatura por su pertinencia y por disponer de resultados y protocolos de comparación. Se incluirán líneas base sencillas, como el pronóstico ingenuo y una estrategia trivial de trading; modelos estadísticos multivariados y otros modelos publicados; y modelos sin el diseño de representación temporal modular. También se realizarán controles para distinguir el efecto de organizar las ramas mediante las propiedades de los datos. Se controlarán la información de entrada, el preprocesamiento, el entrenamiento y los recursos.

La representación se integrará en las plataformas existentes de pronóstico y aprendizaje por refuerzo para realizar los experimentos. Las configuraciones y métricas se registrarán mediante la infraestructura disponible y se organizarán en un cubo de procesamiento analítico en línea (OLAP) para facilitar el análisis. El resultado esperado es un método reproducible y una caracterización de con qué configuraciones y procedimientos mejora el desempeño, lo mantiene en un nivel equivalente o lo empeora. Si la evidencia es insuficiente para decidir, el resultado se declarará inconcluso.

1. Problema y motivación

El aprendizaje de representaciones transforma las observaciones en características que facilitan una tarea, como pronosticar valores o seleccionar acciones [1, 2]. En series temporales, diseñar esa transformación exige decidir cuánto pasado proporcionar, cómo agrupar las variables, qué resolución temporal conservar y en qué etapa combinar la información. Estas decisiones están relacionadas: una capa puede reconocer patrones breves y otra integrar un contexto mayor; resumir cada variable demasiado pronto puede ocultar relaciones que aparecen con retraso entre ellas.

Una representación uniforme puede resultar insuficiente cuando las variables cambian a ritmos distintos. Explorar muchas combinaciones de ventanas y arquitecturas permite adaptarlas, pero consume recursos y aumenta el riesgo de escoger una configuración demasiado ajustada a los datos de validación [3]. La pregunta es si un análisis previo de las propiedades temporales permite orientar la selección y configuración de los modelos y mejorar su desempeño en el conjunto de prueba reservado.

El proyecto parte de experiencia con sistemas de pronóstico y RL para trading. En ellos se han probado extractores modulares, distintas formas de combinar sus salidas y codificadores preentrenados. La necesidad práctica es organizar mejor esas decisiones y mejorar las representaciones que reciben los modelos del sistema. Las tareas propuestas permitirán comparar resultados con la literatura, y la integración en las plataformas existentes permitirá evaluar su utilidad financiera. Se utilizarán tanto líneas base sencillas como modelos sin procesamiento diferenciado por ramas.

Pregunta de investigación. ¿En qué condiciones agrupar variables en ramas según sus propiedades temporales y adaptar el contexto que procesa cada rama mejora el desempeño de un modelo de pronóstico o RL en datos reservados, frente a un modelo que no utilice este procesamiento diferenciado por rama, con información, entrenamiento y recursos comparables?

La pregunta se responderá con evaluaciones específicas de pronóstico y de RL. En trading se comparará el agente con una estrategia trivial y con una variante del mismo algoritmo que no utilice la representación modular propuesta. La primera comparación medirá utilidad frente a una referencia sencilla; la segunda permitirá atribuir las diferencias al diseño de representación. Los resultados de pronóstico y de RL se presentarán con sus métricas respectivas, sin suponer que una mejora predictiva implica una mejora de decisión.

2. Fundamentos y trabajos relacionados

2.1. Representación temporal y componentes del modelo

Una *ventana de entrada* es el segmento histórico que se entrega al modelo. Se representará por $X_{1:L} \in \mathbb{R}^{L \times p}$, donde L es el número de instantes y p el de variables. El *campo receptivo de una activación* es la parte de esa entrada que puede influir en una salida concreta de una capa. Por ejemplo, una ventana puede contener 144 observaciones mientras una activación de la primera capa utiliza solo tres. Las capas posteriores pueden ampliar ese alcance. Cuando se hable del campo receptivo de una rama, se hará referencia al de sus activaciones de salida, medido respecto de la entrada original.

El bloque de representación realiza una transformación aprendida $Z = f_{\theta}(X)$, donde θ contiene los pesos ajustados durante el entrenamiento y Z es la secuencia de características que utilizarán las capas siguientes. En la arquitectura modular, las variables se distribuyen en B grupos, $G_1, \dots, G_B$. Cada rama contiene un detector de patrones D_j como módulo separado, un componente de integración temporal I_j y una adaptación de salida A_j :

$$Z_j = A_j(I_j(D_j(X_{:,G_j}))) \in \mathbb{R}^{L_j \times c_j}. \quad (1)$$

Aquí $X_{:,G_j}$ contiene las variables del grupo j , L_j es la longitud de la secuencia producida y c_j el número de características por instante, también llamadas *canales*. El detector D_j tendrá una interfaz independiente para entrenarlo, guardar sus pesos y reutilizarlo. I_j y A_j serán configurables y podrán implementarse separados o en un componente conjunto; si alguna función no requiere una transformación, se representará mediante la identidad. La ecuación describe esa composición funcional y no exige que integración y adaptación sean siempre redes independientes.

Antes de combinar las ramas, el consolidador establecerá qué instantes corresponden entre sus salidas y concatenará las características. Si una rama reduce su resolución temporal, L_j podrá ser distinto de L y será necesario especificar esa correspondencia. El núcleo temporal procesará la secuencia conjunta; el cabezal de pronóstico producirá $\hat{Y}_{L+1:L+H}$, las predicciones de los siguientes H pasos. En aprendizaje por refuerzo, las salidas se adaptarán al algoritmo de selección de acciones o estimación de valor. Cada aplicación utilizará un modelo entrenado para su objetivo.

2.2. Propiedades temporales para orientar el diseño

Una *escala temporal* describe la duración de un patrón o una dependencia: por ejemplo, el período de una oscilación o cuánto tarda en disminuir la semejanza entre una señal y sus valores pasados. El *perfil temporal* reunirá medidas de esas propiedades para cada variable. Se calculará exclusivamente con sus datos de entrenamiento e incluirá decaimiento de autocorrelación, distribución de energía entre frecuencias, periodicidades dominantes y estabilidad de las estimaciones entre segmentos de la serie.

Estas medidas se expresarán en unidades comparables teniendo en cuenta la frecuencia de muestreo y la longitud histórica disponible. Las frecuencias se normalizarán respecto de la frecuencia de Nyquist, equivalente a la mitad de la frecuencia de muestreo. El escalado común de los perfiles se ajustará durante el desarrollo del procedimiento y se mantendrá fijo al evaluarlo, para conservar las diferencias entre conjuntos de datos.

El perfil de una variable describe su comportamiento individual. La semejanza entre perfiles puede orientar qué variables comparten una rama, pero no demuestra una relación causal ni una dependencia con retraso entre ellas. Estas últimas se examinarán mediante un análisis separado. Tampoco se supondrá que una periodicidad observada determina por sí sola el campo receptivo óptimo: esa relación es parte de lo que se evaluará. Las señales sintéticas permitirán comprobar si los perfiles recuperan propiedades conocidas; los conjuntos públicos permitirán estudiar si esas propiedades ayudan a pronosticar.

2.3. Modelos de referencia

DLinear mostró que un modelo lineal sencillo puede superar arquitecturas más complejas en varios conjuntos de pronóstico [4]. PatchTST divide la historia en segmentos o *parches* y procesa las variables de manera independiente [5]. iTransformer representa cada variable como una unidad de entrada del mecanismo de atención para aprender relaciones entre ellas [6]. Estos trabajos justifican comparar el método tanto con referencias sencillas como con modelos que procesan las variables por separado o conjuntamente.

Varios métodos incorporan múltiples escalas. TimesNet organiza variaciones periódicas en representaciones bidimensionales [7]; MTST utiliza ramas con distintas resoluciones de parche [8]; Pathformer aprende rutas entre escalas [9]; y TimeMixer combina componentes en resoluciones finas y gruesas [10]. MSGNet aprende relaciones entre variables que dependen de la escala [11]. CCM aprende grupos de variables mediante asignaciones y prototipos regularizados por similitud [12]; DUET combina agrupación temporal con pertenencias graduadas de las variables a grupos [13]. Leddam y CATS estudian otras formas de representar dependencias entre series [14, 15]. Por tanto, la presencia de ramas, agrupaciones o múltiples escalas ya tiene antecedentes directos.

También existen representaciones aprendidas que aprovechan propiedades de las señales. CoST separa tendencia y estacionalidad mediante aprendizaje contrastivo [16], mientras BTSF combina información temporal y espectral [17]. En audio, SincNet y LEAF incorporan operaciones de procesamiento de señales cuyos parámetros se aprenden con la tarea [18, 19]. Sin embargo, EfficientLEAF encontró que sus extractores aprendibles no superaban consistentemente un banco de filtros fijo en las tareas evaluadas [20]. Estos antecedentes motivan el diseño basado en propiedades de señales y, a la vez, la necesidad de comprobar su utilidad frente a alternativas sencillas.

2.4. Diferencia que estudiará la propuesta

FFORMA utiliza características de una serie para ponderar modelos completos de pronóstico [21]. EMTSF busca mediante evolución combinaciones de módulos espaciales y temporales [22]. REP-Net divide el procesamiento en representación, extracción y proyección y evalúa configuraciones de esas etapas [23]. DUET es un comparador especialmente cercano porque aborda tanto diferencias temporales como relaciones entre variables.

La contribución propuesta es estudiar si las propiedades temporales permiten orientar conjuntamente la agrupación de variables, el contexto de las ramas y la selección de los modelos de sus extractores. También se evaluará si el procedimiento es útil en conjuntos distintos de los utilizados para desarrollarlo. Para ello se distinguirán *familias de datos*: conjuntos relacionados por su fuente y dominio, cuyas variantes no se tratarán como evidencia independiente. En cada tarea reservada se calcularán perfiles y se seleccionarán y entrenarán modelos con sus datos de entrenamiento y validación. Se mantendrán fijos el procedimiento de selección, las alternativas admisibles y los criterios de evaluación establecidos durante el desarrollo.

La revisión inicial no identificó un método que combine esa regla previa de diseño con una evaluación entre familias reservadas y controles de capacidad, entrenamiento y costo. Esta diferencia deberá verificarse mediante la revisión sistemática del primer semestre. Si se encuentra un método equivalente, se incorporará como referencia y se delimitará la contribución antes de realizar la evaluación final.

El preentrenamiento por capas de autoencoders y la reconstrucción de valores ocultos en series temporales son antecedentes de las modalidades de entrenamiento [24, 25]. El sistema existente permite exportar por separado codificadores y decodificadores y configurar el reajuste de extractores [26, 27]. Esa experiencia facilita la implementación. La conexión del modelo completo se verificará comprobando que la señal de aprendizaje llega a los componentes que deben ajustarse y que sus pesos se actualizan.

3. Objetivos e hipótesis

3.1. Objetivo general

Desarrollar y evaluar un procedimiento basado en las propiedades temporales de los datos para agrupar variables, seleccionar y configurar los modelos de cada rama y aprender una representación temporal modular, comprobando su desempeño en pronóstico y aprendizaje por refuerzo frente a líneas base y modelos sin ese procesamiento diferenciado, con información, entrenamiento y recursos comparables.

3.2. Objetivos específicos

1. Definir los componentes y las interfaces de la representación modular, y estimar propiedades temporales que orienten la agrupación de variables y el contexto de cada rama.
2. Construir un procedimiento reproducible para agrupar variables, seleccionar los modelos adecuados para cada rama y configurar su contexto temporal, integración y adaptación, con entrenamiento desde cero o con detectores preentrenados fijos o ajustables.

3. Comparar el procedimiento con modelos de la literatura y variantes controladas de su arquitectura en tareas públicas reservadas, midiendo error, costo, estabilidad y condiciones de fallo.
4. Integrar la representación en las plataformas existentes de pronóstico y RL, registrar las configuraciones y métricas en la infraestructura analítica y evaluar la aplicación financiera frente a una estrategia trivial, la representación actual y una variante sin el procesamiento modular propuesto.

3.3. Hipótesis y forma de contrastarlas

La evaluación principal de pronóstico se realizará mediante H1. H2 estudiará el mecanismo de agrupación y H3 la conservación de las secuencias hasta combinar las ramas, principalmente con señales sintéticas de estructura conocida. La parte de la pregunta correspondiente a RL se responderá con una evaluación aplicada propia, usando métricas de decisión y desempeño financiero. Los análisis de pronóstico y RL se informarán por separado.

El desarrollo del procedimiento se denominará E1 y su evaluación en familias públicas reservadas, E2. E0 comprende la generación de señales sintéticas, con datos separados para desarrollo y prueba. E3 corresponde a la aplicación financiera en aprendizaje por refuerzo. La sección de fases experimentales detalla cada una.

La unidad principal de evaluación será una *tarea de pronóstico*, definida por un conjunto de datos, unas variables objetivo y un horizonte. Una misma tarea se repetirá desde distintos puntos de inicio del pronóstico, llamados *orígenes de evaluación*, y con distintas *semillas aleatorias*, que controlan la aleatoriedad del entrenamiento. Estas repeticiones no se contarán como tareas independientes.

Se utilizará el error absoluto medio escalado (MASE): el error de pronóstico dividido por un error de referencia calculado con entrenamiento. La sección 5.3 define su fórmula. Cada variable y origen tendrán un denominador propio, compartido por todos los métodos; si alguno es nulo, la tarea se informará aparte y no se usará para H1. Se promediarán los errores escalados con igual peso entre variables objetivo, pasos del horizonte, orígenes y semillas. Para cada tarea t se calculará

$$\Delta_t = \text{MASE}_{t,\text{método}} - \text{MASE}_{t,\text{control}} \quad (2)$$

Un valor negativo favorece al método propuesto. El efecto global Δ dará igual peso a las tareas de cada conjunto, a los conjuntos de cada familia y a las familias. Así, una fuente que aporte muchas series no dominará el resultado. La estimación de incertidumbre conservará las comparaciones de métodos sobre las mismas tareas y la dependencia entre objetivos y horizontes de una fuente.

Antes de E2 se fijarán las F familias de evaluación, un margen de relevancia práctica $\varepsilon > 0$ y el nivel de error estadístico $\alpha = 0.05$. El margen expresará qué diferencia de MASE se considera relevante. El piloto comprobará si la cantidad de datos permite estimarla con precisión suficiente. Se evaluarán $K = F + 4$ efectos: el global y los F efectos por familia de H1, la pendiente de H2 y los dos contrastes de H3. Cada efecto tendrá un intervalo bilateral con cobertura nominal $1 - \alpha/K$, aplicando el ajuste de Bonferroni y el remuestreo de la sección 5.3. La cobertura y estabilidad de esos intervalos se comprobarán mediante simulación; si los datos o las simulaciones no permiten sostener su precisión, el resultado afectado se declarará inconcluso.

H1 • Utilidad de organizar las ramas mediante perfiles temporales. En familias públicas reservadas, el método reducirá el MASE frente al control principal seleccionado durante E1 entre un modelo sin procesamiento diferenciado por ramas y un modelo modular organizado sin utilizar los perfiles temporales. La selección de los modelos de esos controles se realizará con criterios y presupuestos comparables a los de la propuesta. Se elegirá como control principal la alternativa con menor MASE agregado en E1, siguiendo la misma ponderación por tareas, conjuntos y familias. El procedimiento que selecciona sus configuraciones con entrenamiento y validación se fijará antes de E2. Se utilizarán las mismas entradas, modalidad de entrenamiento y presupuesto de ajuste. H1 se considerará respaldada si el límite superior del intervalo de Δ es menor que $-\varepsilon$ y el límite superior de cada efecto por familia es menor o igual que ε . Esto exige una mejora relevante global y ausencia de un empeoramiento mayor que el margen en cada familia. Si una familia no puede evaluarse con precisión suficiente, no se afirmará ese resultado conjunto.

H2 • Utilidad de la agrupación cuando las escalas son distintas. La ventaja del diseño basado en perfiles frente a una asignación permutada aumentará con la heterogeneidad de las escalas temporales. La permutación cambiará qué variables se asignan a los grupos, conservando las características de la arquitectura. El experimento sintético variará un nivel conocido de heterogeneidad h , manteniendo constantes el tamaño de muestra, el número de variables y la

distribución del ruido. Se definirá

$$e(h) = \text{MASE}(\text{perfiles}, h) - \text{MASE}(\text{permutación}, h).$$

H2 se considerará respaldada si el límite superior del intervalo de la pendiente β de $e(h)$ respecto de h es menor que cero. Una pendiente negativa indicará que la ventaja relativa crece con la heterogeneidad, aunque por sí sola no demostrará que el método sea mejor en todos sus niveles. En datos públicos se explorará la relación entre esa diferencia de desempeño y la heterogeneidad estimada de los perfiles, definida como $q(X)$ en la sección 4.2; este análisis complementario no sustituirá el experimento con estructura conocida.

H3 • Conservación de las secuencias hasta combinar las ramas. Cuando existan relaciones conocidas con retraso entre variables, combinar las secuencias alineadas antes de resumirlas reducirá el error frente a resumir cada rama por separado antes de combinarla. Las dos variantes recibirán las mismas activaciones de un extractor entrenado con un procedimiento fijado durante E1 y mantenido sin cambios durante este contraste. Solo se ajustarán los módulos que combinan las ramas y los cabezales. Se definirá

$$d_r = \text{MASE}(\text{fusión temporal}, r) - \text{MASE}(\text{resumen temprano}, r), \quad \gamma = d_1 - d_0,$$

donde $r = 1$ indica dependencia entre variables con retraso y $r = 0$ un control que conserva el comportamiento temporal de cada variable, pero elimina esa dependencia. H3 requerirá que el límite superior del intervalo de d_1 sea menor que $-\varepsilon$ y el de γ menor que cero. Se medirá la memoria adicional necesaria para conservar las secuencias. En datos públicos se realizará un análisis complementario sobre tareas donde un diagnóstico separado, calculado con entrenamiento, identifique relaciones predictivas entre variables con retraso.

4. Método

4.1. Organización del trabajo con CRISP-DM

Se utilizará CRISP-DM para organizar el trabajo en comprensión del problema, comprensión de los datos, preparación, modelado, evaluación e integración en las plataformas [28]. La comprensión del problema establecerá la tarea, los objetivos y las restricciones del sistema; el análisis de datos determinará sus propiedades y calidad; la preparación definirá entradas y transformaciones compatibles. El modelado incluirá la selección de técnicas y la configuración de los componentes. El proceso permitirá revisar decisiones durante el desarrollo. Antes de la prueba reservada quedarán fijados el procedimiento, sus alternativas y los criterios de evaluación.

La selección de modelos partirá del análisis de los datos y de las necesidades del sistema. Para cada grupo de variables se estudiarán las arquitecturas que puedan aprovechar su estructura temporal y producir salidas compatibles con el consolidador. Entrenamiento y validación permitirán comparar las alternativas antes de elegir la configuración que se evaluará en prueba.

4.2. Preparación de datos y construcción de las ramas

Cada conjunto se documentará con su fuente, frecuencia de muestreo, zona horaria cuando corresponda, variables, objetivos y momento en que cada dato está disponible. La normalización, la imputación de valores ausentes y el cálculo de perfiles se ajustarán únicamente con entrenamiento. En cada decisión se utilizará solo información disponible hasta ese instante. Una transformación que procese una ventana histórica completa será admisible si no utiliza observaciones posteriores al momento que se intenta pronosticar y todos los comparadores tienen acceso a la misma información original.

En los experimentos controlados se utilizará la misma información de entrada y el mismo preprocesamiento común. Cuando un modelo requiera un formato específico, se documentará la adaptación sin añadir información no disponible para sus controles. Para cada variable i se calculará un perfil d_i y su estabilidad entre segmentos de entrenamiento. Los retardos y frecuencias se expresarán en coordenadas comparables. Cada componente se escalará mediante estadísticas robustas ajustadas en E1 y fijadas antes de E2; $\tilde{d}_i$ denotará el perfil escalado. Se resumirá la heterogeneidad mediante la mediana de las distancias entre pares de perfiles:

$$q(X) = \text{mediana}_{i < k} \|\tilde{d}_i - \tilde{d}_k\|_2. \quad (3)$$

Esta medida expresa diferencias entre los perfiles utilizados por el procedimiento; no se interpretará como una medida de dificultad de pronóstico o causalidad.

El análisis basado en perfiles propondrá una agrupación G , los contextos temporales R y las alternativas de modelos admisibles para cada rama, reunidas en $\mathcal{M}$. Con parámetros de diseño η , esta etapa se expresará como

$$(G, R, \mathcal{M}) = A_\eta(\tilde{d}_1, \dots, \tilde{d}_p). \quad (4)$$

El agrupamiento jerárquico será un punto de partida para reunir perfiles semejantes, no una decisión inmodificable para todas las tareas. Durante E1 se definirán el número máximo de ramas, los criterios de agrupación, los contextos temporales admisibles y el catálogo de modelos. La selección final entre candidatos se realizará mediante entrenamiento y validación, evaluando su integración en el modelo completo. En E2 podrán resultar arquitecturas distintas para distintas tareas y ramas; permanecerán fijos los criterios y el presupuesto con los que se eligen, y la prueba no participará en esa elección.

Si el perfil de una variable es inestable, se asignará a una rama común y se registrará que no fue posible justificar una especialización con esos datos. Para H3 se estimarán por separado relaciones predictivas entre variables con distintos retardos. Ese diagnóstico utilizará solo entrenamiento y no modificará la regla A_η durante E2.

4.3. Selección de modelos, arquitectura y entrenamiento

La selección considerará modelos convolucionales temporales, recurrentes, basados en atención y combinaciones de ellos. No se fijará por defecto un mismo modelo para todas las ramas. Para cada alternativa se examinarán el tipo y cantidad de datos, las escalas temporales, la longitud de contexto, las relaciones entre variables, la posibilidad de preentrenamiento y la compatibilidad con las etapas posteriores. El catálogo concreto y sus rangos de configuración se justificarán mediante literatura e implementaciones reproducibles durante E1.

Las convoluciones temporales permitirán configurar el alcance mediante profundidad, tamaño de filtro y dilatación [29]. En modelos recurrentes se declararán la historia accesible y el tratamiento de sus estados; en atención, la longitud de secuencia y las restricciones de acceso temporal. En todos los casos se verificará qué observaciones puede utilizar cada salida y se conservará una secuencia de características compatible con el resto del sistema.

El detector D_j será un módulo separado, con interfaz para entrenamiento externo, importación y exportación de pesos. El integrador I_j combinará información temporal cuando el detector no proporcione por sí solo el contexto requerido. La adaptación A_j ajustará, cuando sea necesario, dimensiones y correspondencia temporal. Se configurarán y compararán versiones con I_j y A_j separados o integrados; cualquiera podrá ser la identidad si su transformación no es necesaria. Si cambia la resolución temporal, se especificarán las marcas de tiempo, la alineación y su costo antes de evaluar.

La selección se realizará con el objetivo final del sistema. Cuando se utilice un autoencoder, la calidad de reconstrucción permitirá examinar el preentrenamiento, pero la elección para pronóstico o RL se comprobará con validación de la tarea correspondiente. Se conservarán las configuraciones y los resultados de los candidatos, incluidas las alternativas descartadas. DOIN y sus herramientas de optimización se utilizarán para ajustar los parámetros y decisiones estructurales que requieran búsqueda, después del análisis de datos y modelos.

El consolidador alineará las secuencias y concatenará sus características en cada instante. El núcleo temporal procesará la representación conjunta y podrá reducir su número de características conservando la secuencia. Para pronóstico, un cabezal transformará el último estado del núcleo en predicciones de los siguientes H pasos. En aprendizaje por refuerzo, una instancia de esta arquitectura alimentará las salidas que requiera el algoritmo. Cuando existan actor y crítico —componentes que seleccionan acciones y estiman su valor, respectivamente— se declarará si utilizan una representación compartida o representaciones separadas.

La Figura 2 muestra el detector separado y las funciones configurables de integración y adaptación. Cada componente podrá contener varias capas; sus tipos, tamaños, repeticiones y conexiones formarán parte de la configuración del extractor.

Se compararán tres modalidades de entrenamiento, identificadas como R0, R1 y R2 para facilitar su seguimiento en los experimentos:




Figura 2: Arquitectura conceptual. Las líneas discontinuas representan propuestas de diseño obtenidas del análisis de entrenamiento; la selección final de modelos utiliza validación. Las líneas continuas muestran el flujo de datos. Cada rama recibe las variables de su grupo. D_j es el detector separado; I_j y A_j representan la integración y la adaptación configurables, que podrán combinarse o actuar como identidad. El bloque de alineación y fusión reúne las funciones del consolidador y el núcleo temporal de la Figura 1. Fuente: elaboración propia.

Tabla 1: Inicialización y entrenamiento de los detectores.

Modo	Pesos iniciales del detector	Entrenamiento del modelo completo
R0	Inicialización aleatoria.	Detector y resto del modelo se ajustan juntos.
R1	Codificador preentrenado.	El detector se mantiene fijo; se ajusta el resto.
R2	El mismo codificador preentrenado que en R1.	Detector y resto del modelo continúan ajustándose.

El preentrenamiento utilizará un autoencoder: el codificador aprenderá una representación y un decodificador auxiliar reconstruirá la entrada o unos valores ocultos mediante una máscara definida previamente. La reconstrucción ordinaria no se interpretará por sí sola como eliminación de ruido. Se conservarán el codificador y el decodificador entrenados, así como una copia separada de los pesos modificados durante el ajuste posterior.

La implementación se comprobará con pruebas de actualización de parámetros. En R1, los pesos del detector deberán permanecer fijos. En R2, se verificará que los gradientes del objetivo final lleguen al detector y modifiquen sus pesos; también se especificará cómo se tratan estados que no se actualizan mediante gradientes. Si se entrena el resto del modelo sobre características guardadas en un archivo, se considerará extracción fija, porque ese procedimiento no actualiza el codificador [30].

Las tres modalidades se examinarán durante E1. Una de ellas se elegirá y fijará antes de E2 para el contraste principal de H1, aplicándola de la misma manera al método y a sus controles. Esto permite comparar la organización de las ramas sin dar al método una ventaja de preentrenamiento que no tengan los controles. H3 tendrá su propio contraste con un extractor común y fijo: una variante conservará las secuencias hasta combinarlas y la otra resumirá primero cada rama. Se entrenarán sus módulos de combinación y sus cabezales con presupuestos comparables.

Antes de entrenar se comprobarán disponibilidad de datos, correspondencia temporal, dimensiones y memoria requerida. Durante E1 se estudiarán los tipos de modelos, sus configuraciones y sus combinaciones dentro de las ramas. Los controles dispondrán de alternativas compatibles y presupuestos de selección comparables. Las decisiones y rangos de búsqueda quedarán fijados antes de la evaluación reservada. Si el presupuesto exige reducir alternativas, se priorizarán mediante el análisis de datos, las implementaciones disponibles y los resultados de desarrollo, manteniendo la selección de modelos como parte del procedimiento.

La Figura 3 distingue las decisiones que se fijan durante el desarrollo de los pesos y perfiles que se aprenden con los datos de cada tarea.




Figura 3: Separación entre desarrollo y evaluación. Las decisiones generales se fijan con los datos de desarrollo. En cada tarea nueva, los perfiles se estiman y los pesos se entrenan con el segmento de entrenamiento; la validación selecciona configuraciones y puntos de parada. Los datos de prueba se reservan para evaluar el procedimiento ya definido. Fuente: elaboración propia.

4.4. Fases experimentales

El estudio separará el desarrollo del procedimiento, las pruebas reservadas y la aplicación al sistema existente. La Tabla 2 resume el propósito de cada fase.

Tabla 2: Datos y propósito de las fases experimentales.

Fase	Datos	Propósito
E0	Señales sintéticas con estructura conocida.	Comprobar los perfiles y los mecanismos de H2 y H3, con señales separadas para desarrollo y prueba.
E1	Familias públicas de desarrollo.	Definir los criterios de agrupación y selección de modelos, las modalidades de entrenamiento, los comparadores y presupuestos; fijar márgenes de relevancia y comprobar precisión estadística.
E2	Familias públicas reservadas.	Contrastar H1 con el procedimiento ya fijado y estudiar su utilidad en tareas de distinto origen.
E3	Datos financieros históricos identificados y divididos de antemano.	Integrar la representación en el agente y compararla con la estrategia trivial y los controles de representación. Es una entrega obligatoria, con análisis separado de H1–H3.

Señales sintéticas. E0 combinará procesos autorregresivos, componentes periódicos, tendencias y eventos localizados. Para H2 se variará la separación entre escalas manteniendo constantes la cantidad de datos y el ruido. Para H3 se compararán procesos con relaciones entre variables a distintos retardos y controles contruidos con realizaciones independientes de esos procesos. Los controles deberán conservar, en distribución, el comportamiento temporal de cada variable, el tamaño de muestra y el ruido, eliminando la relación entre variables prevista por el generador. Esta propiedad se comprobará con repeticiones. Alterar el orden temporal de las muestras se reservará para pruebas de sensibilidad, porque también modifica el comportamiento individual de las series.

Se separarán generadores de desarrollo y una reserva sintética para H2 y H3. Las ecuaciones, los rangos y las semillas de esa reserva se fijarán antes de ajustar la regla; sus resultados no se consultarán hasta finalizar E1 y fijar perfiles, arquitectura, entrenamiento y contrastes. Se incluirán señales cuyas propiedades cambien en el tiempo y casos que incumplan los supuestos del diagnóstico, para observar cuándo deja de recuperar las escalas. En estos experimentos se conocerá el ruido añadido. Ese conocimiento no se extenderá a datos reales, donde no puede suponerse que todo residuo sea ruido.

Tareas públicas. Se examinarán conjuntos de energía, clima, tráfico y otros dominios recogidos en TFB, Monash y GIFT-Eval [31, 32, 33]. Para evaluar la agrupación, un conjunto deberá contener variables distintas observadas conjuntamente y permitir al menos dos agrupaciones de variables diferentes. También deberá tener frecuencia documentada, licencia compatible, historia suficiente para las divisiones de entrenamiento y evaluación, y denominadores de MASE no nulos en entrenamiento. Los conjuntos univariados podrán utilizarse para verificar implementaciones, pero no para probar la utilidad de agrupar variables.

Las familias, los horizontes y las divisiones temporales se fijarán antes de E2. Las variantes de una misma fuente se mantendrán en la misma familia; no se crearán familias independientes dividiendo aleatoriamente las ventanas de un conjunto. Esta separación permitirá estudiar la generalización del procedimiento, además de la evaluación habitual de cada modelo en su segmento de prueba. En las tareas reservadas se entrenarán modelos nuevos, aplicando la regla definida en E1 a sus propios datos de entrenamiento.

Aplicación al sistema de trading. Durante el desarrollo se elegirán una tarea financiera histórica y un algoritmo compatibles con la plataforma para E3. Se incluirá una estrategia trivial, definida antes de evaluar, como referencia básica de trading. Además se comparará el agente con la representación propuesta, con su representación actual y con una variante que no utilice procesamiento diferenciado por ramas; las dos últimas podrán coincidir si la arquitectura actual cumple esa condición. Estas variantes mantendrán constantes entorno, observaciones, recompensa, acciones, calendario y presupuesto de selección. Se verificarán la integración y la actualización de parámetros. La decisión de compartir representaciones entre actor y crítico dependerá del algoritmo [34]; se declarará también cómo se incorporan la posición y el estado de cuenta.

Se fijarán de antemano una medida principal de desempeño en RL, su margen de relevancia y las métricas financieras complementarias. Se utilizarán las mismas reglas contables, de costos y de ejecución para las variantes y la estrategia trivial. La comparación principal para responder la pregunta de investigación será la del agente con representación modular frente al agente sin ese procesamiento, manteniendo el algoritmo. Se estimarán diferencias e intervalos teniendo en cuenta semillas y períodos compartidos, y se declarará mejora, equivalencia, perjuicio o resultado inconcluso según el protocolo fijado antes de la prueba. La superioridad frente a la estrategia trivial será evidencia de utilidad, pero no bastará por sí sola para atribuir la mejora al diseño modular. Los resultados de E3 se informarán por separado de H1–H3 y no se mezclarán con MASE ni con su ajuste de multiplicidad.

TradeMaster y FinRL-Meta serán candidatos iniciales para localizar un experimento financiero publicado con datos, código y protocolo recuperables [35, 36]. Cuando se encuentre uno compatible, se incorporará la comparación y se documentarán las diferencias respecto del estudio original. Si no puede recuperarse, E3 se realizará de todas formas frente a la estrategia trivial y los controles del sistema definidos anteriormente y se informará la limitación de comparación externa. La integración en la plataforma de pronóstico se apoyará en los mismos componentes y experimentos de representación, evitando duplicar evaluaciones equivalentes.

5. Evaluación y análisis de resultados

5.1. Modelos de referencia y controles experimentales

Los comparadores se elegirán por la pregunta que permiten responder:

1. Como referencias básicas se utilizarán el pronóstico ingenuo y el estacional ingenuo, junto con una estrategia trivial de trading para RL, seleccionada antes de evaluar y compatible con el entorno. Se incorporará un modelo estadístico multivariado pertinente y reproducible; DLinear aportará además una referencia lineal aprendida.
2. PatchTST e iTransformer permitirán comparar estrategias de procesamiento independiente y conjunto de las variables.
3. DUET será un comparador obligatorio por su proximidad a la propuesta. Antes de examinar los resultados de E1 se elegirá además un método multiescala entre MTST, Pathformer y TimeMixer.
4. Se utilizarán modelos sin el procesamiento diferenciado por ramas como controles del diseño propuesto, con selección de arquitectura y ajuste bajo recursos comparables. Un control modular organizado sin perfiles permitirá separar el efecto de usar ramas del efecto de organizarlas mediante los datos.

5. Se realizarán *ablaciones*, es decir, comparaciones que alteran una decisión concreta: permutar la correspondencia entre variables y perfiles, usar un campo receptivo común o resumir las ramas antes de combinarlas.

El control permutado cambiará qué variables ocupan los grupos, conservando el número y tamaño de las ramas, los tipos de modelos seleccionados, los contextos temporales, las interfaces, los objetivos y el presupuesto. Solo se admitirán permutaciones compatibles con esas interfaces. Así se podrá estudiar la correspondencia entre datos y diseño sin atribuirle una diferencia debida a cambiar también los modelos disponibles. Se evitará permutar conjuntamente datos, objetivos y módulos de forma que solo cambien sus nombres. Las permutaciones y los desempates se fijarán antes de evaluar la reserva.

El método y sus controles arquitecturales utilizarán las mismas semillas, criterios de entrenamiento y límites de búsqueda. Sus catálogos de modelos serán comparables y sus restricciones se documentarán. El número de parámetros se igualará dentro de una tolerancia definida en el piloto cuando esa comparación sea viable; también se informarán tiempo, memoria y error para presupuestos comparables. Además del procedimiento completo, se realizarán comparaciones manteniendo fijos los tipos de modelos para distinguir la contribución de la agrupación, la selección de modelos y sus parámetros.

MSGNet o CCM podrá añadirse si su interfaz y costo permiten una comparación adecuada. El presupuesto se concentrará en los controles necesarios para responder las hipótesis; no se probarán todas las combinaciones de modelos, modalidades de entrenamiento y conjuntos disponibles.

5.2. Selección de datos y comparación con resultados publicados

Para cada conjunto candidato se localizará un resultado publicado pertinente, su tarea, las métricas y el protocolo experimental. Se comprobarán el acceso a datos y código, las divisiones de entrenamiento y prueba, y su compatibilidad con la separación entre familias. La selección se cerrará antes de ejecutar la evaluación reservada. El número de familias necesario se determinará con el inventario y el piloto de precisión estadística.

Antes de atribuir diferencias al método se reproducirá al menos un modelo de referencia. La tolerancia de reproducción se fijará según la precisión numérica y la variación entre ejecuciones, sin ajustarla después de conocer el resultado propio. Cada comparación se identificará como reproducción del estudio original, evaluación de métodos bajo un protocolo común adaptado o aplicación al sistema propio. Si cambian simultáneamente algoritmo, información o simulador, la diferencia se atribuirá al sistema completo; para aislar el efecto de la representación se mantendrán controles con información y actualización equivalentes.

Se identificarán archivos, versiones, fechas, instrumentos, frecuencia, variables y divisiones temporales, conservando copias o registros con huellas digitales de los archivos cuando sea posible. Compartir el nombre de un conjunto no demuestra que los datos sean idénticos. Las discrepancias entre artículo, suplemento y código se documentarán junto con la versión adoptada. En trading también se comprobarán momento y precio de ejecución, comisiones, deslizamiento, restricciones y contabilidad. Un protocolo que utilice información futura deberá corregirse para todos los métodos y se presentará como una adaptación.

H1 conservará MASE y su forma de agregación. Para comparar con cada publicación se añadirán sus métricas exactas, incluidas escala y forma de promediar los errores. Si el estudio original evalúa un modelo fijo y aquí se reentrena periódicamente, sus referencias se ejecutarán también bajo esa política; las cifras resultantes no se presentarán como reproducción directa de la tabla original. Una media publicada sin información suficiente sobre su variación no bastará para afirmar una diferencia estadísticamente significativa.

La lista detallada de comprobaciones y el inventario de candidatos se encuentran en el protocolo de comparabilidad y aplicación RL. Entre las comprobaciones pendientes figuran el tratamiento de la normalización en TradeMaster y la exposición previa del proyecto a los conjuntos candidatos.

5.3. Medidas de desempeño, incertidumbre y costo

El MASE expresa el error absoluto del modelo respecto de un error de referencia calculado con entrenamiento [37]. Para la variable objetivo k y el origen de evaluación o , sean n_o el número de observaciones de entrenamiento, m_k el

período estacional y H los pasos futuros evaluados. Se calcularán

$$a_{k,o} = \frac{1}{n_o - m_k} \sum_{u=m_k+1}^{n_o} |y_{k,u} - y_{k,u-m_k}|, \quad \text{MASE}_{k,o} = \frac{H^{-1} \sum_{h=1}^H |y_{k,n_o+h} - \hat{y}_{k,n_o+h}|}{a_{k,o}}. \quad (5)$$

El denominador $a_{k,o}$ es el error medio de repetir el valor de un período estacional anterior dentro del entrenamiento. Se compartirá entre todos los métodos y se promediarán después los errores escalados según la sección 3.3. El período m_k procederá de los metadatos o de una regla fijada en E1. Si algún denominador requerido es cero, la tarea se declarará no evaluable para H1 antes de examinar sus errores de prueba. Se informarán también el error absoluto medio (MAE), el error cuadrático medio (MSE), el desempeño por horizonte y la variación entre semillas; los errores en eventos específicos se medirán cuando esos eventos estén definidos previamente.

Los datos se dividirán cronológicamente y se evaluarán desde sucesivos orígenes, desplazando el punto de inicio del pronóstico según una política fijada de antemano [38]. Se usarán horizontes de prueba no solapados cuando la longitud disponible lo permita. Antes de cada origen se volverán a estimar perfiles y pesos solo con los datos entonces disponibles. Una observación ya evaluada podrá usarse en un entrenamiento posterior cuando haya pasado a formar parte del historial observable, con la misma política para todos los métodos. Los resultados de prueba no cambiarán la regla de diseño, los rangos de búsqueda ni los criterios de parada [3].

La incertidumbre se estimará mediante *bootstrap jerárquico*, un procedimiento que repite el análisis tomando muestras con reemplazo y conserva la estructura de los datos. Para el efecto global se remuestrearán familias, conjuntos y tareas; para un efecto por familia se mantendrá fija esa familia y se remuestrearán sus conjuntos y tareas. En H2 y H3 se remuestrearán configuraciones del generador y repeticiones, manteniendo juntas las variantes comparadas de cada experimento. Las semillas y los orígenes se agregarán dentro de cada tarea; si se remuestrean errores temporales, se usarán bloques contiguos para conservar su dependencia.

Los $K = F + 4$ intervalos definidos en la sección 3.3 aplicarán el ajuste de Bonferroni. Su cobertura y sensibilidad a la longitud de los bloques se estudiarán por simulación en E1, antes de examinar la evaluación final. Se publicarán efectos e intervalos por tarea y familia. El análisis complementario de H2 relacionará $q(X)$ con la diferencia de error entre la asignación basada en perfiles y su permutación.

El costo energético se medirá en vatios-hora (Wh) con un instrumento seleccionado y validado durante E1. Para tareas t , métodos m , semillas s y orígenes o , se contabilizará

$$C_{\text{total}} = \sum_{t,o} C_{\text{perfil},t,o} + \sum_{t,m,s,o} (C_{\text{pre}} + C_{\text{ajuste}} + C_{\text{eval}})_{t,m,s,o}. \quad (6)$$

Los términos corresponden al cálculo de perfiles, preentrenamiento, ajuste y evaluación. El ajuste incluirá todos los candidatos explorados, la selección por validación, las paradas tempranas y los intentos fallidos que consuman recursos. El preentrenamiento incluirá el decodificador. Si se reutiliza un codificador, se distinguirán su costo inicial, el costo adicional de cada uso y el acumulado, indicando cómo se reparte el trabajo compartido.

Se reportarán por separado el tiempo transcurrido de cada ejecución, las horas de CPU y GPU, las operaciones estimadas y la memoria máxima, junto con hardware y cantidad de trabajos simultáneos. Las duraciones de trabajos paralelos no se sumarán como si fueran tiempo transcurrido; tampoco se confundirá memoria con energía. El costo de desarrollar el procedimiento en E1 se separará del de aplicarlo a una tarea nueva. Se comprobará así si una mejora justifica sus recursos y si puede atribuirse al diseño en lugar de a una mayor capacidad o búsqueda.

5.4. Interpretación de los resultados

El margen ε permitirá distinguir relevancia práctica de una diferencia pequeña. Para una diferencia de MASE cuyo signo negativo favorezca al método y cuyo intervalo ajustado sea $[L, U]$, se aplicarán estos criterios:

- **Beneficio relevante:** $U < -\varepsilon$.
- **Equivalencia práctica:** $[L, U] \subseteq [-\varepsilon, \varepsilon]$.
- **Perjuicio relevante:** $L > \varepsilon$.
- **Resultado inconcluso:** cualquier otro caso, porque el intervalo no permite decidir entre las categorías anteriores.

H1 exigirá beneficio global y no inferioridad por familia, expresada por $U_f \leq \varepsilon$. H2 se decidirá por $U_\beta < 0$, y H3 por $U_{d_1} < -\varepsilon$ junto con $U_\gamma < 0$. El margen de MASE no se aplicará a la pendiente de H2 ni sustituirá el criterio de interacción de H3. La ausencia de evidencia de mejora no se interpretará automáticamente como equivalencia.

Se estudiará la sensibilidad del resultado retirando cada conjunto por turnos, sin utilizar ese análisis como una segunda oportunidad para declarar significación. El piloto fijará el tamaño de evaluación necesario. Si la precisión prevista no puede alcanzarse, se informará el resultado como inconcluso; no se ampliarán los datos o modelos después de observar la prueba para intentar obtener un resultado favorable.

6. Viabilidad y plan de trabajo

6.1. Recursos e integración con el sistema existente

El proyecto dispone de cuatro GPU de distintas capacidades, CPU local y software para gestionar datos, preprocesar series, entrenar modelos y registrar experimentos. La planificación tendrá en cuenta que las cuatro GPU pueden no estar disponibles simultáneamente. La generación de señales y los diagnósticos que no requieran redes neuronales se ejecutarán en CPU; el costo del resto se medirá mediante pilotos representativos.

La implementación inicial comprobará el ensamblaje de los componentes, la actualización de pesos y las interfaces con las plataformas de pronóstico y RL. DOIN proporcionará la infraestructura de optimización y registro de experimentos. Las configuraciones, modelos, particiones, semillas, métricas y costos se identificarán en ese registro y se organizarán en el cubo OLAP existente para comparar resultados por tarea y componente. La optimización con las herramientas disponibles se aplicará a los parámetros y decisiones estructurales que requieran búsqueda, después de seleccionar las alternativas pertinentes mediante el análisis de datos y modelos.

Durante E1 se reducirá el número de configuraciones antes de reservar recursos para la evaluación final. Desde el piloto se asignará presupuesto a la integración y evaluación financiera E3. Si los recursos resultan insuficientes, se acotará esa evaluación durante el desarrollo a una tarea y un agente, manteniendo la estrategia trivial y la comparación de la propuesta con un modelo sin procesamiento diferenciado por ramas.

6.2. Cronograma de seis semestres

La Tabla 3 resume las actividades y entregas previstas para los seis semestres.

El alcance mínimo incluirá comprensión y preparación de datos, selección de modelos por rama, pruebas sintéticas, evaluación pública e integración evaluada en RL. Si es necesario reducir trabajo, se retirarán alternativas redundantes, comparadores opcionales y ampliaciones de activos o períodos. Se conservarán la selección justificada de modelos, la separación entre desarrollo y prueba, los controles del procesamiento modular y la medición completa de costos.

6.3. Riesgos y uso responsable de los datos

El principal riesgo científico es que las propiedades temporales estimadas no permitan anticipar una organización útil de las ramas. Los resultados de equivalencia o perjuicio delimitarán las condiciones en que el método no aporta una ventaja; los inconclusos mostrarán dónde falta evidencia. También puede ocurrir que los conjuntos disponibles no cubran suficiente variedad o que la regla funcione solo en ciertos dominios. La evaluación por familias permitirá examinar esas limitaciones.

Tabla 3: Plan de trabajo y entregas previstas.

Sem.	Trabajo principal	Entrega
1	Revisión sistemática, definición del método, inventario de datos y protocolos, y piloto de precisión y costo.	Protocolo inicial registrado; manuscrito de revisión o diseño.
2	Implementación de perfiles, selección de modelos y componentes; señales sintéticas de desarrollo y reserva definida; pruebas de gradientes e interfaces.	Software reproducible; pruebas de recuperación de escalas e integración.
3	Desarrollo E1; selección de modelos por rama, controles y entrenamiento; fijación de los protocolos E2 y E3.	Manuscrito metodológico; protocolos finales de evaluación.
4	Pruebas de H1 en E2 y de H2/H3 en la reserva sintética; comprobación de reproducibilidad.	Manuscrito principal con resultados y límites de interpretación.
5	Integración y evaluación E3 frente a la estrategia trivial y los controles de representación; comparación publicada cuando su protocolo sea recuperable.	Modelo y evaluación financiera; manuscrito aplicado si los resultados y el calendario lo permiten.
6	Análisis conjunto, réplica independiente, escritura de tesis y defensa.	Tesis, modelos, configuraciones y documentación reproducible.

La revisión sistemática puede identificar un método equivalente. En ese caso se incorporará como comparador y se precisará la pregunta antes de E2. El trabajo experimental seguirá siendo útil si permite identificar cuándo conviene emplear una alternativa más sencilla o menos costosa.

Los experimentos utilizarán datos públicos conforme a sus licencias y señales sintéticas. La evaluación financiera será histórica, sin intervenciones sobre usuarios. Se publicarán configuraciones, resultados desfavorables o inconclusos y consumo computacional para facilitar la reproducción y evitar repetir búsquedas sin evidencia de utilidad. Todo conjunto empleado en preentrenamiento se identificará junto con su posible solapamiento con la evaluación; una fuente utilizada para desarrollar el método o preentrenarlo no se presentará como completamente nueva.

7. Contribuciones esperadas

1. Un procedimiento basado en datos para agrupar variables, seleccionar los modelos de sus extractores y configurar el contexto temporal, la integración y la adaptación de sus ramas.
2. Evidencia sobre cómo las diferencias de escala y las relaciones entre variables con retraso afectan a la utilidad de esa organización y a la necesidad de conservar las secuencias hasta combinarlas.
3. Comparaciones que distingan el efecto de agrupar y procesar variables por ramas del efecto de seleccionar modelos, preentrenarlos o asignarles más recursos.
4. Un protocolo para evaluar el procedimiento en familias de datos reservadas, con modelos de referencia, estimación de incertidumbre y costos completos.
5. Una representación integrada en las plataformas existentes, con evaluación financiera frente a una estrategia trivial y modelos sin el diseño modular, y registro de configuraciones y métricas en el cubo OLAP.

La contribución se apoyará en la relación comprobada entre las propiedades de los datos, las decisiones de arquitectura y los resultados obtenidos. La evaluación permitirá determinar tanto dónde el procedimiento aporta una mejora como dónde resulta preferible una alternativa más sencilla.

Referencias

- [1] Y. Bengio, A. Courville y P. Vincent, «Representation Learning: A Review and New Perspectives», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, n.º 8, pp. 1798–1828, 2013. DOI: 10.1109/TPAMI.2013.50.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. <https://www.deeplearningbook.org/>.

- [3] G. C. Cawley y N. L. C. Talbot, «On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation», *Journal of Machine Learning Research*, vol. 11, n.º 70, pp. 2079–2107, 2010. <https://jmlr.org/papers/v11/cawley10a.html>.
- [4] A. Zeng et al., «Are Transformers Effective for Time Series Forecasting?», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 9, pp. 11121–11128, 2023. DOI: 10.1609/aaai.v37i9.26317.
- [5] Y. Nie et al., «A Time Series is Worth 64 Words: Long-term Forecasting with Transformers», *International Conference on Learning Representations*, 2023. <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=JePfAI8fah>.
- [7] H. Wu et al., «TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis», *International Conference on Learning Representations*, 2023. https://openreview.net/forum?id=ju_Uqw384Oq.
- [8] Y. Zhang et al., «Multi-resolution Time-Series Transformer for Long-term Forecasting», *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, vol. 238, pp. 4222–4230, 2024. <https://proceedings.mlr.press/v238/zhang24l.html>.
- [9] P. Chen et al., «Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=IJkOCMP2aW>.
- [10] S. Wang et al., «TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=7oLshfEIC2>.
- [11] W. Cai et al., «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, n.º 10, pp. 11141–11149, 2024. DOI: 10.1609/aaai.v38i10.28991.
- [12] J. Chen et al., «From Similarity to Superiority: Channel Clustering for Time Series Forecasting», *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-4152.
- [13] X. Qiu et al., «DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting», *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 1185–1196, 2025. DOI: 10.1145/3690624.3709325.
- [14] G. Yu et al., «Revitalizing Multivariate Time Series Forecasting: Learnable Decomposition with Inter-Series Dependencies and Intra-Series Variations Modeling», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 57818–57841, 2024. <https://proceedings.mlr.press/v235/yu24s.html>.
- [15] J. Lu et al., «CATS: Enhancing Multivariate Time Series Forecasting by Constructing Auxiliary Time Series as Exogenous Variables», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 32990–33006, 2024. <https://proceedings.mlr.press/v235/lu24d.html>.
- [16] G. Woo et al., «CoST: Contrastive Learning of Disentangled Seasonal-Trend Representations for Time Series Forecasting», *International Conference on Learning Representations*, 2022. <https://openreview.net/forum?id=PilZY3omXV2>.
- [17] L. Yang y S. Hong, «Unsupervised Time-Series Representation Learning with Iterative Bilinear Temporal-Spectral Fusion», *Proceedings of the 39th International Conference on Machine Learning*, vol. 162, pp. 25038–25054, 2022. <https://proceedings.mlr.press/v162/yang22e.html>.
- [18] M. Ravanelli y Y. Bengio, «Speaker Recognition from Raw Waveform with SincNet», *arXiv preprint arXiv:1808.00158*, 2018. DOI: 10.48550/arXiv.1808.00158.
- [19] N. Zeghidour et al., «LEAF: A Learnable Frontend for Audio Classification», *International Conference on Learning Representations*, 2021. <https://openreview.net/forum?id=jM76BCb6F9m>.
- [20] J. Schlüter y G. Gutenbrunner, «EfficientLEAF: A Faster Learnable Audio Frontend of Questionable Use», *arXiv preprint arXiv:2207.05508*, 2022. DOI: 10.48550/arXiv.2207.05508.
- [21] P. Montero-Manso et al., «FFORMA: Feature-based Forecast Model Averaging», *International Journal of Forecasting*, vol. 36, n.º 1, pp. 86–92, 2020. DOI: 10.1016/j.ijforecast.2019.02.011.
- [22] Z. Liang y Y. Sun, «Evolutionary Neural Architecture Search for Multivariate Time Series Forecasting», *Proceedings of the 15th Asian Conference on Machine Learning*, vol. 222, pp. 771–786, 2024. <https://proceedings.mlr.press/v222/liang24a.html>.

- [23] R. Leppich et al., «Decomposing the Time Series Forecasting Pipeline: A Modular Approach for Time Series Representation, Information Extraction, and Projection», *arXiv preprint arXiv:2507.05891*, 2025. DOI: 10.48550/arXiv.2507.05891.
- [24] Y. Bengio et al., «Greedy Layer-Wise Training of Deep Networks», *Advances in Neural Information Processing Systems*, vol. 19, 2007. https://proceedings.neurips.cc/paper_files/paper/2006/file/5da713a690c067105aeb2fae32403405-Paper.pdf.
- [25] Z. Li et al., «Ti-MAE: Self-Supervised Masked Time Series Autoencoders», *arXiv preprint arXiv:2301.08871*, 2023. DOI: 10.48550/arXiv.2301.08871.
- [26] H. Bastidas, «Gestor de autoencoder en `feature-extractor`», 2026. Inspección estática; commit `df86252`; consultado el 7 de septiembre de 2026. https://github.com/harveybc/feature-extractor/blob/df86252a174a1f5b9f77f4cb1bcb78fcdfe429e8/app/autoencoder_manager.py.
- [27] H. Bastidas, «Configuración de carga de extractor y `train_fe`», 2026. Configuración del repositorio, commit `20ec571`; consultada el 7 de septiembre de 2026. https://github.com/harveybc/predictor/blob/20ec57145b4ed3eb647eabe2b7591f35a3dbbf47/examples/config/phase_3_1/phase_3_1_cnn_25200_1h_config.json.
- [28] IBM, *IBM SPSS Modeler CRISP-DM Guide*, versión 19. Documentación de la metodología y de la selección de técnicas de modelado. https://www.ibm.com/docs/en/SS3RA7_19.0.0/pdf/ModelerCRISPDM.pdf.
- [29] S. Bai, J. Z. Kolter y V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling», *arXiv preprint arXiv:1803.01271*, 2018. DOI: 10.48550/arXiv.1803.01271.
- [30] Keras Team, «Transfer learning & fine-tuning», 2023. Documentación oficial; consultada el 7 de septiembre de 2026. https://keras.io/guides/transfer_learning/.
- [31] X. Qiu et al., «TFB: Towards Comprehensive and Fair Benchmarking of Time Series Forecasting Methods», *Proceedings of the VLDB Endowment*, vol. 17, n.º 9, pp. 2363–2377, 2024. DOI: 10.14778/3665844.3665863.
- [32] R. Godahewa et al., «Monash Time Series Forecasting Archive», *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2021. <https://openreview.net/forum?id=I0117rc0jcb>.
- [33] T. Aksu et al., «GIFT-Eval: A Benchmark for General Time Series Forecasting Model Evaluation», *arXiv preprint arXiv:2410.10393*, 2024. DOI: 10.48550/arXiv.2410.10393.
- [34] A. Raffin et al., «Stable-Baselines3: Reliable Reinforcement Learning Implementations», *Journal of Machine Learning Research*, vol. 22, n.º 268, pp. 1–8, 2021. <http://jmlr.org/papers/v22/20-1364.html>.
- [35] S. Sun et al., «TradeMaster: A Holistic Quantitative Trading Platform Empowered by Reinforcement Learning», *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/file/b8f6f7f2ba4137124ac976286eacb611-Paper-Datasets_and_Benchmarks.pdf.
- [36] X.-Y. Liu et al., «FinRL-Meta: Market Environments and Benchmarks for Data-Driven Financial Reinforcement Learning», *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*, 2022. https://papers.neurips.cc/paper_files/paper/2022/file/0bf54b80686d2c4dc0808c2e98d430f7-Paper-Datasets_and_Benchmarks.pdf.
- [37] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy», *International Journal of Forecasting*, vol. 22, n.º 4, pp. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.
- [38] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.a ed.. OTexts, 2021. Sección 5.10: evaluación con origen rodante. <https://otexts.com/fpp3/tscv.html>.