

Diseño de representaciones temporales modulares mediante procesamiento diferenciado de variables

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje de representaciones · series temporales · arquitectura modular · pronóstico multivariado · aprendizaje por refuerzo · generalización

Resumen

La *representación temporal* es la parte de una arquitectura para pronóstico o aprendizaje por refuerzo que transforma la información de una serie temporal multivariada de entrada en conocimiento usable por las capas de salida. Las series temporales multivariadas pueden reunir variables cuyos ritmos de cambio, periodicidades y relaciones son distintos. Algunos modelos de pronóstico y aprendizaje por refuerzo (RL) procesan todas las variables con la misma ventana y el mismo extractor de características; otros incorporan varias escalas temporales mediante una representación elegida de antemano o una búsqueda de configuraciones que puede ser costosa. Esta propuesta estudiará si las propiedades de los datos de entrenamiento permiten orientar las decisiones de diseño de la representación tanto para pronóstico como para RL.

Se diseñará la *representación temporal modular* mostrada en la Figura 1, formada por:

- *ramas* que procesan grupos de variables usando extractores de características configurados para cada grupo
- *módulo de fusión de características* que alinea y concatena las secuencias
- *núcleo* que combina la información y reduce dimensionalidad conservando el eje temporal
- *cabezales de salida* que se adaptan a la tarea: pronóstico para estimar valores o aprendizaje por refuerzo para seleccionar acciones y, según el algoritmo, estimar funciones de valor.




Figura 1. Representación temporal modular. Las ramas, numeradas de 1 a B , procesan grupos de variables, el módulo de fusión de características alinea y concatena sus secuencias, y el núcleo combina la información para los cabezales de salida.

El procedimiento analizará los datos de entrenamiento para proponer grupos de variables, contextos temporales y modelos adecuados para cada rama. Las alternativas se seleccionarán mediante validación de la tarea, considerando sus requisitos y los recursos disponibles.

Cada extractor tendrá un detector de patrones separado y componentes configurables de integración temporal y adaptación, que podrán combinarse u omitirse cuando no sean necesarios. El detector podrá entrenarse desde cero o importar pesos preentrenados, mantenerlos fijos o ajustarlos con el modelo completo.

Se evaluarán tareas de pronóstico y RL con series multivariadas y protocolos disponibles en la literatura. Se comparará la propuesta con referencias sencillas, modelos publicados y variantes sin el diseño modular, controlando entradas, entrenamiento y recursos.

La representación se integrará en plataformas existentes de pronóstico y RL. Sus configuraciones y métricas se registrarán en un cubo OLAP existente que permitirá organizar y facilitar el análisis y visualización de los resultados. Se espera obtener un método reproducible y determinar si el uso de la representación temporal modular basada en datos mejora el desempeño, lo mantiene en un nivel equivalente o lo empeora. La evidencia insuficiente se declarará inconclusa.

1. Definición del problema y justificación

Según Bengio et al. [1], el aprendizaje de representaciones transforma las observaciones en características que facilitan una tarea, como pronosticar valores o seleccionar acciones. En series temporales, diseñar esa transformación exige decidir cuánto pasado proporcionar, cómo agrupar las variables, qué resolución temporal conservar y en qué etapa combinar la información.

Una representación uniforme puede resultar insuficiente cuando las variables cambian a ritmos distintos. Explorar muchas combinaciones de ventanas y arquitecturas permite adaptarlas, pero consume recursos. Como muestran Cawley y Talbot [2], la selección también puede sobreajustarse a los datos utilizados para comparar configuraciones. La pregunta es si un análisis previo de las propiedades de los datos permite orientar la selección y configuración de los modelos y mejorar su desempeño en el conjunto de prueba reservado.

El proyecto parte de sistemas de pronóstico y RL para trading en los que se han probado extractores modulares y codificadores preentrenados. La necesidad práctica es orientar la selección y combinación de estos componentes mediante un análisis de los datos, y comprobar tanto su utilidad financiera como su desempeño frente a resultados de métodos publicados.

Pregunta de investigación. ¿En qué condiciones agrupar variables según sus propiedades y adaptar el procesamiento de cada rama a las características específicas de estos datos mejora el desempeño de un modelo de pronóstico o RL en datos reservados, frente a un modelo que no utilice este procesamiento diferenciado por rama, con datos, entrenamiento y recursos comparables?

La pregunta se responderá con evaluaciones separadas de pronóstico y RL, ya que una mejora predictiva no implica por sí sola mejores decisiones de trading.

2. Objetivos

2.1. Objetivo general

Desarrollar y evaluar un procedimiento que utilice las propiedades de los datos y los requisitos de la tarea para agrupar variables, seleccionar y configurar los extractores de cada rama y aprender una representación temporal modular. Se comprobará su desempeño en pronóstico y aprendizaje por refuerzo frente a líneas base y modelos sin ese procesamiento diferenciado, con información, entrenamiento y recursos comparables.

2.2. Objetivos específicos

1. Definir los componentes e interfaces de la representación e identificar propiedades de los datos que orienten la agrupación de variables y el procesamiento de cada rama.

2. Construir un procedimiento reproducible de diseño y selección de modelos, con entrenamiento desde cero o con detectores preentrenados, fijos o ajustables.
3. Comparar el procedimiento con métodos publicados y variantes controladas en tareas reservadas, midiendo desempeño, costo y variación de los resultados.
4. Integrar la representación en plataformas existentes de pronóstico y RL, registrar los experimentos y evaluar su aplicación financiera frente a una estrategia trivial, la representación actual y una variante sin el diseño modular propuesto.

3. Marco teórico y antecedentes

3.1. Representación temporal y componentes del modelo

Una *ventana de entrada* es el segmento histórico que recibe el modelo. Se denotará por $X \in \mathbb{R}^{L \times p}$, con L instantes y p variables. El *campo receptivo* de una activación es la parte de esa entrada que puede influir en ella. Una ventana puede contener 144 observaciones y una activación de la primera capa utilizar solo tres. Las capas siguientes pueden ampliar ese alcance, como ilustra la arquitectura de Bai et al. [3].

Las variables se distribuirán en B grupos. Cada rama j producirá una secuencia de características mediante un detector de patrones D_j , una integración temporal I_j y una adaptación A_j :

$$Z_j = A_j(I_j(D_j(X_{:,G_j}))) \in \mathbb{R}^{L_j \times c_j}. \quad (1)$$

G_j identifica las variables del grupo, L_j la longitud de la secuencia de salida y c_j sus características por instante, también llamadas canales. El detector será un módulo separado que podrá preentrenarse y reutilizarse. Integración y adaptación serán configurables: podrán implementarse juntas, separadas o como identidad cuando no se requiera alguna transformación. La Figura 2 muestra un ejemplo con capas de Keras.




Figura 2. Ejemplo de una rama con capas de Keras [4], [5]. Las dimensiones indican instantes por características, sin el lote. Las convoluciones usan paso y dilatación 1, con ReLU en el detector. La LSTM conserva la secuencia y el adaptador reduce las características por instante. Configuración ilustrativa con detector reutilizable.

El módulo de fusión alinearán las secuencias y concatenará sus características. Si las ramas tienen resoluciones distintas, se especificará a qué instante corresponde cada salida. El núcleo procesará la secuencia conjunta antes de los cabezales. Cada aplicación entrenará el modelo para su objetivo: pronóstico de valores futuros o aprendizaje de una política y, cuando corresponda, funciones de valor.

3.2. Propiedades de los datos que orientan el diseño

El análisis distinguirá cantidad y calidad de datos, distribución de valores, comportamiento temporal y relaciones entre variables. Hyndman y Athanasopoulos [6] describen características calculadas sobre series para resumir distintos aspectos de su comportamiento. Su función aquí será orientar decisiones concretas: las ausencias y la distribución condicionarán la preparación y compatibilidad de los modelos; las periodicidades y dependencias respecto del pasado ayudarán a proponer grupos y contextos.

Un *perfil temporal* reunirá, para cada variable, decaimiento de autocorrelación, distribución de energía entre frecuencias, periodicidades dominantes y estabilidad entre segmentos de entrenamiento. Una *escala temporal* será la duración de un patrón o dependencia. Los perfiles describirán estas propiedades, pero su semejanza no demostrará

causalidad ni relaciones entre variables con retraso; estas se examinarán por separado. Una periodicidad tampoco determina por sí sola el contexto más adecuado para la tarea.

3.3. Antecedentes y contribución propuesta

DLinear [7] mostró que un modelo lineal puede superar varios transformadores evaluados en pronóstico. PatchTST [8] procesa segmentos de cada variable con pesos compartidos entre variables; iTransformer [9] representa las variables como unidades de entrada de la atención para modelar sus relaciones. MTST [10] utiliza ramas de distintas resoluciones, Pathformer [11] adapta las rutas entre escalas y TimeMixer [12] combina componentes en varias resoluciones.

Otros trabajos abordan directamente la agrupación. MSGNet [13] aprende relaciones entre variables a distintas escalas. CCM [14] aprende asignaciones a grupos y representaciones de esos grupos. DGCformer [15] combina un autoencoder y convoluciones sobre grafos para agrupar variables antes de aplicar atención. DUET [16] combina extractores según distribuciones temporales y aprende relaciones entre canales en frecuencia para seleccionar conexiones mediante una máscara de atención. Por tanto, agrupar variables y usar varios extractores ya tiene antecedentes directos.

La adaptación del diseño también se ha estudiado desde otras perspectivas. FFORMA [17] utiliza características de las series para ponderar pronósticos de modelos completos; EMTSF [18] busca mediante evolución módulos de convolución espacial y temporal. REP-Net [19] estudia configuraciones de representación, extracción de información y proyección. Ma et al. [20] proponen en un preprint de 2026 actualizar grupos mediante el error de validación y volver a un modelo global cuando la especialización no mejora ese error.

El vínculo con procesamiento de señales tiene ejemplos como CoST [21], que aprende representaciones de tendencia y estacionalidad, y LEAF [22], que aprende un banco de filtros para audio. Sin embargo, EfficientLEAF [23] encontró que sus alternativas aprendibles no superaban consistentemente un banco mel fijo en seis tareas de audio. Estas evidencias motivan comparar las decisiones aprendidas con diseños sencillos, sin trasladar automáticamente resultados de audio a otras series.

La contribución que se evaluará es un procedimiento de diseño previo al entrenamiento final que conecte el diagnóstico de los datos con la agrupación, el contexto y la elección de extractores por rama, y conserve sus secuencias hasta la fusión. Se medirá el aporte de esas decisiones con controles de arquitectura, inicialización y recursos, tanto en pronóstico como en su integración en RL. La novedad se delimita en ese procedimiento y su evidencia experimental; no se atribuye a la modularidad, al agrupamiento o a la selección de modelos por separado.

El preentrenamiento mediante reconstrucción tiene antecedentes específicos para series temporales, como TiMAE [24]. El código del proyecto permite guardar codificadores y decodificadores por separado [25]; sus configuraciones contemplan cargar extractores y habilitar su ajuste [26]. El ensamblaje y la actualización conjunta de sus parámetros se comprobarán durante la implementación.

4. Metodología

El trabajo seguirá las seis etapas de CRISP-DM descritas en la guía de IBM [27]. La Tabla 1 resume su aplicación. Durante el desarrollo se podrán revisar decisiones; antes de la prueba final quedarán fijados los datos, las alternativas, los presupuestos y los criterios de evaluación.

Tabla 1. Aplicación de CRISP-DM al proyecto.

Etapa	Actividad	Entrega
Comprensión del problema	Definir tareas, entradas, salidas y restricciones de las plataformas.	Requisitos y criterios de comparación.
Comprensión de los datos	Inventariar fuentes y examinar calidad, distribución, patrones y relaciones.	Inventario y diagnóstico.
Preparación de los datos	Separar entrenamiento, validación y prueba; ajustar transformaciones y preparar entradas.	Particiones y transformaciones reproducibles.
Modelado	Proponer grupos y modelos por rama, configurar sus conexiones y entrenar.	Procedimiento y modelos seleccionados.
Evaluación	Contrastar hipótesis y medir desempeño, incertidumbre y costo.	Resultados y límites de interpretación.
Despliegue e integración	Conectar los módulos con las plataformas y registrar su evaluación y seguimiento.	Componentes reutilizables y evaluación financiera.

4.1. Comprensión del problema

Para pronóstico se definirán variables objetivo, horizontes y frecuencia de actualización. Para RL se especificarán observaciones, acciones, recompensa y condiciones de ejecución. Se documentarán las interfaces de las plataformas y los límites de tiempo y memoria. Estos requisitos determinarán qué modelos y formatos son admisibles; la validación permitirá elegir entre ellos.

Una predicción ingenua o una estrategia trivial de trading ofrecerán referencias básicas. Los modelos sin procesamiento diferenciado por ramas permitirán comprobar el aporte del diseño modular. El piloto establecerá los márgenes de mejora relevante y los recursos disponibles para las comparaciones.

4.2. Comprensión de los datos

Se utilizarán el inventario financiero existente y conjuntos públicos con protocolos publicados. TFB [28] será un punto de partida por reunir tareas y métodos de pronóstico de distintos dominios. Para evaluar agrupaciones se requerirán variables distintas observadas conjuntamente, frecuencia documentada e historia suficiente. Se registrarán versiones, fechas, licencias, datos ausentes y momento de disponibilidad de cada variable.

La comparación con la literatura conservará datos, particiones, objetivos, horizontes y métricas cuando se declare una reproducción directa. Se reproducirá al menos una referencia con una tolerancia fijada previamente a partir de su variación documentada o de ejecuciones de desarrollo. Si se adapta el protocolo, todos los métodos recibirán el mismo tratamiento y se identificará la adaptación.

En finanzas se comprobarán además instrumentos, precios de ejecución, comisiones, deslizamiento y restricciones. TradeMaster [29] y FinRL-Meta [30] ofrecen entornos y referencias para buscar experimentos compatibles. La comparación externa dependerá de recuperar sus datos y condiciones; la evaluación con controles propios se realizará en cualquier caso.

4.3. Preparación de los datos

Cada tarea tendrá entrenamiento, validación y prueba separados cronológicamente. Con entrenamiento se ajustarán transformaciones y pesos; con validación se elegirán configuraciones y puntos de parada; con prueba se evaluará el modelo seleccionado. Las transformaciones y descomposiciones usarán exclusivamente información disponible al producir cada entrada, considerando retrasos de publicación. Se documentarán fuentes ya utilizadas en desarrollo o preentrenamiento para evitar presentarlas como nuevas.

El diagnóstico de entrenamiento registrará cantidad de observaciones, distribución de valores y ausencias, además de los perfiles temporales d_t . Las primeras propiedades orientarán la preparación y las restricciones de los modelos; los perfiles propondrán grupos y contextos. Se comprobará su estabilidad entre segmentos y se analizarán por separado las relaciones entre variables con retraso. Las decisiones de diseño quedarán registradas junto con la propiedad que las motivó.

Los retardos tendrán unidades comparables y las frecuencias se expresarán respecto de Nyquist, la mitad de la frecuencia de muestreo. Un escalado robusto común, ajustado en desarrollo y después fijado, producirá los perfiles $\tilde{d}_i$. Su diferencia se resumirá como

$$q = \text{mediana}_{i < k} \|\tilde{d}_i - \tilde{d}_k\|_2. \quad (2)$$

q medirá diferencias entre perfiles temporales, no calidad de los datos ni dificultad de la tarea. Se conservarán marcas de tiempo y correspondencias entre las entradas y salidas de cada rama. Las adaptaciones de formato no aportarán información adicional respecto de los comparadores.

4.4. Modelado

El procedimiento combinará propuestas basadas en entrenamiento y selección mediante validación del modelo completo:

1. **Agrupar variables.** Se partirá de agrupamiento jerárquico de perfiles. Su estabilidad determinará si se mantiene la agrupación propuesta o se incluye una alternativa de procesamiento común.
2. **Elegir contexto y modelos candidatos.** Se considerarán convoluciones, recurrencia, atención e híbridos compatibles con los datos y la tarea. Las ramas podrán usar modelos distintos. El catálogo, sus rangos y el máximo de ramas se fijarán durante el desarrollo.
3. **Ensamblar y entrenar.** Se conectarán extractores, fusión, núcleo y cabezales, comprobando dimensiones, alineación y actualización de parámetros.
4. **Seleccionar el modelo completo.** Se evaluará el objetivo de pronóstico o RL. La búsqueda de hiperparámetros y estructura con DEAP en DOIN (nivel 2) se concentrará en alternativas que el diagnóstico no permita resolver, con presupuesto y parada temprana definidos para entrenamiento y búsqueda.

El diseño fijará profundidad, tamaños de filtros y dilatación en convoluciones; historia accesible y estados en recurrencia; y longitud de secuencia y acceso al pasado en atención. La modularidad permitirá optimizar el tipo de modelo de cada componente, sus capas y conexiones compatibles, junto con hiperparámetros de entrenamiento como la tasa de aprendizaje. Estas alternativas se compararán mediante validación del modelo completo. La integración añadirá contexto y la adaptación preparará dimensiones y alineación cuando sean necesarias. El núcleo combinará las secuencias antes del cabezal; su reducción de dimensionalidad conservará el eje temporal.




Figura 3. Arquitectura conceptual. Las líneas discontinuas muestran propuestas de diseño a partir de los datos de entrenamiento; la validación selecciona los modelos. Las continuas muestran el flujo de datos. Cada rama contiene un detector D_j separado e integración I_j y adaptación A_j configurables. El bloque de fusión y núcleo reúne esos dos componentes de la Figura 1.

El detector se entrenará mediante las modalidades de la Tabla 2. Para preentrenarlo, un autoencoder reconstruirá los valores originales a partir de entradas completas o parcialmente ocultas. Se reutilizará el codificador y se conservará el decodificador por separado. Reconstruir una señal no demostrará por sí solo eliminación de ruido.

Tabla 2. Inicialización y entrenamiento del detector.

Código	Modalidad	Entrenamiento
R0	Desde cero	Detector y resto del modelo se ajustan desde una inicialización aleatoria.
R1	Preentrenado y congelado	Se importan pesos y se mantiene fijo el detector; se entrena el resto.
R2	Preentrenado y ajustable	Se importan los mismos pesos iniciales de R1 y se ajustan con el modelo completo.

Se comprobará que el detector congelado conserve sus parámetros y que el ajustable reciba gradientes del objetivo final. Se especificará el tratamiento de estados de normalización que se actualicen sin gradientes, siguiendo las distinciones de la guía de Keras [31]. La comparación principal usará una modalidad elegida en desarrollo y aplicada por igual al método y sus controles. En cada tarea reservada se entrenarán modelos nuevos con sus propios datos; el procedimiento de selección permanecerá fijo, como muestra la Figura 4.




Figura 4. Separación entre desarrollo y evaluación. Durante el desarrollo se fija el procedimiento; cada tarea analiza sus datos de entrenamiento, selecciona candidatos con validación y evalúa el modelo elegido en prueba reservada.

4.5. Evaluación

La Tabla 3 distingue el efecto global del diseño de los mecanismos de agrupación y fusión. La evaluación en RL tendrá criterios propios y no se mezclará con el error de pronóstico.

Tabla 3. Hipótesis y comparaciones experimentales.

Código	Hipótesis	Comparación
H1	El diseño basado en datos mejora el pronóstico global sin perjuicio relevante por familia.	Método frente al control principal elegido en desarrollo.
H2	La ventaja de agrupar mediante perfiles aumenta con las diferencias de escala temporal.	Agrupación por perfiles frente a asignación permutada en señales sintéticas.
H3	Con relaciones entre variables con retraso, conservar las secuencias hasta fusionarlas mejora el pronóstico.	Fusión de secuencias frente a resumen temprano, con y sin esas relaciones.

4.5.1 Organización de los experimentos

Los cuatro bloques de la Tabla 4 separan desarrollo, pruebas reservadas y aplicación. Una *familia de datos* reúne conjuntos relacionados por fuente y dominio. Sus variantes se mantendrán juntas para que distintas ventanas de una fuente no se cuenten como familias independientes.

Tabla 4. Bloques experimentales y finalidad.

Código	Bloque	Datos y uso
E0	Pruebas sintéticas	Señales conocidas, separadas para desarrollar diagnósticos y contrastar H2 y H3.
E1	Desarrollo del método	Familias públicas para fijar criterios de diseño, controles, entrenamiento, presupuestos y precisión estadística.
E2	Evaluación pública reservada	Otras familias para contrastar H1. Cada tarea tendrá entrenamiento, validación y prueba propios.
E3	Aplicación financiera	Datos históricos para evaluar la representación en RL; entrega obligatoria, independiente de H1–H3.

Las señales sintéticas combinarán procesos autorregresivos, periodicidades, tendencias y eventos localizados. Para H2 se variarán escalas conservando cantidad de datos y distribución del ruido. Para H3 se construirán pares con y sin dependencias entre variables, conservando en distribución el comportamiento individual. Esta conservación se verificará con repeticiones; desordenar instantes no servirá como único control porque altera también cada serie. Se incluirán cambios de comportamiento y casos donde el diagnóstico falle.

La reserva sintética fijará generadores, rangos y semillas antes de desarrollar la regla; sus resultados permanecerán cerrados hasta terminar ese desarrollo. Para la evaluación pública se fijarán familias, horizontes y particiones. El piloto determinará cuántas familias y repeticiones permiten una comparación suficientemente precisa dentro del presupuesto.

4.5.2 Modelos de referencia y controles

Se comparará con pronóstico ingenuo y estacional ingenuo, un modelo estadístico multivariado pertinente, DLinear, PatchTST, iTransformer y DUET. Antes de examinar resultados de desarrollo se elegirá además un método multiescala entre MTST, Pathformer y TimeMixer. Los antecedentes de agrupación, incluidos CCM, DGCformer y el método de Ma et al., se considerarán para un comparador adicional según disponibilidad y compatibilidad del protocolo.

El control principal de H1 será la mejor alternativa en desarrollo entre un modelo sin procesamiento diferenciado por ramas y uno modular organizado sin perfiles. Se elegirá con el mismo error agregado que se utilizará en la evaluación final. Las comparaciones adicionales modificarán una decisión concreta: asignación de variables, contexto o fusión antes o después de resumir las ramas.

Método y controles recibirán la misma información y preprocesamiento común, con semillas, presupuestos y oportunidades de selección comparables. En los controles de arquitectura se igualará el número de parámetros entrenables dentro de una tolerancia fijada en el piloto. Las referencias publicadas conservarán su arquitectura; se informarán parámetros, tiempo y memoria de todos los modelos. La asignación permutada conservará número y tamaño de ramas, modelos, contextos e interfaces; cambiará qué variables llegan a cada rama. Se fijarán varias permutaciones antes de evaluar, evitando cambios que solo renombren conjuntamente datos y módulos.

4.5.3 Desempeño y relevancia de las diferencias

La unidad será una tarea de pronóstico: conjunto, variables objetivo y horizonte. Las repeticiones con distintas semillas aleatorias y puntos de inicio del pronóstico, u *orígenes*, se agregarán dentro de la tarea. Se evaluará desde orígenes sucesivos, siguiendo el esquema descrito por Hyndman y Athanasopoulos [6], con una política de reentrenamiento fijada previamente. Una observación ya evaluada podrá incorporarse al historial de un origen posterior; sus errores de prueba no cambiarán las reglas de diseño o selección.

La medida principal será el error absoluto medio escalado, MASE, propuesto por Hyndman y Koehler [32] y descrito también para referencias estacionales en [6]. Para una variable k y un origen o , el denominador $a_{k,o}$ será el error absoluto medio, calculado en entrenamiento, de repetir el valor de un período anterior. Con H pasos futuros:

$$\text{MASE}_{k,o} = \frac{1}{H a_{k,o}} \sum_{h=1}^H |y_{k,o+h} - \hat{y}_{k,o+h}|. \quad (3)$$

El período estacional procederá de metadatos o de una regla fijada en desarrollo; sin estacionalidad se utilizará el valor inmediatamente anterior. Los métodos compartirán denominadores. Una tarea con denominador cero se identificará antes de examinar sus errores de prueba y se informará aparte de H1. Se añadirán las métricas y agregaciones exactas de las publicaciones comparadas, como MAE y MSE.

Se promediarán los errores con igual peso entre variables objetivo, pasos, orígenes y semillas. Para la tarea t :

$$\Delta_t = \text{MASE}_{t,\text{método}} - \text{MASE}_{t,\text{control}}. \quad (4)$$

El efecto global Δ dará igual peso a tareas dentro de cada conjunto, conjuntos dentro de cada familia y familias. Una diferencia negativa favorecerá al método. Se fijará antes de la prueba un margen $\varepsilon > 0$ que represente una diferencia relevante de MASE. Para un intervalo $[L, U]$:

- **Mejora relevante:** $U < -\varepsilon$.
- **Equivalencia práctica:** $[L, U] \subseteq [-\varepsilon, \varepsilon]$.
- **Perjuicio relevante:** $L > \varepsilon$.
- **Resultado inconcluso:** cualquiera de los demás casos.

Se informarán resultados por tarea, familia y horizonte. La ausencia de una mejora demostrada no se interpretará como equivalencia.

4.5.4 Contraste de las hipótesis

Mejora global (H1). Se requerirá un límite superior de Δ menor que $-\varepsilon$ y un límite superior por familia menor o igual que ε . Así, una mejora promedio no ocultará un perjuicio relevante en una familia. Si una familia no ofrece precisión suficiente, no se podrá afirmar el resultado conjunto.

Agrupación por escalas (H2). Para cada nivel conocido de heterogeneidad sintética h se calculará

$$e(h) = \text{MASE}(\text{perfiles}, h) - \text{MASE}(\text{permutación}, h).$$

Se estimará la pendiente de $e(h)$ mediante una regresión lineal sobre niveles y ponderaciones fijados previamente. H2 requerirá que su límite superior sea menor que cero: una ventaja relativa creciente, aunque no necesariamente superioridad en todos los niveles. La relación con q en datos públicos será complementaria.

Conservación de las secuencias (H3). Se compararán fusión de secuencias y resumen temprano sobre las mismas activaciones de un extractor entrenado y fijo. Solo se ajustarán los módulos de combinación y cabezales. Para señales con relaciones entre variables con retraso ($r = 1$) y sus controles sin esas relaciones ($r = 0$):

$$d_r = \text{MASE}(\text{fusión de secuencias}, r) - \text{MASE}(\text{resumen temprano}, r), \quad \gamma = d_1 - d_0.$$

H3 requerirá que el límite superior de d_1 sea menor que $-\varepsilon$ y el de γ menor que cero. Se medirá la memoria adicional. Los contrastes públicos guiados por relaciones detectadas en entrenamiento serán complementarios.

Incertidumbre y multiplicidad. Con F familias reservadas se evaluarán $K = F + 4$ efectos: uno global y F por familia para H1, una pendiente para H2 y dos diferencias para H3. Se usarán intervalos bilaterales con cobertura nominal $1 - 0.05/K$, aplicando Bonferroni al conjunto. El margen de MASE no se aplicará a la pendiente ni a la diferencia de diferencias γ .

Los intervalos se estimarán mediante *bootstrap jerárquico*, remuestreando familias, conjuntos y tareas y manteniendo emparejados los métodos. Para efectos por familia se fijará la familia correspondiente. Objetivos y horizontes de una fuente permanecerán vinculados; las semillas y orígenes se agregarán dentro de cada tarea. En señales sintéticas se

remuestrearán configuraciones y repeticiones con sus controles emparejados. Si se remuestran errores temporales, se usarán bloques contiguos para conservar dependencia.

El piloto comprobará mediante simulación la precisión y cobertura de los intervalos y su sensibilidad a la longitud de bloque. Cuando la cantidad o diversidad de datos no permitan sostenerlas, el contraste será inconcluso. Se examinará la sensibilidad al retirar conjuntos, sin ampliar la prueba ni redefinir hipótesis después de observar resultados.

4.5.5 Costo de obtener el resultado

Se registrarán diagnóstico, preentrenamiento, búsqueda, ajuste y evaluación, incluidos decodificador, candidatos descartados y ejecuciones fallidas. Se distinguirá el costo de desarrollar el procedimiento del de aplicarlo a nuevas tareas. Al reutilizar un codificador se informarán costo inicial, costo adicional por uso y acumulado, atribuyendo el trabajo compartido sin contarlos varias veces.

Las medidas serán energía en vatios-hora, tiempo transcurrido, horas de CPU y GPU y memoria máxima, con hardware y concurrencia documentados. El instrumento de medida energética se verificará durante el piloto. Las duraciones de trabajos paralelos no se sumarán como tiempo transcurrido. Esta contabilidad acompañará las comparaciones de desempeño.

4.6. Despliegue e integración

Los extractores se integrarán con interfaces para importar y exportar pesos y conectar sus salidas con la fusión, el núcleo y los cabezales. Se verificará el flujo de gradientes de los componentes entrenables. La integración en pronóstico y RL utilizará las plataformas existentes.

Durante el desarrollo se elegirán una tarea financiera y un algoritmo compatibles con la plataforma. Se compararán la representación propuesta, la actual y una variante sin procesamiento diferenciado por ramas; las dos últimas podrán coincidir. Las variantes compartirán observaciones, acciones, recompensa, entorno, calendario y presupuesto. Se documentarán la entrada de posición y estado de cuenta y, cuando existan actor y crítico, si comparten la representación.

Antes de la prueba se fijarán métrica principal, margen relevante y medidas complementarias, incluyendo rentabilidad neta, riesgo y caída máxima del capital. Los costos y condiciones de ejecución serán comunes. Las diferencias se estimarán sobre los mismos períodos y con varias semillas; sus intervalos conservarán esa dependencia. Superar una estrategia trivial dará una referencia de utilidad; la comparación entre representaciones permitirá atribuir el efecto al diseño. Este análisis tendrá su propio control de multiplicidad y no modificará H1–H3.

DOIN proporcionará optimización y registro; el cubo OLAP organizará configuraciones, particiones, semillas, métricas y costos. Se conservarán candidatos descartados, versiones de pesos y reglas de reentrenamiento para reproducir y analizar los experimentos.

5. Viabilidad, recursos y riesgos

Se dispone de cuatro GPU de distintas capacidades, CPU y plataformas de datos y entrenamiento. El piloto medirá tiempos y memoria con disponibilidad parcial de las GPU y reservará recursos para RL. Si es necesario reducir alcance, se retirarán comparadores opcionales y configuraciones redundantes, conservando pruebas sintéticas, evaluación pública y aplicación financiera con sus controles principales.

Los riesgos científicos son que el diagnóstico no mejore el diseño, que la utilidad se limite a ciertos dominios o que los datos no permitan estimarla con precisión. Se publicarán resultados favorables, desfavorables e inconclusos. Se respetarán las licencias de los datos y la evaluación financiera será histórica.

6. Cronograma

Tabla 5. Actividades y entregas previstas en seis semestres.

Sem.	Actividad principal	Entrega
1	Actualizar antecedentes, definir tareas e interfaces, inventariar datos y realizar el piloto.	Diseño registrado, inventario y presupuesto.
2	Implementar diagnóstico y componentes; construir señales sintéticas y comprobar el entrenamiento.	Software, pruebas y reserva sintética (E0).
3	Desarrollar criterios de diseño, elegir controles y cerrar protocolos.	Procedimiento fijado (E1) y manuscrito metodológico.
4	Evaluar familias reservadas y contrastar agrupación y fusión en señales sintéticas.	Resultados E2 y H1–H3; manuscrito principal.
5	Integrar y evaluar en RL frente a controles y referencias compatibles.	Evaluación financiera (E3) y módulos reutilizables.
6	Integrar resultados, comprobar reproducibilidad, escribir y defender la tesis.	Tesis, modelos y documentación.

7. Resultados y contribuciones esperadas

1. Un procedimiento reproducible que conecte el análisis de los datos con la agrupación, el contexto y la selección de extractores por rama.
2. Evidencia que distinga el aporte del diseño del efecto de la arquitectura, el preentrenamiento y los recursos, incluyendo resultados desfavorables y límites de aplicación.
3. Componentes integrados y evaluados en pronóstico y RL, con configuraciones, pesos y registros experimentales reproducibles.

Referencias

- [1] Y. Bengio, A. Courville y P. Vincent, «Representation Learning: A Review and New Perspectives», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, n.º 8, pp. 1798–1828, 2013. DOI: 10.1109/TPAMI.2013.50.
- [2] G. C. Cawley y N. L. C. Talbot, «On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation», *Journal of Machine Learning Research*, vol. 11, n.º 70, pp. 2079–2107, 2010. <https://jmlr.org/papers/v11/cawley10a.html>.
- [3] S. Bai, J. Z. Kolter y V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling», *arXiv preprint arXiv:1803.01271*, 2018. DOI: 10.48550/arXiv.1803.01271.
- [4] Keras Team, «Conv1D layer», documentación oficial de Keras 3, consultada el 9 de septiembre de 2026. https://keras.io/api/layers/convolution_layers/convolution1d/.
- [5] Keras Team, «LSTM layer», documentación oficial de Keras 3, consultada el 9 de septiembre de 2026. https://keras.io/api/layers/recurrent_layers/lstm/.
- [6] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.^a ed. OTexts, 2021, cap. 4 y secs. 5.8 y 5.10. <https://otexts.com/fpp3/>.
- [7] A. Zeng et al., «Are Transformers Effective for Time Series Forecasting?», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 9, pp. 11121–11128, 2023. DOI: 10.1609/aaai.v37i9.26317.
- [8] Y. Nie et al., «A Time Series is Worth 64 Words: Long-term Forecasting with Transformers», *International Conference on Learning Representations*, 2023. <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [9] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=JePfAI8fah>.

- [10] Y. Zhang et al., «Multi-resolution Time-Series Transformer for Long-term Forecasting», *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, vol. 238, pp. 4222–4230, 2024. <https://proceedings.mlr.press/v238/zhang241.html>.
- [11] P. Chen et al., «Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=IJkOCMP2aW>.
- [12] S. Wang et al., «TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=7oLshfEIC2>.
- [13] W. Cai et al., «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, n.º 10, pp. 11141–11149, 2024. DOI: 10.1609/aaai.v38i10.28991.
- [14] J. Chen et al., «From Similarity to Superiority: Channel Clustering for Time Series Forecasting», *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-4152.
- [15] Q. Liu, Y. Fang, P. Jiang y G. Li, «DGCformer: Deep Graph Clustering Transformer for Multivariate Time Series Forecasting», *arXiv preprint arXiv:2405.08440*, 2024. <https://arxiv.org/abs/2405.08440>.
- [16] X. Qiu et al., «DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting», *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 1185–1196, 2025. DOI: 10.1145/3690624.3709325.
- [17] P. Montero-Manso et al., «FFORMA: Feature-based Forecast Model Averaging», *International Journal of Forecasting*, vol. 36, n.º 1, pp. 86–92, 2020. DOI: 10.1016/j.ijforecast.2019.02.011.
- [18] Z. Liang y Y. Sun, «Evolutionary Neural Architecture Search for Multivariate Time Series Forecasting», *Proceedings of the 15th Asian Conference on Machine Learning*, vol. 222, pp. 771–786, 2024. <https://proceedings.mlr.press/v222/liang24a.html>.
- [19] R. Leppich et al., «Decomposing the Time Series Forecasting Pipeline: A Modular Approach for Time Series Representation, Information Extraction, and Projection», *arXiv preprint arXiv:2507.05891*, 2025. DOI: 10.48550/arXiv.2507.05891.
- [20] Z. Ma, Á. López-Oriona, H. Ombao y Y. Sun, «Forecasting Multivariate Time Series under Predictive Heterogeneity: A Validation-Driven Clustering Framework», *arXiv preprint arXiv:2604.13748*, 2026. <https://arxiv.org/abs/2604.13748>.
- [21] G. Woo et al., «CoST: Contrastive Learning of Disentangled Seasonal-Trend Representations for Time Series Forecasting», *International Conference on Learning Representations*, 2022. <https://openreview.net/forum?id=PilZY3omXV2>.
- [22] N. Zeghidour et al., «LEAF: A Learnable Frontend for Audio Classification», *International Conference on Learning Representations*, 2021. <https://openreview.net/forum?id=jM76BCb6F9m>.
- [23] J. Schlüter y G. Gutenbrunner, «EfficientLEAF: A Faster Learnable Audio Frontend of Questionable Use», *arXiv preprint arXiv:2207.05508*, 2022. DOI: 10.48550/arXiv.2207.05508.
- [24] Z. Li et al., «Ti-MAE: Self-Supervised Masked Time Series Autoencoders», *arXiv preprint arXiv:2301.08871*, 2023. DOI: 10.48550/arXiv.2301.08871.
- [25] H. Bastidas, «Gestor de autoencoder de feature-extractor», código fuente, revisión df86252, 2026. https://github.com/harveybc/feature-extractor/blob/df86252a174a1f5b9f77f4cb1bcb78fcdfe429e8/app/autoencoder_manager.py.
- [26] H. Bastidas, «Configuración de carga y ajuste del extractor de características», código fuente, revisión 20ec571, 2026. https://github.com/harveybc/predictor/blob/20ec57145b4ed3eb647eabe2b7591f35a3dbbf47/examples/config/phase_3_1/phase_3_1_cnn_25200_1h_config.json.
- [27] IBM, *IBM SPSS Modeler CRISP-DM Guide*, versión 14, 2011. https://inseaddataanalytics.github.io/INSEADAnalytics/CRISP_DM.pdf.
- [28] X. Qiu et al., «TFB: Towards Comprehensive and Fair Benchmarking of Time Series Forecasting Methods», *Proceedings of the VLDB Endowment*, vol. 17, n.º 9, pp. 2363–2377, 2024. DOI: 10.14778/3665844.3665863.
- [29] S. Sun et al., «TradeMaster: A Holistic Quantitative Trading Platform Empowered by Reinforcement Learning», *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/file/b8f6f7f2ba4137124ac976286eacb611-Paper-Datasets_and_Benchmarks.pdf.

- [30] X.-Y. Liu et al., «FinRL-Meta: Market Environments and Benchmarks for Data-Driven Financial Reinforcement Learning», *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*, 2022. https://papers.neurips.cc/paper_files/paper/2022/file/0bf54b80686d2c4dc0808c2e98d430f7-Paper-Datasets_and_Benchmarks.pdf.
- [31] Keras Team, «Transfer learning & fine-tuning», documentación oficial, actualizada en 2023, consultada el 9 de septiembre de 2026. https://keras.io/guides/transfer_learning/.
- [32] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy», *International Journal of Forecasting*, vol. 22, n.º 4, pp. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.