
Diseño y aprendizaje de representaciones temporales modulares

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje de representaciones · series temporales · arquitectura modular · campos receptivos · pronóstico multivariado · generalización

Resumen

Una serie temporal multivariada reúne variables cuyos ritmos de cambio, periodicidades y relaciones pueden ser distintos. Muchos modelos, sin embargo, aplican a todas ellas la misma ventana y el mismo extractor, mientras que otros incorporan varias escalas mediante una arquitectura elegida de antemano o una búsqueda costosa. Esta propuesta estudiará si algunas de esas decisiones pueden fundamentarse con propiedades calculadas exclusivamente sobre los datos de entrenamiento.

Se diseñará una *representación temporal modular* formada por ramas que procesan grupos de variables. En cada rama, un detector reconoce patrones locales, un integrador combina información a lo largo del tiempo y una adaptación opcional alinea su salida con las demás ramas. Cada activación tendrá un campo receptivo conocido: la extensión del pasado que puede influir en ella. El procedimiento estimará perfiles temporales, propondrá grupos de variables con escalas compatibles y asignará campos receptivos dentro de un conjunto finito. Las secuencias resultantes se alinearán y fusionarán antes del cabezal de pronóstico. Los pesos podrán aprenderse desde cero o mediante un codificador preentrenado; estos regímenes se compararán por separado para no confundir el efecto de la estructura con el de la inicialización.

El estudio combinará señales sintéticas con estructura conocida, bancos públicos multivariados y una aplicación financiera secundaria. El diseño informado se comparará con referencias simples y recientes, una arquitectura monolítica y módulos con asignación no informada, bajo las mismas entradas y presupuestos medidos. Las familias usadas para desarrollar la regla no aparecerán en la evaluación confirmatoria. La unidad estadística será la tarea de pronóstico, no cada ventana ni cada semilla. El resultado esperado es un método reproducible y una caracterización de cuándo ayuda, empata o perjudica; la tesis seguirá siendo informativa si una referencia más simple resulta preferible.

1. Problema y motivación

El aprendizaje de representaciones busca transformar observaciones en variables que faciliten una tarea posterior [1], [2]. En series temporales, la decisión no se limita a escoger una red. También comprende cuánto pasado mostrar, cómo agrupar variables, qué resolución conservar, qué operaciones aplicar y en qué momento combinar la información. Estas decisiones son dependientes: una convolución con un campo receptivo corto no puede usar una regularidad lenta; una reducción temprana puede ocultar desfases entre variables; y una transformación que mejora una medida interna puede eliminar eventos útiles para el pronóstico.

En la práctica coexisten dos estrategias. Una aplica una representación uniforme a todas las variables y confía en que el modelo aprenda sus diferencias. La otra prueba muchas combinaciones de ventanas, transformaciones y arquitecturas. La primera puede imponer un sesgo inadecuado; la segunda consume recursos y puede adaptar el procedimiento al conjunto de validación [3]. Falta establecer si descriptores temporales calculados antes de entrenar permiten restringir esas decisiones sin perder desempeño fuera de muestra.

La motivación también nace de experiencia previa con tuberías de pronóstico que aplanan las variables, resumen cada rama antes de combinarla, conservan secuencias completas o reutilizan codificadores preentrenados. Esa variedad muestra que la forma de presentar la historia al modelo no es un detalle neutro. La propuesta convierte esa observación en una pregunta experimental general, evaluada primero en datos públicos no financieros. Una

aplicación posterior a series financieras permitirá estudiar transferibilidad, pero no definirá por sí sola la validez del método.

Pregunta de investigación. ¿En qué condiciones agrupar variables por perfiles temporales estimados únicamente en entrenamiento y asignar a cada grupo un campo receptivo acorde mejora el pronóstico fuera de muestra frente a representaciones monolíticas o modulares no informadas, con entradas, régimen de aprendizaje y recursos comparables?

La pregunta no supone que toda serie tenga grupos estables ni que una arquitectura modular siempre sea superior. También admite como resultado que ciertos perfiles no sean identificables, que la asignación informada no mejore una asignación simple o que su costo no se justifique.

2. Marco teórico y antecedentes

2.1. Representación, escala temporal y campo receptivo

Sea $X_{1:L} \in \mathbb{R}^{L \times p}$ una ventana de p variables observadas hasta el instante de decisión, y sea $Y_{L+1:L+H}$ el horizonte que se desea pronosticar. Una representación aprendida es una transformación parametrizada $Z = f_\theta(X)$ cuyas activaciones se ajustan mediante un objetivo de entrenamiento. En una representación modular, las variables se dividen en grupos $G_1, \dots, G_B$. El extractor de la rama j distingue un detector temporal D_j , un integrador I_j y una adaptación de salida A_j (esta última puede ser la identidad):

$$Z_j = A_j(I_j(D_j(X_{:,G_j}))) \in \mathbb{R}^{L_j \times d_j}. \quad (1)$$

L_j es la longitud de la secuencia a la salida de esa rama: no se supone $L_j = L$ si hay submuestreo. Las ramas deben compartir una correspondencia temporal explícita antes de la fusión G_ψ ; un cabezal h_ω produce el pronóstico. Esta separación describe interfaces y modos de entrenamiento; no impone tres redes independientes ni congelación obligatoria. El campo receptivo de una activación del detector no equivale a la historia accesible al predictor completo.

El *campo receptivo* de una activación es la porción de la historia que puede afectarla. Puede ampliarse mediante dilataciones, tamaños de parche, recurrencia o atención. La *escala temporal característica* resume cuánto tarda una dependencia en decaer o qué periodicidades aparecen de forma estable. No son conceptos idénticos: detectar una periodicidad no garantiza que usar exactamente esa ventana mejore el pronóstico. La tesis estudia esa relación como una hipótesis, no como una regla universal.

El perfil temporal de una variable se estimará solo en el prefijo de entrenamiento e incluirá medidas predeclaradas de decaimiento de autocorrelación, concentración espectral, periodicidades dominantes y estabilidad entre subventanas. Los retardos se expresarán respecto a la frecuencia de muestreo y a la historia disponible; las frecuencias se normalizarán respecto a Nyquist. La escala común de los descriptores se aprenderá en las familias de desarrollo y quedará fija antes de la confirmación. Así, la heterogeneidad entre tareas no desaparecerá por normalizar cada una de manera independiente. No se llamará «ruido» a todo residuo de una serie real ni se interpretará una transformada como información causal. Las señales sintéticas permitirán comprobar si los diagnósticos recuperan escalas conocidas; los datos públicos decidirán si son útiles para pronosticar.

2.2. Lo que ya resuelven los modelos recientes

Los modelos lineales DLinear mostraron que una referencia simple puede superar arquitecturas mucho más complejas en varios bancos [4]. PatchTST segmenta la historia en parches y procesa cada variable de manera independiente [5]; iTransformer invierte los ejes habituales y usa variables como tokens para aprender relaciones multivariadas [6]. Estos resultados obligan a comparar cualquier arquitectura modular con referencias simples y con estrategias de dependencia e independencia entre canales.

La representación multiescala tampoco es nueva. TimesNet organiza variaciones periódicas en tensores bidi-

mensionales [7]; MTST utiliza ramas con diferentes resoluciones de parche [8]; Pathformer aprende rutas entre escalas [9]; y TimeMixer mezcla componentes en resoluciones finas y gruesas [10]. MSGNet aprende relaciones entre variables que cambian con la escala [11]. CCM agrupa canales a partir de una métrica aprendida [12], mientras DUET combina agrupación temporal y agrupación suave de canales [13]. Leddam y CATS ofrecen otras formas de representar dependencias entre series [14], [15]. Por ello, esta investigación no reclamará como aporte el simple uso de ramas, múltiples ventanas, agrupación, descomposición o atención.

CoST separa componentes estacionales y de tendencia mediante aprendizaje contrastivo [16]; BTSF combina representaciones temporales y espectrales [17]. Fuera de las series de pronóstico, SincNet y LEAF muestran que operaciones inspiradas en procesamiento de señales pueden parametrizarse y aprenderse con la tarea [18], [19]. EfficientLEAF encontró que frentes aprendibles más baratos no superaron consistentemente un banco fijo en sus tareas [20]. Ese resultado adverso es importante: incorporar conocimiento de señales no garantiza utilidad.

2.3. Vecinos directos y brecha provisional

FFORMA usa características de una serie para ponderar modelos completos de pronóstico [21]; EMTSF realiza búsqueda evolutiva de módulos espaciales y temporales [22]; y REP-Net descompone la tubería de pronóstico en representación, extracción y proyección, evaluando configuraciones de cada etapa [23]. DUET es el vecino más exigente porque también trata de responder a heterogeneidad temporal y relaciones entre canales. La diferencia que deberá demostrar esta tesis no es la modularidad: es si un perfil calculado antes del entrenamiento permite restringir conjuntamente grupos y campos receptivos, y si esa regla se transfiere a familias nuevas.

La revisión inicial no encontró todavía un método que reúna las tres condiciones que aquí se estudiarán: (i) estimar un perfil temporal reutilizable sin observar los resultados de prueba; (ii) usarlo para restringir conjuntamente la agrupación de variables y los campos receptivos internos, en vez de escoger únicamente un modelo terminado; y (iii) evaluar la transferencia de esa regla de composición a familias de datos no usadas para desarrollarla, con controles explícitos de capacidad, régimen de aprendizaje y costo. Esta es una *brecha provisional*. La revisión sistemática del primer semestre deberá confirmarla, estrecharla o reemplazarla si aparece un método equivalente.

El preentrenamiento por capas de autoencoders y la reconstrucción enmascarada de series son antecedentes del régimen de aprendizaje, no de la regla de diseño [24], [25]. Reutilizar pesos de un codificador tampoco se reclamará como novedad. La experiencia técnica previa incluye exportación separada de codificador y decodificador y configuraciones para reajustar extractores en tareas de pronóstico [26], [27]. Esa evidencia respalda la viabilidad, pero no demuestra que el acoplamiento diferenciable requerido por esta propuesta ya esté implementado. La integración se verificará mediante una prueba de flujo de gradientes y no mediante nombres de opciones o archivos de configuración.

3. Objetivos e hipótesis

3.1. Objetivo general

Desarrollar y evaluar un procedimiento para diseñar y aprender representaciones temporales modulares que vincule perfiles de dependencia estimados en los datos de entrenamiento con la agrupación de variables y los campos receptivos de sus ramas, con una frontera explícita del detector y un régimen de aprendizaje declarado, y determinar sus condiciones de utilidad para el pronóstico multivariado bajo restricciones de información y recursos.

3.2. Objetivos específicos

1. Formalizar el contrato de una representación temporal modular —detector, integrador, adaptación, consolidador y cabezal— y caracterizar, sin usar datos futuros, perfiles de dependencia que puedan orientar agrupaciones y campos receptivos.
2. Construir una regla reproducible que traduzca esos perfiles en un diseño inicial de ramas, especifique la correspondencia temporal entre sus salidas y declare el régimen de aprendizaje (conjunto desde cero, detector congelado o detector ajustable).

3. Evaluar el procedimiento frente a referencias fuertes y ablaciones en tareas públicas no usadas para desarrollarlo, midiendo error, costo total, estabilidad y condiciones de fallo; posteriormente examinar su utilidad en una aplicación financiera separada.

3.3. Hipótesis falsables

La unidad primaria será una tarea de pronóstico definida por conjunto de datos, variables objetivo y horizonte. Los orígenes rodantes y las semillas serán repeticiones dentro de la tarea, no observaciones independientes. Para cada tarea t se calculará

$$\Delta_t = \text{MASE}_{t,\text{método}} - \text{MASE}_{t,\text{control}}, \quad (2)$$

de modo que un valor negativo favorece al método. Antes de examinar las familias confirmatorias se fijará un margen práctico $\varepsilon > 0$, sustentado en el piloto de precisión y costo, y se conservará sin cambios durante E2.

H1 • Utilidad del diseño informado. En familias públicas no usadas para desarrollar la regla, la representación modular informada reducirá el error escalado frente al mejor control congelado entre una TCN monolítica y una arquitectura modular con agrupación y campos receptivos no informados. El contraste usará las mismas entradas, el mismo régimen de aprendizaje y el mismo presupuesto de ajuste. Una mejora que solo aparezca al añadir preentrenamiento al método propuesto no identificará el efecto de la regla estructural. H1 quedará respaldada únicamente si el límite superior del intervalo simultáneo de Δ es menor que $-\varepsilon$ y ninguna familia predeclarada muestra perjuicio material.

H2 • Mecanismo de acoplamiento. La ventaja de la regla informada sobre una asignación permutada aumentará a medida que crezca la heterogeneidad de escalas temporales. El contraste principal será un experimento sintético factorial en el que las clases de escala sean conocidas y la heterogeneidad cambie sin alterar el tamaño de muestra, el número de variables ni la distribución del ruido. La pendiente entre heterogeneidad y diferencia de error deberá ser negativa y su intervalo simultáneo excluir cero. En datos públicos se estimará la misma asociación con perfiles calculados antes de entrenar, pero se interpretará como evidencia de transferencia, no como prueba causal del mecanismo.

H3 • Conservación temporal hasta la fusión. En tareas sintéticas con dependencias cruzadas rezagadas conocidas, fusionar las secuencias alineadas antes de resumirlas reducirá el error frente a resumir cada rama antes de la fusión. El experimento comparará tareas emparejadas con y sin interacción rezagada y mantendrá fijos los extractores, la historia de entrada y el régimen de aprendizaje. La variante que conserva la secuencia usa más memoria de activaciones; esa diferencia se medirá en vez de ocultarse bajo una supuesta igualdad de información. En datos públicos, H3 tendrá un análisis complementario limitado a tareas identificadas mediante un diagnóstico rezagado calculado solo con entrenamiento.

Los perfiles marginales se calcularán sobre las variables de entrada y orientarán compatibilidad de escalas, no dependencia causal entre variables. Las relaciones rezagadas usadas en H3 se estimarán mediante un diagnóstico separado. Un detector preentrenado no resuelve por sí solo ninguno de esos problemas de identificación.

4. Método propuesto

4.1. Contrato de datos y representación

Cada conjunto se almacenará con procedencia, frecuencia, zona temporal cuando corresponda, variables observadas, objetivo y marcas de disponibilidad. Todo ajuste de normalización, imputación, agrupación o diagnóstico se realizará con el segmento de entrenamiento. Una transformación será admisible solo si puede aplicarse causalmente en el punto de decisión y si la misma información original está disponible para todos los comparadores. Las operaciones que usan toda una ventana histórica no se considerarán fuga por ese solo hecho; la validez dependerá de que la ventana termine antes del instante pronosticado.

La entrada común será la serie normalizada sin transformaciones específicas. El método calculará por variable un perfil d_j y una medida de estabilidad entre subventanas. Los retardos y frecuencias se expresarán en coordenadas comparables, y cada componente se escalará con estadísticas robustas aprendidas en E1 y congeladas antes de E2.

La heterogeneidad de una tarea se resumirá mediante

$$q(X) = \text{mediana}_{j < k} \|\tilde{d}_j - \tilde{d}_k\|_2, \quad (3)$$

donde q no pretende medir dificultad ni causalidad: solo cuantifica cuán distintos son los perfiles usados por la regla. Con esos perfiles, una regla A_η producirá una partición G y un conjunto de campos receptivos R :

$$(G, R) = A_\eta(\tilde{d}_1, \dots, \tilde{d}_p). \quad (4)$$

La primera realización de A_η agrupará perfiles mediante agrupamiento jerárquico y asignará a cada grupo el campo receptivo admisible más cercano a sus escalas dominantes. Agrupar perfiles semejantes significa que esas variables compartirán una rama y un alcance temporal; no afirma que sean causalmente dependientes. El número máximo de ramas, el umbral de corte y la cuadrícula finita de campos receptivos se fijarán en E1. Esta elección concreta hace refutable el mecanismo sin afirmar que sea la única traducción posible. Si el perfil de una variable no es estable, la regla no inventará una especialización: la asignará a una rama común y registrará el caso como no identificado. Para H3 se calculará aparte un diagnóstico de predictibilidad cruzada por retardos, siempre dentro de entrenamiento y sin usarlo para redefinir A_η durante E2.

4.2. Arquitectura y aprendizaje

La realización principal usará bloques convolucionales temporales causales, porque permiten calcular el campo receptivo y modificarlo mediante profundidad, tamaño de núcleo y dilatación [28]. En cada rama, D_j detectará patrones locales; I_j integrará esas activaciones hasta alcanzar el campo receptivo asignado; y A_j ajustará, cuando sea necesario, longitud y número de canales sin alterar la correspondencia temporal. Cada rama entregará $Z_j \in \mathbb{R}^{L_j \times d_j}$. Si hay submuestreo, la regla de alineación, su costo y la marca temporal de cada salida se declararán antes de entrenar.

La variante principal concatenará las salidas alineadas por instante, aplicará un mezclador temporal común y proyectará su último estado a los horizontes de pronóstico. La ablación de H3 partirá de las mismas salidas de rama, pero las resumirá antes de concatenarlas y empleará un cabezal vectorial con parámetros comparables. Ambas recibirán la misma historia; se publicarán por separado parámetros, operaciones y memoria de activaciones, pues conservar una secuencia y resumirla no tienen el mismo ancho de representación.

La Figura 1 sitúa el detector como submódulo inicial del extractor, no como una red distinta por obligación.




Figura 1: Arquitectura conceptual. Los perfiles estimados en entrenamiento determinan qué variables comparten rama y qué alcance temporal usa cada una. El detector reconoce patrones locales, el integrador reúne contexto y la adaptación alinea las salidas antes de fusionarlas. Fuente: elaboración propia.

Se distinguirán tres regímenes, comparables en arquitectura e información de entrada:

Régimen	Inicialización de D_j	Ajuste con el predictor
R0	aleatoria	detector y predictor se ajustan juntos
R1	codificador preentrenado	detector congelado; resto ajustable
R2	el mismo codificador preentrenado	detector y resto ajustables

Cuando se use preentrenamiento, un decodificador auxiliar Q_j reconstruirá la entrada o los elementos ocultos por una máscara definida previamente. Una reconstrucción ordinaria no se presentará como eliminación de ruido. La pareja codificador–decodificador se conservará como artefacto reproducible; el predictor utilizará el codificador y guardará por separado cualquier copia reajustada. En R1 se comprobará que no reciba gradientes y en R2 que permanezca conectado a la pérdida final. Entrenar sobre activaciones guardadas en un archivo será tratado como extracción fija, no como ajuste de extremo a extremo [29].

Los tres regímenes se examinarán durante E1. Antes de E2 se congelará uno para el contraste principal y se aplicará de manera idéntica al método y a sus controles. Los resultados de desarrollo no sostendrán por sí solos una conclusión sobre las ventajas del preentrenamiento.

Una segunda familia de bloques, probablemente basada en parches, se incorporará solo como análisis de robustez si el piloto demuestra que el presupuesto permite separar el efecto de la regla del efecto del operador.

Las restricciones comprobables —causalidad, dimensiones, disponibilidad y memoria máxima— se aplicarán antes de entrenar. Las decisiones heurísticas —agrupación, escala y ancho— se evaluarán durante el desarrollo. Tasas de aprendizaje, ancho y regularización se ajustarán dentro de rangos comunes para todos los métodos. La Figura 2 resume qué queda fijo antes de la confirmación y qué se aprende dentro de una tarea nueva.




Figura 2: Protocolo confirmatorio. Las decisiones generales se fijan con familias de desarrollo. En cada tarea nueva, perfiles, ramas y pesos se estiman solo con entrenamiento y validación; la prueba reservada se consulta una vez y no modifica el procedimiento. Fuente: elaboración propia.

4.3. Fases experimentales

Tabla 1: Fases y función de cada fuente de evidencia.

Fase	Datos	Propósito	Uso en el estudio
E0	Señales sintéticas multicomponente	Calibrar perfiles y estudiar escalas y desfases conocidos.	Pruebas de mecanismo para H2 y H3.
E1	Familias públicas de desarrollo	Elegir opciones finitas, régimen R0/R1/R2, presupuesto y márgenes.	Desarrollo del procedimiento.
E2	Familias públicas reservadas	Probar H1 con la regla congelada y repetir los análisis de transferencia.	Evaluación confirmatoria principal.
E3	Datos financieros históricos	Examinar la transferencia a un dominio con cambios temporales marcados.	Aplicación secundaria.

E0 combinará procesos autorregresivos, componentes periódicos, tendencias y eventos localizados. Un primer factor variará la separación entre escalas con tamaño y ruido constantes. Un segundo comparará relaciones cruzadas

con retardos conocidos frente a controles obtenidos por permutación temporal, de modo que se conserven las distribuciones marginales y se destruya la alineación rezagada. E0 se dividirá en generadores de calibración y generadores reservados: las ecuaciones, rangos y semillas de prueba se fijarán antes de ajustar la regla. También habrá casos no estacionarios y mal especificados para observar cuándo los perfiles dejan de ser identificables. El ruido aditivo tendrá magnitud conocida, pero esa construcción no se extrapolará como una medida de «señal verdadera» en datos reales.

El censo de E1 y E2 considerará conjuntos públicos de energía, clima, tráfico y otros dominios incluidos en TFB, Monash y GIFT-Eval [30], [31], [32]. Una unidad será elegible solo si contiene variables no duplicadas observadas conjuntamente y permite comparar al menos dos particiones distintas, además de tener frecuencia documentada, licencia compatible, historia suficiente para las particiones previstas y un denominador MASE no nulo en entrenamiento. Los conjuntos univariados podrán servir para comprobar la implementación de referencias, pero no probarán las hipótesis sobre agrupación. Familias, horizontes y particiones se congelarán antes de puntuar E2. La separación se hará por dominio y fuente, no repartiendo al azar ventanas del mismo conjunto entre desarrollo y confirmación.

5. Diseño de evaluación

5.1. Comparadores y ablaciones

El conjunto mínimo incluirá:

1. pronóstico estacional ingenuo y DLinear como pisos de complejidad;
2. PatchTST e iTransformer como referencias de independencia y dependencia entre variables;
3. DUET como vecino directo de agrupación temporal y de canales, y un método multiescala elegido entre MTST, Pathformer o TimeMixer antes de observar E1;
4. una TCN monolítica y una modular con grupos aleatorios, ambas construidas con el mismo contrato del método;
5. ablaciones que permutan los perfiles, fijan un campo receptivo común y adelantan el resumen temporal.

MSGNet o CCM se incorporará como análisis de robustez si su interfaz y costo permiten una comparación limpia. No se ejecutarán todos los modelos publicados ni el producto cartesiano de regímenes, familias y ablaciones. Cada comparador tendrá una función: establecer un piso, aislar modularidad, aislar la regla informada o enfrentar el vecino directo. El monolítico, el modular aleatorio y el método recibirán la misma cinta de semillas, búsqueda de hiperparámetros y régimen de aprendizaje. Sus parámetros se igualarán dentro de una tolerancia fijada por el piloto; si esa igualdad oculta diferencias grandes de tiempo o memoria, se informará además la frontera entre error y costo.

5.2. Medidas, incertidumbre y costo

La métrica primaria será el error absoluto medio escalado (MASE), cuyo denominador se calculará únicamente con el entrenamiento [33]. Si ese denominador es cero, la tarea se marcará como no evaluable para H1 y se informará por separado; no se sustituirá por una constante elegida después de ver los resultados. MAE y error cuadrático se informarán como secundarios, junto con desempeño por horizonte, estabilidad entre semillas y error en eventos cuando exista una definición previa.

El período estacional usado por MASE se tomará de los metadatos del conjunto o de una regla congelada en E1; nunca se elegirá con la prueba. El costo total se expresará como

$$C_{\text{total}} = \sum_{t,o} C_{\text{perfil},t,o} + \sum_{t,m,s,o} (C_{\text{pre}} + C_{\text{ajuste}} + C_{\text{eval}})_{t,m,s,o}, \quad (5)$$

donde m , s y o identifican método, semilla y origen de evaluación. Se medirán tiempo, memoria máxima, operaciones estimadas y energía con un instrumento fijado durante E1. El preentrenamiento por tarea y su decodificador se incluirán en cada celda correspondiente. Si un codificador compartido se reutiliza, se publicarán por separado su

costo inicial, el costo marginal y el acumulado. Una mejora obtenida con más capacidad o más cómputo no se atribuirá únicamente al diseño estructural.

Las repeticiones por semilla y origen se agregarán dentro de cada tarea. Un bootstrap jerárquico re-muestreará familias, conjuntos y tareas; si estima incertidumbre temporal, conservará bloques contiguos. H2 estimará además la asociación entre $q(X)$ y la diferencia pareada entre la asignación informada y su permutación. La familia confirmatoria de H1–H3 se corregirá mediante el procedimiento de Holm [34]. Se publicarán intervalos y efectos por tarea y familia, no solo promedios.

Las particiones serán cronológicas y la evaluación empleará orígenes rodantes no solapados cuando la longitud lo permita. El ajuste del diseño se repetirá dentro de cada muestra de entrenamiento; no se recalculará con prueba. Estas precauciones siguen la evidencia sobre selección sesgada y evaluación temporal [3], [35].

5.3. Criterios de decisión

H1 se juzgará contra un comparador principal elegido durante el desarrollo y congelado antes de E2. H2 y H3 usarán contrastes pareados dentro de la misma tarea sintética. Para un intervalo simultáneo $[L, U]$ de la diferencia Δ , se declarará *beneficio práctico* si $U < -\epsilon$, *equivalencia práctica* si $[L, U] \subseteq [-\epsilon, \epsilon]$, y *perjuicio práctico* si $L > \epsilon$; cualquier otro caso será *inconcluso*. H2 exigirá además la pendiente negativa definida en su enunciado y H3 una interacción entre presencia de dependencia rezagada y estrategia de fusión. Un promedio favorable que dependa de un único conjunto o que oculte perjuicio material en una familia no respaldará H1. El análisis de E1 fijará el tamaño de banco necesario; si no puede alcanzar la precisión prevista, E2 se declarará inconcluso en lugar de ampliar datos o modelos después de conocer el resultado.

6. Viabilidad, ética y plan de trabajo

6.1. Recursos y relación con el sistema existente

El trabajo parte de cuatro GPU propias de capacidades diferentes, CPU local, software funcional para datos, preprocesamiento, modelos y registro de experimentos, y experiencia previa con campañas reproducibles. La disponibilidad simultánea no se presupone. E0 y los diagnósticos se ejecutarán en CPU; E1 reducirá el espacio antes de reservar cómputo confirmatorio. El costo se medirá con pilotos y no se estimará multiplicando una sola corrida por toda la tesis.

La implementación previa permite exportar codificadores y decodificadores y declarar el reajuste de extractores, pero todavía deberá demostrarse el flujo de gradientes del modelo compuesto. Esa verificación es una tarea inicial de ingeniería, no evidencia a favor de las hipótesis. La aplicación financiera usará datos históricos y un protocolo separado; no intervendrá en la selección del método ni de los comparadores principales.

6.2. Cronograma de seis semestres

El mínimo defendible comprende contrato, mecanismo, E0, E1 y E2. Si faltan recursos, se retirarán primero la segunda familia de bloques, CCM como integración y E3. No se recortarán el comparador simple, la separación por familias ni la contabilidad de costo.

6.3. Riesgos y ética

El mayor riesgo científico es que los perfiles temporales no anticipen qué diseño ayuda. Ese resultado refutaría el mecanismo, pero permitiría identificar condiciones en las que una arquitectura común o una búsqueda directa es preferible. Otro riesgo es que un antecedente equivalente elimine la brecha; en ese caso se adoptará como comparador y se estrechará la pregunta antes de E2. También puede ocurrir que los bancos públicos no contengan suficiente heterogeneidad o que los resultados dependan del dominio; la separación por familias hará visible esa limitación.

Los experimentos principales usarán datos públicos con sus licencias y datos sintéticos sin participantes humanos. No se recopilarán decisiones clínicas, datos personales ni intervenciones sobre usuarios. La validación financiera será histórica. Se publicarán configuraciones fallidas, consumo computacional y resultados nulos para reducir repetición innecesaria de cómputo. El preentrenamiento usará solo particiones permitidas; todo corpus previo compartido se

Tabla 2: Plan de trabajo y productos verificables.

Sem.	Trabajo principal	Producto
1	Revisión sistemática, contrato formal, banco y piloto de precisión/costo.	Protocolo registrado y artículo de revisión o diseño.
2	Implementación del perfil, regla y arquitectura; E0 completo.	Software reproducible y estudio de identificabilidad.
3	E1 en familias públicas; recorte de descriptores y comparadores.	Artículo metodológico y diseño E2 congelado.
4	E2, análisis confirmatorio y auditoría de reproducibilidad.	Artículo principal con resultados positivos, negativos o inconclusos.
5	Validación externa y E3 financiera o de aprendizaje por refuerzo si las condiciones previas se cumplen.	Artículo aplicado; si se recorta E3, análisis ampliado de E2.
6	Integración, réplica independiente, tesis y defensa.	Tesis, artefactos y documentos de reproducibilidad.

declarará con su posible solapamiento, y una familia vista durante preentrenamiento no se presentará después como completamente nueva.

7. Contribuciones esperadas

La investigación busca cuatro contribuciones acotadas:

1. un procedimiento que traduzca perfiles temporales estimados sin datos futuros en grupos de variables y campos receptivos para una representación modular;
2. una caracterización experimental de cuándo la heterogeneidad de escalas y las dependencias rezagadas hacen útil esa composición, y cuándo no pueden identificarse con los datos disponibles;
3. evidencia que separe el efecto del diseño estructural del efecto de la modularidad, el preentrenamiento y la capacidad computacional;
4. un protocolo reproducible, con comparadores actuales y costos completos, para evaluar transferencia a tareas y familias no usadas durante el desarrollo.

El aporte no se atribuirá al uso de autoencoders, a la existencia de varias ramas ni a la reutilización de pesos. Se evaluará un vínculo concreto entre perfiles calculados en entrenamiento, agrupación y campo receptivo. Si ese vínculo no resulta más informativo que una asignación no informada, la tesis establecerá dónde falla y qué alternativa simple ofrece una mejor relación entre error y costo.

Referencias

- [1] Y. Bengio, A. Courville y P. Vincent, «Representation Learning: A Review and New Perspectives,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, n.º 8, págs. 1798-1828, 2013. DOI: 10.1109/TPAMI.2013.50
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. dirección: <https://www.deeplearningbook.org/>
- [3] G. C. Cawley y N. L. C. Talbot, «On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation,» *Journal of Machine Learning Research*, vol. 11, n.º 70, págs. 2079-2107, 2010. dirección: <https://jmlr.org/papers/v11/cawley10a.html>
- [4] A. Zeng et al., «Are Transformers Effective for Time Series Forecasting?» *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 9, págs. 11 121-11 128, 2023. DOI: 10.1609/aaai.v37i9.26317

-
- [5] Y. Nie et al., «A Time Series is Worth 64 Words: Long-term Forecasting with Transformers,» en *International Conference on Learning Representations*, 2023. dirección: <https://openreview.net/forum?id=Jbdc0vTOcol>
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting,» en *International Conference on Learning Representations*, 2024. dirección: <https://openreview.net/forum?id=JePfAI8fah>
- [7] H. Wu et al., «TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis,» en *International Conference on Learning Representations*, 2023. dirección: https://openreview.net/forum?id=ju_Uqw384Oq
- [8] Y. Zhang et al., «Multi-resolution Time-Series Transformer for Long-term Forecasting,» en *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, ép. Proceedings of Machine Learning Research, vol. 238, 2024, págs. 4222-4230. dirección: <https://proceedings.mlr.press/v238/zhang24l.html>
- [9] P. Chen et al., «Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting,» en *International Conference on Learning Representations*, 2024. dirección: <https://openreview.net/forum?id=IJkOCMP2aW>
- [10] S. Wang et al., «TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting,» en *International Conference on Learning Representations*, 2024. dirección: <https://openreview.net/forum?id=7oLshfEIC2>
- [11] W. Cai et al., «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting,» en *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, 2024, págs. 11 141-11 149. DOI: 10.1609/aaai.v38i10.28991
- [12] J. Chen et al., «From Similarity to Superiority: Channel Clustering for Time Series Forecasting,» en *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-4152
- [13] X. Qiu et al., «DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting,» en *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2025, págs. 1185-1196. DOI: 10.1145/3690624.3709325
- [14] G. Yu et al., «Revitalizing Multivariate Time Series Forecasting: Learnable Decomposition with Inter-Series Dependencies and Intra-Series Variations Modeling,» en *Proceedings of the 41st International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 235, 2024, págs. 57 818-57 841. dirección: <https://proceedings.mlr.press/v235/yu24s.html>
- [15] J. Lu et al., «CATS: Enhancing Multivariate Time Series Forecasting by Constructing Auxiliary Time Series as Exogenous Variables,» en *Proceedings of the 41st International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 235, 2024, págs. 32 990-33 006. dirección: <https://proceedings.mlr.press/v235/lu24d.html>
- [16] G. Woo et al., «CoST: Contrastive Learning of Disentangled Seasonal-Trend Representations for Time Series Forecasting,» en *International Conference on Learning Representations*, 2022. dirección: <https://openreview.net/forum?id=PilZY3omXV2>
- [17] L. Yang y S. Hong, «Unsupervised Time-Series Representation Learning with Iterative Bilinear Temporal-Spectral Fusion,» en *Proceedings of the 39th International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 162, 2022, págs. 25 038-25 054. dirección: <https://proceedings.mlr.press/v162/yang22e.html>
- [18] M. Ravanelli e Y. Bengio, «Speaker Recognition from Raw Waveform with SincNet,» *arXiv preprint arXiv:1808.00158*, 2018. DOI: 10.48550/arXiv.1808.00158
- [19] N. Zeghidour et al., «LEAF: A Learnable Frontend for Audio Classification,» en *International Conference on Learning Representations*, 2021. dirección: <https://openreview.net/forum?id=jM76BCb6F9m>
- [20] J. Schlüter y G. Gutenbrunner, «EfficientLEAF: A Faster Learnable Audio Frontend of Questionable Use,» *arXiv preprint arXiv:2207.05508*, 2022. DOI: 10.48550/arXiv.2207.05508

-
- [21] P. Montero-Manso et al., «FFORMA: Feature-based Forecast Model Averaging,» *International Journal of Forecasting*, vol. 36, n.º 1, págs. 86-92, 2020. DOI: 10.1016/j.ijforecast.2019.02.011
- [22] Z. Liang e Y. Sun, «Evolutionary Neural Architecture Search for Multivariate Time Series Forecasting,» en *Proceedings of the 15th Asian Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 222, 2024, págs. 771-786. dirección: <https://proceedings.mlr.press/v222/liang24a.html>
- [23] R. Leppich et al., «Decomposing the Time Series Forecasting Pipeline: A Modular Approach for Time Series Representation, Information Extraction, and Projection,» *arXiv preprint arXiv:2507.05891*, 2025. DOI: 10.48550/arXiv.2507.05891
- [24] Y. Bengio et al., «Greedy Layer-Wise Training of Deep Networks,» en *Advances in Neural Information Processing Systems*, vol. 19, 2007. dirección: https://proceedings.neurips.cc/paper_files/paper/2006/file/5da713a690c067105aeb2fae32403405-Paper.pdf
- [25] Z. Li et al., «Ti-MAE: Self-Supervised Masked Time Series Autoencoders,» *arXiv preprint arXiv:2301.08871*, 2023. DOI: 10.48550/arXiv.2301.08871
- [26] H. Bastidas, *Codificador CNN y gestor de autoencoder en feature-extractor*, https://github.com/harveybc/feature-extractor/blob/df86252a174a1f5b9f77f4cb1bcb78fcdfe429e8/app/plugins/encoder_plugin_cnn.py, Inspección estática; commit df86252, 2024.
- [27] H. Bastidas, *Configuración de carga de extractor y train_fe*, https://github.com/harveybc/predictor/blob/20ec57145b4ed3eb647eabe2b7591f35a3dbbf47/examples/config/phase_3_1/phase_3_1_cnn_25200_1h_config.json, Evidencia de configuración, no de flujo de gradientes, 2024.
- [28] S. Bai, J. Z. Kolter y V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling,» *arXiv preprint arXiv:1803.01271*, 2018. DOI: 10.48550/arXiv.1803.01271
- [29] Keras Team, *Transfer learning & fine-tuning*, https://keras.io/guides/transfer_learning/, Documentación oficial; consultada el 7 de septiembre de 2026, 2023.
- [30] X. Qiu et al., «TFB: Towards Comprehensive and Fair Benchmarking of Time Series Forecasting Methods,» *Proceedings of the VLDB Endowment*, vol. 17, n.º 9, págs. 2363-2377, 2024. DOI: 10.14778/3665844.3665863
- [31] R. Godahewa et al., «Monash Time Series Forecasting Archive,» en *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2021. dirección: <https://openreview.net/forum?id=I0117rc0jcb>
- [32] T. Aksu et al., «GIFT-Eval: A Benchmark for General Time Series Forecasting Model Evaluation,» en *Proceedings of the 42nd International Conference on Machine Learning*, 2025. dirección: <https://openreview.net/forum?id=Z2cMOOANFX>
- [33] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy,» *International Journal of Forecasting*, vol. 22, n.º 4, págs. 679-688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001
- [34] S. Holm, «A Simple Sequentially Rejective Multiple Test Procedure,» *Scandinavian Journal of Statistics*, vol. 6, n.º 2, págs. 65-70, 1979.
- [35] C. Bergmeir, R. J. Hyndman y B. Koo, «A Note on the Validity of Cross-validation for Evaluating Autoregressive Time Series Prediction,» *Computational Statistics & Data Analysis*, vol. 120, págs. 70-83, 2018. DOI: 10.1016/j.csda.2017.11.003