
Diseño y aprendizaje de representaciones temporales modulares

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje de representaciones · series temporales · arquitectura modular · campos receptivos · pronóstico multivariado · generalización

Resumen

Una serie temporal multivariada reúne variables cuyos ritmos de cambio, periodicidades y relaciones pueden ser distintos. Muchos modelos, sin embargo, aplican a todas ellas la misma ventana y el mismo extractor, mientras que otros incorporan varias escalas mediante una arquitectura elegida de antemano o una búsqueda costosa. Esta propuesta estudiará si algunas de esas decisiones pueden fundamentarse con propiedades calculadas exclusivamente sobre los datos de entrenamiento.

Se diseñará una *representación temporal modular* formada por ramas que procesan grupos de variables. En cada rama, un detector reconoce patrones locales, un integrador incorpora contexto temporal y una adaptación opcional prepara la salida para su combinación con las demás ramas. Un consolidador alinea y concatena las secuencias; un núcleo temporal procesa la representación conjunta y puede reducir su número de canales conservando el eje temporal. Los módulos de salida se adaptan a la tarea: pronóstico multihorizonte en los experimentos públicos y política o estimación de valor, según el algoritmo, en la aplicación de aprendizaje por refuerzo. El procedimiento estimará perfiles exclusivamente en entrenamiento y los utilizará para proponer grupos de variables y campos receptivos —la extensión del pasado que puede afectar a una activación— dentro de un conjunto finito. Los pesos se aprenderán bajo regímenes de inicialización y ajuste definidos por separado. La Figura 1 presenta los módulos y sus conexiones.

El estudio combinará señales sintéticas con estructura conocida y tareas públicas multivariadas seleccionadas por su pertinencia y por disponer de resultados y protocolos de comparación en la literatura. En esas tareas se contrastará el diseño informado con referencias simples y recientes, una arquitectura monolítica y módulos con asignación no informada. Las familias utilizadas para desarrollar la regla se separarán de la evaluación confirmatoria y se conservará el control de entradas, régimen de aprendizaje y recursos. Como entrega obligatoria, la representación se integrará en la plataforma existente de aprendizaje por refuerzo para trading y se evaluará en simulación histórica frente a su representación de referencia. Esta evaluación tendrá un protocolo propio y no modificará retrospectivamente las hipótesis públicas. El estudio distinguirá beneficio, equivalencia, perjuicio e incertidumbre. En los contrastes públicos, la unidad estadística será la tarea de pronóstico, no cada ventana ni cada semilla. El resultado esperado es un método reproducible y una caracterización de cuándo ayuda, empata o perjudica; la tesis seguirá siendo informativa si una referencia más simple resulta preferible.




Figura 1: Organización de alto nivel de la representación temporal modular. Las ramas procesan grupos de variables; el consolidador alinea y concatena sus secuencias, y el núcleo temporal combina la información antes de las salidas específicas de cada aplicación. El detalle interno de las ramas se presenta en la Figura 2. Fuente: elaboración propia.

1. Problema y motivación

El aprendizaje de representaciones busca transformar observaciones en variables que faciliten una tarea posterior [1], [2]. En series temporales, la decisión no se limita a escoger una red. También comprende cuánto pasado mostrar, cómo agrupar variables, qué resolución conservar, qué operaciones aplicar y en qué momento combinar la información. Estas decisiones son dependientes: una activación convolucional no puede depender directamente de observaciones fuera de su campo receptivo, aunque las capas posteriores puedan integrar un contexto mayor; una reducción temprana puede ocultar desfases entre variables; y una transformación que mejora una medida interna puede eliminar eventos útiles para el pronóstico.

En la práctica coexisten dos estrategias. Una aplica una representación uniforme a todas las variables y confía en que el modelo aprenda sus diferencias. La otra prueba muchas combinaciones de ventanas, transformaciones y arquitecturas. La primera puede imponer un sesgo inadecuado; la segunda consume recursos y puede adaptar el procedimiento al conjunto de validación [3]. Falta establecer si descriptores temporales calculados antes de entrenar permiten restringir esas decisiones sin perder desempeño fuera de muestra.

La motivación también nace de experiencia previa con tuberías de pronóstico que aplanan las variables, resumen cada rama antes de combinarla, conservan secuencias completas o reutilizan codificadores preentrenados. Esa variedad muestra que la forma de presentar la historia al modelo no es un detalle neutro. La propuesta convierte esa observación en una pregunta experimental general. La motivación aplicada es mejorar la representación de las entradas de los agentes de aprendizaje por refuerzo del sistema existente. Los conjuntos públicos permiten contrastar el mecanismo con literatura reproducible; la integración y evaluación financiera comprueban su funcionamiento en el uso previsto por el autor.

Pregunta de investigación. ¿En qué condiciones agrupar variables por perfiles temporales estimados únicamente en entrenamiento y asignar a cada grupo un campo receptivo acorde mejora el pronóstico fuera de muestra frente a representaciones monolíticas o modulares no informadas, con entradas, régimen de aprendizaje y recursos comparables?

La aplicación obligatoria examinará, por separado, si el procedimiento de representación puede integrarse en un agente de aprendizaje por refuerzo de la plataforma existente y cómo afecta a su desempeño frente a la representación

de referencia bajo un protocolo financiero histórico común. Una mejora de pronóstico no se interpretará por sí sola como una mejora de decisión o de desempeño financiero.

La pregunta no supone que toda serie tenga grupos estables ni que una arquitectura modular siempre sea superior. También admite como resultado que ciertos perfiles no sean identificables, que la asignación informada no mejore una asignación simple o que su costo no se justifique.

2. Marco teórico y antecedentes

2.1. Representación, escala temporal y campo receptivo

Sea $X_{1:L} \in \mathbb{R}^{L \times p}$ una ventana de p variables observadas hasta el instante de decisión, y sea $Y_{L+1:L+H}$ el horizonte que se desea pronosticar. Una representación aprendida es una transformación parametrizada $Z = f_\theta(X)$ cuyas activaciones se ajustan mediante un objetivo de entrenamiento. En una representación modular, las variables se dividen en grupos $G_1, \dots, G_B$. El extractor de la rama j distingue un detector temporal D_j , un integrador I_j y una adaptación de salida A_j (esta última puede ser la identidad):

$$Z_j = A_j(I_j(D_j(X_{:,G_j}))) \in \mathbb{R}^{L_j \times c_j}. \quad (1)$$

L_j es la longitud de la secuencia a la salida de esa rama: no se supone $L_j = L$ si hay submuestreo. Las ramas deben compartir una correspondencia temporal explícita antes de la fusión G_ψ ; un cabezal h_ω produce el pronóstico. Esta separación describe interfaces y modos de entrenamiento; no impone tres redes independientes ni congelación obligatoria. El campo receptivo de una activación del detector no equivale a la historia accesible al predictor completo. Esta notación formaliza el consumidor de pronóstico utilizado en H1–H3; la aplicación de aprendizaje por refuerzo conservará las interfaces de representación y adaptará las salidas al algoritmo elegido.

El *campo receptivo* de una activación es la porción de la historia que puede afectarla. Puede ampliarse mediante dilataciones, tamaños de parche, recurrencia o atención. La *escala temporal característica* resume cuánto tarda una dependencia en decaer o qué periodicidades aparecen de forma estable. No son conceptos idénticos: detectar una periodicidad no garantiza que usar exactamente esa ventana mejore el pronóstico. La tesis estudia esa relación como una hipótesis, no como una regla universal.

El perfil temporal de una variable se estimará solo en el prefijo de entrenamiento e incluirá medidas predeclaradas de decaimiento de autocorrelación, concentración espectral, periodicidades dominantes y estabilidad entre subventanas. Los retardos se expresarán respecto a la frecuencia de muestreo y a la historia disponible; las frecuencias se normalizarán respecto a la frecuencia de Nyquist, que corresponde a la mitad de la frecuencia de muestreo. La escala común de los descriptores se aprenderá en las familias de desarrollo y quedará fija antes de la confirmación. Así, la heterogeneidad entre tareas no desaparecerá por normalizar cada una de manera independiente. No se llamará «ruido» a todo residuo de una serie real ni se interpretará una transformada como información causal. Las señales sintéticas permitirán comprobar si los diagnósticos recuperan escalas conocidas; los datos públicos decidirán si son útiles para pronosticar.

2.2. Lo que ya resuelven los modelos recientes

Los modelos lineales DLinear mostraron que una referencia simple puede superar arquitecturas mucho más complejas en varios bancos [4]. PatchTST segmenta la historia en parches y procesa cada variable de manera independiente [5]; iTransformer invierte los ejes habituales y usa variables como tokens para aprender relaciones multivariadas [6]. Estos resultados obligan a comparar cualquier arquitectura modular con referencias simples y con estrategias de dependencia e independencia entre canales.

La representación multiescala tampoco es nueva. TimesNet organiza variaciones periódicas en tensores bidimensionales [7]; MTST utiliza ramas con diferentes resoluciones de parche [8]; Pathformer aprende rutas entre escalas [9]; y TimeMixer mezcla componentes en resoluciones finas y gruesas [10]. MSGNet aprende relaciones entre variables que cambian con la escala [11]. CCM aprende asignaciones y prototipos de grupos de canales, regularizados por su similitud [12], mientras DUET combina agrupación temporal y agrupación suave de canales [13]. Leddam y CATS ofrecen otras formas de representar dependencias entre series [14], [15]. Por ello, esta investigación no reclamará como aporte el simple uso de ramas, múltiples ventanas, agrupación, descomposición o atención.

CoST separa componentes estacionales y de tendencia mediante aprendizaje contrastivo [16]; BTSF combina

representaciones temporales y espectrales [17]. Fuera de las series de pronóstico, SincNet y LEAF muestran que operaciones inspiradas en procesamiento de señales pueden parametrizarse y aprenderse con la tarea [18], [19]. EfficientLEAF encontró que frentes aprendibles más baratos no superaron consistentemente un banco fijo en sus tareas [20]. Ese resultado adverso es importante: incorporar conocimiento de señales no garantiza utilidad.

2.3. Vecinos directos y brecha provisional

FFORMA usa características de una serie para ponderar modelos completos de pronóstico [21]; EMTSF realiza búsqueda evolutiva de módulos espaciales y temporales [22]; y REP-Net descompone la tubería de pronóstico en representación, extracción y proyección, evaluando configuraciones de cada etapa [23]. DUET es el vecino más exigente porque también trata de responder a heterogeneidad temporal y relaciones entre canales. La diferencia que deberá demostrar esta tesis no es la modularidad: es si un perfil calculado antes del entrenamiento permite restringir conjuntamente grupos y campos receptivos, y si esa regla se transfiere a familias nuevas.

La revisión inicial no encontró todavía un método que reúna las tres condiciones que aquí se estudiarán: (i) estimar un perfil temporal reutilizable sin observar los resultados de prueba; (ii) usarlo para restringir conjuntamente la agrupación de variables y los campos receptivos internos, en vez de escoger únicamente un modelo terminado; y (iii) evaluar la transferencia de esa regla de composición a familias de datos no usadas para desarrollarla, con controles explícitos de capacidad, régimen de aprendizaje y costo. Esta es una *brecha provisional*. La revisión sistemática del primer semestre deberá confirmarla, estrecharla o reemplazarla si aparece un método equivalente.

El preentrenamiento por capas de autoencoders y la reconstrucción enmascarada de series son antecedentes del régimen de aprendizaje, no de la regla de diseño [24], [25]. Reutilizar pesos de un codificador tampoco se reclamará como novedad. La experiencia técnica previa incluye exportación separada de codificador y decodificador y configuraciones para reajustar extractores en tareas de pronóstico [26], [27]. Esa evidencia respalda la viabilidad, pero no demuestra que el acoplamiento diferenciable requerido por esta propuesta ya esté implementado. La integración se verificará mediante una prueba de flujo de gradientes y no mediante nombres de opciones o archivos de configuración.

3. Objetivos e hipótesis

3.1. Objetivo general

Desarrollar y evaluar un procedimiento para diseñar y aprender representaciones temporales modulares que vincule perfiles estimados en entrenamiento con la agrupación de variables y los campos receptivos de sus ramas, contrastar sus condiciones de utilidad en tareas públicas de pronóstico multivariado e integrar y evaluar su aplicación en el sistema existente de aprendizaje por refuerzo para trading, bajo restricciones explícitas de información y recursos.

3.2. Objetivos específicos

1. Formalizar el contrato de una representación temporal modular —detector, integrador, adaptación, consolidador y cabezales de salida— y caracterizar, sin usar datos futuros, perfiles temporales marginales que puedan orientar agrupaciones y campos receptivos.
2. Construir una regla reproducible que traduzca esos perfiles en un diseño inicial de ramas, especifique la correspondencia temporal entre sus salidas y declare el régimen de aprendizaje (conjunto desde cero, detector congelado o detector ajustable).
3. Evaluar el procedimiento frente a referencias fuertes y ablaciones en tareas públicas no usadas para desarrollarlo, seleccionadas por su pertinencia y comparabilidad con la literatura, midiendo error, costo, estabilidad y condiciones de fallo.
4. Integrar las representaciones temporales modulares en un agente de aprendizaje por refuerzo de la plataforma existente y evaluar su efecto frente a la representación de referencia mediante un protocolo financiero histórico predeclarado, con control del algoritmo, la información disponible, la simulación y el presupuesto de ajuste.

3.3. Hipótesis falsables

La unidad primaria será una tarea de pronóstico definida por conjunto de datos, variables objetivo y horizonte. Los orígenes rodantes y las semillas serán repeticiones dentro de la tarea, no observaciones independientes. Cada

variable objetivo tendrá su propio denominador del error absoluto medio escalado (MASE; §5.3), calculado con el entrenamiento disponible en el origen correspondiente y compartido por todos los métodos. Si un denominador predeclarado es nulo, la tarea completa no será elegible para H1 y se informará por separado. Dentro de cada tarea, los errores escalados se promediarán con igual peso entre variables objetivo, pasos del horizonte, orígenes y semillas. Para cada tarea t se calculará

$$\Delta_t = \text{MASE}_{t,\text{método}} - \text{MASE}_{t,\text{control}}, \quad (2)$$

de modo que un valor negativo favorece al método. El efecto principal Δ dará igual peso a las tareas dentro de cada conjunto, a los conjuntos dentro de cada familia y a las familias. Esta jerarquía evita que una fuente con muchas series domine la conclusión. El remuestreo conservará el emparejamiento entre métodos y la dependencia entre objetivos y horizontes de una misma fuente.

Antes de abrir la evaluación confirmatoria (E2) se fijarán un margen práctico $\varepsilon > 0$, el nivel $\alpha = 0.05$ y las F familias públicas. El piloto comprobará si el banco permite resolver un margen elegido por relevancia para la tarea; no se escogerá ε solo porque produzca significación. El conjunto confirmatorio contendrá $K = F + 4$ efectos: el efecto global y los F efectos por familia de H1, la pendiente de H2 y los dos contrastes de H3. Para cada uno se construirá un intervalo bilateral con cobertura nominal $1 - \alpha/K$ mediante el remuestreo pareado y jerárquico descrito en §5.3. Si las simulaciones de desarrollo o el soporte observado muestran que esos intervalos no son estables, el resultado correspondiente se declarará inconcluso.

H1 • Utilidad del diseño informado. En familias públicas no usadas para desarrollar la regla, la representación modular informada reducirá el error escalado frente al mejor control congelado entre una red convolucional temporal (TCN) monolítica y una arquitectura modular con agrupación y campos receptivos no informados. El contraste usará las mismas entradas, el mismo régimen de aprendizaje y el mismo presupuesto de ajuste. Una mejora que solo aparezca al añadir preentrenamiento al método propuesto no identificará el efecto de la regla estructural. H1 quedará respaldada únicamente si el límite superior del intervalo de Δ es menor que $-\varepsilon$ y, en cada familia predeclarada, el límite superior es menor o igual que ε . Una familia estimada con precisión insuficiente impedirá afirmar el resultado conjunto.

H2 • Mecanismo de acoplamiento. La ventaja de la regla informada sobre una asignación permutada aumentará a medida que crezca la heterogeneidad de escalas temporales. El contraste principal será un experimento sintético factorial en el que las clases de escala sean conocidas y la heterogeneidad cambie sin alterar el tamaño de muestra, el número de variables ni la distribución del ruido. Sea $e(h) = \text{MASE}(\text{informada}, h) - \text{MASE}(\text{permutada}, h)$ para el nivel conocido de heterogeneidad h . H2 quedará respaldada si el límite superior del intervalo de la pendiente β de $e(h)$ respecto a h es menor que cero. Esta prueba identifica si la ventaja relativa crece con la heterogeneidad; no demuestra por sí sola un beneficio absoluto. En datos públicos, $q(X)$ será una covariable de un análisis complementario, no un sustituto del factor generativo conocido ni una prueba causal del mecanismo.

H3 • Conservación temporal hasta la fusión. En tareas sintéticas con dependencias cruzadas rezagadas conocidas, fusionar las secuencias alineadas antes de resumirlas reducirá el error frente a resumir cada rama antes de la fusión. Para aislar la fusión, las dos variantes recibirán activaciones del mismo extractor, obtenido mediante un protocolo fijado en desarrollo y congelado durante este contraste; solo se ajustarán la fusión y el cabezal. Sea $d_r = \text{MASE}(\text{fusión temporal}, r) - \text{MASE}(\text{resumen temprano}, r)$, donde $r = 1$ indica acoplamiento cruzado rezagado y $r = 0$ un control con las mismas leyes temporales marginales, pero sin ese acoplamiento. Se definirá $\gamma = d_1 - d_0$. H3 requerirá que el límite superior de d_1 sea menor que $-\varepsilon$ y que el de γ sea menor que cero. La variante que conserva la secuencia usa más memoria de activaciones; esa diferencia se medirá. En datos públicos, H3 tendrá un análisis complementario limitado a tareas identificadas mediante un diagnóstico rezagado calculado solo con entrenamiento.

Los perfiles marginales se calcularán sobre las variables de entrada y orientarán compatibilidad de escalas, no dependencia causal entre variables. Las relaciones rezagadas usadas en H3 se estimarán mediante un diagnóstico separado. Un detector preentrenado no resuelve por sí solo ninguno de esos problemas de identificación.

4. Método propuesto

4.1. Contrato de datos y representación

Cada conjunto se almacenará con procedencia, frecuencia, zona temporal cuando corresponda, variables observadas, objetivo y marcas de disponibilidad. Todo ajuste de normalización, imputación, agrupación o diagnóstico se realizará

con el segmento de entrenamiento. Una transformación será admisible solo si puede aplicarse causalmente en el punto de decisión y si la misma información original está disponible para todos los comparadores. Las operaciones que usan toda una ventana histórica no se considerarán fuga por ese solo hecho; la validez dependerá de que la ventana termine antes del instante pronosticado.

La entrada común será la serie normalizada sin transformaciones específicas. El método calculará para cada variable i un perfil d_i y una medida de estabilidad entre subventanas. Los retardos y frecuencias se expresarán en coordenadas comparables, y cada componente se escalará con estadísticas robustas aprendidas en E1 y congeladas antes de E2. La heterogeneidad de una tarea se resumirá mediante

$$q(X) = \text{mediana}_{i < k} \|\tilde{d}_i - \tilde{d}_k\|_2, \quad (3)$$

donde q no pretende medir dificultad ni causalidad: solo cuantifica cuán distintos son los perfiles usados por la regla. Con esos perfiles, una regla A_η producirá una partición G y un conjunto de campos receptivos R :

$$(G, R) = A_\eta(\tilde{d}_1, \dots, \tilde{d}_p). \quad (4)$$

La primera realización de A_η agrupará perfiles mediante agrupamiento jerárquico y asignará a cada grupo el campo receptivo admisible más cercano a sus escalas dominantes. Agrupar perfiles semejantes significa que esas variables compartirán una rama y un alcance temporal; no afirma que sean causalmente dependientes. El número máximo de ramas, el umbral de corte y la cuadrícula finita de campos receptivos se fijarán en E1. Esta elección concreta hace refutable el mecanismo sin afirmar que sea la única traducción posible. Si el perfil de una variable no es estable, la regla no inventará una especialización: la asignará a una rama común y registrará el caso como no identificado. Para H3 se calculará aparte un diagnóstico de predictibilidad cruzada por retardos, siempre dentro de entrenamiento y sin usarlo para redefinir A_η durante E2.

4.2. Arquitectura y aprendizaje

La realización principal usará bloques convolucionales temporales causales, porque permiten calcular el campo receptivo y modificarlo mediante profundidad, tamaño de núcleo y dilatación [28]. En cada rama, D_j detectará patrones locales; I_j integrará esas activaciones hasta alcanzar el campo receptivo asignado; y A_j ajustará, cuando sea necesario, longitud y número de canales sin alterar la correspondencia temporal. Cada rama entregará $Z_j \in \mathbb{R}^{L_j \times c_j}$, donde c_j es su número de canales de salida. Si hay submuestreo, la regla de alineación, su costo y la marca temporal de cada salida se declararán antes de entrenar.

La variante principal consolidará las salidas —alineación y concatenación por instante—, aplicará un núcleo temporal común (el mezclador temporal de la representación conjunta, que puede reducir canales conservando el eje temporal) y proyectará su último estado a los horizontes de pronóstico. En la aplicación de aprendizaje por refuerzo, ese mismo núcleo alimentará las salidas de política y/o valor según el algoritmo elegido, sin obligar a compartir una sola red entre actor y crítico. En el contraste mecanístico de H3, un extractor compartido producirá las mismas salidas de rama para las dos variantes y permanecerá congelado: una conservará las secuencias hasta la fusión y la otra resumirá cada rama antes de concatenarla. Se ajustarán únicamente sus módulos de fusión y cabezales bajo presupuestos comparables. Este contraste atribuirá el efecto a la forma de fusionar una representación común. El contraste principal de H1 utilizará el régimen de aprendizaje elegido durante E1 y fijado antes de la evaluación confirmatoria, aplicado de manera idéntica al método y a sus controles. Se publicarán por separado parámetros, operaciones y memoria de activaciones.

La Figura 2 sitúa el detector como submódulo inicial del extractor, no como una red distinta por obligación.

Se distinguirán tres regímenes, comparables en arquitectura e información de entrada:

Régimen	Inicialización de D_j	Ajuste con el predictor
R0	aleatoria	detector y predictor se ajustan juntos
R1	codificador preentrenado	detector congelado; resto ajustable
R2	el mismo codificador preentrenado	detector y resto ajustables




Figura 2: Arquitectura conceptual. Las líneas discontinuas representan decisiones de diseño obtenidas con entrenamiento; las líneas continuas muestran el flujo de tensores. Cada rama recibe $X_{:,G_j}$, el detector reconoce patrones locales, el integrador reúne contexto y la adaptación alinea las secuencias antes de fusionarlas. Fuente: elaboración propia.

Cuando se use preentrenamiento, un decodificador auxiliar Q_j reconstruirá la entrada o los elementos ocultos por una máscara definida previamente. Una reconstrucción ordinaria no se presentará como eliminación de ruido. La pareja codificador–decodificador se conservará como artefacto reproducible; el predictor utilizará el codificador y guardará por separado cualquier copia reajustada. En R1 se verificará que los pesos del detector permanezcan invariantes durante el ajuste del predictor. En R2 se comprobarán su conexión diferenciable con la pérdida final y la actualización efectiva de sus parámetros mediante una prueba controlada. También se declarará el tratamiento de estados no entrenables. Entrenar sobre activaciones guardadas en un archivo será tratado como extracción fija, no como ajuste de extremo a extremo [29].

Los tres regímenes se examinarán durante E1. Antes de E2 se congelará uno para el contraste principal y se aplicará de manera idéntica al método y a sus controles. Los resultados de desarrollo no sostendrán por sí solos una conclusión sobre las ventajas del preentrenamiento.

Una segunda familia de bloques, probablemente basada en parches, se incorporará solo como análisis de robustez si el piloto demuestra que el presupuesto permite separar el efecto de la regla del efecto del operador.

Las restricciones comprobables —causalidad, dimensiones, disponibilidad y memoria máxima— se aplicarán antes de entrenar. Las decisiones heurísticas —agrupación, escala y ancho— se evaluarán durante el desarrollo. Las variantes construidas con el mismo contrato compartirán rangos de ajuste. Los comparadores externos conservarán espacios compatibles con sus implementaciones de referencia, predeclarados y sujetos al mismo límite de recursos de selección. La Figura 3 resume qué queda fijo antes de la confirmación y qué se aprende dentro de una tarea nueva.




Figura 3: Protocolo confirmatorio. Las decisiones generales se fijan con familias de desarrollo. En cada tarea nueva, los perfiles se estiman y los pesos se entrenan con el segmento de entrenamiento; la validación selecciona configuraciones y puntos de parada. La prueba se usa exclusivamente en la campaña predeclarada y no modifica el procedimiento. Fuente: elaboración propia.

4.3. Fases experimentales

Tabla 1: Fases y función de cada fuente de evidencia.

Fase	Datos	Propósito	Uso en el estudio
E0	Señales sintéticas multicomponente	Desarrollar y calibrar perfiles; probar mecanismos con una reserva separada.	Desarrollo y pruebas reservadas de H2 y H3.
E1	Familias públicas de desarrollo	Elegir opciones finitas, régimen R0/R1/R2, presupuesto y márgenes.	Desarrollo del procedimiento.
E2	Familias públicas reservadas	Probar H1 con la regla congelada y repetir los análisis de transferencia.	Evaluación confirmatoria principal.
E3	Datos financieros históricos con procedencia y particiones fijadas	Integrar la representación en un agente RL del sistema existente y compararla con su representación de referencia bajo el mismo protocolo.	Evaluación aplicada obligatoria; análisis separado de H1–H3.

E0 combinará procesos autorregresivos, componentes periódicos, tendencias y eventos localizados. Un primer factor variará la separación entre escalas con tamaño y ruido constantes. Un segundo comparará sistemas con acoplamiento cruzado rezagado frente a controles contruados con realizaciones independientes de los mismos procesos. Esos controles conservarán, en distribución, las leyes temporales marginales, el tamaño de muestra y el ruido, pero eliminarán el vínculo cruzado previsto; esta propiedad se comprobará mediante replicación antes de usar el contraste. Las permutaciones temporales se reservarán, en todo caso, como pruebas de estrés y no como control causal principal.

E0 se dividirá en generadores de desarrollo y una reserva sintética para H2 y H3. Los primeros podrán usarse durante E1. Las ecuaciones, rangos y semillas de la reserva se fijarán antes de ajustar la regla, pero sus resultados permanecerán cerrados hasta congelar, al final de E1, perfiles, regla, arquitectura, régimen y contrastes. También habrá casos no estacionarios y mal especificados para observar cuándo los perfiles dejan de ser identificables. El ruido aditivo tendrá magnitud conocida, pero esa construcción no se extrapolará como una medida de «señal verdadera» en datos reales.

El censo de E1 y E2 considerará conjuntos públicos de energía, clima, tráfico y otros dominios incluidos en TFB, Monash y GIFT-Eval [30], [31], [32]. Una unidad será elegible solo si contiene variables no duplicadas observadas conjuntamente y permite comparar al menos dos particiones distintas, además de tener frecuencia documentada, licencia compatible, historia suficiente para las particiones previstas y un denominador MASE no nulo en entrenamiento. Los conjuntos univariados podrán servir para comprobar la implementación de referencias, pero no probarán las hipótesis sobre agrupación. Familias, horizontes y particiones se congelarán antes de puntuar E2. La separación se hará por dominio y fuente, no repartiendo al azar ventanas del mismo conjunto entre desarrollo y confirmación.

E3 integrará la representación modular en un agente de aprendizaje por refuerzo de la plataforma existente. Se elegirá durante el desarrollo un algoritmo compatible y una tarea financiera histórica acotada. El contraste principal de esta aplicación mantendrá constantes el entorno, las observaciones disponibles, la recompensa, el espacio de acciones, el calendario de entrenamiento y el presupuesto de selección, y cambiará la representación de entrada. Se verificarán el ensamblaje y el régimen efectivo de actualización de parámetros; la decisión de compartir o separar representaciones entre actor y crítico se declarará según el algoritmo elegido, como corresponde a políticas con extractores configurables [33]. La evaluación utilizará métricas de desempeño financiero y riesgo definidas sobre una trayectoria contable común y se informará separadamente de los contrastes públicos de pronóstico. Cuando existan datos, código y protocolo recuperables de un estudio publicado pertinente —los primeros candidatos de inspección son los bancos de aprendizaje por refuerzo financiero TradeMaster y FinRL-Meta [34], [35]—, se incorporará una comparación bajo ese protocolo; las diferencias no reproducibles se declararán expresamente. Si no se recupera un comparador publicado con artefactos suficientes, E3 seguirá siendo obligatoria sobre la tarea propia y la comparación bibliográfica financiera se informará como no realizada, sin sustituirla por cifras incomparables. El análisis de E3 será

aplicado, predeclarado y separado: no se añade a la familia inferencial de H1–H3 ni la modifica retrospectivamente.

5. Diseño de evaluación

5.1. Comparadores y ablaciones

El conjunto mínimo incluirá:

1. pronóstico estacional ingenuo y DLinear como pisos de complejidad;
2. PatchTST e iTransformer como referencias de independencia y dependencia entre variables;
3. DUET como vecino directo de agrupación temporal y de canales, y un método multiescala elegido entre MTST, Pathformer o TimeMixer antes de observar E1;
4. una TCN monolítica y una modular con grupos aleatorios, ambas construidas con el mismo contrato del método;
5. ablaciones que permutan la asignación entre variables y perfiles, fijan un campo receptivo común y adelantan el resumen temporal.

El control permutado aleatorizará qué variables ocupan los grupos definidos por los perfiles. Mantendrá el número y tamaño de las ramas, el repertorio de campos receptivos, la interfaz, los objetivos y el presupuesto del diseño informado; nunca permutará conjuntamente datos, objetivos y módulos de manera que el cambio sea solo nominal. Sus realizaciones y desempates se fijarán antes de abrir la reserva.

MSGNet o CCM se incorporará como análisis de robustez si su interfaz y costo permiten una comparación limpia. No se ejecutarán todos los modelos publicados ni el producto cartesiano de regímenes, familias y ablaciones. Cada comparador tendrá una función: establecer un piso, aislar modularidad, aislar la regla informada o enfrentar el vecino directo. El monolítico, el modular aleatorio y el método recibirán la misma cinta de semillas, búsqueda de hiperparámetros y régimen de aprendizaje. Sus parámetros se igualarán dentro de una tolerancia fijada por el piloto; si esa igualdad oculta diferencias grandes de tiempo o memoria, se informará además la frontera entre error y costo.

5.2. Selección de tareas públicas y comparabilidad con la literatura

La selección de conjuntos seguirá el orden pregunta y mecanismo → resultado publicado pertinente → tarea y protocolo → artefactos → elegibilidad del conjunto; no se elegirán datos por popularidad aislada ni después de observar dónde gana el método propio. Para cada candidato se localizará la tabla o figura publicada con su protocolo ejecutable (artículo, suplemento, código y configuración), se verificará la pertinencia del conjunto para el mecanismo estudiado, se identificarán exactamente datos y particiones —con copia o manifiesto con *hashes* cuando sea posible— y se comprobará su compatibilidad con la separación entre familias de desarrollo y prueba reservada; las variantes de un mismo origen no se contarán como familias independientes. Antes de atribuir diferencias al método se reproducirá al menos una referencia, con una tolerancia de reproducción fijada por precisión numérica y variación entre ejecuciones, nunca después de observar el resultado propio. La selección se congelará antes de ejecutar la comparación reservada; el número suficiente de familias lo establecerán el censo y el piloto, no una cifra fijada de antemano.

Se distinguirán tres afirmaciones que no deben mezclarse: la *reproducción* de un resultado publicado con sus artefactos recuperados; la *comparación controlada* de métodos bajo un protocolo común declarado, que no equivale automáticamente al benchmark original si lo modifica; y la *aplicación al sistema propio*, cuya utilidad no permite comparar directamente contra cifras obtenidas en otros mercados o simuladores. Comparar modelos diferentes es legítimo —esa es la comparación—, pero cuando la atribución al diseño de la representación sea central se incluirá un control con información y actualización equivalentes; si cambian a la vez algoritmo, información, entorno o actualización, la atribución será al sistema completo. Se conservará MASE y su agregación para H1 y se añadirán las métricas exactas del protocolo publicado (por ejemplo, MSE o MAE con su escala y reducción especificadas), sin sustituir unas por otras ni mezclar sus márgenes; si la política rodante propia difiere del protocolo de prueba publicado, las referencias se volverán a ejecutar bajo la política propia y el resultado se rotulará como adaptación, no como reproducción. Un mismo nombre de conjunto no demuestra identidad de datos: cuando falte un *snapshot* idéntico se consignará «identidad de datos no verificada», las contradicciones entre artículo, suplemento y código se registrarán con la versión adoptada, y una media publicada sin dispersión suficiente no sostendrá afirmaciones de

significación. La ficha de comparabilidad completa —identidad de datos, universo, tiempo, particiones, disponibilidad, preprocesamiento, entrenamiento, actualización, simulador, ejecución, contabilidad, métricas, incertidumbre y código— y el inventario inicial de candidatos se mantienen en el protocolo de comparabilidad y aplicación RL, documento auxiliar versionado del repositorio.

5.3. Medidas, incertidumbre y costo

La métrica primaria será el error absoluto medio escalado (MASE) [36]. Para el objetivo k y el origen o , con n_o observaciones de entrenamiento y período estacional m_k , se definirán

$$a_{k,o} = \frac{1}{n_o - m_k} \sum_{u=m_k+1}^{n_o} |y_{k,u} - y_{k,u-m_k}|, \quad \text{MASE}_{k,o} = \frac{H^{-1} \sum_{h=1}^H |y_{k,n_o+h} - \hat{y}_{k,n_o+h}|}{a_{k,o}}. \quad (5)$$

Cada variable objetivo y cada origen tendrán así un denominador propio, calculado únicamente con su segmento de entrenamiento y compartido por todos los métodos. Los errores escalados se promediarán después con los pesos definidos en §3.3. Si cualquiera de los denominadores exigidos es cero, la tarea se marcará como no evaluable para H1 antes de examinar sus errores de prueba; no se sustituirá por una constante elegida después. MAE y error cuadrático se informarán como secundarios, junto con desempeño por horizonte, estabilidad entre semillas y error en eventos cuando exista una definición previa.

El período estacional m_k se tomará de los metadatos del conjunto o de una regla congelada en E1; nunca se elegirá con la prueba. Para la ecuación siguiente, C representará energía consumida, medida en Wh con un instrumento fijado y validado durante E1:

$$C_{\text{total}} = \sum_{t,o} C_{\text{perfil},t,o} + \sum_{t,m,s,o} (C_{\text{pre}} + C_{\text{ajuste}} + C_{\text{eval}})_{t,m,s,o}, \quad (6)$$

donde m , s y o identifican método, semilla y origen de evaluación. C_{ajuste} incluirá todos los candidatos de la búsqueda, la selección por validación, las paradas tempranas y los intentos fallidos que consuman recursos, no solo el modelo ganador. El preentrenamiento por tarea y su decodificador se incluirán en cada celda correspondiente. Si un codificador compartido se reutiliza, se publicarán por separado su costo inicial, el costo marginal y el acumulado, junto con la regla de asignación del trabajo compartido.

El tiempo de pared, la suma de horas de CPU y GPU, las operaciones estimadas y el máximo de memoria por ejecución se informarán por separado, identificando hardware y concurrencia. La memoria máxima y las duraciones de trabajos paralelos no se sumarán como si fueran energía o tiempo de pared. El costo de desarrollar la regla en E1 se distinguirá del costo de aplicarla en una tarea nueva. Una mejora obtenida con más capacidad o más cómputo no se atribuirá únicamente al diseño estructural.

Las repeticiones por semilla y origen se agregarán dentro de cada tarea. Para el efecto global, un bootstrap jerárquico re-muestreará familias, conjuntos y tareas; para cada efecto por familia mantendrá fija la familia y re-muestreará sus conjuntos y tareas. En H2 y H3 se re-muestrearán configuraciones del generador y repeticiones, conservando juntas todas las variantes pareadas de cada unidad sintética. Los métodos permanecerán pareados y, cuando se remuestreen errores temporales, se conservarán bloques contiguos. Los $K = F + 4$ intervalos confirmatorios definidos en §3.3 usarán el ajuste de Bonferroni. Su cobertura y sensibilidad al tamaño de bloque se estudiarán mediante simulación durante E1, sin escoger después la variante más favorable. H2 estimará además la asociación exploratoria entre $q(X)$ y la diferencia pareada entre la asignación informada y su permutación. Se publicarán intervalos y efectos por tarea y familia, no solo promedios.

Las particiones serán cronológicas y seguirán una política rodante predeclarada, con horizontes de prueba no solapados cuando la longitud lo permita [37]. La regla general permanecerá congelada; antes de cada origen se volverán a estimar perfiles y pesos únicamente con los datos entonces disponibles. Una observación evaluada en un origen anterior podrá incorporarse a entrenamientos posteriores cuando ya sea observable, bajo la misma política para todos los métodos. Los resultados de prueba no modificarán la regla, los espacios de ajuste ni los criterios de parada. La separación entre selección y evaluación busca reducir el sesgo de selección [3]; la dependencia restante entre errores se tratará mediante el remuestreo declarado.

5.4. Criterios de decisión

H1 se juzgará contra un comparador principal elegido durante el desarrollo y congelado antes de E2. H2 y H3 usarán contrastes pareados dentro de la misma tarea sintética. Para cada intervalo ajustado $[L, U]$ de una diferencia expresada de manera que los valores negativos favorezcan al método, se declarará *beneficio práctico* si $U < -\varepsilon$, *equivalencia práctica* si $[L, U] \subseteq [-\varepsilon, \varepsilon]$, y *perjuicio práctico* si $L > \varepsilon$; cualquier otro caso será *inconcluso*.

H1 requerirá beneficio práctico en el efecto global y no inferioridad por familia, definida por $U_f \leq \varepsilon$. H2 se decidirá por $U_\beta < 0$ y H3 por $U_{d_1} < -\varepsilon$ junto con $U_\gamma < 0$, según sus definiciones en §3.3. Un análisis por exclusión de cada conjunto se publicará como sensibilidad, no como una segunda regla de significación. El análisis de E1 fijará el tamaño de banco necesario; si no puede alcanzar la precisión prevista, el contraste afectado se declarará inconcluso en lugar de ampliar datos o modelos después de conocer el resultado.

6. Viabilidad, ética y plan de trabajo

6.1. Recursos y relación con el sistema existente

El trabajo parte de cuatro GPU propias de capacidades diferentes, CPU local, software funcional para datos, preprocesamiento, modelos y registro de experimentos, y experiencia previa con campañas reproducibles. La disponibilidad simultánea no se presupone. La generación sintética y los diagnósticos no neuronales de E0 se ejecutarán en CPU; sus contrastes neuronales usarán el mismo contrato de recursos que las demás comparaciones. E1 reducirá el espacio antes de reservar cómputo confirmatorio. El costo se medirá con pilotos y no se estimará multiplicando una sola corrida por toda la tesis.

La implementación previa permite exportar codificadores y decodificadores y declarar el reajuste de extractores, pero todavía deberá demostrarse el flujo de gradientes del modelo compuesto. Esa verificación es una tarea inicial de ingeniería, no evidencia a favor de las hipótesis. La integración y evaluación E3 en el sistema de aprendizaje por refuerzo usará datos históricos y un protocolo separado, con presupuesto reservado desde el piloto —la forma de cumplirla con recursos limitados es acotar la campaña durante el desarrollo, no eliminarla al final—; no intervendrá en la selección del método ni de los comparadores principales de pronóstico. DOIN y la infraestructura de optimización existente se utilizarán como infraestructura, sin reconstruirlas como parte de la tesis.

6.2. Cronograma de seis semestres

Tabla 2: Plan de trabajo y productos verificables.

Sem.	Trabajo principal	Producto
1	Revisión sistemática, contrato formal, banco y piloto de precisión/costo; inicio del inventario de artefactos para la comparación con literatura.	Protocolo registrado y artículo de revisión o diseño.
2	Implementación del perfil, regla y arquitectura; E0 de desarrollo completo y reserva sintética cerrada; verificación del flujo de gradientes del modelo compuesto y prueba inicial de su interfaz con el agente de RL.	Software reproducible, estudio de identificabilidad y prueba de interfaz con el agente.
3	E1 en familias públicas; recorte de descriptores y comparadores; fijación del protocolo aplicado de E3 (agente, identidad de datos y recursos).	Artículo metodológico, diseño E2 congelado y protocolo E3 fijado.
4	Reserva sintética de H2/H3 y E2 con el procedimiento congelado; auditoría de reproducibilidad.	Artículo principal con resultados positivos, negativos o inconclusos.
5	Integración final y evaluación histórica E3 del agente RL con representación de referencia y propuesta; comparación con protocolo financiero publicado cuando sus artefactos sean recuperables.	Implementación y evaluación E3 obligatorias; el artículo aplicado depende del resultado y del calendario editorial.
6	Integración, réplica independiente, tesis y defensa.	Tesis, artefactos y documentos de reproducibilidad.

El mínimo defendible comprende el contrato, las pruebas mecanísticas, la evaluación pública y una integración evaluada en el sistema de RL existente. Si faltan recursos, se retirarán primero la segunda familia de bloques, los comparadores opcionales y las ampliaciones de activos, algoritmos o períodos. E3 conservará una tarea, un agente y el contraste entre representación de referencia y propuesta. No se retirarán la separación entre desarrollo y prueba, los controles centrales ni la contabilidad de costos.

6.3. Riesgos y ética

El mayor riesgo científico es que los perfiles temporales no anticipen qué diseño ayuda. La evidencia de equivalencia o perjuicio delimitará la utilidad del mecanismo en las condiciones evaluadas; un resultado inconcluso señalará los límites de la evidencia disponible, sin demostrar ausencia de efecto. Otro riesgo es que un antecedente equivalente elimine la brecha; en ese caso se adoptará como comparador y se estrechará la pregunta antes de E2. También puede ocurrir que los bancos públicos no contengan suficiente heterogeneidad o que los resultados dependan del dominio; la separación por familias hará visible esa limitación.

Los experimentos principales usarán datos públicos con sus licencias y datos sintéticos sin participantes humanos. No se recopilarán decisiones clínicas, datos personales ni intervenciones sobre usuarios. La validación financiera será histórica. Se publicarán configuraciones fallidas, consumo computacional y resultados nulos para reducir repetición innecesaria de cómputo. El preentrenamiento usará solo particiones permitidas; todo corpus previo compartido se declarará con su posible solapamiento, y una familia vista durante preentrenamiento no se presentará después como completamente nueva.

7. Contribuciones esperadas

La investigación busca cinco contribuciones acotadas:

1. un procedimiento que traduzca perfiles temporales estimados sin datos futuros en grupos de variables y campos receptivos para una representación modular;
2. una caracterización experimental de cuándo la heterogeneidad de escalas y las dependencias rezagadas hacen útil esa composición, y cuándo no pueden identificarse con los datos disponibles;
3. evidencia que separe el efecto del diseño estructural del efecto de la modularidad, el preentrenamiento y la capacidad computacional;
4. un protocolo reproducible, con comparadores actuales y costos completos, para evaluar transferencia a tareas y familias no usadas durante el desarrollo;
5. una integración evaluada de la representación modular en un agente de aprendizaje por refuerzo del sistema existente, contrastada con su representación de referencia bajo un protocolo financiero histórico predeclarado, cuyo resultado —positivo, negativo o inconcluso— se informará con sus costos y condiciones de fallo.

El aporte no se atribuirá al uso de autoencoders, a la existencia de varias ramas ni a la reutilización de pesos. Se evaluará un vínculo concreto entre perfiles calculados en entrenamiento, agrupación y campo receptivo. Si no se demuestra una ventaja frente a la asignación no informada, se distinguirán equivalencia, perjuicio e incertidumbre y se comparará la relación entre error y costo de las alternativas efectivamente evaluadas.

Referencias

- [1] Y. Bengio, A. Courville y P. Vincent, «Representation Learning: A Review and New Perspectives,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, n.º 8, págs. 1798-1828, 2013. DOI: 10.1109/TPAMI.2013.50
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. dirección: <https://www.deeplearningbook.org/>
- [3] G. C. Cawley y N. L. C. Talbot, «On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation,» *Journal of Machine Learning Research*, vol. 11, n.º 70, págs. 2079-2107, 2010. dirección: <https://jmlr.org/papers/v11/cawley10a.html>

-
- [4] A. Zeng et al., «Are Transformers Effective for Time Series Forecasting?» *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 9, págs. 11 121-11 128, 2023. DOI: 10.1609/aaai.v37i9.26317
- [5] Y. Nie et al., «A Time Series is Worth 64 Words: Long-term Forecasting with Transformers,» en *International Conference on Learning Representations*, 2023. dirección: <https://openreview.net/forum?id=Jbdc0vTOcol>
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting,» en *International Conference on Learning Representations*, 2024. dirección: <https://openreview.net/forum?id=JePfAI8fah>
- [7] H. Wu et al., «TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis,» en *International Conference on Learning Representations*, 2023. dirección: https://openreview.net/forum?id=ju_Uqw384Oq
- [8] Y. Zhang et al., «Multi-resolution Time-Series Transformer for Long-term Forecasting,» en *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, ép. *Proceedings of Machine Learning Research*, vol. 238, 2024, págs. 4222-4230. dirección: <https://proceedings.mlr.press/v238/zhang24l.html>
- [9] P. Chen et al., «Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting,» en *International Conference on Learning Representations*, 2024. dirección: <https://openreview.net/forum?id=IJkOCMP2aW>
- [10] S. Wang et al., «TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting,» en *International Conference on Learning Representations*, 2024. dirección: <https://openreview.net/forum?id=7oLshfEIC2>
- [11] W. Cai et al., «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting,» en *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, 2024, págs. 11 141-11 149. DOI: 10.1609/aaai.v38i10.28991
- [12] J. Chen et al., «From Similarity to Superiority: Channel Clustering for Time Series Forecasting,» en *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-4152
- [13] X. Qiu et al., «DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting,» en *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2025, págs. 1185-1196. DOI: 10.1145/3690624.3709325
- [14] G. Yu et al., «Revitalizing Multivariate Time Series Forecasting: Learnable Decomposition with Inter-Series Dependencies and Intra-Series Variations Modeling,» en *Proceedings of the 41st International Conference on Machine Learning*, ép. *Proceedings of Machine Learning Research*, vol. 235, 2024, págs. 57 818-57 841. dirección: <https://proceedings.mlr.press/v235/yu24s.html>
- [15] J. Lu et al., «CATS: Enhancing Multivariate Time Series Forecasting by Constructing Auxiliary Time Series as Exogenous Variables,» en *Proceedings of the 41st International Conference on Machine Learning*, ép. *Proceedings of Machine Learning Research*, vol. 235, 2024, págs. 32 990-33 006. dirección: <https://proceedings.mlr.press/v235/lu24d.html>
- [16] G. Woo et al., «CoST: Contrastive Learning of Disentangled Seasonal-Trend Representations for Time Series Forecasting,» en *International Conference on Learning Representations*, 2022. dirección: <https://openreview.net/forum?id=PilZY3omXV2>
- [17] L. Yang y S. Hong, «Unsupervised Time-Series Representation Learning with Iterative Bilinear Temporal-Spectral Fusion,» en *Proceedings of the 39th International Conference on Machine Learning*, ép. *Proceedings of Machine Learning Research*, vol. 162, 2022, págs. 25 038-25 054. dirección: <https://proceedings.mlr.press/v162/yang22e.html>
- [18] M. Ravanelli e Y. Bengio, «Speaker Recognition from Raw Waveform with SincNet,» *arXiv preprint arXiv:1808.00158*, 2018. DOI: 10.48550/arXiv.1808.00158
- [19] N. Zeghidour et al., «LEAF: A Learnable Frontend for Audio Classification,» en *International Conference on Learning Representations*, 2021. dirección: <https://openreview.net/forum?id=jM76BCb6F9m>
- [20] J. Schlüter y G. Gutenbrunner, «EfficientLEAF: A Faster Learnable Audio Frontend of Questionable Use,» *arXiv preprint arXiv:2207.05508*, 2022. DOI: 10.48550/arXiv.2207.05508

-
- [21] P. Montero-Manso et al., «FFORMA: Feature-based Forecast Model Averaging,» *International Journal of Forecasting*, vol. 36, n.º 1, págs. 86-92, 2020. DOI: 10.1016/j.ijforecast.2019.02.011
- [22] Z. Liang e Y. Sun, «Evolutionary Neural Architecture Search for Multivariate Time Series Forecasting,» en *Proceedings of the 15th Asian Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 222, 2024, págs. 771-786. dirección: <https://proceedings.mlr.press/v222/liang24a.html>
- [23] R. Leppich et al., «Decomposing the Time Series Forecasting Pipeline: A Modular Approach for Time Series Representation, Information Extraction, and Projection,» *arXiv preprint arXiv:2507.05891*, 2025. DOI: 10.48550/arXiv.2507.05891
- [24] Y. Bengio et al., «Greedy Layer-Wise Training of Deep Networks,» en *Advances in Neural Information Processing Systems*, vol. 19, 2007. dirección: https://proceedings.neurips.cc/paper_files/paper/2006/file/5da713a690c067105aeb2fae32403405-Paper.pdf
- [25] Z. Li et al., «Ti-MAE: Self-Supervised Masked Time Series Autoencoders,» *arXiv preprint arXiv:2301.08871*, 2023. DOI: 10.48550/arXiv.2301.08871
- [26] H. Bastidas, *Gestor de autoencoder en feature-extractor*, https://github.com/harveybc/feature-extractor/blob/df86252a174a1f5b9f77f4cb1bcb78fcdfe429e8/app/autoencoder_manager.py, Inspección estática; commit df86252; consultado el 7 de septiembre de 2026, 2026.
- [27] H. Bastidas, *Configuración de carga de extractor y train_fe*, https://github.com/harveybc/predictor/blob/20ec57145b4ed3eb647eabe2b7591f35a3dbbf47/examples/config/phase_3_1/phase_3_1_cnn_25200_1h_config.json, Evidencia de configuración, no de flujo de gradientes; commit 20ec571; consultado el 7 de septiembre de 2026, 2026.
- [28] S. Bai, J. Z. Kolter y V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling,» *arXiv preprint arXiv:1803.01271*, 2018. DOI: 10.48550/arXiv.1803.01271
- [29] Keras Team, *Transfer learning & fine-tuning*, https://keras.io/guides/transfer_learning/, Documentación oficial; consultada el 7 de septiembre de 2026, 2023.
- [30] X. Qiu et al., «TFB: Towards Comprehensive and Fair Benchmarking of Time Series Forecasting Methods,» *Proceedings of the VLDB Endowment*, vol. 17, n.º 9, págs. 2363-2377, 2024. DOI: 10.14778/3665844.3665863
- [31] R. Godahewa et al., «Monash Time Series Forecasting Archive,» en *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2021. dirección: <https://openreview.net/forum?id=I0117rc0jcb>
- [32] T. Aksu et al., «GIFT-Eval: A Benchmark for General Time Series Forecasting Model Evaluation,» *arXiv preprint arXiv:2410.10393*, 2024. DOI: 10.48550/arXiv.2410.10393
- [33] A. Raffin et al., «Stable-Baselines3: Reliable Reinforcement Learning Implementations,» *Journal of Machine Learning Research*, vol. 22, n.º 268, págs. 1-8, 2021. dirección: <http://jmlr.org/papers/v22/20-1364.html>
- [34] S. Sun et al., «TradeMaster: A Holistic Quantitative Trading Platform Empowered by Reinforcement Learning,» en *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*, 2023. dirección: https://proceedings.neurips.cc/paper_files/paper/2023/file/b8f6f7f2ba4137124ac976286eac6b11-Paper-Datasets_and_Benchmarks.pdf
- [35] X.-Y. Liu et al., «FinRL-Meta: Market Environments and Benchmarks for Data-Driven Financial Reinforcement Learning,» en *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*, 2022. dirección: https://papers.neurips.cc/paper_files/paper/2022/file/0bf54b80686d2c4dc0808c2e98d430f7-Paper-Datasets_and_Benchmarks.pdf
- [36] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy,» *International Journal of Forecasting*, vol. 22, n.º 4, págs. 679-688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001
- [37] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.^a ed. OTexts, 2021, Sección 5.10: evaluación con origen rodante. dirección: <https://otexts.com/fpp3/tscv.html>