

Diseño y aprendizaje de representaciones temporales modulares

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje de representaciones · series temporales · arquitectura modular · pronóstico multivariado · aprendizaje por refuerzo · generalización

Resumen

Una serie temporal multivariada reúne variables cuyos ritmos de cambio, periodicidades y relaciones pueden ser distintos. Algunos modelos procesan todas las variables con la misma ventana y el mismo extractor; otros incorporan varias escalas mediante una arquitectura elegida de antemano o una búsqueda de configuraciones que puede ser costosa. Esta propuesta estudiará si las propiedades temporales de los datos de entrenamiento permiten orientar esas decisiones de diseño.

Se diseñará una *representación temporal modular* formada por ramas que procesan grupos de variables. En cada rama, un detector reconoce patrones locales, un integrador incorpora contexto temporal y una adaptación opcional prepara la salida para combinarla con las demás ramas. Un consolidador alinea y concatena las secuencias; un núcleo temporal combina la información y puede reducir el número de características por instante conservando el eje temporal. Los cabezales de salida se adaptan a la tarea: pronóstico de varios pasos futuros o, en aprendizaje por refuerzo, selección de acciones o estimación de funciones de valor. El procedimiento analizará las propiedades temporales de los datos de entrenamiento para proponer grupos de variables y determinar cuánto contexto temporal procesará cada rama. El modelo podrá entrenarse desde cero o incorporar detectores preentrenados, cuyos pesos podrán mantenerse fijos o continuar ajustándose durante el entrenamiento del modelo completo. La Figura 1 presenta sus componentes.

El estudio combinará señales sintéticas con estructura conocida y tareas de series temporales multivariadas seleccionadas de la literatura por su pertinencia y por disponer de resultados y protocolos de comparación. El diseño basado en propiedades temporales se comparará con una arquitectura modular que no utilice esas propiedades para organizar sus ramas y con una red sin división en ramas. Se controlarán la información de entrada, el entrenamiento y los recursos, y se incluirán modelos de referencia de la literatura. La representación se integrará en las plataformas existentes de pronóstico y aprendizaje por refuerzo. En esta última se evaluará con datos financieros históricos frente a la representación actual del sistema; se añadirán comparadores publicados cuando sus datos y protocolos permitan una comparación válida. El resultado esperado es un método reproducible y una caracterización de cuándo mejora el desempeño, lo mantiene en un nivel equivalente o lo empeora. Si la evidencia es insuficiente para decidir, el resultado se declarará inconcluso.




Figura 1: Organización de alto nivel de la representación temporal modular. Las ramas procesan grupos de variables; el consolidador alinea y concatena sus secuencias, y el núcleo temporal combina la información antes de las salidas específicas de cada aplicación. B indica el número total de ramas. La reducción de características conserva el eje temporal. El detalle interno de las ramas se presenta en la Figura 2. Fuente: elaboración propia.

1. Problema y motivación

El aprendizaje de representaciones transforma las observaciones en características que facilitan una tarea, como pronosticar valores o seleccionar acciones [1, 2]. En series temporales, diseñar esa transformación exige decidir cuánto pasado proporcionar, cómo agrupar las variables, qué resolución temporal conservar y en qué etapa combinar la información. Estas decisiones están relacionadas: una capa puede reconocer patrones breves y otra integrar un contexto mayor; resumir cada variable demasiado pronto puede ocultar relaciones que aparecen con retraso entre ellas.

Una representación uniforme puede resultar insuficiente cuando las variables cambian a ritmos distintos. Explorar muchas combinaciones de ventanas y arquitecturas permite adaptarlas, pero consume recursos y aumenta el riesgo de escoger una configuración demasiado ajustada a los datos de validación [3]. La pregunta es si un análisis previo de las propiedades temporales permite orientar esa búsqueda y obtener modelos que mantengan su desempeño en datos reservados para evaluación.

El proyecto parte de experiencia con sistemas de pronóstico y aprendizaje por refuerzo para trading. En ellos se han probado extractores modulares, distintas formas de combinar sus salidas y codificadores preentrenados. La necesidad práctica es organizar mejor esas decisiones y mejorar las representaciones que reciben los modelos del sistema. Las tareas públicas permitirán comparar resultados con la literatura; la integración en la plataforma existente permitirá evaluar su utilidad en la aplicación financiera.

Pregunta de investigación. ¿En qué condiciones agrupar variables según sus propiedades temporales y adaptar el contexto que procesa cada rama mejora el pronóstico en datos reservados, frente a una red sin ramas o a una arquitectura modular organizada sin utilizar esas propiedades, con información, entrenamiento y recursos comparables?

La aplicación en aprendizaje por refuerzo se evaluará por separado, comparando la representación propuesta con la que utiliza actualmente el agente bajo las mismas condiciones de simulación histórica. Esta evaluación es necesaria porque una mejora de pronóstico no garantiza mejores decisiones ni mayor rentabilidad. El estudio también identificará situaciones en las que las propiedades estimadas sean inestables, el diseño propuesto no aporte una mejora o su costo resulte injustificado.

2. Fundamentos y trabajos relacionados

2.1. Representación temporal y componentes del modelo

Una *ventana de entrada* es el segmento histórico que se entrega al modelo. Se representará por $X_{1:L} \in \mathbb{R}^{L \times p}$, donde L es el número de instantes y p el de variables. El *campo receptivo de una activación* es la parte de esa entrada que puede influir en una salida concreta de una capa. Por ejemplo, una ventana puede contener 144 observaciones mientras una activación de la primera capa utiliza solo tres. Las capas posteriores pueden ampliar ese alcance. Cuando se hable del campo receptivo de una rama, se hará referencia al de sus activaciones de salida, medido respecto de la entrada original.

Una representación aprendida es una transformación $Z = f_\theta(X)$ cuyos pesos θ se ajustan mediante un objetivo de entrenamiento. En la arquitectura modular, las variables se distribuyen en B grupos, $G_1, \dots, G_B$. Cada grupo se procesa en una rama con un detector de patrones D_j , un integrador temporal I_j y una adaptación de salida A_j :

$$Z_j = A_j(I_j(D_j(X_{:,G_j}))) \in \mathbb{R}^{L_j \times c_j}. \quad (1)$$

Aquí $X_{:,G_j}$ contiene las variables del grupo j , L_j es la longitud de la secuencia producida y c_j es el número de características por instante, también llamadas *canales*. La adaptación puede dejar la salida sin cambios cuando las dimensiones ya sean compatibles. Los tres componentes describen funciones dentro de la rama y pueden entrenarse conjuntamente.

Antes de combinar las ramas, el consolidador establecerá qué instantes corresponden entre sus salidas y concatenará las características. Si una rama reduce su resolución temporal, L_j podrá ser distinto de L y será necesario especificar esa correspondencia. El núcleo temporal procesará la secuencia conjunta; el cabezal de pronóstico producirá $\hat{Y}_{L+1:L+H}$, las predicciones de los siguientes H pasos. En aprendizaje por refuerzo, las salidas se adaptarán al algoritmo de selección de acciones o estimación de valor. Cada aplicación utilizará un modelo entrenado para su objetivo.

2.2. Propiedades temporales para orientar el diseño

Una *escala temporal* describe la duración de un patrón o una dependencia: por ejemplo, el período de una oscilación o cuánto tarda en disminuir la semejanza entre una señal y sus valores pasados. El *perfil temporal* reunirá medidas de esas propiedades para cada variable. Se calculará exclusivamente con sus datos de entrenamiento e incluirá decaimiento de autocorrelación, distribución de energía entre frecuencias, periodicidades dominantes y estabilidad de las estimaciones entre segmentos de la serie.

Estas medidas se expresarán en unidades comparables teniendo en cuenta la frecuencia de muestreo y la longitud histórica disponible. Las frecuencias se normalizarán respecto de la frecuencia de Nyquist, equivalente a la mitad de la frecuencia de muestreo. El escalado común de los perfiles se ajustará durante el desarrollo del procedimiento y se mantendrá fijo al evaluarlo, para conservar las diferencias entre conjuntos de datos.

El perfil de una variable describe su comportamiento individual. La semejanza entre perfiles puede orientar qué variables comparten una rama, pero no demuestra una relación causal ni una dependencia con retraso entre ellas. Estas últimas se examinarán mediante un análisis separado. Tampoco se supondrá que una periodicidad observada determina por sí sola el campo receptivo óptimo: esa relación es parte de lo que se evaluará. Las señales sintéticas permitirán comprobar si los perfiles recuperan propiedades conocidas; los conjuntos públicos permitirán estudiar si esas propiedades ayudan a pronosticar.

2.3. Modelos de referencia

DLinear mostró que un modelo lineal sencillo puede superar arquitecturas más complejas en varios conjuntos de pronóstico [4]. PatchTST divide la historia en segmentos o *parches* y procesa las variables de manera independiente [5]. iTransformer representa cada variable como una unidad de entrada del mecanismo de atención para aprender relaciones entre ellas [6]. Estos trabajos justifican comparar el método tanto con referencias sencillas como con modelos que procesan las variables por separado o conjuntamente.

Varios métodos incorporan múltiples escalas. TimesNet organiza variaciones periódicas en representaciones bidimensionales [7]; MTST utiliza ramas con distintas resoluciones de parche [8]; Pathformer aprende rutas entre escalas [9]; y TimeMixer combina componentes en resoluciones finas y gruesas [10]. MSGNet aprende relaciones

entre variables que dependen de la escala [11]. CCM aprende grupos de variables mediante asignaciones y prototipos regularizados por similitud [12]; DUET combina agrupación temporal con pertenencias graduadas de las variables a grupos [13]. Leddam y CATS estudian otras formas de representar dependencias entre series [14, 15]. Por tanto, la presencia de ramas, agrupaciones o múltiples escalas ya tiene antecedentes directos.

También existen representaciones aprendidas que aprovechan propiedades de las señales. CoST separa tendencia y estacionalidad mediante aprendizaje contrastivo [16], mientras BTSF combina información temporal y espectral [17]. En audio, SincNet y LEAF incorporan operaciones de procesamiento de señales cuyos parámetros se aprenden con la tarea [18, 19]. Sin embargo, EfficientLEAF encontró que sus extractores aprendibles no superaban consistentemente un banco de filtros fijo en las tareas evaluadas [20]. Estos antecedentes motivan el diseño basado en propiedades de señales y, a la vez, la necesidad de comprobar su utilidad frente a alternativas sencillas.

2.4. Diferencia que estudiará la propuesta

FFORMA utiliza características de una serie para ponderar modelos completos de pronóstico [21]. EMTSF busca mediante evolución combinaciones de módulos espaciales y temporales [22]. REP-Net divide el procesamiento en representación, extracción y proyección y evalúa configuraciones de esas etapas [23]. DUET es un comparador especialmente cercano porque aborda tanto diferencias temporales como relaciones entre variables.

La contribución propuesta es estudiar si un perfil calculado antes de entrenar permite decidir conjuntamente la agrupación de variables y el contexto temporal de sus ramas. También se evaluará si el procedimiento sigue siendo útil en conjuntos distintos de los usados para diseñarlo. Para ello se distinguirán *familias de datos*: conjuntos relacionados por su fuente y dominio, cuyas variantes no se tratarán como evidencia independiente. El procedimiento se desarrollará con unas familias y se evaluará con otras reservadas. En cada nueva tarea se estimarán perfiles y se entrenarán pesos propios; lo que permanecerá fijo será la regla que transforma esos perfiles en una arquitectura.

La revisión inicial no identificó un método que combine esa regla previa de diseño con una evaluación entre familias reservadas y controles de capacidad, entrenamiento y costo. Esta diferencia deberá verificarse mediante la revisión sistemática del primer semestre. Si se encuentra un método equivalente, se incorporará como referencia y se delimitará la contribución antes de realizar la evaluación final.

El preentrenamiento por capas de autoencoders y la reconstrucción de valores ocultos en series temporales son antecedentes de las modalidades de entrenamiento [24, 25]. El sistema existente permite exportar por separado codificadores y decodificadores y configurar el reajuste de extractores [26, 27]. Esa experiencia facilita la implementación. La conexión del modelo completo se verificará comprobando que la señal de aprendizaje llega a los componentes que deben ajustarse y que sus pesos se actualizan.

3. Objetivos e hipótesis

3.1. Objetivo general

Desarrollar y evaluar un procedimiento que utilice propiedades temporales de los datos de entrenamiento para organizar las ramas de una representación modular y aprender sus parámetros, comprobar su utilidad en tareas públicas de pronóstico multivariado e integrarlo en las plataformas existentes de pronóstico y aprendizaje por refuerzo para trading, con evaluación explícita de desempeño y costo.

3.2. Objetivos específicos

1. Definir los componentes y las interfaces de la representación modular, y estimar propiedades temporales que orienten la agrupación de variables y el contexto de cada rama.
2. Construir una regla reproducible que organice las ramas a partir de esas propiedades y alinee sus secuencias, con entrenamiento desde cero o con detectores preentrenados fijos o ajustables.
3. Comparar el procedimiento con modelos de la literatura y variantes controladas de su arquitectura en tareas públicas reservadas, midiendo error, costo, estabilidad y condiciones de fallo.

4. Integrar la representación en un agente de aprendizaje por refuerzo de la plataforma existente y compararla con la representación actual mediante simulación financiera histórica, manteniendo controlados el algoritmo, la información, el entorno y el presupuesto de ajuste.

3.3. Hipótesis y forma de contrastarlas

Se realizarán tres pruebas: H1 evaluará el desempeño en datos públicos reservados; H2 examinará si la utilidad de la agrupación depende de las diferencias de escala; y H3 comprobará cuándo conviene conservar las secuencias hasta combinar las ramas. H2 y H3 se contrastarán principalmente con señales sintéticas cuya estructura sea conocida. Los análisis sobre datos públicos servirán como evidencia complementaria de estos dos mecanismos.

El desarrollo del procedimiento se denominará E1 y su evaluación en familias públicas reservadas, E2. E0 comprende la generación de señales sintéticas, con datos separados para desarrollo y prueba. E3 corresponde a la aplicación financiera en aprendizaje por refuerzo. La sección de fases experimentales detalla cada una.

La unidad principal de evaluación será una *tarea de pronóstico*, definida por un conjunto de datos, unas variables objetivo y un horizonte. Una misma tarea se repetirá desde distintos puntos de inicio del pronóstico, llamados *orígenes de evaluación*, y con distintas *semillas aleatorias*, que controlan la aleatoriedad del entrenamiento. Estas repeticiones no se contarán como tareas independientes.

Se utilizará el error absoluto medio escalado (MASE): el error de pronóstico dividido por un error de referencia calculado con entrenamiento. La sección 5.3 define su fórmula. Cada variable y origen tendrán un denominador propio, compartido por todos los métodos; si alguno es nulo, la tarea se informará aparte y no se usará para H1. Se promediarán los errores escalados con igual peso entre variables objetivo, pasos del horizonte, orígenes y semillas. Para cada tarea t se calculará

$$\Delta_t = \text{MASE}_{t,\text{método}} - \text{MASE}_{t,\text{control}}. \quad (2)$$

Un valor negativo favorece al método propuesto. El efecto global Δ dará igual peso a las tareas de cada conjunto, a los conjuntos de cada familia y a las familias. Así, una fuente que aporte muchas series no dominará el resultado. La estimación de incertidumbre conservará las comparaciones de métodos sobre las mismas tareas y la dependencia entre objetivos y horizontes de una fuente.

Antes de E2 se fijarán las F familias de evaluación, un margen de relevancia práctica $\varepsilon > 0$ y el nivel de error estadístico $\alpha = 0.05$. El margen expresará qué diferencia de MASE se considera relevante. El piloto comprobará si la cantidad de datos permite estimarla con precisión suficiente. Se evaluarán $K = F + 4$ efectos: el global y los F efectos por familia de H1, la pendiente de H2 y los dos contrastes de H3. Cada efecto tendrá un intervalo bilateral con cobertura nominal $1 - \alpha/K$, aplicando el ajuste de Bonferroni y el remuestreo de la sección 5.3. La cobertura y estabilidad de esos intervalos se comprobarán mediante simulación; si los datos o las simulaciones no permiten sostener su precisión, el resultado afectado se declarará inconcluso.

H1 · Utilidad de organizar las ramas mediante perfiles temporales. En familias públicas reservadas, el método reducirá el MASE frente al mejor de dos controles elegidos durante E1: una red convolucional temporal (TCN) sin división en ramas y una TCN modular cuya agrupación y campos receptivos se asignen sin utilizar los perfiles. El control principal se fijará antes de E2. Se utilizarán las mismas entradas, modalidad de entrenamiento y presupuesto de ajuste, para distinguir la utilidad del diseño de una ventaja debida exclusivamente al preentrenamiento o a más recursos. H1 se considerará respaldada si el límite superior del intervalo de Δ es menor que $-\varepsilon$ y el límite superior de cada efecto por familia es menor o igual que ε . Esto exige una mejora relevante global y ausencia de un empeoramiento mayor que el margen en cada familia. Si una familia no puede evaluarse con precisión suficiente, no se afirmará ese resultado conjunto.

H2 · Utilidad de la agrupación cuando las escalas son distintas. La ventaja del diseño basado en perfiles frente a una asignación permutada aumentará con la heterogeneidad de las escalas temporales. La permutación cambiará qué variables se asignan a los grupos, conservando las características de la arquitectura. El experimento sintético variará un nivel conocido de heterogeneidad h , manteniendo constantes el tamaño de muestra, el número de variables y la distribución del ruido. Se definirá

$$e(h) = \text{MASE}(\text{perfiles}, h) - \text{MASE}(\text{permutación}, h).$$

H2 se considerará respaldada si el límite superior del intervalo de la pendiente β de $e(h)$ respecto de h es menor que cero. Una pendiente negativa indicará que la ventaja relativa crece con la heterogeneidad, aunque por sí sola no demostrará que el método sea mejor en todos sus niveles. En datos públicos se explorará la relación entre esa diferencia de desempeño y la heterogeneidad estimada de los perfiles, definida como $q(X)$ en la sección 4.1; este análisis complementario no sustituirá el experimento con estructura conocida.

H3 · Conservación de las secuencias hasta combinar las ramas. Cuando existan relaciones conocidas con retraso entre variables, combinar las secuencias alineadas antes de resumirlas reducirá el error frente a resumir cada rama por separado antes de combinarla. Las dos variantes recibirán las mismas activaciones de un extractor entrenado con un procedimiento fijado durante E1 y mantenido sin cambios durante este contraste. Solo se ajustarán los módulos que combinan las ramas y los cabezales. Se definirá

$$d_r = \text{MASE}(\text{fusión temporal}, r) - \text{MASE}(\text{resumen temprano}, r), \quad \gamma = d_1 - d_0,$$

donde $r = 1$ indica dependencia entre variables con retraso y $r = 0$ un control que conserva el comportamiento temporal de cada variable, pero elimina esa dependencia. H3 requerirá que el límite superior del intervalo de d_1 sea menor que $-\varepsilon$ y el de γ menor que cero. Se medirá la memoria adicional necesaria para conservar las secuencias. En datos públicos se realizará un análisis complementario sobre tareas donde un diagnóstico separado, calculado con entrenamiento, identifique relaciones predictivas entre variables con retraso.

4. Método

4.1. Preparación de datos y construcción de las ramas

Cada conjunto se documentará con su fuente, frecuencia de muestreo, zona horaria cuando corresponda, variables, objetivos y momento en que cada dato está disponible. La normalización, la imputación de valores ausentes y el cálculo de perfiles se ajustarán únicamente con entrenamiento. En cada decisión se utilizará solo información disponible hasta ese instante. Una transformación que procese una ventana histórica completa será admisible si no utiliza observaciones posteriores al momento que se intenta pronosticar y todos los comparadores tienen acceso a la misma información original.

En los experimentos controlados, la entrada común será la serie normalizada, sin transformaciones adicionales específicas de un método. Para cada variable i se calculará un perfil d_i y su estabilidad entre segmentos de entrenamiento. Las medidas de retardo y frecuencia se expresarán en coordenadas comparables. Cada componente del perfil se escalará mediante estadísticas robustas ajustadas en E1 y fijadas antes de E2; $\tilde{d}_i$ denotará el perfil escalado. Se resumirá la heterogeneidad de un conjunto mediante la mediana de las distancias entre pares de perfiles:

$$q(X) = \text{mediana}_{i < k} \|\tilde{d}_i - \tilde{d}_k\|_2. \quad (3)$$

Esta medida expresa diferencias entre los perfiles utilizados por el procedimiento; no se interpretará como una medida de dificultad de pronóstico o causalidad.

Una regla A_η , cuyos parámetros de diseño son η , producirá una partición de variables G y los campos receptivos R asignados a sus ramas:

$$(G, R) = A_\eta(\tilde{d}_1, \dots, \tilde{d}_p). \quad (4)$$

La primera implementación utilizará agrupamiento jerárquico: reunirá perfiles semejantes y asignará a cada grupo el campo receptivo permitido más cercano a sus escalas dominantes. El número máximo de ramas, el umbral que determina los grupos y el conjunto finito de campos receptivos posibles se fijarán en E1. Así se obtiene una regla concreta que puede compararse con controles, sin explorar todas las arquitecturas posibles.

Si el perfil de una variable es inestable, se asignará a una rama común y se registrará que no fue posible justificar una especialización con esos datos. Para H3 se estimarán por separado relaciones predictivas entre variables con distintos retardos. Ese diagnóstico utilizará solo entrenamiento y no modificará la regla A_η durante E2.

4.2. Arquitectura y entrenamiento

La implementación principal utilizará convoluciones temporales causales, que impiden que una activación dependa de observaciones futuras. Su campo receptivo puede controlarse mediante el número de capas, el tamaño de los filtros y la dilatación, es decir, la separación entre las posiciones que utiliza el filtro [28]. En cada rama, el detector D_j reconocerá patrones locales y el integrador I_j combinará sus activaciones hasta alcanzar el contexto temporal asignado. Cuando sea necesario, la adaptación A_j ajustará la longitud de la secuencia o el número de características para que las salidas puedan combinarse. Si cambia la resolución temporal, se especificarán antes de entrenar las marcas temporales, la regla de alineación y su costo.

El consolidador alinearán las secuencias y concatenará sus características en cada instante. El núcleo temporal procesará la representación conjunta y podrá reducir su número de características conservando la secuencia. Para pronóstico, un cabezal transformará el último estado del núcleo en predicciones de los siguientes H pasos. En aprendizaje por refuerzo, una instancia de esta arquitectura alimentará las salidas que requiera el algoritmo. Cuando existan actor y crítico —componentes que seleccionan acciones y estiman su valor, respectivamente— se declarará si utilizan una representación compartida o representaciones separadas.

La Figura 2 muestra el procesamiento dentro de las ramas y cómo el análisis de los datos orienta su organización. La división en detector, integrador y adaptación permite especificar sus funciones y decidir qué pesos se entrenan; no exige que sean redes independientes.




Figura 2: Arquitectura conceptual. Las líneas discontinuas representan decisiones de diseño basadas en los datos de entrenamiento; las líneas continuas muestran el flujo de datos. Cada rama recibe las variables de su grupo. D_j , I_j y A_j representan el detector, el integrador y la adaptación. El bloque de alineación y fusión reúne las funciones del consolidador y el núcleo temporal de la Figura 1. Fuente: elaboración propia.

Se compararán tres modalidades de entrenamiento, identificadas como R0, R1 y R2 para facilitar su seguimiento en los experimentos:

Tabla 1: Inicialización y entrenamiento de los detectores.

Modo	Pesos iniciales del detector	Entrenamiento del modelo completo
R0	Inicialización aleatoria.	Detector y resto del modelo se ajustan juntos.
R1	Codificador preentrenado.	El detector se mantiene fijo; se ajusta el resto.
R2	El mismo codificador preentrenado que en R1.	Detector y resto del modelo continúan ajustándose.

El preentrenamiento utilizará un autoencoder: el codificador aprenderá una representación y un decodificador auxiliar reconstruirá la entrada o unos valores ocultos mediante una máscara definida previamente. La reconstrucción

ordinaria no se interpretará por sí sola como eliminación de ruido. Se conservarán el codificador y el decodificador entrenados, así como una copia separada de los pesos modificados durante el ajuste posterior.

La implementación se comprobará con pruebas de actualización de parámetros. En R1, los pesos del detector deberán permanecer fijos. En R2, se verificará que los gradientes del objetivo final lleguen al detector y modifiquen sus pesos; también se especificará cómo se tratan estados que no se actualizan mediante gradientes. Si se entrena el resto del modelo sobre características guardadas en un archivo, se considerará extracción fija, porque ese procedimiento no actualiza el codificador [29].

Las tres modalidades se examinarán durante E1. Una de ellas se elegirá y fijará antes de E2 para el contraste principal de H1, aplicándola de la misma manera al método y a sus controles. Esto permite comparar la organización de las ramas sin dar al método una ventaja de preentrenamiento que no tengan los controles. H3 tendrá su propio contraste con un extractor común y fijo: una variante conservará las secuencias hasta combinarlas y la otra resumirá primero cada rama. Se entrenarán sus módulos de combinación y sus cabezales con presupuestos comparables.

Antes de entrenar se comprobarán disponibilidad de datos, correspondencia temporal, compatibilidad de dimensiones y memoria requerida. Durante E1 se evaluarán las decisiones de agrupación, contexto y número de características. Las variantes del método compartirán rangos de hiperparámetros; los modelos externos conservarán rangos compatibles con sus implementaciones, fijados antes de evaluar y sujetos al mismo límite de recursos de selección. Una segunda clase de bloques, posiblemente basada en parches, se incorporará solo si el piloto permite financiar una comparación que distinga el efecto de la regla del efecto del tipo de capa.

La Figura 3 distingue las decisiones que se fijan durante el desarrollo de los pesos y perfiles que se aprenden con los datos de cada tarea.




Figura 3: Separación entre desarrollo y evaluación. Las decisiones generales se fijan con los datos de desarrollo. En cada tarea nueva, los perfiles se estiman y los pesos se entrenan con el segmento de entrenamiento; la validación selecciona configuraciones y puntos de parada. Los datos de prueba se reservan para evaluar el procedimiento ya definido. Fuente: elaboración propia.

4.3. Fases experimentales

El estudio separará el desarrollo del procedimiento, las pruebas reservadas y la aplicación al sistema existente. La Tabla 2 resume el propósito de cada fase.

Tabla 2: Datos y propósito de las fases experimentales.

Fase	Datos	Propósito
E0	Señales sintéticas con estructura conocida.	Comprobar los perfiles y los mecanismos de H2 y H3, con señales separadas para desarrollo y prueba.
E1	Familias públicas de desarrollo.	Elegir la regla, las opciones de arquitectura, la modalidad de entrenamiento, los comparadores principales y los presupuestos; fijar márgenes de relevancia y comprobar precisión estadística.
E2	Familias públicas reservadas.	Contrastar H1 con el procedimiento ya fijado y estudiar su utilidad en tareas de distinto origen.
E3	Datos financieros históricos identificados y divididos de antemano.	Integrar la representación en el agente de aprendizaje por refuerzo y compararla con la actual. Es una entrega obligatoria, con análisis separado de H1–H3.

Señales sintéticas. E0 combinará procesos autorregresivos, componentes periódicos, tendencias y eventos localizados. Para H2 se variará la separación entre escalas manteniendo constantes la cantidad de datos y el ruido. Para H3 se compararán procesos con relaciones entre variables a distintos retardos y controles construidos con realizaciones independientes de esos procesos. Los controles deberán conservar, en distribución, el comportamiento temporal de cada variable, el tamaño de muestra y el ruido, eliminando la relación entre variables prevista por el generador. Esta propiedad se comprobará con repeticiones. Alterar el orden temporal de las muestras se reservará para pruebas de sensibilidad, porque también modifica el comportamiento individual de las series.

Se separarán generadores de desarrollo y una reserva sintética para H2 y H3. Las ecuaciones, los rangos y las semillas de esa reserva se fijarán antes de ajustar la regla; sus resultados no se consultarán hasta finalizar E1 y fijar perfiles, arquitectura, entrenamiento y contrastes. Se incluirán señales cuyas propiedades cambien en el tiempo y casos que incumplan los supuestos del diagnóstico, para observar cuándo deja de recuperar las escalas. En estos experimentos se conocerá el ruido añadido. Ese conocimiento no se extenderá a datos reales, donde no puede suponerse que todo residuo sea ruido.

Tareas públicas. Se examinarán conjuntos de energía, clima, tráfico y otros dominios recogidos en TFB, Monash y GIFT-Eval [30, 31, 32]. Para evaluar la agrupación, un conjunto deberá contener variables distintas observadas conjuntamente y permitir al menos dos agrupaciones de variables diferentes. También deberá tener frecuencia documentada, licencia compatible, historia suficiente para las divisiones de entrenamiento y evaluación, y denominadores de MASE no nulos en entrenamiento. Los conjuntos univariados podrán utilizarse para verificar implementaciones, pero no para probar la utilidad de agrupar variables.

Las familias, los horizontes y las divisiones temporales se fijarán antes de E2. Las variantes de una misma fuente se mantendrán en la misma familia; no se crearán familias independientes dividiendo aleatoriamente las ventanas de un conjunto. Esta separación permitirá estudiar la generalización del procedimiento, además de la evaluación habitual de cada modelo en su segmento de prueba. En las tareas reservadas se entrenarán modelos nuevos, aplicando la regla definida en E1 a sus propios datos de entrenamiento.

Aplicación al sistema de trading. Durante el desarrollo se elegirán una tarea financiera histórica acotada y un algoritmo compatible con la plataforma para E3. Se compararán la representación actual y la propuesta manteniendo constantes entorno, observaciones disponibles, recompensa, acciones posibles, calendario de entrenamiento y presupuesto de selección. Se verificarán la integración en el agente y la actualización de sus parámetros. La decisión de compartir representaciones entre actor y crítico dependerá del algoritmo, como ocurre en implementaciones con extractores configurables [33]. Se declarará cómo se incorporan la posición y el estado de cuenta del agente.

Se fijarán de antemano una medida principal de desempeño y las métricas de rentabilidad y riesgo, calculadas con las mismas reglas contables y de ejecución para ambas variantes. Las semillas y las repeticiones sobre un mismo período se analizarán teniendo en cuenta que comparten datos de mercado. Los resultados de E3 se presentarán por separado de H1–H3 y no se utilizarán para cambiar sus hipótesis o criterios después de observar la prueba.

TradeMaster y FinRL-Meta serán candidatos iniciales para localizar un experimento financiero publicado con datos, código y protocolo recuperables [34, 35]. Cuando se encuentre uno compatible, se incorporará la comparación y se documentarán las diferencias respecto del estudio original. Si no puede recuperarse, E3 se realizará de todas formas frente a la representación actual del sistema y se informará la limitación de comparación externa. La integración en la plataforma de pronóstico se apoyará en los mismos componentes y experimentos de representación, evitando duplicar evaluaciones equivalentes.

5. Evaluación y análisis de resultados

5.1. Modelos de referencia y controles experimentales

Los comparadores se elegirán por la pregunta que permiten responder:

1. El pronóstico estacional ingenuo —que repite el valor del período estacional anterior— y DLinear aportarán referencias de baja complejidad.

2. PatchTST e iTransformer permitirán comparar estrategias de procesamiento independiente y conjunto de las variables.
3. DUET será un comparador obligatorio por su proximidad a la propuesta. Antes de examinar los resultados de El se elegirá además un método multiescala entre MTST, Pathformer y TimeMixer.
4. Una TCN sin ramas y una TCN modular con asignación aleatoria se construirán bajo las mismas condiciones del método propuesto para distinguir la utilidad de las ramas de la utilidad de organizarlas mediante perfiles.
5. Se realizarán *ablaciones*, es decir, comparaciones que alteran una decisión concreta: permutar la correspondencia entre variables y perfiles, usar un campo receptivo común o resumir las ramas antes de combinarlas.

El control permutado cambiará qué variables ocupan los grupos, conservando el número y tamaño de las ramas, los campos receptivos disponibles, las dimensiones de las interfaces, los objetivos y el presupuesto. Se evitará permutar datos, objetivos y módulos conjuntamente, porque eso podría limitarse a cambiar sus nombres sin alterar el procesamiento. Las permutaciones y las reglas de desempate se fijarán antes de evaluar los datos reservados.

El método y sus dos controles arquitecturales utilizarán la misma lista de semillas, procedimiento de búsqueda de hiperparámetros y modalidad de entrenamiento. El número de parámetros se igualará dentro de una tolerancia definida en el piloto. Se reportarán además tiempo y memoria, porque una cantidad similar de parámetros no garantiza el mismo costo. Si hay diferencias importantes, se comparará también el error obtenido para distintos niveles de recursos.

MSGNet o CCM podrá añadirse si su interfaz y costo permiten una comparación adecuada. El presupuesto se concentrará en los controles necesarios para responder las hipótesis; no se probarán todas las combinaciones de modelos, modalidades de entrenamiento y conjuntos disponibles.

5.2. Selección de datos y comparación con resultados publicados

Para cada conjunto candidato se localizará un resultado publicado pertinente, su tarea, las métricas y el protocolo experimental. Se comprobarán el acceso a datos y código, las divisiones de entrenamiento y prueba, y su compatibilidad con la separación entre familias. La selección se cerrará antes de ejecutar la evaluación reservada. El número de familias necesario se determinará con el inventario y el piloto de precisión estadística.

Antes de atribuir diferencias al método se reproducirá al menos un modelo de referencia. La tolerancia de reproducción se fijará según la precisión numérica y la variación entre ejecuciones, sin ajustarla después de conocer el resultado propio. Cada comparación se identificará como reproducción del estudio original, evaluación de métodos bajo un protocolo común adaptado o aplicación al sistema propio. Si cambian simultáneamente algoritmo, información o simulador, la diferencia se atribuirá al sistema completo; para aislar el efecto de la representación se mantendrán controles con información y actualización equivalentes.

Se identificarán archivos, versiones, fechas, instrumentos, frecuencia, variables y divisiones temporales, conservando copias o registros con huellas digitales de los archivos cuando sea posible. Compartir el nombre de un conjunto no demuestra que los datos sean idénticos. Las discrepancias entre artículo, suplemento y código se documentarán junto con la versión adoptada. En trading también se comprobarán momento y precio de ejecución, comisiones, deslizamiento, restricciones y contabilidad. Un protocolo que utilice información futura deberá corregirse para todos los métodos y se presentará como una adaptación.

H1 conservará MASE y su forma de agregación. Para comparar con cada publicación se añadirán sus métricas exactas, incluidas escala y forma de promediar los errores. Si el estudio original evalúa un modelo fijo y aquí se reentrena periódicamente, sus referencias se ejecutarán también bajo esa política; las cifras resultantes no se presentarán como reproducción directa de la tabla original. Una media publicada sin información suficiente sobre su variación no bastará para afirmar una diferencia estadísticamente significativa.

La lista detallada de comprobaciones y el inventario de candidatos se encuentran en el protocolo de comparabilidad y aplicación RL. Entre las comprobaciones pendientes figuran el tratamiento de la normalización en TradeMaster y la exposición previa del proyecto a los conjuntos candidatos.

5.3. Medidas de desempeño, incertidumbre y costo

El MASE expresa el error absoluto del modelo respecto de un error de referencia calculado con entrenamiento [36]. Para la variable objetivo k y el origen de evaluación o , sean n_o el número de observaciones de entrenamiento, m_k el período estacional y H los pasos futuros evaluados. Se calcularán

$$a_{k,o} = \frac{1}{n_o - m_k} \sum_{u=m_k+1}^{n_o} |y_{k,u} - y_{k,u-m_k}|, \quad \text{MASE}_{k,o} = \frac{H^{-1} \sum_{h=1}^H |y_{k,n_o+h} - \hat{y}_{k,n_o+h}|}{a_{k,o}}. \quad (5)$$

El denominador $a_{k,o}$ es el error medio de repetir el valor de un período estacional anterior dentro del entrenamiento. Se compartirá entre todos los métodos y se promediarán después los errores escalados según la sección 3.3. El período m_k procederá de los metadatos o de una regla fijada en E1. Si algún denominador requerido es cero, la tarea se declarará no evaluable para H1 antes de examinar sus errores de prueba. Se informarán también el error absoluto medio (MAE), el error cuadrático medio (MSE), el desempeño por horizonte y la variación entre semillas; los errores en eventos específicos se medirán cuando esos eventos estén definidos previamente.

Los datos se dividirán cronológicamente y se evaluarán desde sucesivos orígenes, desplazando el punto de inicio del pronóstico según una política fijada de antemano [37]. Se usarán horizontes de prueba no solapados cuando la longitud disponible lo permita. Antes de cada origen se volverán a estimar perfiles y pesos solo con los datos entonces disponibles. Una observación ya evaluada podrá usarse en un entrenamiento posterior cuando haya pasado a formar parte del historial observable, con la misma política para todos los métodos. Los resultados de prueba no cambiarán la regla de diseño, los rangos de búsqueda ni los criterios de parada [3].

La incertidumbre se estimará mediante *bootstrap jerárquico*, un procedimiento que repite el análisis tomando muestras con reemplazo y conserva la estructura de los datos. Para el efecto global se remuestrearán familias, conjuntos y tareas; para un efecto por familia se mantendrá fija esa familia y se remuestrearán sus conjuntos y tareas. En H2 y H3 se remuestrearán configuraciones del generador y repeticiones, manteniendo juntas las variantes comparadas de cada experimento. Las semillas y los orígenes se agregarán dentro de cada tarea; si se remuestrean errores temporales, se usarán bloques contiguos para conservar su dependencia.

Los $K = F + 4$ intervalos definidos en la sección 3.3 aplicarán el ajuste de Bonferroni. Su cobertura y sensibilidad a la longitud de los bloques se estudiarán por simulación en E1, antes de examinar la evaluación final. Se publicarán efectos e intervalos por tarea y familia. El análisis complementario de H2 relacionará $q(X)$ con la diferencia de error entre la asignación basada en perfiles y su permutación.

El costo energético se medirá en vatios-hora (Wh) con un instrumento seleccionado y validado durante E1. Para tareas t , métodos m , semillas s y orígenes o , se contabilizará

$$C_{\text{total}} = \sum_{t,o} C_{\text{perfil},t,o} + \sum_{t,m,s,o} (C_{\text{pre}} + C_{\text{ajuste}} + C_{\text{eval}})_{t,m,s,o}. \quad (6)$$

Los términos corresponden al cálculo de perfiles, preentrenamiento, ajuste y evaluación. El ajuste incluirá todos los candidatos explorados, la selección por validación, las paradas tempranas y los intentos fallidos que consuman recursos. El preentrenamiento incluirá el decodificador. Si se reutiliza un codificador, se distinguirán su costo inicial, el costo adicional de cada uso y el acumulado, indicando cómo se reparte el trabajo compartido.

Se reportarán por separado el tiempo transcurrido de cada ejecución, las horas de CPU y GPU, las operaciones estimadas y la memoria máxima, junto con hardware y cantidad de trabajos simultáneos. Las duraciones de trabajos paralelos no se sumarán como si fueran tiempo transcurrido; tampoco se confundirá memoria con energía. El costo de desarrollar el procedimiento en E1 se separará del de aplicarlo a una tarea nueva. Se comprobará así si una mejora justifica sus recursos y si puede atribuirse al diseño en lugar de a una mayor capacidad o búsqueda.

5.4. Interpretación de los resultados

El margen ε permitirá distinguir relevancia práctica de una diferencia pequeña. Para una diferencia de MASE cuyo signo negativo favorezca al método y cuyo intervalo ajustado sea $[L, U]$, se aplicarán estos criterios:

- **Beneficio relevante:** $U < -\varepsilon$.
- **Equivalencia práctica:** $[L, U] \subseteq [-\varepsilon, \varepsilon]$.
- **Perjuicio relevante:** $L > \varepsilon$.
- **Resultado inconcluso:** cualquier otro caso, porque el intervalo no permite decidir entre las categorías anteriores.

H1 exigirá beneficio global y no inferioridad por familia, expresada por $U_f \leq \varepsilon$. H2 se decidirá por $U_\beta < 0$, y H3 por $U_{d_1} < -\varepsilon$ junto con $U_\gamma < 0$. El margen de MASE no se aplicará a la pendiente de H2 ni sustituirá el criterio de interacción de H3. La ausencia de evidencia de mejora no se interpretará automáticamente como equivalencia.

Se estudiará la sensibilidad del resultado retirando cada conjunto por turnos, sin utilizar ese análisis como una segunda oportunidad para declarar significación. El piloto fijará el tamaño de evaluación necesario. Si la precisión prevista no puede alcanzarse, se informará el resultado como inconcluso; no se ampliarán los datos o modelos después de observar la prueba para intentar obtener un resultado favorable.

6. Viabilidad y plan de trabajo

6.1. Recursos e integración con el sistema existente

El proyecto dispone de cuatro GPU de distintas capacidades, CPU local y software para gestionar datos, preprocesar series, entrenar modelos y registrar experimentos. La planificación tendrá en cuenta que las cuatro GPU pueden no estar disponibles simultáneamente. La generación de señales y los diagnósticos que no requieran redes neuronales se ejecutarán en CPU; el costo del resto se medirá mediante pilotos representativos.

La implementación inicial comprobará el ensamblaje de los componentes, la actualización de los pesos y las interfaces con las plataformas de pronóstico y aprendizaje por refuerzo. DOIN proporcionará la infraestructura existente de optimización y registro de experimentos. La tesis se concentrará en el procedimiento de representación y utilizará esa infraestructura para ejecutar las búsquedas de parámetros que sigan siendo necesarias.

Durante E1 se reducirá el número de configuraciones antes de reservar recursos para la evaluación final. Desde el piloto se asignará presupuesto a la integración y evaluación financiera E3. Si los recursos resultan insuficientes, se acotará esa evaluación durante el desarrollo a una tarea y un agente, manteniendo la comparación entre la representación actual y la propuesta.

6.2. Cronograma de seis semestres

La Tabla 3 resume las actividades y entregas previstas para los seis semestres.

El alcance mínimo incluirá la definición del método, las pruebas sintéticas, la evaluación pública y la integración evaluada en el sistema de aprendizaje por refuerzo. Si es necesario reducir trabajo, se retirarán primero la segunda clase de bloques, los comparadores opcionales y las ampliaciones de activos, algoritmos o períodos. Se conservarán la separación entre desarrollo y prueba, los controles principales y la medición completa de costos.

6.3. Riesgos y uso responsable de los datos

El principal riesgo científico es que las propiedades temporales estimadas no permitan anticipar una organización útil de las ramas. Los resultados de equivalencia o perjuicio delimitarán las condiciones en que el método no aporta una ventaja; los inconclusos mostrarán dónde falta evidencia. También puede ocurrir que los conjuntos disponibles no cubran suficiente variedad o que la regla funcione solo en ciertos dominios. La evaluación por familias permitirá examinar esas limitaciones.

La revisión sistemática puede identificar un método equivalente. En ese caso se incorporará como comparador y se precisará la pregunta antes de E2. El trabajo experimental seguirá siendo útil si permite identificar cuándo conviene emplear una alternativa más sencilla o menos costosa.

Tabla 3: Plan de trabajo y entregas previstas.

Sem.	Trabajo principal	Entrega
1	Revisión sistemática, definición del método, inventario de datos y protocolos, y piloto de precisión y costo.	Protocolo inicial registrado; manuscrito de revisión o diseño.
2	Implementación de perfiles y arquitectura; señales sintéticas de desarrollo y reserva definida; pruebas de gradientes e interfaces.	Software reproducible; pruebas de recuperación de escalas e integración.
3	Desarrollo E1; selección de perfiles, comparadores y entrenamiento; fijación de los protocolos E2 y E3.	Manuscrito metodológico; protocolos finales de evaluación.
4	Pruebas de H1 en E2 y de H2/H3 en la reserva sintética; comprobación de reproducibilidad.	Manuscrito principal con resultados y límites de interpretación.
5	Integración y evaluación E3 frente a la representación actual; comparación publicada cuando su protocolo sea recuperable.	Modelo y evaluación financiera; manuscrito aplicado si los resultados y el calendario lo permiten.
6	Análisis conjunto, réplica independiente, escritura de tesis y defensa.	Tesis, modelos, configuraciones y documentación reproducible.

Los experimentos utilizarán datos públicos conforme a sus licencias y señales sintéticas. La evaluación financiera será histórica, sin intervenciones sobre usuarios. Se publicarán configuraciones, resultados desfavorables o inconclusos y consumo computacional para facilitar la reproducción y evitar repetir búsquedas sin evidencia de utilidad. Todo conjunto empleado en preentrenamiento se identificará junto con su posible solapamiento con la evaluación; una fuente utilizada para desarrollar el método o preentrenarlo no se presentará como completamente nueva.

7. Contribuciones esperadas

1. Un procedimiento reproducible que utilice propiedades temporales de entrenamiento para agrupar variables y asignar contexto temporal a las ramas de una representación modular.
2. Evidencia sobre cómo las diferencias de escala y las relaciones entre variables con retraso afectan a la utilidad de esa organización y a la necesidad de conservar las secuencias hasta combinarlas.
3. Comparaciones que distingan el efecto de la regla de diseño del efecto de utilizar ramas, preentrenamiento o más recursos computacionales.
4. Un protocolo para evaluar el procedimiento en familias de datos reservadas, con modelos de referencia, estimación de incertidumbre y costos completos.
5. Una representación integrada en las plataformas existentes, con evaluación financiera en aprendizaje por refuerzo frente a la representación actual y documentación de desempeño, costo y condiciones de fallo.

La contribución se apoyará en la relación comprobada entre las propiedades de los datos, las decisiones de arquitectura y los resultados obtenidos. La evaluación permitirá determinar tanto dónde el procedimiento aporta una mejora como dónde resulta preferible una alternativa más sencilla.

Referencias

- [1] Y. Bengio, A. Courville y P. Vincent, «Representation Learning: A Review and New Perspectives», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, n.º 8, pp. 1798–1828, 2013. DOI: 10.1109/TPAMI.2013.50.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. <https://www.deeplearningbook.org/>.
- [3] G. C. Cawley y N. L. C. Talbot, «On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation», *Journal of Machine Learning Research*, vol. 11, n.º 70, pp. 2079–2107, 2010. <https://jmlr.org/papers/v11/cawley10a.html>.

- [4] A. Zeng et al., «Are Transformers Effective for Time Series Forecasting?», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 9, pp. 11121–11128, 2023. DOI: 10.1609/aaai.v37i9.26317.
- [5] Y. Nie et al., «A Time Series is Worth 64 Words: Long-term Forecasting with Transformers», *International Conference on Learning Representations*, 2023. <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=JePfAI8fah>.
- [7] H. Wu et al., «TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis», *International Conference on Learning Representations*, 2023. https://openreview.net/forum?id=ju_Uqw384Oq.
- [8] Y. Zhang et al., «Multi-resolution Time-Series Transformer for Long-term Forecasting», *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, vol. 238, pp. 4222–4230, 2024. <https://proceedings.mlr.press/v238/zhang24l.html>.
- [9] P. Chen et al., «Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=lJkOCMP2aW>.
- [10] S. Wang et al., «TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=7oLshfEIC2>.
- [11] W. Cai et al., «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, n.º 10, pp. 11141–11149, 2024. DOI: 10.1609/aaai.v38i10.28991.
- [12] J. Chen et al., «From Similarity to Superiority: Channel Clustering for Time Series Forecasting», *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-4152.
- [13] X. Qiu et al., «DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting», *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 1185–1196, 2025. DOI: 10.1145/3690624.3709325.
- [14] G. Yu et al., «Revitalizing Multivariate Time Series Forecasting: Learnable Decomposition with Inter-Series Dependencies and Intra-Series Variations Modeling», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 57818–57841, 2024. <https://proceedings.mlr.press/v235/yu24s.html>.
- [15] J. Lu et al., «CATS: Enhancing Multivariate Time Series Forecasting by Constructing Auxiliary Time Series as Exogenous Variables», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 32990–33006, 2024. <https://proceedings.mlr.press/v235/lu24d.html>.
- [16] G. Woo et al., «CoST: Contrastive Learning of Disentangled Seasonal-Trend Representations for Time Series Forecasting», *International Conference on Learning Representations*, 2022. <https://openreview.net/forum?id=PilZY3omXV2>.
- [17] L. Yang y S. Hong, «Unsupervised Time-Series Representation Learning with Iterative Bilinear Temporal-Spectral Fusion», *Proceedings of the 39th International Conference on Machine Learning*, vol. 162, pp. 25038–25054, 2022. <https://proceedings.mlr.press/v162/yang22e.html>.
- [18] M. Ravanelli y Y. Bengio, «Speaker Recognition from Raw Waveform with SincNet», *arXiv preprint arXiv:1808.00158*, 2018. DOI: 10.48550/arXiv.1808.00158.
- [19] N. Zeghidour et al., «LEAF: A Learnable Frontend for Audio Classification», *International Conference on Learning Representations*, 2021. <https://openreview.net/forum?id=jM76BCb6F9m>.
- [20] J. Schlüter y G. Gutenbrunner, «EfficientLEAF: A Faster Learnable Audio Frontend of Questionable Use», *arXiv preprint arXiv:2207.05508*, 2022. DOI: 10.48550/arXiv.2207.05508.
- [21] P. Montero-Manso et al., «FFORMA: Feature-based Forecast Model Averaging», *International Journal of Forecasting*, vol. 36, n.º 1, pp. 86–92, 2020. DOI: 10.1016/j.ijforecast.2019.02.011.
- [22] Z. Liang y Y. Sun, «Evolutionary Neural Architecture Search for Multivariate Time Series Forecasting», *Proceedings of the 15th Asian Conference on Machine Learning*, vol. 222, pp. 771–786, 2024. <https://proceedings.mlr.press/v222/liang24a.html>.
- [23] R. Leppich et al., «Decomposing the Time Series Forecasting Pipeline: A Modular Approach for Time Series Representation, Information Extraction, and Projection», *arXiv preprint arXiv:2507.05891*, 2025. DOI: 10.48550/arXiv.2507.05891.

- [24] Y. Bengio et al., «Greedy Layer-Wise Training of Deep Networks», *Advances in Neural Information Processing Systems*, vol. 19, 2007. https://proceedings.neurips.cc/paper_files/paper/2006/file/5da713a690c067105aeb2fae32403405-Paper.pdf.
- [25] Z. Li et al., «Ti-MAE: Self-Supervised Masked Time Series Autoencoders», *arXiv preprint arXiv:2301.08871*, 2023. DOI: 10.48550/arXiv.2301.08871.
- [26] H. Bastidas, «Gestor de autoencoder en `feature-extractor`», 2026. Inspección estática; commit `df86252`; consultado el 7 de septiembre de 2026. https://github.com/harveybc/feature-extractor/blob/df86252a174a1f5b9f77f4cb1bcb78fcdfe429e8/app/autoencoder_manager.py.
- [27] H. Bastidas, «Configuración de carga de extractor y `train_fe`», 2026. Configuración del repositorio, commit `20ec571`; consultada el 7 de septiembre de 2026. https://github.com/harveybc/predictor/blob/20ec57145b4ed3eb647eabe2b7591f35a3dbbf47/examples/config/phase_3_1/phase_3_1_cnn_25200_1h_config.json.
- [28] S. Bai, J. Z. Kolter y V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling», *arXiv preprint arXiv:1803.01271*, 2018. DOI: 10.48550/arXiv.1803.01271.
- [29] Keras Team, «Transfer learning & fine-tuning», 2023. Documentación oficial; consultada el 7 de septiembre de 2026. https://keras.io/guides/transfer_learning/.
- [30] X. Qiu et al., «TFB: Towards Comprehensive and Fair Benchmarking of Time Series Forecasting Methods», *Proceedings of the VLDB Endowment*, vol. 17, n.º 9, pp. 2363–2377, 2024. DOI: 10.14778/3665844.3665863.
- [31] R. Godahewa et al., «Monash Time Series Forecasting Archive», *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2021. <https://openreview.net/forum?id=I0117rc0jcb>.
- [32] T. Aksu et al., «GIFT-Eval: A Benchmark for General Time Series Forecasting Model Evaluation», *arXiv preprint arXiv:2410.10393*, 2024. DOI: 10.48550/arXiv.2410.10393.
- [33] A. Raffin et al., «Stable-Baselines3: Reliable Reinforcement Learning Implementations», *Journal of Machine Learning Research*, vol. 22, n.º 268, pp. 1–8, 2021. <http://jmlr.org/papers/v22/20-1364.html>.
- [34] S. Sun et al., «TradeMaster: A Holistic Quantitative Trading Platform Empowered by Reinforcement Learning», *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/file/b8f6f7f2ba4137124ac976286eacb611-Paper-Datasets_and_Benchmarks.pdf.
- [35] X.-Y. Liu et al., «FinRL-Meta: Market Environments and Benchmarks for Data-Driven Financial Reinforcement Learning», *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*, 2022. https://papers.neurips.cc/paper_files/paper/2022/file/0bf54b80686d2c4dc0808c2e98d430f7-Paper-Datasets_and_Benchmarks.pdf.
- [36] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy», *International Journal of Forecasting*, vol. 22, n.º 4, pp. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.
- [37] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.a ed.. OTexts, 2021. Sección 5.10: evaluación con origen rodante. <https://otexts.com/fpp3/tscv.html>.