

Diseño de representaciones temporales modulares basado en datos

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje de representaciones · series temporales · arquitectura modular · pronóstico multivariado · aprendizaje por refuerzo · generalización

Resumen

La *representación temporal* es la parte de una arquitectura para pronóstico o aprendizaje por refuerzo que transforma la información de una serie temporal multivariada de entrada en conocimiento usable por las capas de salida. Las series temporales multivariadas pueden reunir variables cuyos ritmos de cambio, periodicidades y relaciones son distintos. Algunos modelos de pronóstico y aprendizaje por refuerzo (RL) procesan todas las variables con la misma ventana y el mismo extractor de características, otros incorporan varias escalas temporales mediante una representación elegida de antemano o una búsqueda de configuraciones que puede ser costosa. Esta propuesta estudiará si las propiedades temporales de los datos de entrenamiento permiten orientar las decisiones de diseño de la representación temporal tanto para pronóstico como para RL.

Se diseñará la *representación temporal modular* mostrada en la Figura 1, formada por:

- *ramas 1..B* que procesan grupos de variables usando extractores de características especializados
- *módulo de fusión de características* que alinea y concatena las secuencias
- *núcleo temporal* que combina la información y reduce dimensionalidad conservando el eje temporal
- *cabezales de salida* que se adaptan a la tarea: pronóstico para estimar valores o aprendizaje por refuerzo para seleccionar acciones y, según el algoritmo, estimar funciones de valor.




Figura 1. Representación temporal modular. Las ramas 1..B procesan grupos de variables, el módulo de fusión de características alinea y concatena sus secuencias, y el núcleo temporal combina la información para los cabezales de salida.

El procedimiento analizará los datos de entrenamiento para proponer grupos de variables, contextos temporales y modelos adecuados para cada rama. Las alternativas se seleccionarán mediante validación de la tarea, considerando sus requisitos y los recursos disponibles.

Cada extractor tendrá un detector de patrones separado y componentes configurables de integración temporal y adaptación, que podrán combinarse u omitirse cuando no sean necesarios. El detector podrá entrenarse desde cero o importar pesos preentrenados, mantenerlos fijos o ajustarlos con el modelo completo.

Se evaluarán tareas de pronóstico y RL con series multivariadas y protocolos disponibles en la literatura. Se comparará la propuesta con referencias sencillas, modelos publicados y variantes sin el diseño modular, controlando entradas, entrenamiento y recursos.

La representación se integrará en plataformas existentes de pronóstico y RL. Sus configuraciones y métricas se registrarán en un cubo OLAP existente que permitirá organizar y facilitar el análisis y visualización de los resultados. Se espera obtener un método reproducible y determinar si el uso de la representación modular basada en datos mejora el desempeño, lo mantiene en un nivel equivalente o lo empeora. La evidencia insuficiente se declarará inconclusa.

1. Definición del problema y justificación

El aprendizaje de representaciones transforma las observaciones en características que facilitan una tarea, como pronosticar valores o seleccionar acciones [1, 2]. En series temporales, diseñar esa transformación exige decidir cuánto pasado proporcionar, cómo agrupar las variables, qué resolución temporal conservar y en qué etapa combinar la información.

Una representación uniforme puede resultar insuficiente cuando las variables cambian a ritmos distintos. Explorar muchas combinaciones de ventanas y arquitecturas permite adaptarlas, pero consume recursos y aumenta el riesgo de escoger una configuración demasiado ajustada a los datos de validación [3]. La pregunta es si un análisis previo de las propiedades temporales permite orientar la selección y configuración de los modelos y mejorar su desempeño en el conjunto de prueba reservado.

El proyecto parte de sistemas de pronóstico y RL para trading en los que se han probado extractores modulares y codificadores preentrenados. La necesidad práctica es orientar la selección y combinación de estos componentes mediante un análisis de los datos, y comprobar tanto su utilidad financiera como su desempeño frente a métodos publicados.

Pregunta de investigación. ¿En qué condiciones agrupar variables según sus propiedades temporales y adaptar el procesamiento de cada rama a las características específicas de estos datos, mejora el desempeño de un modelo de pronóstico o RL en datos reservados, frente a un modelo que no utilice este procesamiento independiente por rama, con datos, entrenamiento y recursos comparables?

La pregunta se responderá con evaluaciones separadas de pronóstico y RL, ya que una mejora predictiva no implica por sí sola mejores decisiones de trading.

2. Objetivos

2.1. Objetivo general

Desarrollar y evaluar un procedimiento basado en las propiedades temporales de los datos para agrupar variables, seleccionar y configurar los modelos de cada rama y aprender una representación temporal modular, comprobando su desempeño en pronóstico y aprendizaje por refuerzo frente a líneas base y modelos sin ese procesamiento diferenciado, con información, entrenamiento y recursos comparables.

2.2. Objetivos específicos

1. Definir los componentes y las interfaces de la representación modular, y estimar propiedades temporales que orienten la agrupación de variables y el contexto de cada rama.

2. Construir un procedimiento reproducible para agrupar variables, seleccionar los modelos adecuados para cada rama y configurar su contexto temporal, integración y adaptación, con entrenamiento desde cero o con detectores preentrenados fijos o ajustables.
3. Comparar el procedimiento con modelos de la literatura y variantes controladas de su arquitectura en tareas públicas reservadas, midiendo error, costo, estabilidad y condiciones de fallo.
4. Integrar la representación en las plataformas existentes de pronóstico y RL, registrar las configuraciones y métricas en la infraestructura analítica y evaluar la aplicación financiera frente a una estrategia trivial, la representación actual y una variante sin el procesamiento modular propuesto.

3. Marco teórico y antecedentes

3.1. Representación temporal y componentes del modelo

Una *ventana de entrada* es el segmento histórico que se entrega al modelo. Se representará por $X_{1:L} \in \mathbb{R}^{L \times p}$, donde L es el número de instantes y p el de variables. El *campo receptivo de una activación* es la parte de esa entrada que puede influir en una salida concreta de una capa. Por ejemplo, una ventana puede contener 144 observaciones mientras una activación de la primera capa utiliza solo tres. Las capas posteriores pueden ampliar ese alcance. Cuando se hable del campo receptivo de una rama, se hará referencia al de sus activaciones de salida, medido respecto de la entrada original.

El bloque de representación realiza una transformación aprendida $Z = f_{\theta}(X)$, donde θ contiene los pesos ajustados durante el entrenamiento y Z es la secuencia de características que utilizarán las capas siguientes. En la arquitectura modular, las variables se distribuyen en B grupos, $G_1, \dots, G_B$. Cada rama contiene un detector de patrones D_j como módulo separado, un componente de integración temporal I_j y una adaptación de salida A_j :

$$Z_j = A_j(I_j(D_j(X_{:,G_j}))) \in \mathbb{R}^{L_j \times c_j}. \quad (1)$$

Aquí $X_{:,G_j}$ contiene las variables del grupo j , L_j es la longitud de la secuencia producida y c_j el número de características por instante, también llamadas *canales*. El detector D_j tendrá una interfaz independiente para entrenarlo, guardar sus pesos y reutilizarlo. I_j y A_j serán configurables y podrán implementarse separados o en un componente conjunto; si alguna función no requiere una transformación, se representará mediante la identidad. La ecuación describe esa composición funcional y no exige que integración y adaptación sean siempre redes independientes.

Antes de combinar las ramas, el módulo de fusión de características establecerá qué instantes corresponden entre sus salidas y concatenará las características. Si una rama reduce su resolución temporal, L_j podrá ser distinto de L y será necesario especificar esa correspondencia. El núcleo temporal procesará la secuencia conjunta; el cabezal de pronóstico producirá $\hat{Y}_{L+1:L+H}$, las predicciones de los siguientes H pasos. En aprendizaje por refuerzo, las salidas se adaptarán al algoritmo de selección de acciones o estimación de valor. Cada aplicación utilizará un modelo entrenado para su objetivo.

3.2. Propiedades temporales para orientar el diseño

Una *escala temporal* describe la duración de un patrón o una dependencia: por ejemplo, el período de una oscilación o cuánto tarda en disminuir la semejanza entre una señal y sus valores pasados. El *perfil temporal* reunirá medidas de esas propiedades para cada variable. Se calculará exclusivamente con sus datos de entrenamiento e incluirá decaimiento de autocorrelación, distribución de energía entre frecuencias, periodicidades dominantes y estabilidad de las estimaciones entre segmentos de la serie.

Los perfiles se expresarán en unidades comparables entre tareas. Su cálculo y normalización se especifican en la sección 4.3.

Los perfiles individuales pueden orientar la agrupación, pero su semejanza no demuestra causalidad ni dependencias entre variables con retraso. Estas se examinarán por separado. Tampoco se supondrá que una periodicidad determina el campo receptivo óptimo: la utilidad de esa relación se evaluará con señales sintéticas y datos públicos.

3.3. Modelos de referencia

DLinear mostró que un modelo lineal sencillo puede superar arquitecturas más complejas en varios conjuntos de pronóstico [4]. PatchTST divide la historia en segmentos o *parches* y procesa las variables de manera independiente [5]. iTransformer representa cada variable como una unidad de entrada del mecanismo de atención para aprender relaciones entre ellas [6]. Estos trabajos justifican comparar el método tanto con referencias sencillas como con modelos que procesan las variables por separado o conjuntamente.

Varios métodos incorporan múltiples escalas. TimesNet organiza variaciones periódicas en representaciones bidimensionales [7]; MTST utiliza ramas con distintas resoluciones de parche [8]; Pathformer aprende rutas entre escalas [9]; y TimeMixer combina componentes en resoluciones finas y gruesas [10]. MSGNet aprende relaciones entre variables que dependen de la escala [11]. CCM aprende grupos de variables mediante asignaciones y prototipos regularizados por similitud [12]; DUET combina agrupación temporal con pertenencias graduadas de las variables a grupos [13]. Leddam y CATS estudian otras formas de representar dependencias entre series [14, 15]. Por tanto, la presencia de ramas, agrupaciones o múltiples escalas ya tiene antecedentes directos.

También existen representaciones aprendidas que aprovechan propiedades de las señales. CoST separa tendencia y estacionalidad mediante aprendizaje contrastivo [16], mientras BTSF combina información temporal y espectral [17]. En audio, SincNet y LEAF incorporan operaciones de procesamiento de señales cuyos parámetros se aprenden con la tarea [18, 19]. Sin embargo, EfficientLEAF encontró que sus extractores aprendibles no superaban consistentemente un banco de filtros fijo en las tareas evaluadas [20]. Estos antecedentes motivan el diseño basado en propiedades de señales y, a la vez, la necesidad de comprobar su utilidad frente a alternativas sencillas.

3.4. Diferencia que estudiará la propuesta

FFORMA utiliza características de una serie para ponderar modelos completos de pronóstico [21]. EMTSF busca mediante evolución combinaciones de módulos espaciales y temporales [22]. REP-Net divide el procesamiento en representación, extracción y proyección y evalúa configuraciones de esas etapas [23]. DUET es un comparador especialmente cercano porque aborda tanto diferencias temporales como relaciones entre variables.

La contribución propuesta es comprobar si las propiedades temporales orientan conjuntamente la agrupación de variables, el contexto y la selección de modelos por rama. Se evaluará el procedimiento en *familias de datos* reservadas: conjuntos relacionados por su fuente y dominio, cuyas variantes no se contarán como evidencia independiente.

La revisión inicial no identificó un método que combine esa regla previa de diseño con una evaluación entre familias reservadas y controles de capacidad, entrenamiento y costo. Esta diferencia deberá verificarse mediante la revisión sistemática del primer semestre. Si se encuentra un método equivalente, se incorporará como referencia y se delimitará la contribución antes de realizar la evaluación final.

El preentrenamiento por capas y la reconstrucción de valores ocultos tienen antecedentes en autoencoders [24, 25]. El sistema existente permite exportar codificadores y decodificadores y configurar el reajuste de extractores [26, 27]; el entrenamiento conjunto se verificará en la implementación.

4. Metodología

4.1. Organización del trabajo con CRISP-DM

CRISP-DM organizará el trabajo en comprensión del problema y los datos, preparación, modelado, evaluación e integración en las plataformas [28]. El análisis de datos orientará la selección de modelos y sus configuraciones; la validación comparará las alternativas. Las decisiones podrán revisarse durante el desarrollo, y el procedimiento quedará fijado antes de la prueba reservada.

H1 evaluará la utilidad del método en pronóstico; H2, la agrupación por escalas; y H3, la conservación de secuencias hasta fusionar las ramas. Las dos últimas utilizarán principalmente señales sintéticas. RL tendrá una evaluación aplicada con métricas de decisión y desempeño financiero.

El desarrollo del procedimiento se denominará E1 y su evaluación en familias públicas reservadas, E2. E0 comprende la generación de señales sintéticas, con datos separados para desarrollo y prueba. E3 corresponde a la aplicación financiera en aprendizaje por refuerzo. La sección de fases experimentales detalla cada una.

4.2. Selección de datos y comparación con resultados publicados

Para cada conjunto candidato se localizará un resultado publicado pertinente, su tarea, las métricas y el protocolo experimental. Se comprobarán el acceso a datos y código, las divisiones de entrenamiento y prueba, y su compatibilidad con la separación entre familias. La selección se cerrará antes de ejecutar la evaluación reservada. El número de familias necesario se determinará con el inventario y el piloto de precisión estadística.

Se reproducirá al menos un modelo de referencia, con tolerancia fijada previamente según precisión numérica y variación entre ejecuciones. Se distinguirán reproducción del estudio original, comparación bajo protocolo común adaptado y aplicación propia. Si cambian algoritmo, información o simulador, la diferencia corresponderá al sistema completo; el efecto de la representación se aislará con controles equivalentes.

Se identificarán archivos, versiones, fechas, instrumentos, frecuencia, variables y divisiones temporales, conservando huellas digitales cuando sea posible. Se documentarán discrepancias entre artículo, suplemento y código. En trading se igualarán ejecución, comisiones, deslizamiento, restricciones y contabilidad. Corregir un protocolo con información futura exigirá adaptar todos los métodos y declarar el cambio.

H1 conservará MASE y su agregación. Las comparaciones publicadas añadirán las métricas, escalas y promedios originales. Si se adopta reentrenamiento periódico, se aplicará también a las referencias y se declarará como adaptación. Una media publicada sin información sobre su variación no permitirá afirmar significación estadística.

La lista detallada de comprobaciones y el inventario de candidatos se encuentran en el protocolo de comparabilidad y aplicación RL. Entre las comprobaciones pendientes figuran el tratamiento de la normalización en TradeMaster y la exposición previa del proyecto a los conjuntos candidatos.

4.3. Preparación de datos y construcción de las ramas

Se documentarán fuente, frecuencia de muestreo, zona horaria, variables, objetivos y disponibilidad temporal de cada dato. Normalización, imputación y perfiles se ajustarán solo con entrenamiento. Las transformaciones podrán utilizar la ventana histórica completa, pero ninguna observación posterior al instante de pronóstico o decisión.

Los controles compartirán información y preprocesamiento común; las adaptaciones de formato no añadirán datos. Para cada variable i se calculará un perfil d_i y su estabilidad entre segmentos. Los retardos tendrán unidades comparables y las frecuencias se normalizarán respecto de Nyquist, la mitad de la frecuencia de muestreo. El escalado robusto de los perfiles se ajustará en E1 y se fijará antes de E2, conservando diferencias entre tareas; $\tilde{d}_i$ denotará el perfil escalado. Su heterogeneidad se resumirá como

$$q(X) = \text{mediana}_{i < k} \|\tilde{d}_i - \tilde{d}_k\|_2. \quad (2)$$

Esta medida expresa diferencias entre los perfiles utilizados por el procedimiento; no se interpretará como una medida de dificultad de pronóstico o causalidad.

El análisis basado en perfiles propondrá una agrupación G , los contextos temporales R y las alternativas de modelos admisibles para cada rama, reunidas en $\mathcal{M}$. Con parámetros de diseño η , esta etapa se expresará como

$$(G, R, \mathcal{M}) = A_\eta(\tilde{d}_1, \dots, \tilde{d}_p). \quad (3)$$

El agrupamiento jerárquico será el punto de partida. E1 fijará los criterios de agrupación, el máximo de ramas, los contextos admisibles, el catálogo de modelos y el presupuesto. En E2, cada tarea podrá seleccionar arquitecturas distintas mediante entrenamiento y validación del modelo completo, sin consultar la prueba ni modificar esos criterios.

Si el perfil de una variable es inestable, se asignará a una rama común y se registrará que no fue posible justificar una especialización con esos datos. Para H3 se estimarán por separado relaciones predictivas entre variables con distintos retardos. Ese diagnóstico utilizará solo entrenamiento y no modificará la regla A_η durante E2.

4.4. Selección de modelos, arquitectura y entrenamiento

Las ramas podrán utilizar modelos convolucionales, recurrentes, de atención o híbridos. La selección considerará cantidad y estructura de los datos, escalas, contexto, relaciones entre variables, preentrenamiento y compatibilidad

con los demás componentes. El catálogo y los rangos de configuración se justificarán en E1 mediante literatura e implementaciones reproducibles.

Las convoluciones temporales permitirán configurar el alcance mediante profundidad, tamaño de filtro y dilatación [29]. En modelos recurrentes se declararán la historia accesible y el tratamiento de sus estados; en atención, la longitud de secuencia y las restricciones de acceso temporal. En todos los casos se verificará qué observaciones puede utilizar cada salida y se conservará una secuencia de características compatible con el resto del sistema.

La implementación conservará la separación de D_j y permitirá configurar I_j y A_j por separado, conjuntamente o como identidad. El integrador añadirá contexto cuando el detector no lo proporcione; la adaptación ajustará dimensiones y correspondencia temporal. Se verificarán interfaces, marcas de tiempo, memoria y costos.

La elección se basará en la validación de la tarea final, no únicamente en la reconstrucción del autoencoder. DOIN ajustará los parámetros y decisiones estructurales que aún requieran búsqueda, registrando también los candidatos descartados.

Tras la alineación y concatenación, el núcleo procesará la secuencia conjunta. Para pronóstico, el cabezal utilizará su último estado para predecir H pasos. En RL se definirán salidas de política o valor; cuando existan actor y crítico, que seleccionan acciones y estiman valor, se declarará si comparten la representación.

La Figura 2 muestra el detector separado y las funciones configurables de integración y adaptación. Cada componente podrá contener varias capas; sus tipos, tamaños, repeticiones y conexiones formarán parte de la configuración del extractor.




Figura 2. Arquitectura conceptual. Las líneas discontinuas muestran propuestas de diseño a partir de los datos de entrenamiento; la validación selecciona los modelos. Las continuas muestran el flujo de datos. Cada rama contiene un detector D_j separado e integración I_j y adaptación A_j configurables. Alineación y fusión reúnen el módulo de fusión de características y el núcleo temporal de la Figura 1.

Se compararán tres modalidades de entrenamiento, identificadas como R0, R1 y R2 para facilitar su seguimiento en los experimentos:

Tabla 1. Inicialización y entrenamiento de los detectores.

Modo	Pesos iniciales del detector	Entrenamiento del modelo completo
R0	Inicialización aleatoria.	Detector y resto del modelo se ajustan juntos.
R1	Codificador preentrenado.	El detector se mantiene fijo; se ajusta el resto.
R2	El mismo codificador preentrenado que en R1.	Detector y resto del modelo continúan ajustándose.

El preentrenamiento utilizará un autoencoder: el codificador aprenderá una representación y un decodificador auxiliar reconstruirá la entrada o unos valores ocultos mediante una máscara definida previamente. La reconstrucción

ordinaria no se interpretará por sí sola como eliminación de ruido. Se conservarán el codificador y el decodificador entrenados, así como una copia separada de los pesos modificados durante el ajuste posterior.

La implementación se comprobará con pruebas de actualización de parámetros. En R1, los pesos del detector deberán permanecer fijos. En R2, se verificará que los gradientes del objetivo final lleguen al detector y modifiquen sus pesos; también se especificará cómo se tratan estados que no se actualizan mediante gradientes. Si se entrena el resto del modelo sobre características guardadas en un archivo, se considerará extracción fija, porque ese procedimiento no actualiza el codificador [30].

E1 elegirá una de las tres modalidades para H1 y la fijará para el método y sus controles, evitando ventajas exclusivas de preentrenamiento. H3 utilizará el extractor común y fijo definido en su contraste.

La Figura 3 distingue las decisiones que se fijan durante el desarrollo de los pesos y perfiles que se aprenden con los datos de cada tarea.




Figura 3. Separación entre desarrollo y evaluación. E1 fija el procedimiento; cada tarea estima perfiles y entrena candidatos con entrenamiento, selecciona con validación y evalúa el modelo resultante en prueba reservada.

4.5. Fases experimentales

El estudio separará el desarrollo del procedimiento, las pruebas reservadas y la aplicación al sistema existente. La Tabla 2 resume el propósito de cada fase.

Tabla 2. Datos y propósito de las fases experimentales.

Fase	Datos	Propósito
E0	Señales sintéticas con estructura conocida.	Comprobar los perfiles y los mecanismos de H2 y H3, con señales separadas para desarrollo y prueba.
E1	Familias públicas de desarrollo.	Definir los criterios de agrupación y selección de modelos, las modalidades de entrenamiento, los comparadores y presupuestos; fijar márgenes de relevancia y comprobar precisión estadística.
E2	Familias públicas reservadas.	Contrastar H1 con el procedimiento ya fijado y estudiar su utilidad en tareas de distinto origen.
E3	Datos financieros históricos identificados y divididos de antemano.	Integrar la representación en el agente y compararla con la estrategia trivial y los controles de representación. Es una entrega obligatoria, con análisis separado de H1–H3.

Señales sintéticas. E0 combinará procesos autorregresivos, periodicidades, tendencias y eventos localizados. Los generadores implementarán los contrastes de H2 y H3. Para H3, realizaciones independientes eliminarán las relaciones entre variables conservando, en distribución, sus propiedades individuales, tamaño de muestra y ruido; esto se comprobará con repeticiones. Permutar el orden temporal se reservará para sensibilidad, porque altera también la estructura individual.

La reserva sintética fijará ecuaciones, rangos y semillas antes de ajustar la regla y permanecerá cerrada hasta terminar E1. Incluirá cambios temporales y fallos de los supuestos del diagnóstico. El ruido añadido será conocido; en datos reales no se supondrá que todo residuo es ruido.

Tareas públicas. Se examinarán conjuntos de energía, clima, tráfico y otros dominios recogidos en TFB, Monash y GIFT-Eval [31, 32, 33]. Para evaluar la agrupación, un conjunto deberá contener variables distintas observadas conjuntamente y permitir al menos dos agrupaciones de variables diferentes. También deberá tener frecuencia documentada, licencia compatible, historia suficiente para las divisiones de entrenamiento y evaluación, y denominadores de MASE no nulos en entrenamiento. Los conjuntos univariados podrán utilizarse para verificar implementaciones, pero no para probar la utilidad de agrupar variables.

Antes de E2 se fijarán familias, horizontes y divisiones temporales. Las variantes de una fuente permanecerán juntas; dividir sus ventanas no creará familias independientes. En cada tarea reservada se entrenará un modelo nuevo con el procedimiento fijado en E1 y sus propios datos de entrenamiento y validación.

Aplicación al sistema de trading. E1 elegirá una tarea financiera histórica y un algoritmo compatibles con la plataforma para E3. Se compararán una estrategia trivial y el agente con la representación propuesta, la actual y una variante sin procesamiento diferenciado por ramas; las dos últimas podrán coincidir. Las variantes del agente compartirán entorno, observaciones, recompensa, acciones, calendario y presupuesto. Se especificarán la posición y el estado de cuenta en la entrada, y si actor y crítico comparten representación [34].

Se fijarán antes de la prueba la métrica principal de RL, su margen de relevancia y las métricas financieras complementarias. Con reglas contables, costos y ejecución comunes, se estimarán diferencias e intervalos que consideren semillas y períodos compartidos. La comparación con el agente sin diseño modular medirá el aporte de la representación; superar la estrategia trivial mostrará utilidad básica. Se distinguirán mejora, equivalencia, perjuicio e incertidumbre. E3 se analizará por separado de H1–H3 y de su ajuste de multiplicidad.

TradeMaster y FinRL-Meta permitirán buscar experimentos publicados con datos, código y protocolos recuperables [35, 36]. Si existe uno compatible, se reproducirá la comparación y se documentarán las diferencias. En caso contrario, E3 conservará los controles propios y declarará la limitación de comparación externa. La plataforma de pronóstico reutilizará los componentes y experimentos correspondientes.

4.6. Modelos de referencia y controles experimentales

Los comparadores se elegirán por la pregunta que permiten responder:

1. Como referencias básicas se utilizarán el pronóstico ingenuo y el estacional ingenuo, junto con una estrategia trivial de trading para RL, seleccionada antes de evaluar y compatible con el entorno. Se incorporará un modelo estadístico multivariado pertinente y reproducible; DLinear aportará además una referencia lineal aprendida.
2. PatchTST e iTransformer permitirán comparar estrategias de procesamiento independiente y conjunto de las variables.
3. DUET será un comparador obligatorio por su proximidad a la propuesta. Antes de examinar los resultados de E1 se elegirá además un método multiescala entre MTST, Pathformer y TimeMixer.
4. Se utilizarán modelos sin el procesamiento diferenciado por ramas como controles del diseño propuesto, con selección de arquitectura y ajuste bajo recursos comparables. Un control modular organizado sin perfiles permitirá separar el efecto de usar ramas del efecto de organizarlas mediante los datos.
5. Se realizarán *ablaciones*, es decir, comparaciones que alteran una decisión concreta: permutar la correspondencia entre variables y perfiles, usar un campo receptivo común o resumir las ramas antes de combinarlas.

El control permutado cambiará la asignación de variables conservando número y tamaño de ramas, modelos, contextos, interfaces, objetivos y presupuesto. Las permutaciones compatibles y los desempates se fijarán antes de la prueba. Se evitará permutar simultáneamente datos, objetivos y módulos de manera que solo cambien sus nombres.

El método y sus controles compartirán semillas, criterios de entrenamiento, límites de búsqueda y catálogos comparables. Cuando sea viable, se igualarán parámetros dentro de una tolerancia fijada en el piloto; también se compararán error, tiempo y memoria. Ablaciones con tipos de modelos fijos distinguirán los efectos de agrupación, selección de modelos y configuración.

MSGNet o CCM podrá añadirse si su interfaz y costo lo permiten. Se priorizarán los controles de las hipótesis sobre la exploración exhaustiva de combinaciones.

4.7. Hipótesis y criterios de contraste

La unidad principal de evaluación será una *tarea de pronóstico*, definida por un conjunto de datos, unas variables objetivo y un horizonte. Una misma tarea se repetirá desde distintos puntos de inicio del pronóstico, llamados *orígenes de evaluación*, y con distintas *semillas aleatorias*, que controlan la aleatoriedad del entrenamiento. Estas repeticiones no se contarán como tareas independientes.

Se utilizará el error absoluto medio escalado (MASE): el error de pronóstico dividido por un error de referencia calculado con entrenamiento. La sección 4.8 define su fórmula. Cada variable y origen tendrán un denominador propio, compartido por todos los métodos; si alguno es nulo, la tarea se informará aparte y no se usará para H1. Se promediarán los errores escalados con igual peso entre variables objetivo, pasos del horizonte, orígenes y semillas. Para cada tarea t se calculará

$$\Delta_t = \text{MASE}_{t,\text{método}} - \text{MASE}_{t,\text{control}}. \quad (4)$$

Un valor negativo favorece al método propuesto. El efecto global Δ dará igual peso a las tareas de cada conjunto, a los conjuntos de cada familia y a las familias. Así, una fuente que aporte muchas series no dominará el resultado. La estimación de incertidumbre conservará las comparaciones de métodos sobre las mismas tareas y la dependencia entre objetivos y horizontes de una fuente.

Antes de E2 se fijarán las F familias de evaluación, un margen de relevancia práctica $\varepsilon > 0$ y el nivel de error estadístico $\alpha = 0.05$. El margen expresará qué diferencia de MASE se considera relevante. El piloto comprobará si la cantidad de datos permite estimarla con precisión suficiente. Se evaluarán $K = F + 4$ efectos: el global y los F efectos por familia de H1, la pendiente de H2 y los dos contrastes de H3. Cada efecto tendrá un intervalo bilateral con cobertura nominal $1 - \alpha/K$, aplicando el ajuste de Bonferroni y el remuestreo de la sección 4.8. La cobertura y estabilidad de esos intervalos se comprobarán mediante simulación; si los datos o las simulaciones no permiten sostener su precisión, el resultado afectado se declarará inconcluso.

H1 • Utilidad de organizar las ramas mediante perfiles temporales. En familias públicas reservadas, el método reducirá el MASE frente al control principal: la alternativa con menor MASE agregado en E1 entre un modelo sin procesamiento diferenciado por ramas y uno modular organizado sin perfiles. Se mantendrán la ponderación por tareas, conjuntos y familias y las condiciones comparables de selección y entrenamiento. H1 requerirá que el límite superior de Δ sea menor que $-\varepsilon$ y el de cada efecto por familia sea menor o igual que ε : mejora global relevante y no inferioridad por familia. Si alguna familia carece de precisión suficiente, el resultado conjunto será inconcluso.

H2 • Utilidad de la agrupación cuando las escalas son distintas. La ventaja del diseño basado en perfiles frente a una asignación permutada aumentará con la heterogeneidad de las escalas temporales. La permutación cambiará qué variables se asignan a los grupos, conservando las características de la arquitectura. El experimento sintético variará un nivel conocido de heterogeneidad h , manteniendo constantes el tamaño de muestra, el número de variables y la distribución del ruido. Se definirá

$$e(h) = \text{MASE}(\text{perfiles}, h) - \text{MASE}(\text{permutación}, h).$$

H2 se considerará respaldada si el límite superior del intervalo de la pendiente β de $e(h)$ respecto de h es menor que cero. Una pendiente negativa indicará que la ventaja relativa crece con la heterogeneidad, aunque por sí sola no demostrará que el método sea mejor en todos sus niveles. En datos públicos se explorará la relación entre esa diferencia de desempeño y la heterogeneidad estimada de los perfiles, definida como $q(X)$ en la sección 4.3; este análisis complementario no sustituirá el experimento con estructura conocida.

H3 • Conservación de las secuencias hasta combinar las ramas. Cuando existan relaciones conocidas con retraso entre variables, combinar las secuencias alineadas antes de resumirlas reducirá el error frente a resumir cada rama por separado antes de combinarla. Las dos variantes recibirán las mismas activaciones de un extractor entrenado con un procedimiento fijado durante E1 y mantenido sin cambios durante este contraste. Solo se ajustarán los módulos que combinan las ramas y los cabezales. Se definirá

$$d_r = \text{MASE}(\text{fusión temporal}, r) - \text{MASE}(\text{resumen temprano}, r), \quad \gamma = d_1 - d_0,$$

donde $r = 1$ indica dependencia entre variables con retraso y $r = 0$ un control que conserva el comportamiento temporal de cada variable, pero elimina esa dependencia. H3 requerirá que el límite superior del intervalo de d_1 sea menor que $-\varepsilon$ y el de γ menor que cero. Se medirá la memoria adicional necesaria para conservar las secuencias. En datos públicos se realizará un análisis complementario sobre tareas donde un diagnóstico separado, calculado con entrenamiento, identifique relaciones predictivas entre variables con retraso.

4.8. Medidas de desempeño, incertidumbre y costo

El MASE expresa el error absoluto del modelo respecto de un error de referencia calculado con entrenamiento [37]. Para la variable objetivo k y el origen de evaluación o , sean n_o el número de observaciones de entrenamiento, m_k el período estacional y H los pasos futuros evaluados. Se calcularán

$$a_{k,o} = \frac{1}{n_o - m_k} \sum_{u=m_k+1}^{n_o} |y_{k,u} - y_{k,u-m_k}|, \quad \text{MASE}_{k,o} = \frac{H^{-1} \sum_{h=1}^H |y_{k,n_o+h} - \hat{y}_{k,n_o+h}|}{a_{k,o}}. \quad (5)$$

El denominador $a_{k,o}$ es el error medio de repetir el valor de un período estacional anterior dentro del entrenamiento. Se compartirá entre todos los métodos y se promediarán después los errores escalados según la sección 4.7. El período m_k procederá de los metadatos o de una regla fijada en E1. Si algún denominador requerido es cero, la tarea se declarará no evaluable para H1 antes de examinar sus errores de prueba. Se informarán también el error absoluto medio (MAE), el error cuadrático medio (MSE), el desempeño por horizonte y la variación entre semillas; los errores en eventos específicos se medirán cuando esos eventos estén definidos previamente.

Los datos se dividirán cronológicamente y se evaluarán desde sucesivos orígenes, desplazando el punto de inicio del pronóstico según una política fijada de antemano [38]. Se usarán horizontes de prueba no solapados cuando la longitud disponible lo permita. Antes de cada origen se volverán a estimar perfiles y pesos solo con los datos entonces disponibles. Una observación ya evaluada podrá usarse en un entrenamiento posterior cuando haya pasado a formar parte del historial observable, con la misma política para todos los métodos. Los resultados de prueba no cambiarán la regla de diseño, los rangos de búsqueda ni los criterios de parada [3].

La incertidumbre se estimará mediante *bootstrap jerárquico*, un procedimiento que repite el análisis tomando muestras con reemplazo y conserva la estructura de los datos. Para el efecto global se remuestrearán familias, conjuntos y tareas; para un efecto por familia se mantendrá fija esa familia y se remuestrearán sus conjuntos y tareas. En H2 y H3 se remuestrearán configuraciones del generador y repeticiones, manteniendo juntas las variantes comparadas de cada experimento. Las semillas y los orígenes se agregarán dentro de cada tarea; si se remuestran errores temporales, se usarán bloques contiguos para conservar su dependencia.

La simulación en E1 verificará la cobertura de los intervalos ajustados y su sensibilidad a la longitud de los bloques. Se publicarán efectos e intervalos por tarea y familia.

El costo energético se medirá en vatios-hora (Wh) con un instrumento seleccionado y validado durante E1. Para tareas t , métodos m , semillas s y orígenes o , se contabilizará

$$C_{\text{total}} = \sum_{t,o} C_{\text{perfil},t,o} + \sum_{t,m,s,o} (C_{\text{pre}} + C_{\text{ajuste}} + C_{\text{eval}})_{t,m,s,o}. \quad (6)$$

Los términos corresponden al cálculo de perfiles, preentrenamiento, ajuste y evaluación. El ajuste incluirá todos los candidatos explorados, la selección por validación, las paradas tempranas y los intentos fallidos que consuman recursos. El preentrenamiento incluirá el decodificador. Si se reutiliza un codificador, se distinguirán su costo inicial, el costo adicional de cada uso y el acumulado, indicando cómo se reparte el trabajo compartido.

Se informarán tiempo transcurrido, horas de CPU y GPU, operaciones estimadas, memoria máxima, hardware y concurrencia. Se distinguirá el costo de desarrollar el procedimiento en E1 del de aplicarlo a nuevas tareas; los tiempos de trabajos paralelos no se sumarán como duración transcurrida.

4.9. Interpretación de los resultados

El margen ε permitirá distinguir relevancia práctica de una diferencia pequeña. Para una diferencia de MASE cuyo signo negativo favorezca al método y cuyo intervalo ajustado sea $[L, U]$, se aplicarán estos criterios:

- **Beneficio relevante:** $U < -\varepsilon$.
- **Equivalencia práctica:** $[L, U] \subseteq [-\varepsilon, \varepsilon]$.
- **Perjuicio relevante:** $L > \varepsilon$.
- **Resultado inconcluso:** cualquier otro caso, porque el intervalo no permite decidir entre las categorías anteriores.

Los criterios específicos de H1–H3 se aplicarán como se definieron en la sección 4.7; el margen de MASE no se trasladará a pendientes o interacciones. La ausencia de mejora demostrada no se interpretará como equivalencia.

Se comprobará la sensibilidad retirando cada conjunto por turnos. Este análisis no permitirá redefinir contrastes ni ampliar la prueba después de observar resultados para buscar significación.

5. Viabilidad, recursos y riesgos

5.1. Recursos e integración con el sistema existente

El proyecto dispone de cuatro GPU de distintas capacidades, CPU local y software para gestionar datos, preprocesar series, entrenar modelos y registrar experimentos. La planificación tendrá en cuenta que las cuatro GPU pueden no estar disponibles simultáneamente. La generación de señales y los diagnósticos que no requieran redes neuronales se ejecutarán en CPU; el costo del resto se medirá mediante pilotos representativos.

DOIN proporcionará optimización y registro de experimentos. El cubo OLAP existente organizará modelos, configuraciones, particiones, semillas, métricas y costos para comparar tareas y componentes. Se comprobarán las interfaces con las plataformas de pronóstico y RL y el flujo de gradientes del ensamblaje.

El piloto reservará recursos para E3. Si es necesario acotarlo a una tarea y un agente, se mantendrán la estrategia trivial y el control sin procesamiento diferenciado por ramas.

5.2. Riesgos y uso responsable de los datos

Los principales riesgos son perfiles que no orienten un diseño útil, soporte experimental insuficiente o utilidad limitada a ciertos dominios. La evaluación por familias y los resultados de equivalencia, perjuicio o incertidumbre permitirán distinguir estas situaciones.

Se utilizarán datos públicos conforme a sus licencias y señales sintéticas. La evaluación financiera será histórica, sin intervenciones sobre usuarios. Se publicarán configuraciones, costos y resultados, incluidos los desfavorables. Se documentará el solapamiento del preentrenamiento o desarrollo con la evaluación; una fuente ya utilizada no se presentará como completamente nueva.

6. Cronograma

La Tabla 3 resume las actividades y entregas previstas para los seis semestres.

Tabla 3. Plan de trabajo y entregas previstas.

Sem.	Trabajo principal	Entrega
1	Revisión sistemática, definición del método, inventario de datos y protocolos, y piloto de precisión y costo.	Protocolo inicial registrado; manuscrito de revisión o diseño.
2	Implementación de perfiles, selección de modelos y componentes; señales sintéticas de desarrollo y reserva definida; pruebas de gradientes e interfaces.	Software reproducible; pruebas de recuperación de escalas e integración.
3	Desarrollo E1; selección de modelos por rama, controles y entrenamiento; fijación de los protocolos E2 y E3.	Manuscrito metodológico; protocolos finales de evaluación.
4	Pruebas de H1 en E2 y de H2/H3 en la reserva sintética; comprobación de reproducibilidad.	Manuscrito principal con resultados y límites de interpretación.
5	Integración y evaluación E3 frente a la estrategia trivial y los controles de representación; comparación publicada cuando su protocolo sea recuperable.	Modelo y evaluación financiera; manuscrito aplicado si los resultados y el calendario lo permiten.
6	Análisis conjunto, réplica independiente, escritura de tesis y defensa.	Tesis, modelos, configuraciones y documentación reproducible.

El alcance mínimo incluirá comprensión y preparación de datos, selección de modelos por rama, pruebas sintéticas, evaluación pública e integración evaluada en RL. Si es necesario reducir trabajo, se retirarán alternativas redundantes, comparadores opcionales y ampliaciones de activos o períodos. Se conservarán la selección justificada de modelos, la separación entre desarrollo y prueba, los controles del procesamiento modular y la medición completa de costos.

7. Resultados y contribuciones esperadas

1. Un procedimiento basado en datos para agrupar variables, seleccionar los modelos de sus extractores y configurar el contexto temporal, la integración y la adaptación de sus ramas.
2. Evidencia sobre cómo las diferencias de escala y las relaciones entre variables con retraso afectan a la utilidad de esa organización y a la necesidad de conservar las secuencias hasta combinarlas.
3. Comparaciones que distingan el efecto de agrupar y procesar variables por ramas del efecto de seleccionar modelos, preentrenarlos o asignarles más recursos.
4. Un protocolo para evaluar el procedimiento en familias de datos reservadas, con modelos de referencia, estimación de incertidumbre y costos completos.
5. Una representación integrada en las plataformas existentes, con evaluación financiera frente a una estrategia trivial y modelos sin el diseño modular, y registro de configuraciones y métricas en el cubo OLAP.

Referencias

- [1] Y. Bengio, A. Courville y P. Vincent, «Representation Learning: A Review and New Perspectives», *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, n.º 8, pp. 1798–1828, 2013. DOI: 10.1109/TPAMI.2013.50.
- [2] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016. <https://www.deeplearningbook.org/>.
- [3] G. C. Cawley y N. L. C. Talbot, «On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation», *Journal of Machine Learning Research*, vol. 11, n.º 70, pp. 2079–2107, 2010. <https://jmlr.org/papers/v11/cawley10a.html>.
- [4] A. Zeng et al., «Are Transformers Effective for Time Series Forecasting?», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 9, pp. 11121–11128, 2023. DOI: 10.1609/aaai.v37i9.26317.

- [5] Y. Nie et al., «A Time Series is Worth 64 Words: Long-term Forecasting with Transformers», *International Conference on Learning Representations*, 2023. <https://openreview.net/forum?id=Jbdc0vTOcol>.
- [6] Y. Liu et al., «iTransformer: Inverted Transformers Are Effective for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=JePfAI8fah>.
- [7] H. Wu et al., «TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis», *International Conference on Learning Representations*, 2023. https://openreview.net/forum?id=ju_Uqw384Oq.
- [8] Y. Zhang et al., «Multi-resolution Time-Series Transformer for Long-term Forecasting», *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, vol. 238, pp. 4222–4230, 2024. <https://proceedings.mlr.press/v238/zhang24l.html>.
- [9] P. Chen et al., «Pathformer: Multi-scale Transformers with Adaptive Pathways for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=IJkOCMP2aW>.
- [10] S. Wang et al., «TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting», *International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=7oLshfEIC2>.
- [11] W. Cai et al., «MSGNet: Learning Multi-Scale Inter-Series Correlations for Multivariate Time Series Forecasting», *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, n.º 10, pp. 11141–11149, 2024. DOI: 10.1609/aaai.v38i10.28991.
- [12] J. Chen et al., «From Similarity to Superiority: Channel Clustering for Time Series Forecasting», *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-4152.
- [13] X. Qiu et al., «DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting», *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 1185–1196, 2025. DOI: 10.1145/3690624.3709325.
- [14] G. Yu et al., «Revitalizing Multivariate Time Series Forecasting: Learnable Decomposition with Inter-Series Dependencies and Intra-Series Variations Modeling», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 57818–57841, 2024. <https://proceedings.mlr.press/v235/yu24s.html>.
- [15] J. Lu et al., «CATS: Enhancing Multivariate Time Series Forecasting by Constructing Auxiliary Time Series as Exogenous Variables», *Proceedings of the 41st International Conference on Machine Learning*, vol. 235, pp. 32990–33006, 2024. <https://proceedings.mlr.press/v235/lu24d.html>.
- [16] G. Woo et al., «CoST: Contrastive Learning of Disentangled Seasonal-Trend Representations for Time Series Forecasting», *International Conference on Learning Representations*, 2022. <https://openreview.net/forum?id=PilZY3omXV2>.
- [17] L. Yang y S. Hong, «Unsupervised Time-Series Representation Learning with Iterative Bilinear Temporal-Spectral Fusion», *Proceedings of the 39th International Conference on Machine Learning*, vol. 162, pp. 25038–25054, 2022. <https://proceedings.mlr.press/v162/yang22e.html>.
- [18] M. Ravanelli y Y. Bengio, «Speaker Recognition from Raw Waveform with SincNet», *arXiv preprint arXiv:1808.00158*, 2018. DOI: 10.48550/arXiv.1808.00158.
- [19] N. Zeghidour et al., «LEAF: A Learnable Frontend for Audio Classification», *International Conference on Learning Representations*, 2021. <https://openreview.net/forum?id=jM76BCb6F9m>.
- [20] J. Schlüter y G. Gutenbrunner, «EfficientLEAF: A Faster Learnable Audio Frontend of Questionable Use», *arXiv preprint arXiv:2207.05508*, 2022. DOI: 10.48550/arXiv.2207.05508.
- [21] P. Montero-Manso et al., «FFORMA: Feature-based Forecast Model Averaging», *International Journal of Forecasting*, vol. 36, n.º 1, pp. 86–92, 2020. DOI: 10.1016/j.ijforecast.2019.02.011.
- [22] Z. Liang y Y. Sun, «Evolutionary Neural Architecture Search for Multivariate Time Series Forecasting», *Proceedings of the 15th Asian Conference on Machine Learning*, vol. 222, pp. 771–786, 2024. <https://proceedings.mlr.press/v222/liang24a.html>.
- [23] R. Leppich et al., «Decomposing the Time Series Forecasting Pipeline: A Modular Approach for Time Series Representation, Information Extraction, and Projection», *arXiv preprint arXiv:2507.05891*, 2025. DOI: 10.48550/arXiv.2507.05891.
- [24] Y. Bengio et al., «Greedy Layer-Wise Training of Deep Networks», *Advances in Neural Information Processing Systems*, vol. 19, 2007. https://proceedings.neurips.cc/paper_files/paper/2006/file/5da713a690c067105aeb2fae32403405-Paper.pdf.

- [25] Z. Li et al., «Ti-MAE: Self-Supervised Masked Time Series Autoencoders», *arXiv preprint arXiv:2301.08871*, 2023. DOI: 10.48550/arXiv.2301.08871.
- [26] H. Bastidas, «Gestor de autoencoder en `feature-extractor`», 2026. Inspección estática; commit `df86252`; consultado el 7 de septiembre de 2026. https://github.com/harveybc/feature-extractor/blob/df86252a174a1f5b9f77f4cb1bcb78fcdf/e429e8/app/autoencoder_manager.py.
- [27] H. Bastidas, «Configuración de carga de extractor y `train_fe`», 2026. Configuración del repositorio, commit `20ec571`; consultada el 7 de septiembre de 2026. https://github.com/harveybc/predictor/blob/20ec57145b4ed3eb647eabe2b7591f35a3dbbf47/examples/config/phase_3_1/phase_3_1_cnn_25200_1h_config.json.
- [28] IBM, *IBM SPSS Modeler CRISP-DM Guide*, versión 19. Documentación de la metodología y de la selección de técnicas de modelado. https://www.ibm.com/docs/en/SS3RA7_19.0.0/pdf/ModelerCRISPDM.pdf.
- [29] S. Bai, J. Z. Kolter y V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling», *arXiv preprint arXiv:1803.01271*, 2018. DOI: 10.48550/arXiv.1803.01271.
- [30] Keras Team, «Transfer learning & fine-tuning», 2023. Documentación oficial; consultada el 7 de septiembre de 2026. https://keras.io/guides/transfer_learning/.
- [31] X. Qiu et al., «TFB: Towards Comprehensive and Fair Benchmarking of Time Series Forecasting Methods», *Proceedings of the VLDB Endowment*, vol. 17, n.º 9, pp. 2363–2377, 2024. DOI: 10.14778/3665844.3665863.
- [32] R. Godahewa et al., «Monash Time Series Forecasting Archive», *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2021. <https://openreview.net/forum?id=I0117rc0jcb>.
- [33] T. Aksu et al., «GIFT-Eval: A Benchmark for General Time Series Forecasting Model Evaluation», *arXiv preprint arXiv:2410.10393*, 2024. DOI: 10.48550/arXiv.2410.10393.
- [34] A. Raffin et al., «Stable-Baselines3: Reliable Reinforcement Learning Implementations», *Journal of Machine Learning Research*, vol. 22, n.º 268, pp. 1–8, 2021. <http://jmlr.org/papers/v22/20-1364.html>.
- [35] S. Sun et al., «TradeMaster: A Holistic Quantitative Trading Platform Empowered by Reinforcement Learning», *Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track*, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/file/b8f6f7f2ba4137124ac976286eacb611-Paper-Datasets_and_Benchmarks.pdf.
- [36] X.-Y. Liu et al., «FinRL-Meta: Market Environments and Benchmarks for Data-Driven Financial Reinforcement Learning», *Advances in Neural Information Processing Systems 35, Datasets and Benchmarks Track*, 2022. https://papers.neurips.cc/paper_files/paper/2022/file/0bf54b80686d2c4dc0808c2e98d430f7-Paper-Datasets_and_Benchmarks.pdf.
- [37] R. J. Hyndman y A. B. Koehler, «Another Look at Measures of Forecast Accuracy», *International Journal of Forecasting*, vol. 22, n.º 4, pp. 679–688, 2006. DOI: 10.1016/j.ijforecast.2006.03.001.
- [38] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.a ed.. OTexts, 2021. Sección 5.10: evaluación con origen rodante. <https://otexts.com/fpp3/tscv.html>.