

Selección secuencial de codificadores de memoria para aprendizaje por refuerzo en tareas no vistas, con abstención calibrada

Propuesta de investigación doctoral

Harvey Demian Bastidas Caicedo

Doctorado en Inteligencia Artificial · Universidad de La Sabana

Palabras clave: aprendizaje por refuerzo · AutoRL · codificadores de memoria · curvas de aprendizaje parciales · aprendizaje selectivo · observabilidad parcial

Resumen

En aprendizaje por refuerzo con observabilidad parcial, el agente debe resumir su historia para actuar. Puede hacerlo con una ventana fija, una red recurrente, una convolución temporal o atención, pero ninguna familia domina en todos los problemas y compararlas exige entrenamientos costosos y variables. Esta propuesta pregunta si es posible elegir un codificador de memoria para una tarea nueva sin completar siempre el entrenamiento de todos los candidatos.

Una *fidelidad* será una evaluación del mismo candidato en la misma tarea con diferente presupuesto de entrenamiento. Por ejemplo, observar su curva al 10 % y al 100 % corresponde a dos fidelidades: la primera cuesta menos, pero puede anticipar mal el resultado final. El tamaño del modelo y los diagnósticos iniciales serán descriptores, no fidelidades. Una *semilla aleatoria* será una repetición completa del entrenamiento bajo aleatoriedad controlada.

Se construirá un selector que combine descriptores y curvas parciales para recomendar un codificador, comprar una observación adicional o terminar con «evidencia insuficiente». La regla que ordena sus consultas se fijará antes de calibrar la incertidumbre y se evaluará en tareas no usadas durante el ajuste. La validez buscada será simultánea durante la trayectoria de consultas y marginal para una tarea nueva de la población declarada; no se presentará como garantía para cualquier entorno de RL.

El estudio usará POPGym como banco principal de problemas de memoria, CARL como contraste separado de cambio de contexto y ARLBench como referencia para el protocolo de AutoRL y la medición de costos [1], [2], [3]. El selector se comparará con una elección fija aprendida en desarrollo, asignación aleatoria, métodos de asignación de presupuesto y un competidor completo basado en curvas de aprendizaje. La unidad primaria será el entorno base no visto; dificultades, contextos y semillas quedarán anidados. El resultado será útil tanto si reduce costo con riesgo controlado como si identifica las condiciones en las que la evidencia parcial no permite recomendar.

1. Planteamiento del problema

La elección de memoria afecta lo que un agente puede recuperar de su historia y el costo con el que aprende. Trabajos recientes muestran, por ejemplo, que trazas compactas de memoria pueden ser más eficientes que ventanas extensas en ciertos entornos parcialmente observables [4]. Sin embargo, esa ventaja depende de la estructura del problema; no basta para escoger una familia antes de entrenarla.

AutoRL ya ofrece métodos sólidos para ajustar automáticamente hiperparámetros y distribuir presupuesto [3], [5]. Hyperband y ASHA detienen temprano configuraciones poco prometedoras [6], [7]; BOHB combina esa asignación con un modelo probabilístico [8]; y DARTS-RL estudia búsqueda diferenciable de arquitecturas [9]. La extrapolación de curvas también puede anticipar resultados finales y acelerar la selección de modelos en aprendizaje supervisado [10]. Por tanto, esta propuesta no parte de que la selección actual carezca de método. Su problema específico es otro: decidir entre codificadores de memoria cuando la relación entre una curva corta y el resultado final puede cambiar de una tarea de RL a otra.

Confiar siempre en las primeras observaciones puede producir una recomendación perjudicial; exigir siempre el entrenamiento completo elimina cualquier ahorro. Además, se ha documentado que las predicciones de estos modelos pueden diferir de las evaluaciones completas de RL incluso cuando se usan para analizar, y no solo para optimizar, una configuración [11]. La pregunta es entonces selectiva: no solo qué codificador parece mejor, sino si la evidencia disponible permite defender esa decisión.

Pregunta de investigación. ¿Puede un selector secuencial, calibrado en tareas separadas, usar descriptores y curvas parciales para elegir entre codificadores de memoria en tareas de aprendizaje por refuerzo no vistas, con menor costo que comparadores de AutoRL, sin superar un límite predefinido de recomendaciones perjudiciales y absteniéndose cuando la evidencia sea insuficiente?

2. Objetivos e hipótesis

2.1. Objetivo general

Diseñar y evaluar un selector secuencial de codificadores de memoria para aprendizaje por refuerzo que combine evaluaciones de distinto costo y pueda abstenerse ante evidencia insuficiente, con medición completa del costo y del error de selección en tareas no vistas.

2.2. Objetivos específicos

1. Formular la selección como una decisión secuencial en la que cada codificador puede consultarse mediante descriptores, curvas parciales o entrenamiento completo, cada fuente con un costo y un error que pueden variar entre tareas.
2. Construir una regla que actualice intervalos de desempeño, elija qué evaluación adicional comprar y recomiende solo cuando la cota superior del arrepentimiento normalizado no supere ε ; en caso contrario, deberá continuar evaluando o abstenerse.
3. Comparar el selector con métodos establecidos de AutoRL en bancos públicos, sobre entornos no vistos durante el ajuste, y medir por separado su comportamiento ante cambios controlados de contexto.

2.3. Hipótesis falsables

Los márgenes de relevancia práctica, la cobertura mínima y las familias de comparadores se fijarán después del piloto y antes de calibrar los umbrales del selector. El comparador principal de H1 será el método adaptativo con mejor resultado de desarrollo según una regla lexicográfica de arrepentimiento y costo definida de antemano; esta elección no podrá cambiar después de abrir calibración. El mejor codificador fijo será un control adicional decisivo: si alcanza el mismo margen de desempeño con menor costo, se concluirá que el selector no aporta valor práctico. Cada hipótesis tendrá tres desenlaces: evidencia favorable, evidencia contraria o resultado inconcluso por falta de precisión.

H1. Eficiencia. La versión del selector obligada a recomendar al agotar el presupuesto reducirá el costo marginal por tarea frente al comparador adaptativo principal, sin superar el margen de no inferioridad fijado para el arrepentimiento simple normalizado sobre todas las tareas de prueba. H1 tendrá evidencia favorable solo si se cumplen conjuntamente el contraste unilateral de ahorro y el de no inferioridad; tendrá evidencia contraria si alguno incumple su margen con precisión suficiente.

H2. Abstención. Sea $A_t = 1$ el evento de emitir una recomendación. Frente al mismo selector obligado a decidir en todas las tareas, la versión con abstención reducirá el riesgo entre sus recomendaciones emitidas y su límite superior unilateral no superará δ , mientras el límite inferior de cobertura no sea menor que γ y el costo sea inferior al de completar sistemáticamente todos los candidatos. H2 tendrá evidencia favorable solo si satisface los cuatro criterios bajo los márgenes registrados; una violación estimada con precisión será evidencia contraria y el soporte insuficiente producirá un resultado inconcluso.

H3. Cambio de contexto. Sin reajustar el selector ni sus umbrales, ante cambios públicos de contexto mantendrá

el límite de recomendaciones perjudiciales y la cobertura mínima definidos para este contraste. H3 usará el mismo contrato de medición de H2 y soporte propio; una violación precisa será evidencia contraria y la falta de soporte se declarará inconclusa.

3. Marco teórico y estado del arte

3.1. Codificador de memoria y valor de referencia

En un proceso de decisión de Markov parcialmente observable, el agente recibe una observación incompleta del estado real. Un *codificador de memoria* c transforma causalmente el historial disponible hasta el tiempo i , $(o_1, a_1, \dots, o_i)$, en un vector z_i que usa la política de acción. La tesis no intenta elegir cualquier forma de representación aprendida: compara un conjunto finito C de arquitecturas que resumen historia y que comparten una interfaz de salida.

Para cada tarea t y candidato c , $V_t(c)$ denotará el retorno esperado, sobre la aleatoriedad de entrenamiento y evaluación, al terminar un presupuesto fijado de antemano. Ese valor no se observa de forma exacta. Se estimará con un grupo común de semillas que el selector nunca podrá consultar durante su decisión. Por tanto, la «mejor opción» será la mejor estimación de referencia dentro del conjunto congelado, no una verdad sobre todas las arquitecturas posibles. Si $c^* = \arg \max_{c \in C} V_t(c)$ y $\hat{c}$ es la recomendación, el error primario será el arrepentimiento simple normalizado

$$R_t^N = \frac{V_t(c^*) - V_t(\hat{c})}{s_t}. \quad (1)$$

La escala positiva s_t será la amplitud entre los cuantiles 0.1 y 0.9 de una política de referencia fija, estimada con semillas separadas y limitada por un piso positivo. La política, el número de semillas y el piso se fijarán antes de calibración y no dependerán de los resultados finales de los candidatos. La misma regla y el mismo umbral ε se usarán en todas las hipótesis [12], [13].

Las semillas ocultas producirán un intervalo para R_t^N que incorpora la incertidumbre de todos los retornos de referencia. Un caso será perjudicial si todo el intervalo supera ε , no perjudicial si todo queda por debajo, e inconcluso si lo cruza. El ganador exacto puede ser incierto sin que la condición respecto de ε lo sea. Todas las recomendaciones permanecerán en el denominador: H2 informará tanto la fracción definitivamente perjudicial como la cota conservadora que cuenta los casos inconclusos como posibles perjuicios, y usará esta última para certificar el límite δ .

3.2. Niveles de evaluación y descriptores

Una fidelidad es una evaluación del mismo objeto con distinto costo y precisión [14]. En esta propuesta, cambiar la fidelidad significa cambiar cuánto se entrena un mismo codificador en una misma tarea. Una curva al 10 %, al 25 % y al 100 % del presupuesto contiene tres niveles de evaluación comparables. La evaluación corta cuesta menos, pero puede estar sesgada respecto del orden final. Los métodos multifidelidad intentan aprovechar precisamente ese intercambio entre costo y precisión [15], [16].

Tabla 1: Evidencia disponible para el selector.

Fuente	Contenido y función
Descriptores baratos	Tamaño del modelo, operaciones estimadas, memoria y diagnósticos iniciales calculados mediante un procedimiento fijo. Son covariables; no se supone que sean versiones aproximadas del retorno.
Curva parcial	Retorno observado tras una fracción predefinida del presupuesto, por ejemplo 10 % o 25 %. Es una fidelidad intermedia porque observa el mismo entrenamiento que se completaría después.
Entrenamiento completo	Retorno tras el presupuesto de referencia. Un grupo de semillas podrá ser consultado por los métodos; otro grupo, oculto y común, se reservará para juzgar la recomendación.

La separación evita llamar «fidelidad» a cualquier número barato. Un diagnóstico inicial podrá incorporarse solo si está disponible antes del resultado que intenta anticipar, su costo se registra y demuestra utilidad adicional sobre descriptores simples y curvas parciales en tareas distintas de aquellas donde fue propuesto. Si no cumple esas condiciones, se retirará sin modificar las hipótesis principales.

3.3. Abstención y control del error

La opción de rechazo permite no emitir una decisión cuando la evidencia no compensa el costo esperado del error [17]. El aprendizaje selectivo estudia la relación entre el error de las predicciones aceptadas y la fracción de casos cubierta [18]. Aquí, abstenerse significa terminar sin recomendar un codificador. No cambia las acciones del agente ni activa una arquitectura de respaldo. Si una aplicación necesita una opción fija para continuar operando, esa política se evaluará por separado y su resultado no se atribuirá al selector. El *riesgo selectivo* será la proporción de recomendaciones perjudiciales entre las tareas donde el método sí recomienda; la *cobertura* será la proporción total de tareas cubiertas. Un método que nunca recomienda tendrá cobertura cero y no podrá satisfacer H2. El riesgo conjunto $\Pr(R_t^N > \varepsilon, A_t = 1)$ y el riesgo condicional $\Pr(R_t^N > \varepsilon \mid A_t = 1)$ se informarán por separado: el primero no sustituye al segundo cuando la cobertura es menor que uno. Si U_t^R es el extremo superior del intervalo de arrepentimiento, la estimación conservadora será

$$\hat{\rho}_{\text{sel}}^+ = \frac{\sum_t A_t \mathbf{1}\{U_t^R > \varepsilon\}}{\sum_t A_t}, \quad \hat{\gamma} = \frac{\sum_t A_t}{n}.$$

La variante obligada usará la misma definición con $A_t = 1$ en las n tareas. El contraste de reducción se hará sobre $\hat{\rho}_{\text{sel}}^+ - \hat{\rho}_{\text{obl}}^+$, con margen y límite unilateral fijados en el registro inicial, antes de calibrar el umbral. Si no se emite ninguna recomendación, el riesgo selectivo quedará indefinido y H2 no podrá recibir evidencia favorable.

El selector producirá intervalos para $V_t(c)$ mediante un modelo jerárquico entrenado solo con tareas de desarrollo. La ruta principal usará una malla finita de presupuestos y una regla de adquisición fijadas antes de calibración. Esa regla definirá la trayectoria de consultas que seguiría si no se detuviera. Cada tarea de calibración generará un único puntaje: la mayor discrepancia, a lo largo de todos los candidatos y etapas de esa trayectoria, entre la predicción y una referencia que conserva la incertidumbre de las semillas ocultas. El umbral calibrado podrá truncar la trayectoria, pero no cambiar el orden subyacente ni la evidencia previa a la parada. Así se evita tratar los puntos dependientes de una curva como si fueran muestras independientes.

La cobertura buscada será simultánea a lo largo de esa trayectoria y marginal para una tarea nueva bajo la intercambiabilidad de las tareas de calibración y prueba [19]. La probabilidad integrará el conjunto de calibración, la tarea nueva y la aleatoriedad de entrenamiento; no será una garantía condicional para cada entorno posible. El control del riesgo entre recomendaciones se analizará por separado, siguiendo el problema de predicciones seleccionadas [20]. Si el estudio no logra justificar esta construcción frente a la adquisición y la parada adaptativas, reportará calibración empírica y dejará inconcluso el componente de certificación de H2. H3 volverá a medir riesgo y cobertura porque la intercambiabilidad no se supondrá bajo cambio de contexto.

3.4. Trabajos cercanos y brecha de investigación

La expresión «selección de representaciones» ya tiene resultados teóricos en RL. Papini et al. seleccionan representaciones de funciones de valor en procesos de decisión de Markov con estructura lineal y bajo una condición estructural específica [21]; Zhang et al. estudian clases de representaciones en modelos de bajo rango, tanto durante la interacción como a partir de datos ya recogidos [22]. Esos trabajos no resuelven el objeto empírico de esta tesis: escoger entre codificadores neuronales de memoria entrenables en problemas parcialmente observables mediante curvas de aprendizaje incompletas.

También existen vecinos directos por cada componente. Hyperband, ASHA y BOHB asignan presupuesto [6], [7], [8]; LC-PFN extrapola curvas [10]; DyHPO decide dinámicamente qué configuración continuar [23]; e ifBO combina predicción de curvas con una regla completa de adquisición incremental [24]. La optimización multifidelidad sensible al costo también ha combinado transferencia de curvas y parada [25]. Por ello, ni la

adquisición incremental ni la suma de costo, transferencia y parada se reclamarán como novedades aisladas. Los predictores entre tareas y las sondas baratas aportan otros antecedentes [26], [27], [28], pero los resultados negativos de predicción en RL impiden suponer que se trasladan sin validación [11].

La brecha que se someterá a prueba es más estrecha: adquirir evidencia parcial de codificadores de memoria y decidir de manera selectiva bajo generalización entre tareas de RL. Los métodos de identificación del mejor brazo con varias fidelidades ofrecen cotas bajo costos y límites de sesgo conocidos [15], [16]. Aquí esos errores deberán estimarse entre tareas y las observaciones de una misma curva son dependientes; la tesis deberá establecer cuándo esa evidencia permite una recomendación calibrada y cuándo obliga a continuar o abstenerse. No se afirmará que esta combinación es inédita hasta completar la revisión sistemática del primer semestre. Si aparece un método equivalente, se adoptará como comparador o se recortará la contribución antes del registro confirmatorio.

3.5. Resultado formal previsto

El resultado teórico previsto tendrá una sola estructura. La evidencia obtenida tras gastar una fracción ℓ del presupuesto se modelará como una observación dependiente de $V_t(c)$ cuyo sesgo y costo pueden variar con la tarea, el codificador y ℓ . La ruta principal fijará una malla finita de fidelidades y una regla de consulta π antes de calibración. Sea s el índice de una consulta en la trayectoria sin parada de π y τ el momento adaptativo en que el umbral calibrado recomienda o agota el presupuesto. Para un conjunto finito C , se buscarán intervalos $[L_{t,s}(c), U_{t,s}(c)]$ tales que

$$\Pr_{\mathcal{D}_{\text{cal}}, t, \xi} (\forall s \leq \tau, \forall c \in C : V_t(c) \in [L_{t,s}(c), U_{t,s}(c)]) \geq 1 - \delta_{\text{int}}. \quad (2)$$

La probabilidad se toma sobre las tareas de calibración $\mathcal{D}_{\text{cal}}$, una tarea nueva t de la población declarada y la aleatoriedad de entrenamiento ξ . El puntaje de calibración será el máximo error de la trayectoria completa de π , ampliado para incluir la incertidumbre con la que se estima el retorno final. Sobre ese evento simultáneo, una recomendación $\hat{c}$ en el momento τ cumple el margen normalizado ε cuando

$$\frac{\max_{c \in C} U_{t,\tau}(c) - L_{t,\tau}(\hat{c})}{s_t} \leq \varepsilon, \quad (3)$$

donde los límites se calibraron sin usar la tarea de prueba. La tesis buscará una cota del costo de alcanzar esta condición bajo un modelo principal de sesgo y dependencia que se fijará tras el piloto. La afirmación será marginal para una tarea nueva bajo los supuestos declarados; no reemplaza la medición del riesgo selectivo de H2 ni promete cobertura condicional para cualquier entorno.

El resultado complementario será una región de imposibilidad. Sea $C_\varepsilon(t) = \{c \in C : [V_t(c^*) - V_t(c)]/s_t \leq \varepsilon\}$ el conjunto de candidatos suficientemente buenos para la tarea t . Si dos clases de tarea inducen la misma distribución de toda la interacción accesible a una política dentro del presupuesto y sus conjuntos C_ε son disjuntos, ninguna regla que use solo esa interacción puede reconocer una opción ε -óptima en ambas clases con probabilidad media superior a $1/2$ bajo probabilidades previas iguales. La demostración precisará la clase de políticas y cuándo una consulta adicional rompe la indistinguibilidad; en la región restante, evaluar por completo o abstenerse será una consecuencia del límite de información disponible.

4. Metodología

4.1. Bancos públicos, particiones y unidad de análisis

El estudio será experimental, comparativo y prerregistrado. POPGym será el banco principal porque contiene quince entornos parcialmente observables y varios niveles de dificultad diseñados para comparar memoria [1]. CARL se usará como contraste separado de cambio de contexto: se variarán propiedades conocidas de la dinámica, pero el valor del contexto se ocultará al agente [2]. ARLBench aportará prácticas, interfaces de comparación y una referencia externa para medir el costo de AutoRL [3]; no sustituirá la prueba de memoria de POPGym. Para H3 se congelarán el meta-selector y sus umbrales, mientras cada codificador se entrenará de nuevo con la receta

prevista para el caso. Ocultar el contexto significará retirar la variable intervenida, no suprimir arbitrariamente las demás observaciones físicas.

El algoritmo principal será Proximal Policy Optimization (PPO), un método de gradiente de política ampliamente usado [29]. Deep Q-Network (DQN), que aprende valores para las acciones, se conservará como análisis de sensibilidad solo si el piloto demuestra compatibilidad y presupuesto suficiente [30]. El preprocesamiento de las observaciones será causal, fijo e idéntico para todos los candidatos dentro de cada tarea; no será una variable de selección en este estudio.

Se distinguirán tres niveles que no deben confundirse. El *entorno base* será la unidad independiente de generalización; el par entorno–dificultad o entorno–contexto será un *caso de evaluación*; y la semilla será una repetición anidada. POPGym permite construir al menos 45 casos a partir de quince entornos y tres niveles de dificultad, pero esos casos no equivalen a 45 unidades independientes. Todos los casos de un entorno permanecerán juntos para impedir que una variante de la misma dinámica aparezca a la vez en ajuste y prueba.

El protocolo tendrá cuatro roles separados: piloto técnico, desarrollo del modelo, calibración de intervalos y prueba confirmatoria. Los pliegues agrupados dentro de desarrollo estimarán el comportamiento del procedimiento; no se tratarán como certificación de un selector fijo porque sus conjuntos de ajuste se solapan. Después de desarrollo se congelarán el selector y su regla de consulta; tareas distintas calibrarán el umbral y un último grupo, abierto una sola vez, sostendrá los contrastes confirmatorios. La dificultad principal de cada entorno se elegirá mediante una regla del banco fijada antes de desarrollo; las demás dificultades serán análisis anidados de sensibilidad. Cada entorno tendrá el mismo peso en el análisis primario.

El piloto hará un censo de bancos públicos compatibles y un análisis conjunto de soporte y recursos antes del registro confirmatorio. La población de generalización quedará limitada a tareas públicas de memoria que cumplan criterios de inclusión registrados; POPGym es una colección diseñada, no una muestra aleatoria de todo RL. POPGym por sí solo no permite defender un riesgo pequeño con alta precisión: aun en el caso binomial ideal, cero recomendaciones perjudiciales en quince unidades independientes producen un límite superior unilateral exacto al 95 % de $1 - 0.05^{1/15} \approx 0.181$; se requieren al menos 59 recomendaciones independientes sin fallos para bajar de 5 %. Estas cifras no incluyen desarrollo, calibración, abstenciones, referencias inciertas ni multiplicidad. La ampliación a otro banco solo se conservará si aporta tareas comparables dentro del techo total de recursos. Sin soporte suficiente, se publicará la curva riesgo–cobertura con su incertidumbre y H2 quedará inconclusa en su componente de certificación. Los bancos se informarán por separado y solo se combinarán bajo una regla establecida antes de la prueba. CARL será una confirmación separada y no inflará el tamaño de muestra de POPGym.

Un estudio financiero propio podrá usarse, como máximo, como réplica posterior. No formará parte de H1 ni H2, no ajustará el método y no podrá convertir en positivo un resultado negativo de los bancos públicos.

4.2. Espacio de codificadores

El espacio principal tendrá cuatro codificadores de memoria y un control sin memoria: una red densa que usa solo la observación actual, una red densa sobre una ventana fija, una convolución temporal causal, una GRU y atención causal. Todos producirán un vector de la misma dimensión y permanecerán dentro de una banda de tamaño fijada en el piloto. La banda será común al selector y a todos los comparadores; se definirá sin usar los entornos de prueba y su costo de calibración se informará por separado. Las diferencias restantes de tiempo, memoria y estabilidad se cobrarán en la decisión. El historial incluirá observaciones, acciones anteriores y marcas de inicio de episodio. La ventana disponible, la longitud de atención, el truncamiento del gradiente recurrente, el tratamiento de límites y la normalización se fijarán en el piloto y se publicarán antes de generar la prueba. Los objetivos auxiliares de preentrenamiento no formarán parte del contraste principal porque mezclarían la arquitectura con otro objetivo de aprendizaje.

Una opción que no sea compatible con un algoritmo o entorno se excluirá antes del registro confirmatorio y con razón publicada. No se sustituirá después de observar resultados. El conjunto pequeño permite entrenar todos los candidatos para construir la estimación de referencia con la que se juzgarán los métodos.

El contrato de entrenamiento fijará recompensa, presupuesto, optimizador, política y cabeza de valor. Los hiperparámetros que afecten de manera desigual a una familia se ajustarán solo en desarrollo, con el mismo presupuesto por familia, y se congelarán antes de calibración. Así, cada candidato será un codificador acompañado por una receta de entrenamiento obtenida bajo reglas comunes, no una arquitectura favorecida por ajustes posteriores. También se reportará una sensibilidad con una receta completamente común para distinguir el efecto de esta decisión de diseño.

4.3. Selector propuesto

El selector usará un modelo probabilístico jerárquico para relacionar los descriptores de tarea y codificador, junto con los puntos observados de la curva, con el retorno al presupuesto completo. El punto de partida será un proceso gaussiano jerárquico sobre el logaritmo del presupuesto, con efectos de tarea y codificador y una observación robusta para separar la variación entre tareas, arquitecturas y semillas. La adquisición inicial elegirá la consulta con mayor reducción esperada de la cota de arrepentimiento por segundo de costo. El piloto podrá reemplazar estas elecciones por incompatibilidad o inestabilidad, pero deberá hacerlo durante desarrollo y documentar el criterio; el modelo, la adquisición y la trayectoria consultable quedarán congelados antes de abrir calibración.

Para una tarea nueva, el procedimiento será:

1. calcular los descriptores admitidos de los cinco candidatos y registrar el presupuesto disponible;
2. estimar para cada candidato un intervalo de retorno final calibrado para la secuencia de consultas acordada;
3. recomendar solo si un candidato satisface $[\max_c U_{t,s}(c) - L_{t,s}(\hat{c})]/s_t \leq \varepsilon$;
4. si la condición no se cumple, comprar la observación que más reduzca la incertidumbre relevante por unidad de costo;
5. repetir hasta recomendar o agotar el presupuesto; en este último caso, devolver «evidencia insuficiente».

Las semillas reservadas y el orden final permanecerán ocultos al selector hasta cerrar su decisión. La versión sin abstención compartirá el mismo modelo, presupuesto y reglas de consulta, pero deberá recomendar cuando el presupuesto termine; así se aislará el efecto de la abstención.

4.4. Comparadores y protocolo

Los comparadores obligatorios serán: un único codificador fijo, elegido solo en desarrollo y usado en todas las tareas nuevas; asignación aleatoria del mismo presupuesto; Hyperband o ASHA; BOHB; ifBO como método completo de adquisición basado en curvas; y el selector propuesto sin abstención [6], [7], [8], [24]. El control fijo no observará curvas de la tarea nueva antes de elegir. El piloto verificará compatibilidad y congelará una implementación por familia; si ifBO no puede respetar el mismo espacio e información, se sustituirá por otro método completo de curvas y se publicará la razón. iMFBO se añadirá solo si su adaptación conserva el mismo espacio de candidatos, niveles de evaluación y presupuesto [31]. DARTS-RL será un análisis secundario si puede operar sobre los mismos codificadores sin recibir información adicional.

Para comparar muchos métodos de selección sin repetir innecesariamente el entrenamiento, se construirá una matriz de curvas una sola vez. Cada método la consultará como si actuara en línea y solo verá los puntos cuyo costo haya pagado. Esta reproducción controlada separa el costo real de producir la evidencia del costo que cada método habría consumido. Las fidelidades serán fracciones de un número fijo de transiciones del entorno, no porcentajes ambiguos de épocas. Cada consulta pagará el tramo adicional de una trayectoria candidato-semilla y los costos de evaluación y recuperación. El piloto comprobará que reanudar conserva los estados del modelo, optimizador, generadores aleatorios y entorno necesarios para representar la misma trayectoria. Cada candidato y caso tendrá hasta diez semillas completas: cinco generarán curvas consultables y cinco permanecerán ocultas para estimar $V_t(c)$. Los grupos de semillas serán comunes a todos los métodos y se fijarán antes del experimento.

El costo primario C será el tiempo de pared, bajo un perfil de recursos fijo y concurrencia uno, desde el inicio de la tarea hasta disponer de la política seleccionada con su entrenamiento completo o emitir una abstención terminal.

Cuando el método recomiende, incluirá una trayectoria completa del candidato entregado; en ambos desenlaces incluirá todos los tramos exploratorios, descriptores, tiempo del selector, recuperación y ejecuciones fallidas que haya consumido. El control fijo pagará una trayectoria completa y no comprará curvas adicionales; en los demás métodos, todo tramo ya observado del candidato final contará como parte de su entrenamiento. CPU-horas, GPU-horas, memoria y una comparación asíncrona con igual número de trabajadores se informarán por separado. Las semillas ocultas serán un costo experimental común para juzgar a todos los métodos; se informarán por separado y no se presentarán como ahorro. La contabilidad distinguirá ese costo común, el costo previo de adquirir la historia y entrenar o calibrar cada método, y el costo marginal esperado de aplicarlo a una tarea nueva con desempeño comparable. Se mostrarán dos escenarios: construir el corpus desde cero y disponer de él previamente para todos los métodos compatibles. Si C_m^{prev} y C_m^{marg} son los costos previo y marginal del método m , se informará el punto de equilibrio frente al comparador b :

$$N^* = \left\lceil \frac{(C_{\text{sel}}^{\text{prev}} - C_b^{\text{prev}})_+}{C_b^{\text{marg}} - C_{\text{sel}}^{\text{marg}}} \right\rceil, \quad (4)$$

cuando el selector tenga menor costo marginal; si no lo tiene, se declarará que la inversión no se amortiza. La estimación de N^* se presentará con intervalo o por escenarios; no se anunciará un umbral finito si el ahorro marginal no se distingue de cero. El presupuesto que define las fidelidades y el presupuesto máximo que cada método puede gastar para decidir se especificarán por separado. El número final de semillas y candidatos se fijará antes de abrir la prueba.

H1 evaluará la versión obligada a decidir sobre todas las tareas de prueba mediante dos contrastes unilaterales agrupados por entorno: superioridad en costo y no inferioridad en arrepentimiento normalizado. H2 comparará el riesgo conservador entre recomendaciones emitidas con el riesgo de la variante obligada sobre todas las tareas, e informará conjuntamente cobertura y costo. La diferencia de riesgo, el límite δ , el error de intervalos δ_{int} y el nivel estadístico α serán cantidades distintas. H2 y H3 usarán límites unilaterales con el entorno base como unidad; los casos inconclusos se conservarán como posibles perjuicios en el límite empleado para certificar. Como resultados secundarios se reportarán evaluaciones completas consumidas, costo hasta cumplir la condición de recomendación, tiempo de pared, GPU-horas, CPU-horas y memoria máxima. La agregación seguirá recomendaciones para experimentos de RL: promedio del 50 % central, perfiles de desempeño e intervalos por remuestreo agrupado por entorno base [13]. El registro confirmatorio repetirá el estadístico, el margen y el sentido de cada contraste de H1–H3 fijados inicialmente; sus valores p se corregirán por multiplicidad con el método de Holm [32].

Habrán dos hitos públicos: un registro inicial del diseño y las reglas de desarrollo, y un registro confirmatorio después del piloto, desarrollo y calibración, pero antes de abrir la prueba. El espacio de candidatos y los márgenes se fijarán antes de calibración; desarrollo no accederá a calibración ni prueba; calibración fijará umbrales sin acceder a la prueba; y la prueba se abrirá una sola vez. Una corrida fallida consumirá el recurso gastado y se reportará. También se publicarán resultados negativos e inconclusos.

5. Viabilidad, riesgos y plan de trabajo

5.1. Evidencia preliminar

La trayectoria del candidato incluye el desarrollo y uso de sistemas modulares para pronóstico temporal, aprendizaje por refuerzo y optimización experimental. Ese trabajo ha requerido integrar modelos intercambiables, conservar configuraciones y particiones, comparar resultados fuera de muestra y ejecutar campañas con presupuestos y criterios de parada explícitos. Esta experiencia respalda la viabilidad técnica de construir el banco de curvas y sus comparadores, pero no se presentará como evidencia a favor de las hipótesis doctorales.

Las evaluaciones internas también dejaron una motivación concreta: varias representaciones plausibles y modelos de mayor capacidad no superaron de manera consistente referencias simples en un dominio aplicado. Ese resultado no se generaliza a POPGym ni entra al análisis de la tesis. Sí muestra por qué conviene estudiar,

con bancos públicos y controles fuertes, qué evidencia justifica invertir en un codificador y cuándo esa evidencia no alcanza.

5.2. Presupuesto y factibilidad

La matriz experimental completa se construirá una sola vez y será compartida por todos los métodos. Con cinco candidatos, 45 casos de POPGym y hasta diez semillas por combinación, el componente inicial tiene un techo preliminar de 2 250 curvas completas. Los puntos de entrenamiento parcial serán cortes de esas mismas curvas, no ejecuciones adicionales. El piloto fijará un techo total que incluya desarrollo, calibración, prueba, la eventual ampliación de tareas, CARL, ajuste por familia, almacenamiento y fallos. La ampliación solo se incorporará si alcanza el soporte científico previsto dentro de ese techo; de lo contrario se conservará un alcance empírico menor y no se afirmará una certificación que los datos no permiten. Estas cantidades son límites de diseño, no recursos ya asignados.

Durante el primer semestre se ejecutará un piloto pequeño que medirá tiempo, memoria y estabilidad por codificador, algoritmo y entorno. El presupuesto final se calculará con el costo observado de cada arquitectura y etapa, en lugar de multiplicar todas las curvas por un promedio único. Se usarán recursos de cómputo propios para el piloto y se solicitará infraestructura institucional o externa para la matriz definitiva. Si el techo disponible no permite el diseño completo, se retirarán primero la réplica financiera, DQN y los análisis secundarios; después se reducirá el alcance de la afirmación de riesgo antes que presentar un tamaño insuficiente como certificación. No se reducirán las unidades de prueba después de observar resultados ni se reutilizarán sus datos para ajustar el selector.

Los principales riesgos científicos son que las curvas parciales no ordenen los codificadores, que los intervalos no se calibren entre tareas y que la abstención reduzca demasiado la cobertura. Los tres tienen una salida interpretable: evidencia contraria o inconclusa, acompañada por una caracterización de cuándo se necesita evaluar por completo. El riesgo técnico es la compatibilidad desigual de los codificadores con los bancos; se resolverá en el piloto antes del registro confirmatorio.

5.3. Ética, reproducibilidad y alcance

Los experimentos principales usarán simuladores y datos públicos, sin participantes humanos ni datos personales. Se publicarán configuraciones, semillas, particiones, costos, código de evaluación y resultados nulos. La réplica financiera, si se conserva, será retrospectiva y no ejecutará operaciones reales. La infraestructura existente podrá instrumentar experimentos, pero no se presentará como contribución ni como evidencia científica.

5.4. Cronograma

Tabla 2: Plan de tres años.

Periodo	Hitos verificables
Año 1	Revisión sistemática y delimitación de novedad; censo de tareas; piloto de compatibilidad, costo y precisión; definición de particiones y márgenes; registro inicial; implementación de comparadores.
Año 2	Construcción separada de datos de desarrollo y calibración; desarrollo del selector; calibración; registro confirmatorio; apertura única de H1 y H2; artículo metodológico.
Año 3	Contraste de cambio de contexto para H3; resultado formal y región de imposibilidad; réplica externa condicionada a recursos; publicación de artefactos, artículo empírico y tesis.

6. Contribuciones esperadas

1. Una formulación precisa de la selección de codificadores de memoria que separa descriptores de niveles de entrenamiento, contabiliza costos previos y marginales y permite no recomendar.

2. Un selector secuencial con incertidumbre válida durante sus consultas y una regla explícita para recomendar, continuar evaluando o abstenerse.
3. Una caracterización teórica de las condiciones en las que la evidencia parcial permite una selección dentro de ε y de los casos en que el ahorro no puede identificarse.
4. Un protocolo público para comparar métodos de selección en entornos no vistos, con resultados positivos, negativos o inconclusos reproducibles.

Resultado mínimo defendible. Determinar, con comparadores fuertes y tareas públicas separadas, cuándo una curva parcial permite seleccionar un codificador de memoria y cuándo es necesario completar el entrenamiento o no recomendar.

Referencias

- [1] S. Morad et al., «POPGym: Benchmarking Partially Observable Reinforcement Learning,» en *Proceedings of the 11th International Conference on Learning Representations*, 2023.
- [2] C. Benjamins et al., «Contextualize Me: The Case for Context in Reinforcement Learning,» *Transactions on Machine Learning Research*, 2023.
- [3] J. Becktepe et al., «ARLBench: Flexible and Efficient Benchmarking for Hyperparameter Optimization in Reinforcement Learning,» *Journal of Data-centric Machine Learning Research*, vol. 3, n.º 3, págs. 1-41, 2026.
- [4] O. Eberhard, M. Muehlebach y C. Vernade, «Partially Observable Reinforcement Learning with Memory Traces,» en *Proceedings of the 42nd International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 267, 2025, págs. 14 934-14 949.
- [5] T. Eimer, M. Lindauer y R. Raileanu, «Hyperparameters in Reinforcement Learning and How To Tune Them,» en *Proceedings of the 40th International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 202, 2023, págs. 9104-9149.
- [6] L. Li et al., «Hyperband: A Novel Bandit-Based Approach to Hyperparameter Optimization,» *Journal of Machine Learning Research*, vol. 18, n.º 185, págs. 1-52, 2018.
- [7] L. Li et al., «A System for Massively Parallel Hyperparameter Tuning,» en *Proceedings of Machine Learning and Systems*, vol. 2, 2020, págs. 230-246.
- [8] S. Falkner, A. Klein y F. Hutter, «BOHB: Robust and Efficient Hyperparameter Optimization at Scale,» en *Proceedings of the 35th International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 80, 2018, págs. 1437-1446.
- [9] Y. Miao et al., «Differentiable Architecture Search for Reinforcement Learning,» en *Proceedings of the First International Conference on Automated Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 188, 2022, págs. 20/1-17.
- [10] S. Adriaensen et al., «Efficient Bayesian Learning Curve Extrapolation using Prior-Data Fitted Networks,» en *Advances in Neural Information Processing Systems*, vol. 36, 2023. DOI: 10.52202/075280-0872.
- [11] J. Dierkes et al., «Performance Prediction in Reinforcement Learning: The Bad and the Ugly,» en *18th European Workshop on Reinforcement Learning*, 2025.
- [12] J.-Y. Audibert, S. Bubeck y R. Munos, «Best Arm Identification in Multi-Armed Bandits,» en *Proceedings of the 23rd Conference on Learning Theory*, 2010, págs. 41-53.
- [13] R. Agarwal et al., «Deep Reinforcement Learning at the Edge of the Statistical Precipice,» en *Advances in Neural Information Processing Systems*, vol. 34, 2021, págs. 29 304-29 320.
- [14] B. Peherstorfer, K. Willcox y M. Gunzburger, «Survey of Multifidelity Methods in Uncertainty Propagation, Inference, and Optimization,» *SIAM Review*, vol. 60, n.º 3, págs. 550-591, 2018. DOI: 10.1137/16M1082469.

- [15] R. Poiani, A. M. Metelli y M. Restelli, «Multi-Fidelity Best-Arm Identification,» en *Advances in Neural Information Processing Systems*, vol. 35, 2022, págs. 17 857-17 870.
- [16] R. Poiani et al., «Optimal Multi-Fidelity Best-Arm Identification,» en *Advances in Neural Information Processing Systems*, vol. 37, 2024. DOI: 10.52202/079017-3874.
- [17] C. K. Chow, «On Optimum Recognition Error and Reject Tradeoff,» *IEEE Transactions on Information Theory*, vol. 16, n.º 1, págs. 41-46, 1970. DOI: 10.1109/TIT.1970.1054406.
- [18] Y. Geifman y R. El-Yaniv, «Selective Classification for Deep Neural Networks,» en *Advances in Neural Information Processing Systems*, vol. 30, 2017, págs. 4878-4887.
- [19] A. N. Angelopoulos et al., «Conformal Risk Control,» en *Proceedings of the 12th International Conference on Learning Representations*, 2024.
- [20] Y. Xu, W. Guo y Z. Wei, «Selective Conformal Risk Control,» *arXiv preprint arXiv:2512.12844*, 2025, versión 2, abril de 2026. DOI: 10.48550/arXiv.2512.12844.
- [21] M. Papini et al., «Reinforcement Learning in Linear MDPs: Constant Regret and Representation Selection,» en *Advances in Neural Information Processing Systems*, vol. 34, 2021, págs. 16 389-16 401.
- [22] W. Zhang et al., «Provably Efficient Representation Selection in Low-rank Markov Decision Processes: From Online to Offline RL,» en *Proceedings of the Thirty-Ninth Conference on Uncertainty in Artificial Intelligence*, ép. Proceedings of Machine Learning Research, vol. 216, 2023, págs. 2488-2497.
- [23] M. Wistuba, A. Kadra y J. Grabocka, «Supervising the Multi-Fidelity Race of Hyperparameter Configurations,» en *Advances in Neural Information Processing Systems*, vol. 35, 2022, págs. 13 470-13 484. DOI: 10.52202/068431-0979.
- [24] H. Rakotoarison et al., «In-Context Freeze-Thaw Bayesian Optimization for Hyperparameter Optimization,» en *Proceedings of the 41st International Conference on Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 235, 2024, págs. 41 982-42 008.
- [25] D. B. Lee et al., «Cost-Sensitive Multi-Fidelity Bayesian Optimization with Transfer of Learning Curve Extrapolation,» *arXiv preprint arXiv:2405.17918*, 2024. DOI: 10.48550/arXiv.2405.17918.
- [26] M. S. Abdelfattah et al., «Zero-Cost Proxies for Lightweight NAS,» en *Proceedings of the 9th International Conference on Learning Representations*, 2021.
- [27] Y. Shen et al., «ProxyBO: Accelerating Neural Architecture Search via Bayesian Optimization with Zero-Cost Proxies,» *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 37, n.º 8, págs. 9792-9801, 2023. DOI: 10.1609/aaai.v37i8.26169.
- [28] Y. Akhauri y M. S. Abdelfattah, «Multi-Predict: Few Shot Predictors for Efficient Neural Architecture Search,» en *Proceedings of the Second International Conference on Automated Machine Learning*, ép. Proceedings of Machine Learning Research, vol. 224, 2023, págs. 23/1-23.
- [29] J. Schulman et al., «Proximal Policy Optimization Algorithms,» *arXiv preprint arXiv:1707.06347*, 2017. DOI: 10.48550/arXiv.1707.06347.
- [30] V. Mnih et al., «Human-level Control through Deep Reinforcement Learning,» *Nature*, vol. 518, págs. 529-533, 2015. DOI: 10.1038/nature14236.
- [31] M. Fan et al., «Multi-fidelity Bayesian Optimization with Multiple Information Sources of Input-dependent Fidelity,» en *Proceedings of the 40th Conference on Uncertainty in Artificial Intelligence*, ép. Proceedings of Machine Learning Research, vol. 244, 2024, págs. 1271-1293.
- [32] S. Holm, «A Simple Sequentially Rejective Multiple Test Procedure,» *Scandinavian Journal of Statistics*, vol. 6, n.º 2, págs. 65-70, 1979.